

UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS NATURAIS E EXATAS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE
IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS
EM CADEIAS DE ISOLADORES**

Santa Maria, RS
2025

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS
À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**. Defesa realizada por videoconferência.

Orientador: Prof. Dr. Daniel Pinheiro Bernardon

Coorientador: Prof. Dr. Paulo César Vargas Luz

Santa Maria, RS
2025

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS
À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**.

Aprovado em 8 de dezembro de 2025:

**Daniel Pinheiro Bernardon, Dr. (UFSM)
(Presidente/Orientador)**

**Paulo César Vargas Luz, Dr. (UFSM)
(Coorientador)**

Banca Um, Dra. (UFSM)

Banca Dois, Dr. (UFSM)

Santa Maria, RS
2025

RESUMO

MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES

AUTOR: Luan Willig Silveira
Orientador: Daniel Pinheiro Bernardon
Coorientador: Paulo César Vargas Luz

A inspeção de cadeias de isoladores em linhas de transmissão e distribuição de energia depende cada vez mais de sistemas automatizados capazes de detectar e classificar falhas a partir de imagens. Nesse contexto, a escolha das técnicas de processamento de imagem aplicadas antes da etapa de modelagem influencia diretamente o desempenho dos modelos de aprendizado de máquina. Este trabalho teve como objetivo desenvolver uma metodologia sistemática para comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem aplicadas à detecção e à classificação de falhas em cadeias de isoladores. A metodologia foi estruturada de forma iterativa e modular, contemplando a seleção e a validação do conjunto de dados, o pré-processamento, o ajuste automático de parâmetros, a escolha e a construção do modelo, o treinamento e a avaliação. Como métricas de avaliação, adotaram-se a acurácia, o F1-score e o tempo de processamento. Para validar a metodologia, avaliou-se o impacto de diferentes técnicas de pré-processamento, aplicadas de forma isolada e híbrida, sobre o desempenho de uma Rede Neural Convolucional (CNN), utilizando dois conjuntos de dados de inspeção de infraestrutura elétrica: o CPLID (*Chinese Power Line Insulator Dataset*) e o DRNPW, composto por imagens capturadas por drones. Também se conduziram experimentos de otimização automática de parâmetros de pré-processamento por busca em grade (*grid search*) e por busca aleatória (*random search*). Os resultados demonstraram que o pré-processamento exerce papel determinante no desempenho dos modelos, mas que não há uma técnica universalmente superior: sua eficácia depende das características do conjunto de dados. No CPLID, com fundos homogêneos e falhas estruturais bem demarcadas, o realce simples de contraste (*Contrast Enhancement*) obteve o melhor desempenho (acurácia de 95,35% e F1-score de 96,55%), ao passo que filtros de suavização e desfoque prejudicaram a detecção. No DRNPW, com imagens de forte poluição visual, as combinações híbridas de realce de contraste e equalização de histograma foram mais eficazes (acurácia de 83,33%), enquanto a supressão da informação de cor apresentou os piores resultados. A otimização de parâmetros identificou um ponto ótimo do fator de contraste em torno de 1,3 a 1,4, com concordância entre a busca em grade e a busca aleatória e acurácia de até 90%, evidenciando que níveis excessivos de contraste introduzem artefatos que degradam o aprendizado. Conclui-se que o tratamento adequado das imagens brutas, ajustado às características de cada conjunto de dados, é condição essencial para o bom desempenho dos modelos de detecção de falhas, sendo tão relevante quanto a escolha da arquitetura da rede neural.

Palavras-chave: Processamento de Imagens. Redes Neurais Convolucionais. Aprendizado de Máquina. Detecção de Falhas. Cadeias de Isoladores. Pré-processamento de

Imagens. Otimização de Parâmetros.

ABSTRACT

IMAGE PROCESSING ENHANCEMENT METHOD APPLIED TO FAULT DETECTION AND CLASSIFICATION IN INSULATOR STRINGS

AUTHOR: Luan Willig Silveira
ADVISOR: Daniel Pinheiro Bernardon
CO-ADVISOR: Paulo César Vargas Luz

The inspection of insulator strings in power transmission and distribution lines increasingly relies on automated systems capable of detecting and classifying faults from images. In this context, the choice of image processing techniques applied before the modeling stage directly influences the performance of machine learning models. This work aimed to develop a systematic methodology to compare, select, combine, and enhance image processing techniques applied to the detection and classification of faults in insulator strings. The methodology was structured in an iterative and modular way, covering dataset selection and validation, preprocessing, automatic parameter tuning, model selection and construction, training, and evaluation. Accuracy, F1-score, and processing time were adopted as evaluation metrics. To validate the methodology, the impact of different preprocessing techniques, applied both individually and in hybrid form, on the performance of a Convolutional Neural Network (CNN) was assessed using two electrical infrastructure inspection datasets: the CPLID (*Chinese Power Line Insulator Dataset*) and the DRNPW, composed of drone-captured images. Experiments on automatic optimization of preprocessing parameters were also conducted through grid search and random search. The results showed that preprocessing plays a decisive role in model performance, but that there is no universally superior technique: its effectiveness depends on the characteristics of the dataset. On CPLID, with homogeneous backgrounds and well-defined structural faults, simple contrast enhancement achieved the best performance (accuracy of 95.35% and F1-score of 96.55%), whereas smoothing and blurring filters impaired detection. On DRNPW, with images of strong visual pollution, hybrid combinations of contrast enhancement and histogram equalization were more effective (accuracy of 83.33%), while suppressing color information produced the worst results. Parameter optimization identified an optimal contrast factor around 1.3 to 1.4, with agreement between grid search and random search and accuracy of up to 90%, showing that excessive contrast levels introduce artifacts that degrade learning. It is concluded that the proper treatment of raw images, adjusted to the characteristics of each dataset, is an essential condition for the good performance of fault detection models, being as relevant as the choice of the neural network architecture.

Keywords: Image Processing. Convolutional Neural Networks. Machine Learning. Fault Detection. Insulator Strings. Image Preprocessing. Parameter Optimization.

SUMÁRIO

1	INTRODUÇÃO	10
1.1	MOTIVAÇÃO E JUSTIFICATIVA	10
1.2	OBJETIVO GERAL	11
1.3	OBJETIVOS ESPECÍFICOS	11
1.4	ESTRUTURA DO TRABALHO	12
2	REVISÃO BIBLIOGRÁFICA	13
2.1	PROCESSAMENTO DE IMAGENS	13
2.1.1	Normalização	14
2.1.2	Redimensionamento e Recorte	15
2.1.3	Aumento de Dados	16
2.1.4	Redução de Ruído	17
2.1.5	Ajuste de Contraste e Brilho	18
2.1.6	Aumento de Nitidez	19
2.1.7	Conversão de Espaço de Cores	20
2.1.8	Restauração e Desembaçamento de Imagens	20
2.1.9	Deteção de Bordas	21
2.1.10	Correção de Iluminação	22
2.1.11	Super-Resolução	23
2.1.12	Conclusão parcial da seção	23
2.2	REDES NEURAIS	24
2.2.1	Tipos de redes neurais	25
2.2.1.1	Perceptron (P), Feed Forward Network (FFN)	25
2.2.1.2	Convolutional neural network (CNN) ou Deep convolutional network (DCN)	27
2.2.2	Funções de ativação	28
2.2.2.1	ReLU (Rectified Linear Unit)	28
2.2.2.2	Sigmoid	28
2.2.2.3	Softmax	28
2.2.2.4	Regras gerais para escolha de funções de ativação	29
2.2.3	Funções de Custo	29
2.2.3.1	Erro Médio Quadrático (MSE)	29
2.2.3.2	Erro Médio Absoluto (MAE)	30
2.2.3.3	Função Huber	30
2.2.3.4	Entropia Cruzada Binária	30
2.2.3.5	Entropia Cruzada Categórica	30
2.2.4	Otimizadores	31
2.3	DATASETS	31

2.4	MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO DE MODELOS	34
2.5	TRABALHOS RELACIONADOS	37
2.5.1	Análise Sustentável da Detecção de Falhas em Isoladores Baseada em Otimização Visual Refinada	38
2.5.2	Detecção de Falhas em Isoladores em Imagens Aéreas de Linhas de Transmissão de Alta Voltagem Baseada em Modelo de Aprendizado Profundo	38
2.5.3	Detecção de Defeitos em Isoladores por Imagem Baseada em Processamento Morfológico e Aprendizado Profundo	38
2.5.4	Detecção Melhorada de Defeitos em Isoladores Utilizando YOLOv7	39
2.5.5	Comparando redes neurais convolucionais e técnicas de pré-processamento para classificação de células HEp-2 em imagens de imunofluorescência	40
2.5.6	Efeitos do pré-processamento de imagens histopatológicas em redes neurais convolucionais.....	41
2.5.7	O impacto de técnicas de pré-processamento e pós-processamento de imagens em frameworks de aprendizado profundo: uma revisão abrangente para análise de imagens de patologia digital	42
2.5.8	Resumo dos Trabalhos.....	42
2.5.9	Justificativa da Relevância da Metodologia Proposta.....	43
2.5.10	Tabela Comparativa dos Trabalhos	43
2.5.11	Considerações sobre os trabalhos relacionados	44
2.6	CONSIDERAÇÕES FINAIS DO CAPÍTULO.....	44
3	METODOLOGIA.....	46
3.1	INÍCIO E DEFINIÇÃO DE MÉTRICAS	50
3.1.1	Início	50
3.2	SELEÇÃO E VALIDAÇÃO DO DATASET	50
3.2.1	Definir métricas: acurácia, F1-score, tempo	51
3.2.2	Selecionar dataset com imagens rotuladas	52
3.2.3	Dataset está balanceado?	53
3.2.4	Aplicar filtros e balanceamento	53
3.3	PRÉ-PROCESSAMENTO	53
3.3.1	Aplicar técnicas básicas: normalização, recorte, ruído	54
3.3.2	Aplicar data augmentation	55
3.3.3	Combinar técnicas?	55
3.3.4	Gerar pipeline de técnicas combinadas	56
3.3.5	Usar técnicas isoladas	56
3.4	AJUSTE DE PARÂMETROS	56
3.4.1	Otimizar parâmetros com busca automática	57

3.5	ESCOLHA E CONSTRUÇÃO DO MODELO	58
3.5.1	Selecionar modelo: CNN, ResNet, YOLO	58
3.5.2	Tipo de tarefa	59
3.5.3	Montar modelo de classificação	59
3.5.4	Montar modelo de detecção	60
3.5.5	Montar modelo de regressão	60
3.6	TREINAMENTO	61
3.6.1	Treinar modelo com dados processados	61
3.7	AVALIAÇÃO E AJUSTES	62
3.7.1	Avaliar com as métricas definidas	63
3.7.2	Desempenho satisfatório?	64
3.7.3	Ajustar processamentos e modelo	64
3.7.4	Comparar diferentes modelos e técnicas	65
3.7.5	Conclusões e recomendações	65
4	COLETA E ANÁLISE DE RESULTADOS	66
4.1	AVALIAÇÃO DE TÉCNICAS DE PRÉ-PROCESSAMENTO EM REDES NEU- RAIS CONVOLUCIONAIS PARA CLASSIFICAÇÃO DE IMAGENS	66
4.1.1	Conjuntos de Dados Avaliados	66
4.1.2	Arquitetura do Modelo	67
4.1.3	Técnicas de Pré-Processamento Avaliadas	67
4.1.4	Resultados e Discussões da Avaliação	68
4.1.4.1	Desempenho na Classificação de Defeitos Estruturais em Isoladores de Li- nhas de Transmissão (CPLID)	68
4.1.4.2	Desempenho na Inspeção Aérea de Isoladores em Ambiente Operacional Real (DRNPW)	70
4.1.5	Conclusão da Avaliação Analítica	72
4.2	OTIMIZAÇÃO DE PARÂMETROS DE PRÉ-PROCESSAMENTO EM VISÃO COMPUTACIONAL	72
4.2.1	Metodologia Experimental	73
4.2.1.1	Conjunto de Dados	73
4.2.1.2	Estratégia de Pré-Processamento	73
4.2.1.3	Modelo de Aprendizado de Máquina	73
4.2.1.4	Estratégia de Otimização Paramétrica	74
4.2.2	Fundamentação Teórica do Método Selecionado	74
4.2.3	Resultados e Análise	75
4.2.4	Síntese da Etapa	75
4.3	AVALIAÇÃO DE BUSCA ALEATÓRIA NA OTIMIZAÇÃO DE PARÂMETROS ...	76
4.3.1	Ajustes Metodológicos	76
4.3.1.1	Estratégia de Otimização Estocástica	76

4.3.2	Fundamentação Teórica do Método de Busca Estocástica	76
4.3.3	Resultados da Busca Aleatória	77
4.3.4	Síntese da Etapa	78
4.4	EXPERIMENTOS ADICIONAIS COM ARQUITETURAS YOLO	78
4.4.1	Modelos Avaliados	79
4.4.2	Compatibilização entre Detecção e Classificação	80
4.4.3	Critério de Referência e Definição das Métricas	80
4.4.4	Resultados no CPLID	81
4.4.5	Resultados no DRNPW	83
4.4.6	Discussão dos Experimentos Adicionais	85
4.4.7	Limitações dos Experimentos Adicionais	87
4.4.8	Síntese da Etapa	88
5	CONCLUSÃO	89
5.1	SÍNTESE DOS RESULTADOS OBTIDOS	89
5.2	LIMITAÇÕES E DESAFIOS ENCONTRADOS	90
5.3	SUGESTÕES PARA PESQUISAS FUTURAS	91
5.4	CONSIDERAÇÕES FINAIS	92
	REFERÊNCIAS BIBLIOGRÁFICAS	93

1 INTRODUÇÃO

Os isoladores elétricos são componentes fundamentais em linhas de transmissão e distribuição de energia, responsáveis por sustentar mecanicamente os condutores e por garantir o isolamento elétrico entre as partes energizadas e as estruturas aterradas. Em linhas de alta tensão, esses componentes são normalmente agrupados em cadeias de isoladores, que ficam expostas de forma contínua a condições ambientais severas, como variações de temperatura, umidade, poluição e descargas atmosféricas. Ao longo do tempo, essa exposição favorece o surgimento de falhas, como trincas, contaminação superficial, perfurações e rupturas, que comprometem a capacidade de isolamento e a confiabilidade do sistema elétrico.

A identificação precoce dessas falhas é essencial para evitar interrupções no fornecimento de energia, reduzir custos de manutenção e prevenir riscos à segurança das instalações e das pessoas. Tradicionalmente, a inspeção de cadeias de isoladores é realizada de forma visual e manual, por equipes especializadas, o que a torna lenta, custosa e sujeita à subjetividade e a erros humanos. Nesse contexto, técnicas de processamento de imagem associadas a modelos de aprendizado de máquina despontam como alternativa promissora para automatizar a detecção e a classificação de falhas, tornando a inspeção mais rápida, econômica e reproduzível.

A eficácia desses sistemas automatizados depende, em grande medida, das técnicas de processamento de imagem empregadas e da forma como são combinadas e ajustadas. Diferentes técnicas, parâmetros e arquiteturas de rede neural podem produzir resultados bastante distintos para um mesmo problema, o que torna relevante o estudo sistemático de como comparar, selecionar, combinar e aprimorar essas técnicas no domínio específico da detecção de falhas em cadeias de isoladores.

1.1 MOTIVAÇÃO E JUSTIFICATIVA

A crescente demanda por sistemas automatizados de inspeção de cadeias de isoladores evidencia a necessidade de técnicas avançadas de processamento de imagem para a detecção precoce de falhas. Conforme demonstrado por Gonzalez e Woods (GONZALEZ; WOODS, 2008), a análise digital de imagens permite extrair características relevantes para identificar anomalias em componentes elétricos, possibilitando diagnósticos mais precisos. Ademais, o emprego de redes neurais tem se destacado na resolução de problemas complexos de classificação e detecção, conforme ressaltado por LeCun et al. (LECUN; BENGIO; HINTON, 2015) e Krizhevsky et al. (KRIZHEVSKY; SUTSKEVER; HINTON, 2012), contribuindo para a robustez dos sistemas de inspeção.

Estudos recentes apontam que a combinação de diferentes técnicas de processamento de imagem, aliada ao ajuste automático de parâmetros, pode resultar em melhorias significativas no desempenho dos sistemas de diagnóstico (SALVI et al., 2021). Assim, a proposta deste trabalho visa desenvolver uma metodologia que integre esses avanços, buscando não apenas aprimorar a acurácia e a eficiência dos processamentos, mas também possibilitar uma análise comparativa que leve em conta a influência de diferentes modelos e datasets.

Dessa forma, esta dissertação justifica-se pela necessidade de inovar na abordagem de detecção e classificação de falhas em cadeias de isoladores, promovendo ganhos práticos para a segurança e manutenção das redes elétricas, e contribuindo para a evolução do estado da arte em processamento de imagem e aprendizado de máquina.

1.2 OBJETIVO GERAL

O objetivo geral deste estudo é desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores.

1.3 OBJETIVOS ESPECÍFICOS

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

- Estabelecer métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento.
- Determinar o tipo de modelo de redes neurais ideal para avaliar o desempenho dos processamentos, podendo abranger classificação, detecção e regressão.
- Construir modelos de redes neurais destinados à avaliação do desempenho das técnicas de processamento de imagem, sem o intuito de encontrar um modelo definitivo.
- Analisar o impacto da escolha do modelo de rede neural no desempenho do processamento, considerando que diferentes modelos podem gerar diferentes resultados para um mesmo processamento.
- Avaliar a influência do dataset na eficácia do processamento, considerando possíveis variações nos resultados devido à utilização de diferentes conjuntos de dados.
- Desenvolver uma metodologia para o aprimoramento dos processamentos de imagem por meio da combinação de diferentes abordagens unitárias.

- Criar um método de ajuste automático de parâmetros dos processamentos de imagem, visando otimizar seus resultados sem a necessidade de intervenção manual extensa.

1.4 ESTRUTURA DO TRABALHO

Além desta introdução, esta dissertação está organizada em mais quatro capítulos. O Capítulo 2 reúne a revisão bibliográfica, com os fundamentos teóricos de processamento de imagem, de redes neurais, de conjuntos de dados e de métricas de avaliação que embasam o estudo, incluindo ainda a discussão dos trabalhos relacionados que caracterizam o estado da arte na área.

O Capítulo 3 detalha a metodologia proposta, descrevendo as etapas para comparar, selecionar, combinar e aprimorar as técnicas de processamento de imagem, bem como a construção e a avaliação dos modelos de rede neural. O Capítulo 4 apresenta a coleta e a análise dos resultados obtidos com a aplicação da metodologia. Por fim, o Capítulo 5 traz as conclusões do trabalho e as recomendações para pesquisas futuras.

2 REVISÃO BIBLIOGRÁFICA

O processamento de imagens é uma ferramenta essencial para garantir a confiabilidade do Sistema Elétrico de Potência (SEP), especialmente na detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica. Essa técnica permite identificar problemas em componentes como isoladores, fixadores e suportes, que, se não tratados, podem causar interrupções no fornecimento de energia. O uso de imagens capturadas por drones ou câmeras especiais facilita a inspeção de grandes extensões de linhas de transmissão, reduzindo custos e aumentando a segurança ao evitar a necessidade de intervenções manuais em locais de difícil acesso (MADUAKO et al., 2022).

Métodos avançados de análise de imagens, como os baseados em aprendizado profundo, ajudam a reconhecer padrões que indicam falhas, mesmo em condições adversas, como baixa visibilidade ou equipamentos desgastados (ALTAIE et al., 2023). Essas abordagens são particularmente úteis em regiões com infraestrutura antiga, onde a manutenção regular é desafiadora. Além disso, o processamento de imagens possibilita uma resposta rápida a problemas, minimizando o impacto de falhas na rede elétrica e melhorando a continuidade do serviço (KUMAR et al., 2018).

A automação proporcionada pelo processamento de imagens também contribui para a eficiência operacional. Técnicas modernas permitem monitorar equipamentos em tempo real, identificando danos antes que se tornem críticos (MADUAKO et al., 2022). Isso é crucial para manter a estabilidade do SEP, especialmente em áreas remotas ou com alta demanda energética. Assim, o processamento de imagens não apenas aprimora a manutenção das linhas de transmissão, mas também reforça a segurança e a confiabilidade do fornecimento de energia elétrica.

A seguir, será apresentada uma revisão dos principais conceitos e técnicas de processamento de imagens, que podem ser aplicados na detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica.

2.1 PROCESSAMENTO DE IMAGENS

O processamento de imagens desempenha um papel fundamental no contexto do Sistema Elétrico de Potência (SEP), especialmente em atividades de inspeção, manutenção preditiva e monitoramento de ativos em linhas de transmissão. Com o uso crescente de drones, câmeras térmicas e sensores ópticos, a obtenção de imagens de componentes da rede elétrica tornou-se mais acessível e eficiente. No entanto, a qualidade e a variabilidade dessas imagens exigem técnicas robustas de pré-processamento para garantir resultados precisos em tarefas como a detecção de falhas, corrosões, aquecimentos anô-


malos e objetos estranhos nas estruturas. Esta seção apresenta os principais métodos de processamento de imagens empregados para preparar dados visuais que serão utilizados em modelos baseados em aprendizado de máquina e redes neurais, contribuindo diretamente para a confiabilidade, segurança e eficiência operacional do SEP.

2.1.1 Normalização

A normalização é uma etapa fundamental no pré-processamento de imagens para redes neurais, pois padroniza os valores dos pixels, facilitando a convergência durante o treinamento e melhorando a generalização do modelo. Um método comum é a normalização de valores de pixels, que escala os valores para intervalos como $[0,1]$ ou $[-1,1]$, frequentemente realizada dividindo os valores originais pelo máximo possível (por exemplo, 255 para imagens de 8 bits) (SHARMA et al., 2024). Outro método é a normalização Z-score, que subtrai a média dos pixels e divide pelo desvio padrão, resultando em dados com média zero e variância unitária (PEI et al., 2023). A equalização de histograma também é utilizada para redistribuir as intensidades dos pixels, aumentando o contraste e destacando detalhes em imagens de baixa qualidade (PEI et al., 2023). Além disso, a padronização de cores, como subtrair os valores médios dos canais RGB, centraliza os dados em torno de uma distribuição normal, o que é particularmente útil para redes convolucionais (MALL et al., 2023). Técnicas mais avançadas, como a normalização por percentis, utilizam o 5º e o 95º percentis como limites para lidar com valores discrepantes, enquanto a correspondência de histogramas ajusta a distribuição de intensidades com base em pontos de referência (ALBERT et al., 2023). Essas abordagens garantem que as redes neurais processem dados de forma consistente, reduzindo a sensibilidade a variações de iluminação ou escala, especialmente em tarefas de visão computacional (SHARMA et al., 2024).

A Figura 1 ilustra o processo de normalização de imagens, onde a imagem original é transformada em uma imagem normalizada, facilitando a extração de características relevantes.

Figura 1 – Normalização de Imagens



Fonte: Kuehlkamp (2013).

2.1.2 Redimensionamento e Recorte

O redimensionamento é essencial para ajustar as imagens ao tamanho de entrada esperado pelas arquiteturas de redes neurais, garantindo compatibilidade e consistência. Um método comum é redimensionar as imagens para um tamanho fixo, como 224x224 pixels, amplamente utilizado em modelos como ResNet e VGG (PEI et al., 2023). Isso pode ser feito por meio de interpolação bilinear ou bicúbica, que suaviza as transições entre pixels, embora métodos mais avançados, como interpolação baseada em Fourier, também sejam explorados (DENNANNI, 2019). O recorte, por outro lado, extrai uma região de interesse da imagem, frequentemente centrada, para preservar áreas relevantes, especialmente quando as dimensões originais variam significativamente (MALL et al.,

2023). Estudos indicam que o redimensionamento para tamanhos menores pode acelerar o treinamento, mas tamanhos muito reduzidos podem comprometer a qualidade das características extraídas (SABOTTKE et al., 2020). Além disso, o recorte aleatório é usado em conjunto com aumento de dados para introduzir variabilidade durante o treinamento (MAHARANA; MONDAL; NEMADE, 2022). Essas técnicas são cruciais para lidar com conjuntos de dados heterogêneos, garantindo que as entradas sejam uniformes sem perda significativa de informação (PEI et al., 2023).

A Figura 2 ilustra o processo de redimensionamento e recorte de imagens, na qual a imagem da esquerda (original) é utilizada para extrair uma região de interesse (recorte) e em seguida redimensionada para um tamanho fixo (imagem da direita).

Figura 2 – Redimensionamento e recorte



Fonte: Adaptado de Venturelli (2021).

2.1.3 Aumento de Dados

O aumento de dados é uma estratégia poderosa para ampliar a diversidade do conjunto de treinamento, reduzindo o risco de sobreajuste e melhorando a robustez do modelo. Técnicas geométricas incluem espelhamento horizontal ou vertical, rotações em ângulos variados (de 1° a 359°), translações, cortes aleatórios e ajustes de escala, que simulam diferentes perspectivas e tamanhos (SHORTEN; KHOSHGOFTAAR, 2019). Transformações no espaço de cores, como ajustes de brilho, contraste, saturação e matiz, ajudam a lidar com variações de iluminação (SHORTEN; KHOSHGOFTAAR, 2019). Métodos mais avançados, como apagamento aleatório, mascaram partes da imagem para simular oclusões, enquanto a mistura de imagens combina pixels de diferentes amostras para criar novas instâncias (SHORTEN; KHOSHGOFTAAR, 2019). Por exemplo, o método Sample-Pairing reduziu o erro no conjunto CIFAR-10 de 8,22% para 6,93% (SHORTEN; KHOSHGOFTAAR, 2019). Além disso, redes adversárias generativas (GANs) são usadas para


gerar imagens sintéticas, especialmente em domínios com dados limitados, como imagens médicas, alcançando melhorias de até 10% em precisão (SHORTEN; KHOSHGOFTAAR, 2019). Essas técnicas são particularmente valiosas em cenários com poucos dados, permitindo que as redes neurais generalizem melhor para condições não vistas (MAHARANA; MONDAL; NEMADE, 2022).

2.1.4 Redução de Ruído

A redução de ruído remove interferências que podem comprometer o desempenho das redes neurais, sendo especialmente crítica em aplicações como imagens médicas e vigilância. Métodos tradicionais, como filtros de média ou mediana, são complementados por abordagens baseadas em aprendizado profundo, como redes neurais convolucionais (CNNs) especializadas, como DnCNNs, que aprendem a mapear imagens ruidosas para versões limpas (SHARMA et al., 2024). Autoencoders também são empregados para reconstruir imagens a partir de representações latentes, eliminando ruídos como Gaussianos ou de sal e pimenta (SHARMA et al., 2024). Técnicas como Total Variation Denoising (TVD) e Non-Local Means (NLM) exploram regularizações e similaridades entre pixels para preservar detalhes (SHARMA et al., 2024). Um estudo demonstrou que a aplicação de DnCNNs em imagens de tomografia computadorizada resultou em uma precisão de detecção de câncer de pulmão variando de 86,17% a 99,67% (SHARMA et al., 2024). Além disso, métodos baseados em redes neurais profundas, como o Deep Neural Filter (DNF), alcançaram melhorias de até 10 dB na relação sinal-ruído em sinais de EEG (PORR et al., 2022). Essas abordagens são essenciais para garantir que as redes neurais processem imagens de alta qualidade, minimizando artefatos que poderiam obscurecer características críticas (SHARMA et al., 2024).

A Figura 3 ilustra o processo de redução de ruído, onde a imagem original (à esquerda) é processada para remover o ruído, resultando em uma imagem mais limpa (à direita).

Figura 3 – Redução de Ruído



Fonte: Adaptado de The MathWorks, Inc. (2023).

2.1.5 Ajuste de Contraste e Brilho

O ajuste de contraste e brilho melhora a visibilidade das características das imagens, sendo crucial para tarefas que dependem de detalhes finos. A equalização de histograma redistribui as intensidades dos pixels para maximizar o contraste, enquanto a equalização adaptativa limitada por contraste (CLAHE) evita a amplificação excessiva de ruído em regiões homogêneas (MALL et al., 2023). A correção gama ajusta a curva de intensidade para realçar detalhes em áreas escuras ou claras, sendo amplamente usada em imagens de baixa qualidade (MALL et al., 2023). Métodos baseados em aprendizado profundo, como redes convolucionais fuzzy, integraram filtros Gaussianos e triangulares para melhorar imagens de íris, alcançando até 97% de precisão em tarefas de reconhecimento (SHARMA et al., 2024). Além disso, técnicas como RetinexDIP foram propostas para melhorar a resolução e reduzir o consumo de memória em comparação com métodos tradicionais (SHARMA et al., 2024). Essas abordagens são fundamentais para preparar imagens para redes neurais, garantindo que as características relevantes sejam destacadas (MALL et al., 2023).

A Figura 4 ilustra o efeito do CLAHE em uma imagem, destacando detalhes que antes estavam obscurecidos.

Figura 4 – Ajuste de Contraste e Brilho com CLAHE



Fonte: Pandey (2023).

2.1.6 Aumento de Nitidez

O aumento de nitidez realça bordas e detalhes finos, facilitando tarefas como detecção de objetos e segmentação. Técnicas tradicionais, como a máscara de desfoque, aplicam filtros de alta passagem para enfatizar transições de intensidade (MALL et al., 2023). Métodos baseados em redes neurais, como CNNs, foram desenvolvidos para detectar e corrigir nitidez, como no caso da detecção de máscaras de desfoque (USM), superando métodos baseados em codificação ternária perpendicular a bordas (YE et al., 2018). Em aplicações específicas, como imagens de documentos, redes convolucionais combinadas com filtros de Gabor e desfoque melhoraram a legibilidade, reduzindo distorções como sombras e ruídos (BEN et al., 2022). Essas técnicas são particularmente úteis em cenários onde a clareza das bordas é essencial para o desempenho do modelo (SHARMA et al., 2024).

A Figura 5 ilustra o efeito do aumento de nitidez em uma imagem, onde os detalhes são mais evidentes após o processamento.

Figura 5 – Aumento de Nitidez



Fonte: Adaptado de Joshi (2015).

2.1.7 Conversão de Espaço de Cores

A conversão de espaço de cores adapta as imagens às necessidades específicas da tarefa, simplificando o processamento ou destacando características relevantes. A conversão de RGB para escala de cinza reduz a dimensionalidade, sendo útil em tarefas onde a cor não é essencial (SHARMA et al., 2024). Espaços como HSV e LAB são preferidos em aplicações que requerem separação de matiz, saturação ou luminância, como segmentação de objetos (SHARMA et al., 2024). Redes neurais também foram usadas para realizar conversões de espaço de cores, como de RGB para XYZ, alcançando erros de cor inferiores a 1,0 unidade E 2000 em mais de 85% dos casos testados (MACDONALD, 2019). Essas conversões são valiosas para otimizar a extração de características e reduzir a complexidade computacional em tarefas de visão computacional (SHARMA et al., 2024).


2.1.8 Restauração e Desembaçamento de Imagens

A restauração de imagens visa recuperar a imagem original a partir de versões degradadas por desfoque, ruído ou outras distorções. O desembaçamento, um subcampo da restauração, utiliza redes neurais como U-Net para corrigir desfoques dinâmicos, alcançando PSNR de 31,53 no conjunto GoPro e 31,32 no Real Blur (LIAN; WANG, 2023). Métodos baseados em autoencoders convolucionais foram propostos para restaurar imagens em aplicações de fotografia computacional e sensoriamento remoto (STEFFENS et al., 2020). Além disso, redes neurais como DnCNNs foram aplicadas para remover ruídos específicos, como speckle em imagens holográficas (SHARMA et al., 2024). Essas

técnicas são cruciais para preparar imagens de alta qualidade para redes neurais, especialmente em domínios onde a clareza é essencial (SUMIDA et al., 2019).

A Figura 6 ilustra o processo de desembaçamento, onde a imagem original (à esquerda) é processada para remover o desfoque, resultando em uma imagem mais nítida (à direita).

Figura 6 – Restauração e Desembaçamento de Imagens



Fonte: Adaptado de The MathWorks, Inc. (2025).

2.1.9 Detecção de Bordas

A detecção de bordas identifica limites e formas nas imagens, sendo uma etapa fundamental em muitas tarefas de visão computacional. Redes neurais, como redes de codificação-decodificação, foram desenvolvidas para detectar bordas com alta precisão, alcançando desempenho comparável ao de detectores tradicionais como o Canny em imagens ruidosas (YU et al., 1994). Métodos inspirados em mecanismos biológicos, como redes com atenção seletiva, melhoraram a extração de características globais, resultando em mapas de bordas mais robustos (ZHANG et al., 2022b). Essas abordagens são essenciais para pré-processar imagens, fornecendo informações estruturais que facilitam a segmentação e o reconhecimento de objetos (YU et al., 1994).

A Figura 7 ilustra o processo de detecção de bordas, onde as bordas da imagem original (à esquerda) são destacadas na imagem processada (à direita).

Figura 7 – Detecção de Bordas




Fonte: Couto (2024).

2.1.10 Correção de Iluminação

A correção de iluminação normaliza as condições de luz nas imagens, garantindo consistência na extração de características. Métodos baseados em aprendizado profundo, como redes convolucionais, foram propostos para corrigir imagens com iluminação desigual, como pinturas, alcançando resultados superiores em métricas como NIQE e LOE (GOSWAMI; SINGH, 2020). Técnicas híbridas que combinam modelos baseados em aprendizado e físicos foram aplicadas para melhorar a detecção de objetos em condições de luz variada, como em imagens de plantações (YANG et al., 2022). Essas abordagens são particularmente úteis em cenários onde a iluminação não uniforme pode comprometer o desempenho do modelo (GOSWAMI; SINGH, 2020).

A Figura 8 ilustra o processo de correção de iluminação, onde a imagem original (à esquerda) é processada para uniformizar a iluminação, resultando em uma imagem mais equilibrada (à direita).

Figura 8 – Correção de Iluminação



Fonte: Bascle, Bernier e Lemaire (2006).

2.1.11 Super-Resolução

A super-resolução aumenta a resolução de imagens, gerando versões de alta qualidade a partir de entradas de baixa resolução. Redes neurais, como redes convolucionais profundas e redes adversárias generativas (GANs), alcançaram resultados impressionantes, com modelos como SRGAN produzindo imagens fotorrealistas (LEDIG et al., 2017). Em aplicações biológicas, redes como DPA-TISR foram desenvolvidas para imagens de células vivas, alcançando fidelidade temporal e consistência em mais de 10.000 pontos temporais (LIU et al., 2025). Essas técnicas são valiosas para tarefas que requerem detalhes finos, como análise médica e vigilância, permitindo que redes neurais processem imagens com maior clareza (LEDIG et al., 2017).

2.1.12 Conclusão parcial da seção


O processamento de imagens é uma etapa crucial para garantir a eficácia dos modelos de aprendizado profundo aplicados ao Sistema Elétrico de Potência (SEP). As técnicas discutidas, como normalização, redimensionamento, aumento de dados e redução de ruído, podem ser fundamentais para preparar as imagens antes de serem alimentadas em redes neurais. Essas abordagens não apenas melhoram a qualidade das imagens, mas também garantem que os modelos sejam mais robustos e capazes de generalizar em diferentes condições. A escolha adequada dessas técnicas pode impactar significativamente o desempenho dos modelos na detecção e classificação de falhas em equipamentos de linhas de transmissão.

Dando continuidade, para que as técnicas de processamento de imagens sejam efetivamente aplicadas, é fundamental compreender os fundamentos das redes neurais, que são as principais ferramentas para análise e classificação dessas imagens. A próxima seção aborda os conceitos essenciais sobre redes neurais.

2.2 REDES NEURAIS

Uma rede neural artificial é formada por um grande número de neurônios para funcionar corretamente, mas para compreender o funcionamento de uma rede neural, deve-se definir o modelo de um único neurônio artificial. Esse modelo é apresentado na Figura 9.

Figura 9 – Modelo de um Neurônio Artificial



Fonte: Soares e Silva (2011).

Os passos para a obtenção da saída de um neurônio artificial são:

1. O modelo recebe um número m de entradas $x_1, x_2, \dots, x_m$;
2. Cada uma dessas entradas é multiplicada por um peso, conforme a Equação 2.1:

$$x_i w_i, \quad \text{para } i = 1, 2, \dots, m \quad (2.1)$$

3. Somam-se as entradas multiplicadas pelos seus respectivos pesos, conforme a Equação 2.2:

$$\sum_{n=1}^m w_n x_n \quad (2.2)$$

4. Adiciona-se o bias, conforme a Equação 2.3:

$$b + \sum_{n=1}^m w_n x_n \quad (2.3)$$

5. O resultado passa por uma função de ativação, conforme a Equação 2.4:

$$\varphi \left(b + \sum_{n=1}^m w_n x_n \right) \quad (2.4)$$

Seguidos os passos, a equação de saída de um neurônio artificial é descrita pela Equação 2.5.

$$y = \varphi \left(b + \sum_{n=1}^m w_n x_n \right) \quad (2.5)$$

Visto o modelo de um único neurônio artificial, o conceito de rede neural composta pela associação de diversos neurônios é descrito a seguir.

2.2.1 Tipos de redes neurais


Existem diversos tipos de redes neurais que se distinguem tanto em termos de seus princípios de funcionamento quanto em suas aplicações práticas específicas. A seguir, serão discutidos alguns desses tipos de redes neurais de maneira individualizada, a fim de fornecer uma compreensão mais aprofundada sobre seu funcionamento e suas aplicações (ALEX, 2020).

2.2.1.1 Perceptron (P), Feed Forward Network (FFN)

FFNs são o tipo mais básico de rede neural, em que a informação flui linearmente até a saída e cada neurônio realiza uma operação matemática linear do tipo apresentado na Equação 2.6. Sendo x o valor de entrada, w o peso e b o bias do neurônio. O resultado passa por uma função de ativação e em seguida é enviado para a próxima camada. As redes neurais do tipo FFN (exemplo mostrado através da Figura 10) possuem conexões em apenas um único sentido, geralmente limitadas a 5 camadas (ALEX, 2020).

$$wx + b \quad (2.6)$$


Figura 10 – FFN



Fonte: Alex (2020).

As redes do tipo P, Figura 11, são um caso especial de uma rede FFN, em que todos os neurônios de uma camada são conectados com todos neurônios da camada seguinte (ALEX, 2020).

Figura 11 – Perceptron



Fonte: Alex (2020).


As FFNs são utilizadas para problemas em que os dados de entrada têm impacto atemporal nos dados de saída, em que a saída não depende do estado anterior da rede neural. Um exemplo é usar informações de um exame de sangue para determinar a presença de uma doença.

2.2.1.2 Convolutional neural network (CNN) ou Deep convolutional network (DCN)

As redes neurais estudadas até então, não consideram uma relação de vizinhança entre os dados de entrada. Por exemplo, não faria a menor diferença se antes do treinamento a posição de todos os dados de entrada fossem embaralhadas da mesma forma. Porém, essa relação de vizinhança pode ser muito importante para alguns casos específicos como no reconhecimento de imagens, reconhecimento de voz, análise grafista do mercado financeiro, etc. No reconhecimento de imagens, por exemplo, grande parte da informação está contida na relação de vizinhança dos pixels como o contraste e a textura.

Uma CNN, cuja estrutura está representada através da Figura 12, percebe uma imagem como uma caixa retangular cuja largura e altura são medidas pelo número de pixels da imagem e a profundidade é representada por cada uma das três camadas de cores, vermelho, verde e azul referidas como canais (VEEN, 2016).

Figura 12 – CNN



Fonte: Veen (2016).

Ao longo das camadas de uma rede CNN, as dimensões da imagem se alteram, pois a medida em que a altura e largura da imagem diminuem, o número de canais aumenta, reduzindo o volume de dados. Esse processo é chamado de pooling, que faz um resumo dos dados através do descarte das saídas menos significativas, mantendo somente às de maior valor (VEEN, 2016).

O processo de convolução é realizado arrastando uma janela (kernel) de dimensão menor pela imagem original, sendo essa janela uma rede FFN (VEEN, 2016). Por exemplo, se uma imagem 5x5 pixels passar pelo processo da convolução e supondo uma janela de 3x3 com passo 1 (stride), primeiramente os 3x3 pixels do canto superior esquerdo da imagem original passarão por uma FFN. Em seguida, essa janela é arrastada 1 pixel

(tamanho do passo) para a direita e o processo se repete até ao final da imagem.

2.2.2 Funções de ativação

As funções de ativação introduzem não-linearidade nas redes neurais, permitindo que elas aprendam relações complexas entre entradas e saídas. Sem essas funções, mesmo com múltiplas camadas, a rede se comportaria como um modelo linear (BADIGER; MATHEW, 2022). Cada camada da rede pode ter uma função de ativação diferente, sendo algumas mais adequadas para camadas ocultas e outras para a camada de saída.

A seguir, são apresentadas as três principais funções de ativação:

2.2.2.1 ReLU (Rectified Linear Unit)

Representada pela Equação 2.7, a ReLU é amplamente utilizada em camadas ocultas. Sua principal vantagem é a eficiência computacional e a aceleração da convergência do gradiente. Contudo, pode causar o problema dos neurônios mortos (Dying ReLU), quando valores negativos resultam sempre em zero (AGARAP, 2018).

$$f(x) = \max(0, x) \quad (2.7)$$

2.2.2.2 Sigmoid

Definida pela Equação 2.8, transforma a entrada em um valor entre 0 e 1, sendo útil para problemas de classificação binária. Apesar de ser diferenciável e fornecer gradientes suaves, sofre com o problema do gradiente pequeno para valores extremos, o que dificulta o aprendizado (LANGER, 2020).

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.8)$$

2.2.2.3 Softmax

A função Softmax é apresentada na Equação 2.9 e é utilizada na camada de saída para classificação multiclasse. Ela converte os valores em uma distribuição de probabilidades, acentuando a classe de maior valor (GAO; PAVEL, 2017).

$$f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (2.9)$$

2.2.2.4 Regras gerais para escolha de funções de ativação

A escolha da função de ativação depende do tipo de problema e da arquitetura da rede. A seguir, são apresentadas algumas diretrizes gerais:

- *Camada de saída:*
 - Regressão: Linear
 - Classificação binária: Sigmoid
 - Classificação multiclasse: Softmax
 - Classificação multirrótulo: Sigmoid
- *Camadas ocultas:*
 - Redes convolucionais: ReLU
 - Redes recorrentes: Tanh ou Sigmoid

2.2.3 Funções de Custo

As funções de custo são responsáveis por medir o quão distante a saída prevista está da saída real. Elas orientam o processo de treinamento ajustando os pesos da rede para minimizar esse erro (RASHID, 2020).

2.2.3.1 Erro Médio Quadrático (MSE)

O Erro Médio Quadrático (MSE) é uma das funções mais comuns em regressão, penalizando fortemente grandes erros e sendo sensível a outliers (GOODFELLOW; BENGIO; COURVILLE, 2016). Ele é definido como a Equação 2.10:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.10)$$

2.2.3.2 Erro Médio Absoluto (MAE)

O Erro Médio Absoluto (MAE) é mais robusto a outliers que o MSE, mas pode ser mais difícil de otimizar. Sua fórmula é apresentada na Equação 2.11:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.11)$$

2.2.3.3 Função Huber

A função Huber combina as vantagens do MSE e MAE, sendo menos sensível a outliers e mais estável para pequenos erros (HUBER, 1964). Ela é definida pela Equação 2.12:

$$L_{\text{Huber}} = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{se } |y - \hat{y}| \leq \delta \\ \delta(|y - \hat{y}| - \frac{1}{2}\delta) & \text{caso contrário} \end{cases} \quad (2.12)$$

2.2.3.4 Entropia Cruzada Binária

A Entropia Cruzada Binária é indicada para problemas de classificação binária (ZHANG; SABUNCU, 2018), sendo expressa pela Equação 2.13:

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (2.13)$$

2.2.3.5 Entropia Cruzada Categórica

Já a Entropia Cruzada Categórica é utilizada em classificação multiclasse com rótulo único por amostra, e sua fórmula é apresentada na Equação 2.14:

$$L = -\sum_{i=1}^n \sum_{j=1}^k y_{ij} \log(\hat{y}_{ij}) \quad (2.14)$$

2.2.4 Otimizadores

Otimizadores são algoritmos que ajustam os pesos da rede neural com base no gradiente da função de custo. Eles influenciam diretamente a velocidade e a qualidade da convergência (RUDER, 2016). Entre os principais otimizadores, destaca-se o Gradiente Descendente, que é a forma mais simples de otimização, mas pode ser lenta e sensível à escolha da taxa de aprendizado. O Gradiente Descendente Estocástico (SGD) atualiza os pesos a cada amostra, adicionando ruído estocástico que pode ajudar a escapar de mínimos locais. O Momentum acrescenta uma fração do gradiente anterior ao atual, acelerando a convergência e suavizando oscilações. O RMSProp ajusta a taxa de aprendizado para cada parâmetro com base na média móvel dos gradientes quadrados (TIELEMAN; HINTON, 2012). Por fim, o Adam combina Momentum e RMSProp, sendo amplamente utilizado por sua eficiência e robustez (KINGMA; BA, 2014).

Compreendidos os principais conceitos sobre redes neurais, é importante discutir o papel dos conjuntos de dados (datasets), que são essenciais para o treinamento e avaliação desses modelos. A próxima seção aborda os desafios e técnicas relacionados aos datasets utilizados em tarefas de detecção de falhas.

2.3 DATASETS

Os conjuntos de dados são fundamentais para o treinamento de redes neurais, fornecendo as amostras necessárias para aprender padrões complexos e realizar previsões precisas. A qualidade, quantidade e diversidade dos dados impactam diretamente o desempenho dos modelos, especialmente em aprendizagem profunda, onde redes com milhões de parâmetros requerem grandes volumes de dados anotados. Conjuntos como o ImageNet, com mais de 14 milhões de imagens em milhares de categorias, foram essenciais para avanços em visão computacional, como a classificação de imagens e detecção de objetos (DENG et al., 2009). Na engenharia elétrica, especificamente na detecção de falhas em cadeias de isoladores e equipamentos de linhas de transmissão, datasets são frequentemente escassos ou desbalanceados, limitando a capacidade dos modelos de generalizar (SHORTEN; KHOSHGOFTAAR, 2019).

Conjuntos de dados desbalanceados são prevalentes na detecção de falhas em linhas de transmissão, onde amostras de isoladores saudáveis superam significativamente as de defeitos, como quebras ou flashovers (descarga elétrica que ocorre sobre a superfície isolante, quando a rigidez dielétrica é rompida) por poluição. Esse desbalanceamento pode levar a modelos enviesados que favorecem a classe majoritária, resultando em baixa sensibilidade para a detecção de falhas (HE; GARCIA, 2009). Por exemplo, no conjunto de dados IDID, a proporção de isoladores saudáveis para defeituosos é de aproximadamente

10:1 para quebras e 5:1 para flashovers, o que dificulta a classificação precisa das classes minoritárias (OBERWEGER; WENDEL; BISCHOF, 2024). Esse desafio é crítico em aplicações de engenharia elétrica, onde a detecção de falhas raras é essencial para garantir a segurança e a confiabilidade do sistema.

Datasets escassos, caracterizados por um número reduzido de amostras, são comuns em áreas onde a coleta de dados é custosa, demorada ou restrita pela raridade de eventos, como na detecção de falhas em isoladores de linhas de transmissão. A escassez de dados aumenta o risco de sobreajuste, onde modelos de redes neurais memorizam os dados de treinamento em vez de aprender padrões generalizáveis (GOODFELLOW; BENGIO; COURVILLE, 2016). Esse problema é agravado em aplicações de engenharia elétrica, onde imagens de falhas, como quebras ou flashovers por poluição, são difíceis de obter em quantidade suficiente. A anotação manual de imagens capturadas por drones, frequentemente usada para identificar defeitos, é demorada e propensa a erros, limitando ainda mais o tamanho dos datasets (ZHENG et al., 2022). Por exemplo, o conjunto de dados Insulator-Defect Detection, com apenas 1600 imagens, enfrenta desafios devido ao número limitado de amostras de defeitos (ZHENG et al., 2022).

O aprendizado por transferência é uma técnica amplamente utilizada para mitigar os desafios de datasets escassos, permitindo que modelos pré-treinados em grandes conjuntos de dados, como o ImageNet, sejam ajustados para tarefas específicas com menos dados (PAN; YANG, 2010). Essa abordagem é eficaz em cenários onde características visuais gerais, como bordas e texturas, podem ser transferidas de datasets genéricos para aplicações especializadas. O aprendizado por transferência tem se mostrado particularmente útil em aplicações de engenharia elétrica, onde datasets específicos são frequentemente escassos.

Uma das formas de tentar diminuir o impacto negativo de bancos de dados escassos, como são os casos citados, é o aumento de dados, uma estratégia essencial para ampliar artificialmente o tamanho e a diversidade dos dados por meio de transformações como rotação, escala, inversão e alterações de iluminação (SHORTEN; KHOSHGOFTAAR, 2019). Esta abordagem é particularmente valiosa quando a coleta de dados reais é custosa, demorada ou limitada pela raridade de eventos, como na detecção de falhas em equipamentos de linhas de transmissão. Na detecção de falhas em linhas de transmissão, essas transformações ajudam a simular diferentes condições ambientais, como variações de luz ou ângulos de captura, comuns em imagens de VANTs (Veículo Aéreo Não Tripulado). Por exemplo, Peng et al. (2023) aplicaram aumento de dados para melhorar a robustez de um modelo YOLOv5 na detecção de defeitos pequenos, como flashovers por poluição, em imagens de linhas de transmissão. Métodos avançados, como redes adversárias generativas (GANs), podem gerar imagens sintéticas de falhas, mas sua aplicação em engenharia elétrica é limitada devido à complexidade computacional (GOODFELLOW et al., 2014). Apesar disso, GANs têm potencial para criar amostras sintéticas de defeitos

raros, como quebras em isoladores, ampliando datasets escassos e reduzindo significativamente o problema da escassez de dados.

O aprendizado semi-supervisionado é uma abordagem promissora para datasets escassos, aproveitando dados não rotulados, que são mais abundantes em inspeções de linhas de transmissão, para melhorar o desempenho do modelo (ENGELEN; HOOS, 2020). Imagens de VANTs capturadas durante inspeções rotineiras podem ser usadas para aprender representações gerais, mesmo sem anotações detalhadas. Embora não haja exemplos específicos na literatura revisada aplicando aprendizado semi-supervisionado diretamente à detecção de falhas em isoladores, Chen et al. (2020) demonstraram sua eficácia em tarefas de visão computacional, sugerindo potencial para aplicações futuras em engenharia elétrica, onde dados não rotulados de inspeções são comuns. Essa técnica pode ser explorada para pré-treinar modelos em grandes conjuntos de imagens de linhas de transmissão antes de ajustá-los em datasets rotulados menores.

A reamostragem é uma técnica comum para abordar o desbalanceamento, envolvendo sobreamostragem da classe minoritária ou subamostragem da classe majoritária para equilibrar a distribuição (JOHNSON; KHOSHGOFTAAR, 2019). Métodos como o SMOTE (Synthetic Minority Over-sampling Technique) geram amostras sintéticas da classe minoritária interpolando exemplos existentes (CHAWLA et al., 2002). Em Oberweger, Wendel e Bischof (2024), os autores aplicaram subamostragem para criar partições balanceadas do conjunto de dados IDID, retrainando a última camada do modelo com regressão logística para melhorar a classificação de isoladores defeituosos. Essa abordagem aumentou a precisão em até 12% para quebras e 7% para flashovers, demonstrando eficácia em cenários desbalanceados. A reamostragem é particularmente útil quando o número de amostras de defeitos é extremamente baixo, como em datasets de inspeção de linhas.

A perda focal é uma função de perda especializada que atribui maior peso a exemplos difíceis, frequentemente pertencentes à classe minoritária, reduzindo o impacto de amostras bem classificadas (LIN et al., 2017). Na detecção de falhas em isoladores, Zheng et al. (2022) utilizaram a perda focal em um modelo YOLOv7 para lidar com o desbalanceamento entre amostras de isoladores e defeitos em imagens de VANTs. A aplicação dessa técnica melhorou a precisão na detecção de defeitos pequenos, como flashovers por poluição, que são menos frequentes. A perda focal é particularmente vantajosa em tarefas de detecção de objetos, onde o fundo da imagem pode dominar a distribuição de classes, como em imagens de linhas de transmissão com fundos complexos.

A unificação de datasets públicos, como proposto por Silva et al. (2020), oferece uma abordagem valiosa para a pesquisa em detecção de falhas. O repositório combina datasets como o de Tomaszewski et al. e o CPLID, fornecendo imagens e anotações no formato COCO. Essa consolidação facilita o acesso a dados diversificados, embora o desbalanceamento e a escassez permaneçam desafios que requerem técnicas avançadas de pré-processamento e treinamento. A unificação de datasets é particularmente útil para

aumentar o número de amostras disponíveis, permitindo treinar modelos mais robustos para detecção de falhas em isoladores (SILVA et al., 2020).

A Tabela 1 resume os principais datasets utilizados na detecção de falhas em isoladores, destacando suas características e desafios.

Tabela 1 – Técnicas para Lidar com Escassez e Desbalanceamento de Dados

Categoria	Técnica	Descrição
Escassez	Aprendizado por Transferência	Reutiliza modelos pré-treinados em grandes conjuntos para tarefas com poucos dados (PAN; YANG, 2010).
Escassez	Aumento de Dados	Aplica transformações (por exemplo, rotação, escala) para ampliar o conjunto de dados (SHORTEN; KHOSHGOFTAAR, 2019).
Escassez	Aprendizado Semi-Supervisionado	Aproveita dados não rotulados para aprender representações gerais (ENGELN; HOOS, 2020).
Desbalanceamento	Reamostragem	Sobreamostra a classe minoritária ou subamostra a majoritária (JOHNSON; KHOSHGOFTAAR, 2019).
Desbalanceamento	Perda Focal	Modifica a perda para focar em exemplos difíceis, geralmente da classe minoritária (LIN et al., 2017).

Após a análise das principais estratégias para lidar com escassez e desbalanceamento de dados, é fundamental compreender como avaliar o desempenho dos modelos desenvolvidos. A seguir, são apresentadas as principais métricas de avaliação utilizadas em tarefas de detecção de falhas em linhas de transmissão.


2.4 MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO DE MODELOS

Na detecção de falhas em cadeias de isoladores e equipamentos de linhas de transmissão, a escolha das métricas de avaliação é fundamental para garantir a eficácia e confiabilidade dos modelos de redes neurais. Métricas comumente utilizadas incluem acurácia, precisão, recall, F1-score, área sob a curva ROC (AUC-ROC) e, para tarefas de detecção de objetos, a média da precisão média (mAP). A acurácia, definida como a proporção de previsões corretas em relação ao total, pode ser enganosa em datasets desbalanceados, onde a classe de falhas é significativamente menos representada que a classe de isolado-

res saudáveis. Por exemplo, em um dataset com 95% de amostras saudáveis, um modelo que sempre prevê "saudável" alcançará alta acurácia, mas falhará em detectar falhas, comprometendo a segurança do sistema (HE; GARCIA, 2009). Em Alam et al. (2025), os autores reportaram uma acurácia de 99,96% para um modelo ensemble RF-LSTM Tuned KNN, mas complementaram a avaliação com precisão, recall e F1-score para abordar o desbalanceamento do conjunto de dados, garantindo uma análise mais robusta do desempenho em classes minoritárias.

A Figura 13 ilustra uma curva ROC típica, que representa a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos para diferentes limiares de decisão. A área sob a curva (AUC) é uma métrica importante para avaliar a capacidade discriminativa do modelo.

Figura 13 – Curva ROC



Fonte: Torres (2025).

A precisão mede a proporção de verdadeiros positivos entre todas as previsões positivas, sendo útil para avaliar a confiabilidade das detecções de falhas. O recall, por outro lado, mede a proporção de verdadeiros positivos entre todas as amostras positivas reais, sendo crítico em aplicações onde falsos negativos (falhas não detectadas) podem levar a falhas catastróficas no sistema de transmissão. O F1-score, a média harmônica entre precisão e recall, oferece uma métrica balanceada que considera ambos os aspectos, sendo amplamente utilizado em cenários desbalanceados (JOHNSON; KHOSHGOFTAAR, 2019).

Para tarefas de detecção de objetos, como identificar defeitos em imagens de VANTs, a métrica mAP é padrão, calculando a precisão média para cada classe e tomando a média geral. Em Zheng et al. (2022), o modelo YOLOv7 foi avaliado no conjunto Insulator-Defect

Detection, utilizando mAP para medir a precisão na detecção de quebras e flashovers, com resultados superiores em comparação com modelos anteriores. A AUC-ROC, que avalia a capacidade do modelo de distinguir entre classes em diferentes limiares, também é relevante, especialmente em classificações binárias (falha vs. não falha). Em Alam et al. (2025), a AUC-ROC foi reportada como 1,0 para classificações binárias, indicando excelente separação entre classes, mas valores menores foram observados em classificações multi-label, refletindo a complexidade de datasets desbalanceados.

Outras métricas, como a matriz de confusão, fornecem uma visão detalhada dos erros do modelo, permitindo calcular taxas de falsos positivos e negativos. Em Alam et al. (2025), matrizes de confusão foram usadas para avaliar o desempenho do modelo ensemble em classificações binárias e multi-label, complementando as métricas de precisão e recall. Para aplicações em tempo real, como inspeções de VANTs, métricas adicionais, como tempo de inferência e complexidade computacional, também são consideradas, especialmente em modelos como YOLOv5 e YOLOv7, que priorizam eficiência (PENG et al., 2023). A escolha das métricas deve, portanto, alinhar-se com os objetivos da aplicação, priorizando recall para segurança e mAP para detecção precisa de objetos em imagens.

Por fim, compreender as métricas de avaliação é essencial para interpretar corretamente os resultados obtidos com diferentes modelos e técnicas de processamento de imagens. A próxima seção apresenta os trabalhos relacionados, situando a metodologia proposta frente ao estado da arte.

A Tabela 2 apresenta um resumo das principais métricas utilizadas para avaliar o desempenho de modelos em tarefas de detecção de falhas em linhas de transmissão, destacando suas características e aplicações.

Tabela 2 – Principais métricas de avaliação de desempenho de modelos

Métrica	Descrição
Acurácia	Proporção de previsões corretas em relação ao total de amostras. Pode ser enganosa em conjuntos desbalanceados.
Precisão	Proporção de verdadeiros positivos entre todas as previsões positivas. Mede a confiabilidade das detecções.
Recall (Sensibilidade)	Proporção de verdadeiros positivos entre todas as amostras positivas reais. Mede a capacidade de encontrar todos os casos positivos.
F1-score	Média harmônica entre precisão e recall. Útil para avaliar o desempenho em cenários desbalanceados.
mAP (mean Average Precision)	Média das precisões médias para cada classe. Padrão em tarefas de detecção de objetos.
AUC-ROC	Área sob a curva ROC. Mede a capacidade do modelo de distinguir entre classes em diferentes limiares.
Matriz de Confusão	Tabela que mostra as previsões corretas e incorretas, detalhando verdadeiros/falsos positivos e negativos.

2.5 TRABALHOS RELACIONADOS

A utilização de ferramentas de inteligência artificial para diagnósticos em equipamentos tem se destacado como uma solução promissora no contexto da manutenção preventiva, especialmente diante do aumento da complexidade dos sistemas industriais e da necessidade de maior confiabilidade operacional (SALVI et al., 2021). O avanço tecnológico e a crescente disponibilidade de dados impulsionaram o desenvolvimento de métodos automatizados, tornando o diagnóstico mais eficiente e preciso.

No setor elétrico, particularmente no sistema elétrico de potência, essas soluções têm ganhado relevância devido à criticidade dos ativos e ao impacto direto na continuidade do fornecimento de energia. A detecção precoce de falhas em componentes como isoladores, transformadores e linhas de transmissão é fundamental para evitar interrupções e reduzir custos de manutenção (WANG et al., 2023). O uso de inteligência artificial permite analisar grandes volumes de dados e identificar padrões complexos, superando limitações das abordagens tradicionais.

Diante desse cenário, diversos pesquisadores têm buscado aprimorar os métodos de diagnóstico automatizado, propondo novas técnicas e avaliando o impacto de diferentes

estratégias de processamento de imagens e aprendizado profundo. As próximas subseções apresentam uma revisão dos principais trabalhos relacionados, com o objetivo de contextualizar a importância do tema e caracterizar o estado da arte na área.

2.5.1 Análise Sustentável da Detecção de Falhas em Isoladores Baseada em Otimização Visual Refinada

O primeiro estudo aborda a detecção de falhas em isoladores em linhas de transmissão aéreas, destacando a vulnerabilidade desses componentes a fatores ambientais. A inspeção manual é ineficaz devido ao alto volume de dados e à complexidade dos fundos das imagens, levando à aplicação da rede neural convolucional de atenção regressiva (RA-CNN). O método proposto melhora a acurácia da detecção ao empregar extração de características em múltiplas escalas e operações recursivas, com otimização pelo algoritmo de Enxame de Partículas (PSO). Os resultados indicam que a RA-CNN (1+2+3) atinge 85,3% de acurácia, superando os modelos FCAN e MG-CNN. Além disso, a abordagem proposta demonstra maior eficiência em tempo real, atingindo 25,4 FPS. (WANG et al., 2023)

2.5.2 Detecção de Falhas em Isoladores em Imagens Aéreas de Linhas de Transmissão de Alta Voltagem Baseada em Modelo de Aprendizado Profundo


O segundo estudo foca na detecção de falhas em isoladores por meio de imagens aéreas, utilizando um modelo YOLO modificado, denominado CSPD-YOLO, baseado no YOLO-v3 e na Rede Parcial de Estágio Cruzado. A pesquisa envolve a criação do conjunto de dados 'InSF-detection', composto por 1.331 imagens e 2.104 falhas rotuladas. O modelo CSPD-YOLO se destaca por uma alta acurácia (AP = 98,18%) e eficiência no processamento (0,011 s), superando modelos tradicionais como YOLO-v3 e YOLO-v4. A análise qualitativa indica que o método é eficaz mesmo em cenários complexos, como presença de rios, vegetação e torres de energia. (LIU et al., 2021)

2.5.3 Detecção de Defeitos em Isoladores por Imagem Baseada em Processamento Morfológico e Aprendizado Profundo

O terceiro estudo propõe um método híbrido para detecção de defeitos em isoladores, combinando aprendizado profundo (Faster RCNN) com processamento morfológico. A segmentação das imagens utiliza técnicas de transformação de forma para identifica-

ção e separação de isoladores, enquanto a detecção de falhas é realizada por um modelo matemático aplicado a imagens binárias. O Faster RCNN alcança $AP = 0,9175$ e $recall = 0,98$, superando abordagens baseadas em ResNet, YOLO e LBP+SVM. Além disso, a análise de desempenho em diferentes níveis de voltagem e condições de ruído demonstra a robustez do modelo (ZHANG et al., 2022a). O processo de segmentação realizado no trabalho é apresentado na Figura 14.

Figura 14 – Segmentação de isoladores



Fonte: Zhang et al. (2022a).

2.5.4 Detecção Melhorada de Defeitos em Isoladores Utilizando YOLOv7

O estudo de Zheng et al. (2022) aborda a detecção de defeitos em isoladores utilizando um modelo YOLOv7 modificado por meio de diversas otimizações em sua arqui-

tetura e processo de treinamento. O trabalho foca na detecção de defeitos em imagens com fundos complexos, utilizando um conjunto de dados com 1600 imagens para o experimento.

A abordagem proposta não utiliza aprendizado por transferência, mas sim melhorias diretas no modelo. As principais modificações incluem:


- O uso do algoritmo **K-means++** para gerar caixas de âncora (*anchor boxes*) mais adequadas aos alvos.
- A adição dos módulos **Coordinate Attention (CoordAtt)** e **HorBlock** para aprimorar a extração de características e focar em informações relevantes.
- A implementação da função de perda **SloU** para acelerar a convergência do modelo e da **focal loss** para lidar com o desbalanceamento entre amostras positivas e negativas.

Os resultados demonstram que o modelo melhorado é eficaz na detecção de defeitos pequenos, como *flashovers* por poluição, alcançando uma precisão média (mAP) de 93,8%. Este desempenho supera o modelo YOLOv7 original, bem como outras abordagens como Faster R-CNN e YOLOv5s.

2.5.5 Comparando redes neurais convolucionais e técnicas de pré-processamento para classificação de células HEp-2 em imagens de imunofluorescência

A pesquisa avalia seis estratégias de pré-processamento e cinco arquiteturas de CNNs de última geração para classificar células HEp-2 em imagens de imunofluorescência, uma tarefa crítica em diagnósticos médicos. Métodos como aumento de dados (rotações, espelhamentos), ajuste fino e otimização de hiperparâmetros foram testados em conjunto com arquiteturas como Inception-V3 e ResNet. Surpreendentemente, o melhor desempenho, com 98,28% de precisão, foi alcançado ao treinar o modelo Inception-V3 do zero, utilizando apenas aumento de dados sem pré-processamento adicional. A conclusão sugere que, para esse tipo de imagem, técnicas tradicionais de pré-processamento podem ser menos impactantes quando o aumento de dados é bem implementado, desafiando a necessidade de etapas complexas de preparação. A contribuição do estudo está em mostrar que, em cenários específicos como imagens médicas de imunofluorescência, estratégias simples podem superar abordagens mais elaboradas, oferecendo uma alternativa eficiente para aplicações práticas em classificação (RODRIGUES; NALDI; MARI, 2020). A Figura 15 apresenta os métodos e combinações de pré-processamentos utilizados no trabalho.

Figura 15 – Etapas do método proposto



Fonte: Rodrigues, Naldi e Mari (2020).

2.5.6 Efeitos do pré-processamento de imagens histopatológicas em redes neurais convolucionais

O artigo analisa como diferentes níveis de pré-processamento afetam a classificação de imagens histopatológicas por CNNs, dividindo os dados em quatro categorias: imagens originais, pré-processadas normalmente (com redução de ruído e aprimoramento de células), outras pré-processadas normalmente e excessivamente pré-processadas (com operações morfológicas adicionais). Os experimentos revelam que o pré-processamento normal melhora a precisão ao remover ruídos de fundo e realçar características celulares, mas o excesso de processamento não agrega valor e pode até degradar o desempenho ao eliminar informações úteis. A conclusão enfatiza a importância de um equilíbrio no pré-processamento, recomendando ajustes moderados para maximizar a eficácia das CNNs em imagens histopatológicas. A contribuição do trabalho é fornecer uma análise comparativa detalhada que orienta pesquisadores e profissionais na escolha de técnicas de pré-processamento, evitando exageros que comprometam a qualidade dos dados em aplicações médicas (ÖZTÜRK; AKDEMİR, 2018).

2.5.7 O impacto de técnicas de pré-processamento e pós-processamento de imagens em frameworks de aprendizado profundo: uma revisão abrangente para análise de imagens de patologia digital

Este trabalho explora como técnicas tradicionais de pré- e pós-processamento de imagens, como redução de ruído, correção de iluminação e segmentação, melhoram o desempenho de redes neurais em tarefas de patologia digital, incluindo classificação (tecido saudável vs. canceroso), detecção (contagem de linfócitos) e segmentação (núcleos e glândulas). Ao analisar uma ampla gama de estudos, os autores concluem que essas técnicas são indispensáveis para lidar com a variabilidade e complexidade das imagens médicas, melhorando significativamente a precisão e a robustez dos modelos de aprendizado profundo. A revisão destaca que o pós-processamento, como refinamento de contornos, também desempenha um papel crucial em tarefas de segmentação. A contribuição do artigo está em consolidar evidências sobre a eficácia dessas abordagens, oferecendo um guia abrangente para pesquisadores que buscam integrar métodos tradicionais ao treinamento de redes neurais, especialmente em contextos de patologia digital onde a qualidade dos dados é crítica (SALVI et al., 2021).

2.5.8 Resumo dos Trabalhos

Diversos estudos abordam o impacto do pré-processamento de imagens na análise por redes neurais convolucionais (CNNs) e outros modelos de aprendizado profundo. O estudo de Liu et al. (2021) e Wang et al. (2023) optam por não realizar processamentos significativos, utilizando apenas redimensionamento e normalização.

Por outro lado, Öztürk e Akdemir (2018) investigam diferentes algoritmos de pré-processamento, incluindo remoção de fundo, filtros de suavização e equalização de histograma, além de um método de sobre-processamento baseado em limiar adaptativo. Rodrigues, Naldi e Mari (2020) testam técnicas como redimensionamento, alongamento de contraste, equalização de histograma e subtração da média, constatando que o uso de imagens originais favorece o desempenho da CNN, enquanto o data augmentation tem impacto positivo. Salvi et al. (2021) destacam que técnicas como remoção de artefatos, normalização de cor e seleção de patches melhoram a precisão dos modelos e reduzem o tempo computacional. Por fim, Zhang et al. (2022a) exploram a segmentação de isoladores para otimizar a classificação.

2.5.9 Justificativa da Relevância da Metodologia Proposta

Os trabalhos analisados demonstram a importância do pré-processamento na análise de imagens, mas também indicam que determinadas abordagens podem comprometer o desempenho da CNN. Em especial, Rodrigues, Naldi e Mari (2020) evidenciam que a eliminação de ruídos e artefatos pode não ser sempre benéfica. Além disso, Salvi et al. (2021) reforçam que técnicas de segmentação e normalização podem aprimorar a análise quando aplicadas corretamente. No entanto, nenhum dos estudos analisados aborda a metodologia específica proposta nesta dissertação, o que destaca sua inovação e potencial contribuição para a área.

2.5.10 Tabela Comparativa dos Trabalhos

A tabela 3 compara os resultados de diferentes estudos sobre pré-processamento de imagens e seu impacto nos modelos de classificação de imagens. Os estudos variam desde melhorias no desempenho até riscos de sobre-processamento, destacando a falta de consenso e a necessidade de novas abordagens. A metodologia proposta neste trabalho busca preencher essa lacuna ao introduzir um método inovador para determinar os processamentos mais eficientes e otimizar os parâmetros de processamento, oferecendo uma solução mais robusta e adaptável para análise de imagens.

Trabalho	Resultado do pré-processamento
Liu et al. (2021)	Sem impacto significativo
Öztürk e Akdemir (2018)	Melhorou contraste, mas risco de sobre-processamento
Rodrigues, Naldi e Mari (2020)	Afetou negativamente a CNN; data augmentation foi positivo
Salvi et al. (2021)	Melhorou precisão e reduziu tempo computacional
Wang et al. (2023)	Sem impacto significativo
Zhang et al. (2022a)	Melhorou o desempenho do modelo
Zheng et al. (2022)	Aumento de dados e aprendizado por transferência melhoraram detecção
Zou et al. (2024)	Aprendizado por transferência eficaz para defeitos em parafusos

Tabela 3 – Comparação dos trabalhos relacionados

A análise desses estudos reforça a lacuna existente na literatura e a necessidade de uma nova abordagem, como a metodologia proposta nesta dissertação. A proposta de um método para determinar os processamentos mais eficientes e otimizar os parâmetros de processamento representa uma contribuição significativa para a área de análise de imagens. Através da combinação de técnicas de pré-processamento adaptativo e otimização de parâmetros, o trabalho busca não apenas melhorar o desempenho dos modelos de aprendizado profundo, mas também oferecer uma solução prática e eficiente para cenários complexos. Essa abordagem pode impactar positivamente diversas áreas, como diagnós-

tico médico, inspeção industrial e análise de imagens aéreas, ao proporcionar resultados mais precisos e confiáveis. Além disso, a metodologia proposta pode servir como base para futuras pesquisas e aplicações em diferentes contextos, ampliando as possibilidades de utilização das redes neurais em tarefas desafiadoras de classificação e detecção de objetos em imagens.

2.5.11 Considerações sobre os trabalhos relacionados

A metodologia apresentada neste trabalho se diferencia dos estudos revisados ao introduzir um novo enfoque que não foi explorado anteriormente. Enquanto os trabalhos existentes se concentram em construção de modelos de redes neurais e utilização de técnicas tradicionais de pré-processamento e normalização, a metodologia deste trabalho propõe a criação de um método para determinar os processamentos mais eficientes das imagens, além de um método de otimização dos parâmetros de processamento. Além disso, a pesquisa busca integrar novas abordagens que possam aprimorar a análise de dados em contextos variados, contribuindo para a evolução das técnicas de aprendizado profundo. A implementação dessas novas abordagens poderá oferecer insights valiosos para futuras investigações e aplicações práticas.

2.6 CONSIDERAÇÕES FINAIS DO CAPÍTULO

Neste capítulo, foram apresentados os principais conceitos e técnicas de processamento de imagens, redes neurais, estratégias para lidar com escassez e desbalanceamento de dados, as métricas de avaliação de desempenho de modelos e os trabalhos relacionados aplicados à detecção de falhas em linhas de transmissão. A revisão evidenciou que o uso de métodos avançados de processamento de imagens e aprendizado profundo é fundamental para garantir a confiabilidade e eficiência do Sistema Elétrico de Potência, especialmente em cenários desafiadores, como a inspeção de grandes extensões e a identificação de defeitos raros.

A escolha adequada das técnicas de pré-processamento, arquitetura de redes neurais e estratégias para tratar limitações dos datasets impacta diretamente na robustez e precisão dos modelos desenvolvidos. Além disso, a seleção criteriosa das métricas de avaliação permite uma análise mais completa do desempenho, especialmente em situações de desbalanceamento entre classes.


Portanto, o domínio desses conceitos é essencial para o desenvolvimento de soluções inovadoras e eficazes na área de inspeção automatizada de linhas de transmissão, contribuindo para a segurança, confiabilidade e continuidade do fornecimento de energia

elétrica. O próximo capítulo irá detalhar a metodologia proposta para aprimoramento dos processamentos e avaliação dos modelos, consolidando os fundamentos discutidos nesta revisão.

3 METODOLOGIA

A metodologia proposta neste estudo tem como objetivo desenvolver um procedimento sistemático para comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem aplicadas à detecção e classificação de falhas em cadeias de isoladores. Em uma visão geral, o processo é estruturado, iterativo e modular, organizado nas etapas principais apresentadas no fluxograma da Figura 16.

Figura 16 – Fluxograma geral da metodologia, integrando todas as etapas principais




Fonte: Autor.

Conforme a Figura 16, o fluxo parte do bloco “Início” e percorre, em sequência, as etapas de “Seleção e validação do dataset”, “Pré-processamento”, “Ajuste de parâmetros”, “Escolha e construção do modelo” e “Treinamento”, até a “Avaliação e ajustes”, encerrando em “Conclusões e recomendações”. O caráter iterativo é dado pelos ciclos de “Avaliação e ajustes”, que retroalimentam as fases de “Pré-processamento” e de “Escolha e construção do modelo”, permitindo o refinamento contínuo das técnicas e dos parâmetros a cada iteração. A divisão em módulos facilita a identificação e a correção de problemas em cada

etapa de forma isolada, sem comprometer o restante do processo.

Cada uma dessas etapas principais desdobra-se em um conjunto de operações e decisões, detalhado no fluxograma da Figura 17, no qual os blocos individuais aparecem agrupados segundo as etapas do fluxo geral apresentado na Figura 16.

Figura 17 – Fluxograma detalhado da metodologia de processamento de imagens



Fonte: Autor.

Nas seções seguintes, cada etapa do fluxo geral é detalhada individualmente, com o respectivo fluxograma, da definição das métricas e da preparação dos dados às estratégias de aprimoramento e à avaliação final dos resultados.

3.1 INÍCIO E DEFINIÇÃO DE MÉTRICAS

Esta seção trata do ponto de partida da metodologia, correspondente ao bloco “Início” do fluxo geral (Figura 16), incluindo a inicialização do ambiente e a definição das métricas utilizadas para avaliar o desempenho ao longo do processo.

3.1.1 Início


O bloco “Início” corresponde ao ponto de partida da metodologia. Sua função é inicializar o ambiente computacional e os recursos necessários, garantindo que as ferramentas de software e as bibliotecas utilizadas estejam configuradas e acessíveis antes das etapas de definição de métricas, coleta e processamento dos dados. Embora simples, essa etapa contribui para a organização do fluxo de trabalho e para a reprodutibilidade do experimento.

A dificuldade dessa etapa é baixa, limitando-se à configuração inicial do projeto. Eventuais erros, como falhas na inicialização de bibliotecas ou na alocação de recursos, são tratados pela verificação das dependências de software, da compatibilidade de versões e da adequação do hardware, como a disponibilidade de GPUs para acelerar o treinamento. A conclusão dessa etapa é pré-requisito para todas as demais.

3.2 SELEÇÃO E VALIDAÇÃO DO DATASET

Esta seção detalha a etapa “Seleção e validação do dataset” do fluxo geral (Figura 16), descrevendo a seleção, a validação e a preparação dos dados que servem de base para a metodologia. O fluxograma dessa etapa é apresentado na Figura 18 e cobre desde a definição das métricas até o balanceamento dos dados.

Figura 18 – Fluxograma da etapa de seleção e validação do dataset



Fonte: Autor.

3.2.1 Definir métricas: acurácia, F1-score, tempo

O bloco “Definir métricas: acurácia, F1-score, tempo” estabelece os critérios objetivos de avaliação que orientam o processo. Nessa etapa são especificadas as métricas

usadas para medir o desempenho das diferentes combinações de técnicas de processamento e de arquiteturas de modelo. Definir essas métricas previamente é importante porque elas orientam as decisões posteriores, da seleção das técnicas de pré-processamento à escolha dos modelos.

As três métricas adotadas (acurácia, F1-score e tempo de processamento) fornecem uma visão abrangente do desempenho do sistema. A acurácia oferece uma medida geral de correção das predições; o F1-score é particularmente útil em datasets desbalanceados, por combinar precisão e recall; e o tempo de processamento é relevante em aplicações práticas nas quais a eficiência computacional é crítica, como na inspeção automatizada de linhas de transmissão.

A dificuldade dessa etapa é baixa, de caráter essencialmente conceitual e de planejamento. Os principais riscos são a escolha de métricas inadequadas ao problema ou a omissão de métricas relevantes; nesses casos, os critérios são revistos ao longo do desenvolvimento, mantendo a coerência com os objetivos do estudo. Essa etapa estabelece as bases quantitativas para as comparações realizadas nas fases seguintes.

3.2.2 Selecionar dataset com imagens rotuladas

A etapa “Selecionar dataset com imagens rotuladas” é uma das que mais impactam a qualidade e a confiabilidade dos resultados. Nessa fase escolhe-se um conjunto de dados adequado, com imagens de cadeias de isoladores e anotações que indiquem a presença ou a ausência de falhas. O dataset deve apresentar diversidade suficiente em condições de iluminação, ângulos de captura, tipos de isoladores e variações de falhas, de modo a favorecer a capacidade de generalização dos modelos.

A qualidade, a quantidade e a diversidade dos dados influenciam diretamente o desempenho e a generalização dos modelos de aprendizado de máquina; sem dados adequados e bem rotulados, o processamento subsequente fica comprometido. Como observa Shorten e Khoshgoftaar (2019), a robustez de um modelo depende da riqueza de seu conjunto de treinamento.

A dificuldade dessa etapa pode ser alta, devido à escassez de datasets públicos específicos para detecção de falhas em isoladores e à necessidade de anotação manual precisa. Caso o dataset selecionado se mostre inadequado, as alternativas incluem a busca por outros datasets, a combinação de múltiplos conjuntos ou a construção de um dataset próprio por meio da coleta e da anotação manual de imagens.

3.2.3 Dataset está balanceado?

O bloco de decisão “Dataset está balanceado?” verifica se as classes de interesse (isoladores com falha e sem falha) estão adequadamente representadas no dataset. Essa verificação identifica desbalanceamentos que poderiam comprometer o treinamento, levando o modelo a favorecer a classe majoritária.

O balanceamento é especialmente relevante na detecção de falhas, em que costuma haver muito mais amostras de isoladores saudáveis do que defeituosos. Segundo He e Garcia (2009), essa assimetria pode gerar modelos enviesados, com alta acurácia geral, mas baixa capacidade de detectar as falhas, que são o objetivo principal do sistema.

A dificuldade dessa etapa é baixa e envolve principalmente a análise estatística da distribuição das classes. Se o dataset estiver desbalanceado, o fluxo segue para a aplicação de filtros e balanceamento; caso contrário, prossegue diretamente para o pré-processamento.

3.2.4 Aplicar filtros e balanceamento

O bloco “Aplicar filtros e balanceamento” é executado quando o dataset está desbalanceado e implementa estratégias para corrigir a distribuição entre as classes. Entre elas estão a reamostragem (sobreamostragem da classe minoritária, por duplicação ou por técnicas como SMOTE, ou subamostragem da classe majoritária), o uso de pesos diferenciados na função de perda e o data augmentation focado na classe minoritária.


Essa etapa é importante porque o desbalanceamento pode comprometer a capacidade do modelo de detectar falhas, que costumam ser a classe minoritária, embora a mais relevante na prática. A aplicação de filtros também pode incluir a remoção de amostras de baixa qualidade ou de outliers que prejudicariam o treinamento.

A dificuldade dessa etapa varia de média a alta, conforme o grau de desbalanceamento e as técnicas escolhidas. Se as técnicas de balanceamento não forem eficazes, as alternativas incluem outros métodos de balanceamento, a revisão dos critérios de qualidade das amostras ou a busca por dados adicionais da classe minoritária.

3.3 PRÉ-PROCESSAMENTO

Esta seção detalha a etapa “Pré-processamento” do fluxo geral (Figura 16), que abrange os processamentos de imagens voltados a otimizar os dados de entrada para melhorar o desempenho dos modelos de rede neural. O fluxograma da Figura 19 ilustra as decisões e operações dessa fase.

Figura 19 – Fluxograma da etapa de pré-processamento



Fonte: Autor.

3.3.1 Aplicar técnicas básicas: normalização, recorte, ruído

No bloco “Aplicar técnicas básicas: normalização, recorte, ruído”, as imagens passam por processamentos essenciais ao desempenho dos modelos. Entre eles estão a normalização (padronização dos valores de pixel para escalas como [0,1] ou Z-score) (SHARMA et al., 2024), o redimensionamento e o recorte (ajuste das imagens às dimensões de entrada do modelo e extração de regiões de interesse) (SHARMA et al., 2024) e a redução de ruído (com filtros como o de mediana ou o gaussiano) (SHARMA et al., 2024).

Conforme Sharma et al. (2024), essas operações “melhoram a qualidade das imagens, mas também garantem que os modelos sejam mais robustos e capazes de genera-

lizar em diferentes condições”. A normalização favorece a convergência estável durante o treinamento, enquanto o recorte adequado direciona a atenção do modelo para as regiões mais relevantes da imagem.

A dificuldade dessa etapa é baixa a média, pois são técnicas bem estabelecidas na literatura. Se o desempenho do modelo piorar após a aplicação dessas técnicas, revisam-se os parâmetros ou a ordem de aplicação em busca de um equilíbrio adequado.

3.3.2 Aplicar data augmentation

O bloco “Aplicar data augmentation” expande artificialmente o dataset por meio de transformações que preservam as características essenciais das imagens, mas introduzem variabilidade capaz de melhorar a generalização do modelo. Entre as transformações usuais estão rotações, espelhamentos, ajustes de brilho e contraste, mudanças de escala e translações, que simulam diferentes condições de captura.

O data augmentation é especialmente útil quando o dataset é limitado ou desbalanceado, por aumentar o número de amostras disponíveis para treinamento. Como aponta Shorten e Khoshgoftaar (2019), técnicas de aumento de dados são importantes para a robustez de modelos de aprendizado profundo.

A dificuldade dessa etapa é baixa a média, mas exige cuidado para não aplicar transformações que alterem características importantes para a detecção de falhas. Se o data augmentation degradar o desempenho, revisam-se os tipos e as intensidades das transformações.

3.3.3 Combinar técnicas?

O bloco de decisão “Combinar técnicas?” define se múltiplas técnicas de processamento serão aplicadas em sequência, formando um pipeline mais elaborado. A decisão é estratégica: combinar técnicas pode produzir ganhos, mas também introduzir complexidade desnecessária ou degradar a qualidade da imagem.

A decisão baseia-se nos resultados preliminares das técnicas aplicadas isoladamente e no conhecimento de domínio sobre quais combinações tendem a ser benéficas. Por exemplo, aplicar redução de ruído seguida de aumento de nitidez pode gerar imagens mais adequadas à detecção de defeitos.

A dificuldade dessa etapa é baixa, por se tratar de uma decisão estratégica. Se a decisão for por combinar técnicas, o fluxo segue para a geração dos pipelines combinados; caso contrário, as técnicas são usadas de forma isolada.

3.3.4 Gerar pipeline de técnicas combinadas

O bloco “Gerar pipeline de técnicas combinadas” é executado quando se opta por explorar a sinergia entre diferentes técnicas de processamento. Nessa etapa criam-se sequências de processamentos, nas quais a saída de uma técnica serve de entrada para a próxima, em busca de um efeito cumulativo superior ao de cada técnica isolada.

Um pipeline pode consistir, por exemplo, em: normalização, redução de ruído, ajuste de contraste e aumento de nitidez. A ordem das operações é importante, pois sequências diferentes produzem resultados distintos.

A dificuldade dessa etapa varia de média a alta, sobretudo pela grande quantidade de combinações possíveis e pela necessidade de identificar as sequências mais eficazes. Um risco comum é criar combinações que introduzam artefatos ou degradem a imagem. Se as combinações não trouxerem melhorias, exploram-se outras ordens de aplicação ou revisa-se a seleção de técnicas.

3.3.5 Usar técnicas isoladas

O bloco “Usar técnicas isoladas” é executado quando se opta por não combinar técnicas, aplicando e avaliando cada processamento de forma independente. Essa abordagem é mais simples e permite avaliar com clareza o impacto individual de cada técnica, o que facilita identificar quais processamentos são mais eficazes para o problema.


Cada técnica é aplicada, avaliada e comparada individualmente, o que estabelece um benchmark do desempenho de cada abordagem. A estratégia é útil nas fases iniciais do desenvolvimento, quando se busca compreender o efeito de cada processamento.

A dificuldade dessa etapa é baixa, por ser uma abordagem direta. O sucesso é avaliado comparando o desempenho do modelo com cada técnica aplicada individualmente ao desempenho de referência, sem processamento.

3.4 AJUSTE DE PARÂMETROS

Esta seção detalha a etapa “Ajuste de parâmetros” do fluxo geral (Figura 16), dedicada à otimização automática dos parâmetros das técnicas de processamento de imagem. O fluxograma da Figura 20 apresenta o fluxo de ajuste automático dos parâmetros.

Figura 20 – Fluxograma da etapa de ajuste de parâmetros



Fonte: Autor.

3.4.1 Otimizar parâmetros com busca automática

O bloco “Otimizar parâmetros com busca automática” substitui a otimização manual, muitas vezes inviável, pelo uso de algoritmos que buscam os valores adequados dos parâmetros das técnicas de processamento avaliadas. Esses parâmetros podem incluir, por exemplo, a intensidade de um filtro de desfoque, o limiar de um ajuste de contraste, os parâmetros de técnicas de redução de ruído ou os fatores de data augmentation.

O objetivo é otimizar os resultados dos processamentos sem exigir intervenção manual extensa. A automação acelera o processo e pode revelar configurações difíceis de identificar de forma heurística. Métodos como busca em grade (grid search), busca aleatória (random search), otimização bayesiana, algoritmos genéticos e otimização por enxame de partículas podem ser empregados conforme a complexidade do espaço de parâmetros.


A dificuldade dessa etapa pode ser alta, pois envolve a escolha e a implementação de algoritmos de otimização apropriados e a definição de um espaço de busca adequado. Um risco comum é a convergência para ótimos locais ou o tempo computacional proibitivo. Se o ajuste automático não produzir melhorias significativas, pode-se alterar o algoritmo de otimização, redefinir as faixas de valores dos parâmetros ou adotar critérios de parada mais adequados.

O sucesso é avaliado de forma quantitativa: a melhora nas métricas de desempenho após a aplicação dos parâmetros otimizados indica que o processo foi eficaz. Essa etapa está diretamente ligada ao objetivo específico de criar um método de ajuste automático de parâmetros dos processamentos de imagem.

3.5 ESCOLHA E CONSTRUÇÃO DO MODELO

Esta seção detalha a etapa “Escolha e construção do modelo” do fluxo geral (Figura 16), que trata da seleção e da configuração das arquiteturas de rede neural utilizadas para avaliar a eficácia das técnicas de processamento de imagem. O fluxograma da Figura 21 ilustra as decisões envolvidas na escolha e na montagem do modelo.

Figura 21 – Fluxograma da etapa de escolha e construção do modelo



Fonte: Autor.

3.5.1 Selecionar modelo: CNN, ResNet, YOLO

No bloco “Selecionar modelo: CNN, ResNet, YOLO” define-se a arquitetura de rede neural usada para avaliar o impacto das técnicas de processamento. A seleção baseia-se na natureza da tarefa (classificação, detecção ou regressão) e nas características do problema de detecção de falhas em isoladores.

As opções cobrem diferentes abordagens: CNNs convencionais, para classificação básica; ResNet, para problemas que requerem redes mais profundas; e YOLO, para detecção de objetos em tempo real. A escolha da arquitetura é importante, pois diferentes tipos de rede possuem princípios de funcionamento e aplicações distintas.

A dificuldade dessa etapa é relativamente baixa, por se tratar de uma decisão estratégica baseada nos requisitos do problema. Ainda assim, uma escolha inadequada pode comprometer os resultados. Se a arquitetura selecionada não apresentar o desempenho esperado, reavalia-se a escolha à luz das características dos dados e dos objetivos da

aplicação.

3.5.2 Tipo de tarefa

O bloco de decisão “Tipo de tarefa” direciona a configuração do modelo selecionado, influenciando aspectos como a função de perda, as métricas de avaliação e a estrutura das camadas finais da rede.

As três opções são: classificação (determinar se um isolador possui falha), detecção (localizar e classificar falhas nas imagens) e regressão (predizer valores contínuos relacionados ao grau de degradação). Cada tarefa exige configurações e métricas de avaliação específicas.

A dificuldade dessa etapa é baixa, por se tratar de uma decisão conceitual baseada nos objetivos do estudo. A escolha correta é essencial para configurar o modelo de forma adequada ao problema.

3.5.3 Montar modelo de classificação

O bloco “Montar modelo de classificação” é executado quando a tarefa é a classificação. Nessa etapa configura-se uma rede neural para classificar imagens de isoladores em categorias discretas (por exemplo, “com falha” e “sem falha” ou diferentes tipos de falha).

A configuração inclui a definição das camadas finais com um número de neurônios igual ao número de classes, a escolha de funções de ativação apropriadas (como a softmax, na classificação multiclasse) e a seleção de funções de perda adequadas (como a entropia cruzada). Também envolve a definição das métricas de avaliação relevantes, como acurácia, precisão, recall e F1-score.

Nesse tipo de modelo, a função de perda usualmente adotada é a entropia cruzada categórica, definida pela Equação 3.1:

$$L_{\text{class}} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}) \quad (3.1)$$

em que N é o número de amostras, C o número de classes, $y_{i,c}$ o rótulo verdadeiro (igual a 1 se a amostra i pertence à classe c e 0 caso contrário) e $\hat{y}_{i,c}$ a probabilidade prevista de a amostra i pertencer à classe c .

A dificuldade dessa etapa é média e exige conhecimento sobre arquiteturas de rede neural para classificação. Se o modelo não apresentar desempenho satisfatório, ajustam-se a arquitetura ou os hiperparâmetros, ou revisa-se o pré-processamento dos dados.

3.5.4 Montar modelo de detecção

O bloco “Montar modelo de detecção” é executado quando a tarefa é a detecção de objetos. Nessa etapa configura-se um modelo capaz não apenas de classificar a presença de falhas, mas também de localizá-las espacialmente, fornecendo coordenadas de bounding boxes ou máscaras de segmentação.

Essa configuração é mais complexa e envolve arquiteturas especializadas como YOLO e R-CNN. Inclui a definição de hiperparâmetros, a configuração de múltiplas escalas e o equilíbrio entre precisão de localização e de classificação. Entre as métricas de avaliação estão o mAP (mean Average Precision) e o IoU (Intersection over Union).

Nesse tipo de modelo, a função de perda é composta, combinando a perda de localização das bounding boxes, a perda de confiança (presença ou ausência de objeto) e a perda de classificação, conforme a Equação 3.2:

$$L_{\text{det}} = \lambda_{\text{loc}} L_{\text{loc}} + \lambda_{\text{conf}} L_{\text{conf}} + \lambda_{\text{cls}} L_{\text{cls}} \quad (3.2)$$

em que L_{loc} , L_{conf} e L_{cls} são, respectivamente, as perdas de localização, de confiança e de classificação, e λ_{loc} , λ_{conf} e λ_{cls} são pesos que equilibram a contribuição de cada termo.

A dificuldade dessa etapa é alta, dada a complexidade das arquiteturas de detecção e a necessidade de dados rotulados com informações de localização. Se o desempenho não for satisfatório, ajustam-se os hiperparâmetros, modificam-se os limiares de confiança ou revisa-se a estratégia de aumento de dados.

3.5.5 Montar modelo de regressão

O bloco “Montar modelo de regressão” é executado quando a tarefa é a regressão. Nessa etapa configura-se um modelo capaz de prever valores contínuos relacionados ao estado dos isoladores, como o grau de degradação, a probabilidade de falha ou índices de severidade.

A configuração inclui camadas finais com ativação linear (ou outra apropriada a saídas contínuas), funções de perda para regressão (como MSE ou MAE) e métricas de avaliação como R^2 , RMSE ou MAE. Essa abordagem pode ser útil quando se deseja uma avaliação mais detalhada do estado dos isoladores.

Nesse tipo de modelo, a função de perda mais comum é o erro médio quadrático (MSE), definido pela Equação 3.3:

$$L_{\text{reg}} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (3.3)$$


em que N é o número de amostras, y_i o valor real e $\hat{y}_i$ o valor previsto pelo modelo.

A dificuldade dessa etapa é média, semelhante à da classificação, mas com considerações específicas para saídas contínuas. Se as previsões não forem adequadas, normalizam-se as variáveis de saída, ajusta-se a função de perda ou modifica-se a arquitetura da rede.

3.6 TREINAMENTO

Esta seção detalha a etapa “Treinamento” do fluxo geral (Figura 16), referente ao treinamento dos modelos de rede neural com os dados processados. O fluxograma da Figura 22 apresenta as atividades dessa etapa.

Figura 22 – Fluxograma da etapa de treinamento



Fonte: Autor.

3.6.1 Treinar modelo com dados processados

O bloco “Treinar modelo com dados processados” é a etapa central de aprendizado do sistema. Nela, a arquitetura previamente selecionada e configurada é treinada com os dados resultantes das etapas de processamento de imagem. O objetivo é que o modelo aprenda a identificar e a classificar as falhas nas imagens de isoladores, ajustando seus pesos de modo a minimizar a função de custo e a otimizar as métricas de desempenho definidas.

Como explica Soares e Silva (2011), o treinamento é a etapa em que o neurônio artificial aprende a associar entradas a saídas desejadas. Além de detectar falhas, os modelos treinados também servem para avaliar o impacto dos diferentes processamentos aplicados nas etapas anteriores.

O treinamento consiste em alimentar a rede com as imagens processadas, calcular o erro entre as previsões e os rótulos verdadeiros e atualizar os pesos por retropropagação. Durante o processo, é importante monitorar métricas como a função de custo e a

acurácia de treinamento e de validação, a fim de identificar problemas como overfitting ou underfitting.


A dificuldade dessa etapa pode ser alta, dada a complexidade do treinamento de redes neurais. Entre os desafios estão a otimização de hiperparâmetros (taxa de aprendizado, tamanho do batch e número de épocas), o gerenciamento de recursos computacionais (tempo de processamento e memória de GPU) e a mitigação do sobreajuste. Se o modelo não convergir, apresentar baixo desempenho ou sobreajuste, pode-se modificar os hiperparâmetros, adotar outros otimizadores (como Adam ou RMSProp), aplicar técnicas de regularização (como dropout) ou revisar a arquitetura da rede.

A redução progressiva da função de custo e o aumento das métricas de desempenho (acurácia, F1-score e tempo de processamento) nos conjuntos de validação e teste indicam que o modelo está aprendendo de forma eficaz. Essa etapa está alinhada ao objetivo de construir modelos de rede neural para avaliar o desempenho das técnicas de processamento de imagem.

3.7 AVALIAÇÃO E AJUSTES

Esta seção detalha a etapa “Avaliação e ajustes” do fluxo geral (Figura 16), que trata da avaliação dos resultados e dos mecanismos de ajuste que permitem a melhoria iterativa da metodologia, incluindo o ciclo de retroalimentação que retorna às etapas anteriores. O fluxograma da Figura 23 ilustra o ciclo de avaliação e ajustes.

Figura 23 – Fluxograma da etapa de avaliação e ajustes



Fonte: Autor.

3.7.1 Avaliar com as métricas definidas

No bloco “Avaliar com as métricas definidas”, o desempenho do sistema é quantificado com as métricas estabelecidas no início da metodologia: acurácia, F1-score e tempo de processamento. Essas métricas são calculadas e analisadas para fornecer uma visão do desempenho do modelo treinado.

A acurácia oferece uma medida geral de correção das predições; o F1-score é particularmente útil em datasets desbalanceados, por combinar precisão e recall; e o tempo de

processamento é relevante em aplicações práticas nas quais a eficiência computacional é crítica, como na inspeção automatizada de linhas de transmissão. Em tarefas de detecção de objetos, métricas adicionais como o mAP (mean Average Precision) também podem ser empregadas.

A dificuldade dessa etapa é moderada e reside sobretudo na interpretação correta das métricas em diferentes contextos, especialmente diante de datasets desbalanceados. O objetivo é fornecer uma avaliação abrangente da detecção e da classificação das falhas, considerando que falsos negativos (falhas não detectadas) podem ter consequências graves em aplicações industriais.

3.7.2 Desempenho satisfatório?

O bloco de decisão “Desempenho satisfatório?” verifica se os resultados atendem aos critérios de sucesso estabelecidos. A decisão baseia-se nos valores das métricas definidas (acurácia, F1-score e tempo) comparados a limiares ou benchmarks predefinidos.

Pode-se estabelecer, por exemplo, que o sistema deve atingir acurácia mínima de 95%, F1-score superior a 0,90 na detecção de falhas e tempo de processamento inferior a 100 ms por imagem. Essa decisão determina se o processo prossegue com ajustes (quando o desempenho é insuficiente) ou avança para a fase de comparação e conclusão.

A dificuldade dessa etapa é baixa, por ser uma decisão baseada em critérios objetivos. É fundamental, contudo, que esses critérios sejam bem definidos e realistas, para evitar ciclos de otimização indefinidos ou conclusões prematuras.

3.7.3 Ajustar processamentos e modelo

O bloco “Ajustar processamentos e modelo” é executado quando o desempenho é insuficiente e implementa o refinamento iterativo. Nessa etapa revisam-se tanto as técnicas de processamento de imagem quanto os parâmetros do modelo em busca de melhores resultados.

Os ajustes podem incluir a revisão das técnicas de pré-processamento, a modificação dos parâmetros otimizados, a exploração de novas combinações de técnicas, o ajuste fino dos hiperparâmetros do modelo ou a seleção de outra arquitetura. Essa etapa é o mecanismo de retroalimentação que permite à metodologia adaptar-se aos resultados obtidos.

A dificuldade dessa etapa varia de média a alta, conforme a extensão dos ajustes. Um risco comum é fazer modificações excessivas que comprometam o aprendizado anterior. Se os ajustes sucessivos não trouxerem melhorias, pode ser necessária uma re-

visão mais ampla da abordagem, incluindo a reconsideração dos dados, da arquitetura do modelo ou dos próprios critérios de sucesso.

3.7.4 Comparar diferentes modelos e técnicas

O bloco “Comparar diferentes modelos e técnicas” é executado quando o desempenho é satisfatório e permite uma análise comparativa dos resultados obtidos com diferentes configurações. Nessa etapa consolidam-se e comparam-se os resultados de todas as combinações de técnicas de processamento, parâmetros otimizados e arquiteturas de modelo avaliadas ao longo da metodologia.

Essa análise é importante para identificar quais estratégias são mais eficazes, em que condições e por quê. Inclui a comparação das métricas de desempenho, a análise dos compromissos entre acurácia e velocidade, a identificação de técnicas complementares e o registro das observações sobre a interação entre processamentos e arquiteturas.

A dificuldade dessa etapa varia de média a alta e exige análise criteriosa e conhecimento de estatística para comparações significativas. O resultado esperado são conclusões claras sobre as abordagens mais eficazes e recomendações práticas para implementação.

3.7.5 Conclusões e recomendações

O bloco “Conclusões e recomendações” é a etapa final da metodologia, na qual o conhecimento obtido é consolidado em conclusões e recomendações práticas. Nessa etapa sintetizam-se os principais achados do estudo, como as técnicas de processamento mais eficazes, as melhores combinações, o impacto das diferentes arquiteturas e as métricas de desempenho alcançadas.

As conclusões devem basear-se nas evidências empíricas obtidas ao longo da metodologia, e as recomendações devem fornecer diretrizes práticas para implementação em cenários reais, incluindo as melhores práticas identificadas, as limitações observadas e sugestões de pesquisas futuras.

A dificuldade dessa etapa é moderada e exige clareza na comunicação, capacidade de síntese e rigor na interpretação dos resultados. O resultado esperado são conclusões completas e recomendações úteis para futuras implementações do sistema de detecção de falhas em isoladores.

4 COLETA E ANÁLISE DE RESULTADOS

Este capítulo apresenta os resultados obtidos com a aplicação da metodologia proposta. Inicia-se com a avaliação do impacto de diferentes técnicas de pré-processamento no desempenho de uma CNN e segue com a otimização de parâmetros de pré-processamento por busca em grade e por busca aleatória. Ao final, apresentam-se experimentos adicionais em que a mesma varredura de pré-processamentos é repetida com arquiteturas da família YOLO, de modo a verificar em que medida os resultados obtidos dependem do modelo empregado.

4.1 AVALIAÇÃO DE TÉCNICAS DE PRÉ-PROCESSAMENTO EM REDES NEURAIS CONVOLUCIONAIS PARA CLASSIFICAÇÃO DE IMAGENS

Esta seção descreve a avaliação conduzida para medir o impacto de diferentes técnicas de pré-processamento de imagens no desempenho de um modelo baseado em Redes Neurais Convolucionais (CNN). O estudo utilizou dois conjuntos de dados voltados à inspeção de infraestrutura elétrica (CPLID e DRNPW), com o objetivo de avaliar a eficácia de diferentes transformações visuais na classificação de falhas e componentes.

A avaliação seguiu uma sequência estruturada: pré-processamento das imagens em resolução de 512×512 pixels, modelagem por CNN, predição e extração de métricas quantitativas.

4.1.1 Conjuntos de Dados Avaliados

A avaliação utilizou dois conjuntos de dados voltados ao monitoramento e à detecção de anomalias em isoladores de redes de transmissão:

1. **CPLID (*Chinese Power Line Insulator Dataset*)**: conjunto de imagens de isoladores elétricos, anotados como normais ou defeituosos. O desafio consiste em identificar corretamente os isoladores com quebras ou anomalias físicas na estrutura.
2. **DRNPW**: conjunto de dados disponibilizado pela CPFL, composto por imagens capturadas por drones e voltado à identificação de aspectos específicos da infraestrutura. As imagens foram anotadas e categorizadas com base nos recortes visuais de interesse.

4.1.2 Arquitetura do Modelo

Para garantir uma avaliação uniforme, foi implementada uma CNN clássica padronizada, o que permitiu isolar a variável independente do estudo (o pré-processamento). A arquitetura adotada é a seguinte:

- **Entrada:** tensores com dimensões definidas conforme as imagens processadas.
- **Camadas de extração de características:** duas camadas convolucionais com 32 filtros (janelas 3×3) e ativação *Rectified Linear Unit* (ReLU), seguidas por redução espacial com *Max-Pooling* (janelas 4×4).
- **Camadas densas:** achatamento vetorial (*Flatten*), seguido de uma camada densa com 8 unidades ocultas (ativação ReLU) e uma camada de saída com ativação *Soft-max*, dimensionada conforme o número de rótulos de cada *dataset*.

A otimização dos pesos foi feita com o algoritmo Adam, usando a função de entropia cruzada categórica esparsa (*sparse_categorical_crossentropy*), por 50 épocas. Para ampliar a robustez e a generalização, aplicou-se *data augmentation* em tempo de treino, com rotações, translações e inversões.

4.1.3 Técnicas de Pré-Processamento Avaliadas

Como variável independente, foram avaliadas diferentes técnicas de manipulação e filtragem de imagem antes do treinamento. As técnicas, aplicadas isoladamente ou em combinação (híbrida), são:

- **Adaptive Threshold:** binarização adaptativa baseada em vizinhança gaussiana, que isola características a partir de limiares locais.
- **CLAHE (*Contrast Limited Adaptive Histogram Equalization*):** equalização de histograma adaptativa por regiões locais (*grids*), que realça detalhes finos e o contraste de texturas sem superexposição nas bordas.
- **CLAHE e Contrast Enhancement (híbrido):** aplicação da equalização adaptativa por blocos, seguida de realce de contraste.
- **Contrast Enhancement:** realce global de contraste, que amplia as diferenças de intensidade por meio de um fator multiplicador aplicado à matriz RGB.
- **Contrast Enhancement e CLAHE (híbrido):** realce global de contraste, seguido da equalização adaptativa por regiões.

- **Contrast Enhancement e Equalize Histogram (híbrido):** realce global de contraste, combinado à equalização do histograma.
- **Denoise (Fast NL-Means):** redução de ruído com preservação de contornos, usando o algoritmo de médias não locais.
- **Edge Detection:** detecção e isolamento das bordas da imagem.
- **Equalize Histogram:** equalização do histograma global, redistribuindo as intensidades na faixa dinâmica disponível.
- **Equalize Histogram e Contrast Enhancement (híbrido):** equalização do histograma global, seguida de realce de contraste.
- **Gaussian Blur:** suavização passa-baixa com *kernel* gaussiano.
- **Gray Scale:** conversão para escala de cinza, com supressão da informação de cor.
- **Median Blur:** filtro não linear da mediana da vizinhança de cada *pixel*, que atenua ruídos do tipo *salt and pepper*.
- **Original Image:** amostra de controle, usada como linha de base sem processamento.

O fluxo de execução incluiu o pré-processamento de todas as imagens (submetidas às variantes listadas e redimensionadas para 512×512 *pixels*), o treinamento das arquiteturas por 50 épocas com partições de validação e a avaliação por meio do *F1-score*, da acurácia, do recall e da precisão.

4.1.4 Resultados e Discussões da Avaliação

As métricas obtidas evidenciam comportamentos distintos conforme o tipo de elemento elétrico inspecionado e a natureza do defeito de cada conjunto de dados. A seguir, os resultados são organizados por cenário de aplicação: a classificação de defeitos estruturais em isoladores de linhas de transmissão (CPLID) e a inspeção aérea de isoladores em ambiente operacional real (DRNPW).

4.1.4.1 Desempenho na Classificação de Defeitos Estruturais em Isoladores de Linhas de Transmissão (CPLID)

O CPLID (*Chinese Power Line Insulator Dataset*) reúne imagens de cadeias de isoladores de linhas de transmissão aéreas, majoritariamente cerâmicos, capturadas por dro-

nes. Nesse conjunto, o defeito de interesse é de natureza estrutural, associado à ausência de disco (*missing cap*) e a fraturas no corpo do isolador, condições que comprometem a rigidez dielétrica da cadeia e podem evoluir para falhas de isolamento na linha.

Para esse tipo de defeito estrutural, as métricas indicam que as estratégias baseadas no aumento do intervalo tonal obtiveram bom desempenho na classificação das fraturas em isoladores de resina e cerâmica. O **Contrast Enhancement simples** apresentou o melhor resultado neste conjunto (acurácia de 95,35% e *F1-score* de 96,55%). Resultados próximos foram obtidos por combinações híbridas: **Contrast Enhancement e Equalize Histogram** (acurácia de 95,35% e *F1-score* de 95,16%) e **CLAHE e Contrast Enhancement** (acurácia de 95,35%), ambas empatadas com o realce de contraste simples em acurácia.

Em contrapartida, as técnicas baseadas em suavização e desfoque reduziram consideravelmente o desempenho: o **Gaussian Blur**, por exemplo, alcançou apenas 67,44% de acurácia, abaixo inclusive do resultado obtido com as imagens originais sem tratamento (93,02%).

Os valores obtidos são apresentados da Figura 24 à Figura 27.




Figura 24 – Acurácia das diferentes estratégias de pré-processamento - CPLID.




Figura 25 – F1-Score das diferentes estratégias de pré-processamento - CPLID.




Figura 26 – Precisão das diferentes estratégias de pré-processamento - CPLID.




Figura 27 – Recall das diferentes estratégias de pré-processamento - CPLID.

4.1.4.2 Desempenho na Inspeção Aérea de Isoladores em Ambiente Operacional Real (DRNPW)

O DRNPW reúne imagens de isoladores capturadas por drones em condições operacionais reais de inspeção de infraestrutura elétrica, disponibilizadas pela CPFL. Diferentemente do CPLID, os isoladores aparecem sobre fundos heterogêneos e com forte poluição visual, cenário que reproduz a dificuldade de campo em distinguir o componente elétrico do ambiente ao seu redor.

Nesse cenário, cujas imagens apresentam fundos com forte poluição visual, os melhores resultados vieram das combinações que ampliam o contraste. A abordagem **Contrast Enhancement e Equalize Histogram** apresentou o melhor desempenho, com 83,33% de acurácia e 75,76% de *F1-score*. Filtros como o **Median Blur** e técnicas adaptativas (**CLAHE** e suas combinações) mantiveram desempenho aceitável, com acurácia em torno de 80,00% e *F1-score* próximo de 71,11%.

A técnica **Gray Scale**, que suprime a informação de cor, apresentou os piores resultados neste conjunto, com 63,33% de acurácia e 49,12% de *F1-score* na validação.

Os valores obtidos são apresentados da Figura 28 à Figura 31.




Figura 28 – Acurácia das diferentes estratégias de pré-processamento - DRNPW.




Figura 29 – F1-Score das diferentes estratégias de pré-processamento - DRNPW.




Figura 30 – Precisão das diferentes estratégias de pré-processamento - DRNPW.




Figura 31 – Recall das diferentes estratégias de pré-processamento - DRNPW.

4.1.5 Conclusão da Avaliação Analítica

Os resultados indicam que as operações baseadas na ampliação do contraste contribuem de forma consistente para o desempenho da CNN nos cenários elétricos avaliados, embora a técnica mais adequada dependa do tipo de elemento inspecionado e da natureza do defeito.

Para a triagem de defeitos estruturais em cadeias de isoladores de linhas de transmissão (disco ausente e fraturas, no CPLID), o realce de contraste simples (*Contrast Enhancement*) foi a estratégia de maior êxito, superando inclusive a amostra de controle sem tratamento. Esse resultado é coerente com a natureza do defeito, cujas assinaturas visuais se concentram na estrutura física do isolador e são realçadas pela ampliação do intervalo tonal.

Já para a inspeção aérea de isoladores em ambiente operacional real, com fundos heterogêneos e poluídos (DRNPW), as abordagens híbridas que combinam realce de contraste e equalização de histograma mostraram-se mais eficazes, por reforçarem o contraste entre o componente e o fundo. Nesse cenário, as técnicas que suprimem a informação de cor (*Gray Scale*) ou que suavizam as texturas (*Gaussian Blur* e demais desfoques) apresentaram os piores resultados, por descartarem informação relevante à identificação do defeito.

Em síntese, o método mostrou-se mais promissor na classificação de defeitos estruturais em isoladores cerâmicos de linhas de transmissão captados por drone, cenário em que atingiu as maiores métricas (acurácia de 95,35% e *F1-score* de 96,55% no CPLID), enquanto a inspeção em ambiente com forte poluição visual permanece como o caso mais desafiador.

4.2 OTIMIZAÇÃO DE PARÂMETROS DE PRÉ-PROCESSAMENTO EM VISÃO COMPUTACIONAL

Nesta etapa, realiza-se a otimização de parâmetros de pré-processamento em um *pipeline* de aprendizado de máquina aplicado à visão computacional. O objetivo foi identificar o valor ótimo do parâmetro de realce de contraste, de modo a maximizar o desempenho de uma CNN em tarefas de classificação. O estudo empregou uma busca em grade (*grid search*), testando diferentes valores do parâmetro em um conjunto de imagens de isoladores de linhas de transmissão.

4.2.1 Metodologia Experimental

4.2.1.1 Conjunto de Dados

Utilizou-se o conjunto de dados DRNPW (*Dataset for Recognition of Non-ceramic Pollution on Windings*), composto por imagens de isoladores de linhas de transmissão. O acervo inclui anotações automáticas para detecção de objetos, totalizando 585 imagens processadas. Após o pré-processamento e o redimensionamento para 640×640 pixels, as imagens foram divididas em conjuntos de treinamento (468 imagens), validação (87 imagens) e teste (30 imagens). O *dataset* é voltado à detecção e à classificação de defeitos estruturais em isoladores, sendo adequado ao contexto de manutenção preditiva em infraestrutura elétrica.

4.2.1.2 Estratégia de Pré-Processamento

A técnica de pré-processamento selecionada foi o *ContrastEnhancement*, que utiliza a biblioteca PIL (*Python Imaging Library*) para ajustar o contraste das imagens. A intensidade da transformação é controlada por uma variável: valores de *factor* menores que 1,0 reduzem o contraste, enquanto valores maiores que 1,0 o aumentam. O hiperparâmetro otimizado foi exclusivamente o *factor*, definido na faixa de 0,5 a 1,611.

4.2.1.3 Modelo de Aprendizado de Máquina

A avaliação baseou-se em uma CNN simples, implementada com o *framework* TensorFlow/Keras. A arquitetura adotada é a seguinte:

- camada de entrada com dimensões (640, 640, 3), correspondente a imagens RGB;
- duas camadas convolucionais com 32 filtros cada (*kernels* de 3×3 e ativação ReLU), seguidas de *max-pooling* (janelas de 4×4);
- camada de achatamento (*Flatten*);
- camada densa com 8 neurônios e ativação ReLU;
- camada de saída com número de neurônios igual ao número de classes e ativação *softmax*.

A compilação utilizou o otimizador Adam com a função de entropia cruzada categórica esparsa (`sparse_categorical_crossentropy`) e a acurácia como métrica de monitoramento. O treinamento foi limitado a 5 épocas. A avaliação do modelo foi feita sobre o conjunto de teste, extraindo-se as métricas de acurácia, precisão, *recall* e *F1-score*.

4.2.1.4 Estratégia de Otimização Paramétrica

A otimização baseou-se em busca em grade (*grid search*), técnica que avalia valores uniformemente distribuídos do hiperparâmetro de interesse. Foram definidas 5 instâncias para o `factor`: 0,5; 0,778; 1,056; 1,333 e 1,611, espaçadas com a função `numpy.linspace`.

Para cada valor do `factor`, o fluxo executou os seguintes passos:

1. pré-processamento das imagens com o valor avaliado;
2. treinamento do modelo CNN por 5 épocas;
3. extração das métricas sobre o conjunto de teste;
4. registro do valor que produziu a maior acurácia.

4.2.2 Fundamentação Teórica do Método Selecionado

A busca em grade é um método consolidado na literatura para o ajuste de parâmetros em espaços discretos e de dimensão reduzida. Seus principais aspectos são:

- **Espaço de busca:** a busca foi realizada de forma uniforme, testando valores entre 0,5 e 1,611 em 5 etapas.
- **Custo computacional:** embora a busca em grade seja ineficiente em cenários com muitas variáveis, essa limitação não é relevante neste caso, em que há apenas uma variável.
- **Reprodutibilidade:** por ser determinística, a técnica oferece maior reprodutibilidade do que métodos como o *random search* ou a otimização bayesiana.

4.2.3 Resultados e Análise

O ciclo de otimização avaliou os 5 valores do `factor` definidos, com os resultados de acurácia apresentados na Tabela 4.

Tabela 4 – Resultados da otimização por busca em grade do parâmetro de contraste (`factor`)

Fator (<code>factor</code>)	Acurácia	Precisão	Recall	F1-Score
0,5	0,767	0,588	0,767	0,665
0,778	0,833	0,694	0,833	0,758
1,056	0,800	0,640	0,800	0,711
1,333	0,900	0,810	0,900	0,853
1,611	0,833	0,694	0,833	0,758

Fonte: Autor.

A análise dos resultados permite as seguintes observações:

- **Ponto ótimo:** o melhor resultado ocorreu com o fator de 1,333, que alcançou 90,0% de acurácia, 81,0% de precisão e 85,3% de *F1-score*. Isso indica que um aumento moderado de contraste favoreceu a detecção das características relevantes ao problema.
- **Estabilidade nos valores adjacentes:** os fatores 0,778 e 1,611 mantiveram bom desempenho, com acurácia de 83,3% e *F1-score* em torno de 75,8%, o que aponta para certa robustez do modelo a pequenas variações de contraste ao redor do ponto ótimo.
- **Comportamento em forma de pico:** o desempenho em função do fator de contraste descreve uma curva com um máximo bem definido; reduções excessivas de contraste (fator de 0,5) prejudicam a predição, resultando na menor acurácia observada (76,7%).

As medições foram registradas no arquivo `optimization_factor_results.json` para fins de reprodutibilidade.

4.2.4 Síntese da Etapa

Os resultados confirmam a utilidade da busca em grade no ajuste dos parâmetros de pré-processamento. O melhor valor do `factor` foi 1,333, com desempenho expressivo na detecção sobre o DRNPW (90,0% de acurácia).

A partir das variações observadas nos índices sob diferentes níveis de contraste, sugerem-se os seguintes encaminhamentos para as próximas etapas:

- avaliar a otimização bayesiana, que permite explorar de forma mais eficiente múltiplos hiperparâmetros;
- ampliar a amostragem em torno da região favorável já identificada, refinando a busca próximo ao valor ótimo do fator de contraste;
- analisar o comportamento interno do modelo por meio de *logs* e *checkpoints*, a fim de diagnosticar eventuais instabilidades;
- estender essas simulações à validação do sistema em condições de operação em infraestrutura elétrica.

4.3 AVALIAÇÃO DE BUSCA ALEATÓRIA NA OTIMIZAÇÃO DE PARÂMETROS

Como complemento à análise anterior, conduziu-se um experimento com busca aleatória (*random search*). O objetivo foi determinar o valor do fator de realce de contraste que maximiza o desempenho da CNN, avaliando instâncias geradas aleatoriamente em um intervalo contínuo. A avaliação manteve o uso do conjunto de dados DRNPW.

4.3.1 Ajustes Metodológicos

O experimento preservou as características da abordagem em grade: o redimensionamento das imagens para 640×640 pixels, a transformação global *ContrastEnhancement* controlada pelo hiperparâmetro *factor* e a mesma arquitetura de modelo.

4.3.1.1 Estratégia de Otimização Estocástica

Diferentemente da busca em grade, com valores espaçados de forma regular, este experimento empregou a busca aleatória. O método consiste em definir o intervalo do parâmetro (0,5 a 3,0) e selecionar valores por amostragem aleatória nesse intervalo. Foram realizadas 5 tentativas (*trials*) independentes.

4.3.2 Fundamentação Teórica do Método de Busca Estocástica

A busca aleatória contrapõe-se à enumeração rígida da busca em grade, ao explorar valores fora de pontos predefinidos. Seus principais aspectos são:

- **Espaço de busca e amostragem:** considera todo o intervalo do domínio e testa valores que não se limitam a passos discretos regulares.
- **Vantagens:** apresenta boa eficiência e flexibilidade na busca por máximos globais, sobretudo quando os parâmetros contínuos têm efeitos difíceis de prever com passos rígidos.
- **Limitações:** não garante cobertura uniforme do espaço, o que aumenta o risco de resultados subótimos quando o número de avaliações é pequeno.

Em comparação com a busca em grade, a busca aleatória pode cobrir melhor regiões intermediárias do espaço de parâmetros, relevantes em modelos profundos.

4.3.3 Resultados da Busca Aleatória

A partir dos valores amostrados do hiperparâmetro `factor`, avaliou-se o desempenho sobre o conjunto de validação, com os resultados apresentados na Tabela 5.

Tabela 5 – Resumo experimental das tentativas de busca aleatória sobre o fator de contraste

Tentativa	Fator (<code>factor</code>)	Acurácia (Validação)
1	1,4364	0,8506
2	2,8768	0,7931
3	2,3300	0,7126
4	1,9966	0,8046
5	0,8900	0,7816

Fonte: Autor.

A análise dos resultados, em comparação com o experimento anterior, permite as seguintes observações:

- **Ponto ótimo:** o melhor desempenho foi obtido com o fator de 1,4364 (Tentativa 1), com 85,06% de acurácia, a maior entre as tentativas. Esse resultado reforça a indicação anterior de que valores um pouco acima de 1,0 favorecem o desempenho do modelo.
- **Sensibilidade a contrastes elevados:** valores de contraste muito altos degradaram o desempenho, com queda para 71,26% no fator 2,3300 (o menor da análise) e para 79,31% no fator 2,8768. Contrastes excessivos introduzem distorções que dificultam a classificação.

- **Comportamento em contrastes reduzidos:** com fator de 0,8900, inferior a 1,0, o modelo manteve desempenho razoável (78,16%), o que indica estabilidade da arquitetura mesmo com atenuação parcial das texturas.
- **Robustez computacional:** todos os ensaios foram concluídos sem instabilidades numéricas ou interrupções no treinamento.

4.3.4 Síntese da Etapa

Os resultados confirmam a viabilidade da busca aleatória no ajuste de parâmetros para visão computacional. O melhor valor obtido, 1,4364, apresentou desempenho de validação compatível com o da busca em grade, cujo fator ótimo ficou próximo de 1,33.

Para trabalhos futuros, sugerem-se os seguintes encaminhamentos:

- combinar a busca aleatória com a otimização bayesiana, reduzindo a incerteza associada à amostragem aleatória;
- ampliar os testes incorporando outras perturbações visuais dos dados (como variações de rotação e de resolução) ao processo de otimização.

4.4 EXPERIMENTOS ADICIONAIS COM ARQUITETURAS YOLO

As avaliações apresentadas nas seções anteriores empregaram uma única arquitetura de modelagem, a CNN clássica descrita no início deste capítulo. Essa escolha é adequada ao propósito de isolar o pré-processamento como variável independente, mas deixa em aberto uma questão pertinente: os efeitos observados decorrem das características das imagens ou da arquitetura utilizada para avaliá-las. Como a metodologia proposta trata a etapa de modelagem como um bloco substituível, é possível repetir a varredura de pré-processamentos trocando apenas esse bloco e verificar se o comportamento se mantém.

Esta seção apresenta os experimentos adicionais conduzidos com esse objetivo, utilizando duas arquiteturas da família YOLO (*You Only Look Once*), em sua versão v8 (JOCHER; CHAURASIA; QIU, 2023). Os resultados aqui reportados complementam, e não substituem, as análises anteriores: os conjuntos de dados, as 14 técnicas de pré-processamento e o número de épocas de treinamento foram mantidos, de modo que a única variável alterada em relação à avaliação inicial é o modelo.

4.4.1 Modelos Avaliados

Foram avaliadas duas arquiteturas adicionais:

- **YOLOv8n (detecção):** modelo de detecção de objetos, que prediz simultaneamente a classe e a localização espacial dos elementos presentes na imagem. Corresponde ao encaminhamento de estender o método a arquiteturas de detecção, permitindo verificar o desempenho do realce de contraste em um objetivo de aprendizado distinto do de classificação.
- **YOLOv8n-cls (classificação):** modelo da mesma família, porém em modo de classificação pura, sem predição de caixas delimitadoras. Sua inclusão tem finalidade de controle: mantém a arquitetura de extração de características do detector e a tarefa da CNN, o que permite separar o efeito da família de modelos do efeito do objetivo de detecção.

Ambos partiram de pesos pré-treinados no conjunto COCO (LIN et al., 2014), prática usual de transferência de aprendizado nessa família de modelos. A Tabela 6 resume a configuração adotada.

Tabela 6 – Configuração dos modelos adicionais avaliados

Parâmetro	YOLOv8n	YOLOv8n-cls
Tarefa	Detecção	Classificação
Pesos iniciais	yolov8n.pt	yolov8n-cls.pt
Parâmetros treináveis	3.066.494	1.437.442
Resolução de entrada	640 × 640	224 × 224
Tamanho do lote	16	16
Otimizador	automático	automático
Taxa de aprendizado inicial	0,01	0,01
Épocas	50	50
Tempo médio por combinação	97 min	9 min

Fonte: Autor.

O treinamento foi executado integralmente em CPU, em um processador Intel Xeon E5-1650 v4 de 3,60 GHz, uma vez que a unidade gráfica do hospedeiro não estava disponível ao ambiente de execução. Essa restrição não altera a qualidade final dos modelos, mas explica a diferença de custo entre as duas arquiteturas: o detector é cerca de dez vezes mais oneroso que o classificador, em razão da resolução de entrada mais alta e da cabeça de predição de caixas. Ao todo, as varreduras compreenderam 56 treinamentos completos, correspondentes a 2 modelos, 2 conjuntos de dados e 14 técnicas de pré-processamento.

4.4.2 Compatibilização entre Detecção e Classificação

Os dois conjuntos de dados possuem exatamente uma anotação por imagem, o que os caracteriza, na prática, como problemas de classificação, mesmo quando os rótulos estão expressos em formato de caixa delimitadora. Para que o desempenho do detector fosse comparável ao dos classificadores sob as mesmas métricas, a saída do YOLOv8n foi reduzida a um único rótulo por imagem, adotando-se a classe da caixa de maior confiança. Imagens sem qualquer detecção recebem um rótulo adicional, SEM DETECCAO, contabilizado como erro.

Nessa redução, empregou-se um limiar de confiança de 0,001, em vez do valor padrão de 0,25. Com o limiar padrão, o modelo não produzia detecção alguma na maior parte das imagens de teste, e as métricas seriam nulas por efeito do limiar, e não por ausência de capacidade preditiva. Cabe registrar que esse procedimento é permissivo com o detector, pois desconsidera a correção da localização da caixa e avalia apenas o rótulo predito.

A qualidade da localização propriamente dita foi verificada em separado, por meio do mAP50 (*mean Average Precision* com limiar de IoU de 0,5), apresentado na Tabela 7.

Tabela 7 – Faixa de mAP50 do YOLOv8n entre as 14 técnicas de pré-processamento

Conjunto de dados	mAP50 mínimo	mAP50 máximo
CPLID	0,0644	0,1272
DRNPW	0,0014	0,0537

Fonte: Autor.

Considerando que detectores de uso prático costumam apresentar mAP50 superior a 0,6, os valores obtidos, uma a duas ordens de grandeza inferiores, indicam que a localização espacial das falhas não foi efetivamente aprendida em nenhuma das combinações avaliadas. As métricas de classificação reportadas a seguir devem, portanto, ser lidas como o desempenho do rótulo predito, e não como evidência de capacidade de detecção.

4.4.3 Critério de Referência e Definição das Métricas

Ambos os conjuntos de teste são desbalanceados, o que torna necessária a adoção de um critério de referência para interpretar os valores absolutos de acurácia. Adota-se aqui o piso majoritário, definido como a acurácia obtida ao responder sempre a classe mais frequente do conjunto de teste, sem observar a imagem. No CPLID, 32 das 43 imagens de teste pertencem à classe *Normal Insulators*, resultando em um piso de 74,42%. No DRNPW, 22 das 30 imagens de teste pertencem a uma única categoria, o que estabelece

um piso de 73,33%. Modelos com desempenho abaixo desse valor não extraem informação útil das imagens.

As métricas foram calculadas com média ponderada pelo suporte de cada classe, critério mantido em relação às avaliações anteriores. Convém observar que, sob essa definição, o *recall* ponderado é numericamente igual à acurácia, razão pela qual as duas colunas coincidem nas tabelas a seguir.

4.4.4 Resultados no CPLID

As Tabelas 8 e 9 apresentam os resultados obtidos pelo YOLOv8n e pelo YOLOv8n-cls no CPLID.

Tabela 8 – Desempenho do YOLOv8n por técnica de pré-processamento - CPLID

Pré-processamento	Acurácia (%)	Precisão (%)	Recall (%)	F1 (%)
<i>Adaptive Threshold</i>	65,12	42,40	65,12	51,36
CLAHE	65,12	42,40	65,12	51,36
CLAHE e <i>Contrast Enh.</i>	55,81	31,15	55,81	39,99
<i>Contrast Enhancement</i>	67,44	48,17	67,44	56,20
<i>Contrast Enh.</i> e CLAHE	72,09	51,97	72,09	60,40
<i>Contrast Enh.</i> e <i>Eq. Histogram</i>	65,12	42,40	65,12	51,36
<i>Denoise</i>	72,09	51,97	72,09	60,40
<i>Edge Detection</i>	67,44	45,48	67,44	54,33
<i>Equalize Histogram</i>	79,07	62,52	79,07	69,83
<i>Eq. Histogram</i> e <i>Contrast Enh.</i>	76,74	58,90	76,74	66,65
<i>Gaussian Blur</i>	76,74	58,90	76,74	66,65
<i>Gray Scale</i>	79,07	62,52	79,07	69,83
<i>Median Blur</i>	74,42	55,38	74,42	63,50
<i>Original Image</i>	65,12	42,40	65,12	51,36
Média	70,10	49,76	70,10	58,09
Piso majoritário	74,42			

Fonte: Autor.

Tabela 9 – Desempenho do YOLOv8n-cls por técnica de pré-processamento - CPLID

Pré-processamento	Acurácia (%)	Precisão (%)	Recall (%)	F1 (%)
<i>Adaptive Threshold</i>	55,81	40,07	55,81	46,65
CLAHE	60,47	41,29	60,47	49,07
CLAHE e <i>Contrast Enh.</i>	51,16	44,90	51,16	43,67
<i>Contrast Enhancement</i>	58,14	56,21	58,14	57,07
<i>Contrast Enh.</i> e CLAHE	69,77	64,28	69,77	65,08
<i>Contrast Enh.</i> e <i>Eq. Histogram</i>	62,79	58,36	62,79	58,35
<i>Denoise</i>	72,09	51,97	72,09	60,40
<i>Edge Detection</i>	67,44	45,48	67,44	54,33
<i>Equalize Histogram</i>	72,09	61,28	72,09	66,25
<i>Eq. Histogram</i> e <i>Contrast Enh.</i>	74,42	67,23	74,42	68,76
<i>Gaussian Blur</i>	74,42	69,89	74,42	71,06
<i>Gray Scale</i>	81,40	84,94	81,40	74,93
<i>Median Blur</i>	67,44	63,12	67,44	64,78
<i>Original Image</i>	60,47	41,29	60,47	49,07
Média	66,28	56,45	66,28	59,25
Piso majoritário	74,42			

Fonte: Autor.

No CPLID, o YOLOv8n obteve acurácia média de 70,10% e o YOLOv8n-cls, de 66,28%, ambas inferiores ao piso majoritário de 74,42% e à média de 84,55% obtida pela CNN. O detector superou o piso em 4 das 14 técnicas avaliadas, e o classificador da mesma família, em apenas 1. O melhor resultado individual entre as duas arquiteturas coube ao YOLOv8n-cls com *Gray Scale* (81,40% de acurácia e 74,93% de *F1-score*), valor ainda distante dos 95,35% alcançados pela CNN com o realce simples de contraste.

Chama atenção a inversão na ordem de mérito das técnicas. Para a CNN, o *Gray Scale* figurava entre os piores tratamentos neste conjunto (76,74% de acurácia), justamente por suprimir a informação de cor; para as duas arquiteturas YOLO, foi o tratamento de melhor ou segundo melhor desempenho. De forma simétrica, as combinações de realce de contraste que lideraram a avaliação com a CNN ficaram entre as piores para o YOLOv8n-cls, caso de CLAHE e *Contrast Enhancement* (51,16%). A Tabela 10 consolida a comparação entre as três arquiteturas.

Tabela 10 – Comparação entre as arquiteturas avaliadas - CPLID

Pré-processamento	Acurácia (%)			F1-score (%)		
	CNN	YOLO	YOLOCLS	CNN	YOLO	YOLOCLS
<i>Adaptive Threshold</i>	67,44	65,12	55,81	80,56	51,36	46,65
<i>CLAHE</i>	90,70	65,12	60,47	94,12	51,36	49,07
<i>CLAHE e Contrast Enh.</i>	95,35	55,81	51,16	95,35	39,99	43,67
<i>Contrast Enhancement</i>	95,35	67,44	58,14	96,55	56,20	57,07
<i>Contrast Enh. e CLAHE</i>	93,02	72,09	69,77	92,94	60,40	65,08
<i>Contrast Enh. e Eq. Hist.</i>	95,35	65,12	62,79	95,16	51,36	58,35
<i>Denoise</i>	67,44	72,09	72,09	80,56	60,40	60,40
<i>Edge Detection</i>	74,42	67,44	67,44	85,33	54,33	54,33
<i>Equalize Histogram</i>	88,37	79,07	72,09	92,54	69,83	66,25
<i>Eq. Hist. e Contrast Enh.</i>	93,02	76,74	74,42	93,08	66,65	68,76
<i>Gaussian Blur</i>	67,44	76,74	74,42	80,56	66,65	71,06
<i>Gray Scale</i>	76,74	79,07	81,40	85,29	69,83	74,93
<i>Median Blur</i>	86,05	74,42	67,44	88,46	63,50	64,78
<i>Original Image</i>	93,02	65,12	60,47	95,08	51,36	49,07
Média	84,55	70,10	66,28	89,68	58,09	59,25

Fonte: Autor.

4.4.5 Resultados no DRNPW

As Tabelas 11 e 12 apresentam os resultados obtidos no DRNPW.

Tabela 11 – Desempenho do YOLOv8n por técnica de pré-processamento - DRNPW

Pré-processamento	Acurácia (%)	Precisão (%)	Recall (%)	F1 (%)
<i>Adaptive Threshold</i>	83,33	69,44	83,33	75,76
CLAHE	70,00	66,96	70,00	68,44
CLAHE e <i>Contrast Enh.</i>	76,67	63,45	76,67	69,43
<i>Contrast Enhancement</i>	76,67	58,78	76,67	66,54
<i>Contrast Enh.</i> e CLAHE	70,00	61,92	70,00	65,71
<i>Contrast Enh.</i> e <i>Eq. Histogram</i>	53,33	28,44	53,33	37,10
<i>Denoise</i>	63,33	43,68	63,33	51,70
<i>Edge Detection</i>	73,33	53,78	73,33	62,05
<i>Equalize Histogram</i>	70,00	49,00	70,00	57,65
<i>Eq. Histogram</i> e <i>Contrast Enh.</i>	66,67	44,44	66,67	53,33
<i>Gaussian Blur</i>	66,67	44,44	66,67	53,33
<i>Gray Scale</i>	80,00	64,00	80,00	71,11
<i>Median Blur</i>	73,33	53,78	73,33	62,05
<i>Original Image</i>	73,33	53,78	73,33	62,05
Média	71,19	53,99	71,19	61,16
Piso majoritário	73,33			

Fonte: Autor.

Tabela 12 – Desempenho do YOLOv8n-cls por técnica de pré-processamento - DRNPW

Pré-processamento	Acurácia (%)	Precisão (%)	Recall (%)	F1 (%)
<i>Adaptive Threshold</i>	83,33	69,44	83,33	75,76
CLAHE	73,33	53,78	73,33	62,05
CLAHE e <i>Contrast Enh.</i>	80,00	64,00	80,00	71,11
<i>Contrast Enhancement</i>	76,67	58,78	76,67	66,54
<i>Contrast Enh.</i> e CLAHE	76,67	58,78	76,67	66,54
<i>Contrast Enh.</i> e <i>Eq. Histogram</i>	53,33	28,44	53,33	37,10
<i>Denoise</i>	63,33	43,68	63,33	51,70
<i>Edge Detection</i>	73,33	53,78	73,33	62,05
<i>Equalize Histogram</i>	70,00	49,00	70,00	57,65
<i>Eq. Histogram</i> e <i>Contrast Enh.</i>	66,67	44,44	66,67	53,33
<i>Gaussian Blur</i>	63,33	43,68	63,33	51,70
<i>Gray Scale</i>	80,00	64,00	80,00	71,11
<i>Median Blur</i>	73,33	53,78	73,33	62,05
<i>Original Image</i>	66,67	52,38	66,67	58,67
Média	71,43	52,71	71,43	60,53
Piso majoritário	73,33			

Fonte: Autor.

No DRNPW, as três arquiteturas apresentaram desempenho médio muito próximo do piso majoritário de 73,33%: 73,81% para a CNN, 71,19% para o YOLOv8n e 71,43% para o YOLOv8n-cls. O melhor resultado individual das arquiteturas YOLO, 83,33% de acurácia e 75,76% de *F1-score* com *Adaptive Threshold*, iguala numericamente o melhor resultado da CNN neste conjunto, obtido com a combinação de realce de contraste e equalização de histograma. Trata-se, contudo, de uma coincidência de valores que reflete o mesmo número de acertos em um conjunto de teste de apenas 30 imagens.

Repete-se aqui a inversão observada no CPLID, de forma ainda mais acentuada: a combinação *Contrast Enhancement* e *Equalize Histogram*, que foi a de melhor desempenho para a CNN neste conjunto, foi a de pior desempenho para as duas arquiteturas YOLO, com 53,33% de acurácia. A Tabela 13 consolida a comparação.

Tabela 13 – Comparação entre as arquiteturas avaliadas - DRNPW

Pré-processamento	Acurácia (%)			F1-score (%)		
	CNN	YOLO	YOLOCLS	CNN	YOLO	YOLOCLS
<i>Adaptive Threshold</i>	73,33	83,33	83,33	62,05	75,76	75,76
CLAHE	80,00	70,00	73,33	71,11	68,44	62,05
CLAHE e <i>Contrast Enh.</i>	70,00	76,67	80,00	57,65	69,43	71,11
<i>Contrast Enhancement</i>	63,33	76,67	76,67	49,12	66,54	66,54
<i>Contrast Enh.</i> e CLAHE	80,00	70,00	76,67	71,11	65,71	66,54
<i>Contrast Enh.</i> e <i>Eq. Hist.</i>	83,33	53,33	53,33	75,76	37,10	37,10
<i>Denoise</i>	76,67	63,33	63,33	66,54	51,70	51,70
<i>Edge Detection</i>	66,67	73,33	73,33	53,33	62,05	62,05
<i>Equalize Histogram</i>	80,00	70,00	70,00	71,11	57,65	57,65
<i>Eq. Hist.</i> e <i>Contrast Enh.</i>	76,67	66,67	66,67	66,54	53,33	53,33
<i>Gaussian Blur</i>	76,67	66,67	63,33	66,54	53,33	51,70
<i>Gray Scale</i>	63,33	80,00	80,00	49,12	71,11	71,11
<i>Median Blur</i>	80,00	73,33	73,33	71,11	62,05	62,05
<i>Original Image</i>	63,33	73,33	66,67	49,12	62,05	58,67
Média	73,81	71,19	71,43	62,87	61,16	60,53

Fonte: Autor.

4.4.6 Discussão dos Experimentos Adicionais

A comparação entre as três arquiteturas, resumida na Tabela 14, permite três observações principais.

Tabela 14 – Acurácia média e número de técnicas acima do piso majoritário

Conjunto	Modelo	Acurácia média (%)	Acima do piso
CPLID	CNN	84,55	10/14
CPLID	YOLOv8n	70,10	4/14
CPLID	YOLOv8n-cls	66,28	1/14
CPLID	<i>Piso majoritário</i>	<i>74,42</i>	
DRNPW	CNN	73,81	8/14
DRNPW	YOLOv8n	71,19	4/14
DRNPW	YOLOv8n-cls	71,43	5/14
DRNPW	<i>Piso majoritário</i>	<i>73,33</i>	

Fonte: Autor.

A primeira observação diz respeito ao DRNPW, no qual nenhuma das três arquiteturas se distanciou do piso majoritário. As três médias situam-se a poucos décimos de ponto percentual do valor obtido por um classificador trivial, o que indica limitação de dados, e não de arquitetura. O conjunto declara 70 categorias, das quais apenas 59 aparecem no treinamento; das 468 imagens de treino, 335 pertencem a uma única categoria, e diversas classes contam com um ou dois exemplos. Sob esse grau de desbalanceamento, nenhuma escolha de modelo é capaz de compensar a ausência de amostras nas classes de cauda.

A segunda observação refere-se ao CPLID, no qual apenas a CNN superou o piso majoritário de forma consistente. Uma explicação plausível está na relação entre a capacidade do modelo e o volume de dados disponível: com 678 imagens de treinamento e duas classes, a CNN clássica, com apenas duas camadas convolucionais e uma camada densa de 8 unidades, dispõe de capacidade compatível com o problema, ao passo que arquiteturas com milhões de parâmetros, ainda que pré-treinadas, tendem a convergir para soluções degeneradas nesse regime de poucos dados.

A terceira observação decorre da comparação entre o YOLOv8n e o YOLOv8n-cls. A hipótese inicial era de que o desempenho inferior do detector se devesse ao objetivo de detecção, mais exigente que o de classificação. O YOLOv8n-cls foi incluído justamente para testar essa hipótese, e o resultado não a sustenta: no CPLID, o desempenho médio não melhorou ao eliminar a predição de caixas, tendo inclusive recuado de 70,10% para 66,28%. Reforça essa leitura o fato de as duas arquiteturas produzirem resultados numericamente idênticos nas quatro métricas em 2 das 14 técnicas no CPLID e em 9 das 14 no DRNPW. Tratando-se de arquiteturas distintas, com resoluções de entrada diferentes e treinadas em execuções independentes, a coincidência até a última casa decimal indica que ambas convergiram para a mesma predição degenerada, tipicamente a de responder sempre a classe majoritária, e não que tenham aprendido representações equivalentes.

Por fim, a inversão na ordem de mérito das técnicas de pré-processamento, observada nos dois conjuntos, merece registro. As técnicas que mais favoreceram a CNN foram,

com frequência, as que menos favoreceram as arquiteturas YOLO, e o inverso também se verificou. Esse comportamento é coerente com o fato de os modelos YOLO partirem de pesos pré-treinados no COCO, cujas estatísticas de cor e contraste são as de fotografias naturais: transformações que se afastam dessa distribuição, como o realce agressivo de contraste, tendem a degradar a utilidade dos filtros já aprendidos, ao passo que a CNN, treinada do zero, ajusta seus filtros à distribuição efetivamente apresentada. A escolha do pré-processamento, portanto, não é independente do modelo e do seu regime de inicialização, o que reforça a necessidade de tratá-los conjuntamente, conforme prevê a estrutura iterativa da metodologia proposta.

4.4.7 Limitações dos Experimentos Adicionais

A interpretação dos resultados desta seção está sujeita a quatro limitações, aqui registradas para delimitar o alcance das conclusões.

- **Assincronia entre as execuções:** as varreduras do YOLOv8n e do YOLOv8n-cls foram executadas em uma única campanha, ao passo que os resultados da CNN provêm de execuções realizadas ao longo de um período mais extenso. A comparação, portanto, não controla eventuais diferenças de ambiente entre as campanhas.
- **Heterogeneidade na definição das métricas:** parte dos resultados da CNN no CPLID foi gerada antes da padronização da média ponderada, o que afeta as colunas de precisão e *F1-score* desses registros. A acurácia não é afetada por essa mudança, razão pela qual a comparação entre arquiteturas privilegia essa métrica.
- **Dimensão dos conjuntos de teste:** com 43 imagens no CPLID e 30 no DRNPW, cada acerto isolado corresponde a 2,3 e 3,3 pontos percentuais de acurácia, respectivamente. Diferenças de poucos pontos entre modelos situam-se dentro da variação atribuível a duas ou três imagens.
- **Efeito da média ponderada:** por premiar o acerto na classe majoritária, a média ponderada atenua a percepção do desbalanceamento. A adoção de métricas como o *F1-score* macro ou a acurácia balanceada distinguiria com maior clareza o modelo que aprendeu daquele que apenas replica a classe dominante, e constitui encaminhamento natural para a continuidade destes experimentos.

4.4.8 Síntese da Etapa

Os experimentos adicionais cumpriram a função de verificar a generalidade das conclusões obtidas com a CNN. Nos dois conjuntos avaliados, as arquiteturas YOLO não superaram a CNN clássica: no CPLID, a diferença é expressiva, com 84,55% de acurácia média contra 70,10% e 66,28%; no DRNPW, as três arquiteturas permanecem estatisticamente indistinguíveis do piso majoritário.

Dois resultados desta etapa têm valor metodológico. O primeiro é a constatação de que, em regime de poucos dados e forte desbalanceamento, o aumento da capacidade do modelo não compensa as limitações do conjunto de dados, o que confirma o diagnóstico de que a escassez de amostras anotadas é o fator mais restritivo nesse domínio. O segundo é a evidência de que a ordem de mérito das técnicas de pré-processamento depende da arquitetura e da forma de inicialização dos pesos, de modo que a seleção do pré-processamento deve ser conduzida em conjunto com a escolha do modelo, e não como etapa independente.

5 CONCLUSÃO

5.1 SÍNTESE DOS RESULTADOS OBTIDOS

Este trabalho propôs e avaliou uma metodologia sistemática para o aprimoramento da detecção e da classificação de falhas em cadeias de isoladores, combinando técnicas de processamento de imagem e Redes Neurais Convolucionais (CNN). A metodologia permitiu avaliar o impacto de diversas técnicas de pré-processamento, de forma isolada e combinada, além de otimizar seus parâmetros. Em uma etapa complementar, a mesma varredura de pré-processamentos foi repetida com duas arquiteturas adicionais da família YOLO, o que permitiu verificar em que medida as conclusões obtidas dependem do modelo empregado.

A análise dos resultados demonstrou que o pré-processamento das imagens exerce papel determinante no desempenho dos modelos em cenários de inspeção de infraestrutura elétrica. Verificou-se, contudo, que não há um processamento universalmente superior: a eficácia de cada técnica depende das características do conjunto de dados e do contexto de captura das anomalias.

No *dataset* CPLID, cujas imagens têm fundos homogêneos e falhas estruturais bem demarcadas em materiais de resina e cerâmica, as técnicas de simples ampliação do contraste, em especial o *Contrast Enhancement*, obtiveram os melhores resultados (acurácia de 95,35% e *F1-score* de 96,55%). Em contrapartida, filtros de suavização e desfoque, como o *Gaussian Blur*, prejudicaram a detecção das bordas do isolador.

No *dataset* DRNPW, composto por imagens de drones com forte poluição visual e fundos ruidosos (áreas de vegetação e ocupação urbana), as abordagens simples tiveram desempenho inferior, e as combinações híbridas foram mais eficazes. A aplicação sequencial de realce de contraste (*Contrast Enhancement*) e equalização de histograma (*Equalize Histogram*) destacou-se na atenuação da interferência do fundo, resultando em ganhos de acurácia e de *F1-score* em relação aos modelos treinados apenas com as imagens originais.

A etapa de otimização de parâmetros evidenciou o impacto de pequenas variações no desempenho das redes. Ao comparar a busca em grade (*Grid Search*) com a busca aleatória (*Random Search*), observou-se concordância na identificação do ponto ótimo, localizado em torno de fatores de realce entre 1,3 e 1,4. Além de consolidar os ganhos em relação ao uso da imagem original, com 90% de acurácia, os resultados evidenciaram a estabilidade do modelo nessa faixa. Constatou-se, ainda, que níveis excessivos de contraste distorcem a imagem e introduzem artefatos que prejudicam o aprendizado.

Por fim, os experimentos adicionais com as arquiteturas YOLOv8n, de detecção, e

YOLOv8n-cls, de classificação, delimitaram o alcance dessas conclusões. Nos dois conjuntos avaliados, essas arquiteturas não superaram a CNN clássica: no CPLID, a acurácia média foi de 70,10% para o YOLOv8n e de 66,28% para o YOLOv8n-cls, ante 84,55% da CNN; no DRNPW, as três arquiteturas permaneceram próximas do piso majoritário, isto é, do desempenho obtido ao responder sempre a classe mais frequente do conjunto de teste. A hipótese de que o desempenho inferior decorreria do objetivo de detecção não se confirmou, uma vez que o modelo da mesma família em modo de classificação pura não apresentou melhora. Observou-se, além disso, que a ordem de mérito das técnicas de pré-processamento se altera conforme a arquitetura: transformações que favoreceram a CNN, como as combinações de realce de contraste, foram justamente as menos favoráveis aos modelos partidos de pesos pré-treinados, e o inverso também se verificou. Esse resultado indica que a seleção do pré-processamento não é independente do modelo nem da forma de inicialização de seus pesos.

5.2 LIMITAÇÕES E DESAFIOS ENCONTRADOS

Apesar dos resultados obtidos, o trabalho enfrentou desafios inerentes à combinação entre a inspeção aérea automatizada e os fluxos de aprendizado profundo.

O principal desafio foi a limitação na quantidade e na disponibilidade de dados. Como observado no início da pesquisa, há grande escassez de bancos de imagens públicos focados em redes de distribuição que contenham um número expressivo de componentes defeituosos com anotações rigorosas. Essa carência, comum na área de sensoramento, obriga o uso de conjuntos de dados fortemente desbalanceados. Como consequência, o baixo volume de amostras da classe minoritária (isoladores com falhas) prejudica o treinamento, aumentando a tendência do modelo a favorecer a classe dominante e a gerar falsos positivos a partir de elementos do fundo da imagem. Os experimentos adicionais reforçaram esse diagnóstico: no DRNPW, em que 335 das 468 imagens de treinamento pertencem a uma única categoria e diversas classes contam com um ou dois exemplos, nenhuma das três arquiteturas avaliadas se distanciou do piso majoritário, o que indica que o aumento da capacidade do modelo não compensa a ausência de amostras nas classes de cauda.

Cabe registrar, ainda, uma limitação de ordem metodológica na comparação entre arquiteturas. Os conjuntos de teste utilizados são reduzidos, com 43 imagens no CPLID e 30 no DRNPW, de modo que cada acerto isolado corresponde a 2,3 e 3,3 pontos percentuais de acurácia, respectivamente. Diferenças de poucos pontos entre modelos situam-se, portanto, dentro da variação atribuível a duas ou três imagens. Soma-se a isso o fato de a média ponderada, adotada no cálculo das métricas, premiar o acerto na classe majoritária e, com isso, atenuar a percepção do desbalanceamento.

Outra limitação foi o alto custo computacional para encontrar os melhores hiperparâmetros. A metodologia proposta permite criar diversos *pipelines*, combinando várias técnicas de processamento em etapas sequenciais. Diante dessa flexibilidade, otimizar todos os parâmetros simultaneamente, testando cada combinação possível, leva à explosão combinatória, fenômeno em que o número de combinações cresce exponencialmente a cada nova variável. Na prática, isso exige um poder de processamento que inviabiliza a avaliação exaustiva em tempo hábil.

5.3 SUGESTÕES PARA PESQUISAS FUTURAS

A partir das limitações apontadas e dos resultados obtidos, sugerem-se os seguintes encaminhamentos para trabalhos futuros:

- **Otimização multiparamétrica por otimização bayesiana:** substituir a busca em grade pela otimização bayesiana, que permite explorar simultaneamente múltiplos parâmetros do *pipeline* de forma mais eficiente, reduzindo o efeito da explosão combinatória.
- **Aumento de dados com GANs:** mitigar a escassez de amostras da classe minoritária por meio de redes generativas adversariais (*Generative Adversarial Networks*), gerando exemplos sintéticos de defeitos e ampliando os conjuntos de dados de forma equilibrada.
- **Integração com arquiteturas de detecção:** aprofundar a extensão do método a arquiteturas de detecção de objetos, como o *You Only Look Once* (YOLO, em sua versão v8), cuja avaliação preliminar foi conduzida neste trabalho. Nessa avaliação, a localização espacial das falhas não foi efetivamente aprendida, com valores de mAP50 uma a duas ordens de grandeza abaixo do usualmente considerado aceitável, o que sugere como encaminhamentos o ajuste fino dos hiperparâmetros de treinamento, a ampliação dos conjuntos anotados com caixas delimitadoras e a avaliação da localização em campo.
- **Adoção de métricas robustas ao desbalanceamento:** substituir ou complementar as métricas ponderadas pelo *F1-score* macro e pela acurácia balanceada, de modo a distinguir com maior clareza o modelo que efetivamente aprendeu daquele que apenas replica a classe dominante, e ampliar os conjuntos de teste para reduzir a incerteza das comparações entre arquiteturas.
- **Escalabilidade e execução em borda:** avaliar o custo temporal introduzido pelo *pipeline* de processamento e verificar seu desempenho em dispositivos embarcados (drones/VANTs), de modo a viabilizar a inspeção dinâmica em campo.

5.4 CONSIDERAÇÕES FINAIS

A principal contribuição deste trabalho é o desenvolvimento de uma metodologia estruturada para a inspeção automatizada de linhas de transmissão. Ao mapear de forma sistemática o impacto do processamento de imagens aéreas, o estudo evidenciou a importância de tratar os dados visuais brutos antes da etapa de modelagem.

Os resultados mostraram que não basta investir apenas em arquiteturas complexas de rede neural se as imagens de entrada apresentarem ruídos e limitações de contraste que ocultam os defeitos. Os experimentos adicionais com as arquiteturas YOLO corroboram essa constatação por outra via: em regime de poucos dados anotados, arquiteturas de maior capacidade não superaram uma rede convolucional simples, e a técnica de pré-processamento mais adequada mostrou-se dependente do modelo adotado. As otimizações documentadas indicam que os modelos preditivos atingem seu melhor desempenho quando o pré-processamento fornece imagens mais nítidas e com maior contraste, oferecendo às redes convolucionais melhores condições para identificar as anomalias em componentes inspecionados em campo.

REFERÊNCIAS

- AGARAP, A. F. Deep learning using rectified linear units (relu). **arXiv preprint arXiv:1803.08375**, 2018.
- ALAM, M. et al. Robust fault detection and classification in power transmission lines via ensemble machine learning models. **Scientific Reports**, Nature Publishing Group, v. 15, p. 86554, 2025.
- ALBERT, S. et al. Comparison of image normalization methods for multi-site deep learning. **Applied Sciences**, v. 13, n. 15, p. 8923, 2023.
- ALEX. **Feedforward Neural Networks and Multilayer Perceptrons**. 2020. <https://boostedml.com/2020/04/feedforward-neural-networks-and-multilayer-perceptrons.html>. Acesso em: 21 abr. 2025.
- ALTAIE, A. S. et al. Fault detection on power transmission line based on wavelet transform and scalogram image analysis. **Energies**, MDPI, v. 16, n. 23, p. 7914, 2023. Disponível em: <https://www.mdpi.com/journal/energies>.
- BADIGER, M.; MATHEW, J. A. Retrospective review of activation functions in artificial neural networks. In: **Proceedings of Third International Conference on Communication, Computing and Electronics Systems**. [S.l.]: Springer, 2022, (Lecture Notes in Electrical Engineering, v. 844). p. 905–919.
- BASCLE, B.; BERNIER, O.; LEMAIRE, V. Illumination-invariant color image correction. In: **Lecture Notes in Computer Science**. [S.l.: s.n.], 2006.
- BEN, M. et al. Deep neural network concept for a blind enhancement of document-images. **Applied Sciences**, v. 12, n. 19, p. 9601, 2022.
- CHAWLA, N. V. et al. Smote: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.
- CHEN, T. et al. A simple framework for contrastive learning of visual representations. **International Conference on Machine Learning**, p. 1597–1607, 2020.
- COUTO, G. **Segmentação baseada em Região**. 2024. LinkedIn Artigos. Publicado em 18 de março de 2024.
- DENG, J. et al. Imagenet: A large-scale hierarchical image database. **2009 IEEE Conference on Computer Vision and Pattern Recognition**, IEEE, p. 248–255, 2009.
- DENNANNI, A. **How to deal with image resizing in Deep Learning**. 2019. Disponível em: <https://medium.com/neuronio/how-to-deal-with-image-resizing-in-deep-learning-e5177fad7d89>.
- ENGELLEN, J. E. V.; HOOS, H. H. A survey on semi-supervised learning. **Machine Learning**, Springer, v. 109, n. 2, p. 373–440, 2020.

GAO, B.; PAVEL, L. On the properties of the softmax function with application in game theory and reinforcement learning. **arXiv preprint arXiv:1704.00805**, 2017.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 3. ed. [S.l.]: Prentice Hall, 2008.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016.

GOODFELLOW, I. et al. Generative adversarial nets. **Advances in Neural Information Processing Systems**, v. 27, 2014.

GOSWAMI, S.; SINGH, S. K. A simple deep learning based image illumination correction method for paintings. **Pattern Recognition Letters**, v. 138, p. 392–396, 2020.

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 21, n. 9, p. 1263–1284, 2009.

HUBER, P. J. Robust estimation of a location parameter. **The Annals of Mathematical Statistics**, Institute of Mathematical Statistics, v. 35, n. 1, p. 73–101, 1964.

JOCHER, G.; CHAURASIA, A.; QIU, J. **Ultralytics YOLOv8**. 2023. Acessado em: 29 jul. 2026. Disponível em: <https://github.com/ultralytics/ultralytics>.

JOHNSON, J. M.; KHOSHGOFTAAR, T. M. Survey on deep learning with class imbalance. **Journal of Big Data**, Springer, v. 6, n. 1, p. 27, 2019.

JOSHI, P. **OpenCV with Python By Example**. Packt Publishing, 2015. Disponível em: <https://www.oreilly.com/library/view/opencv-with-python/9781785283932/>.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. **arXiv preprint arXiv:1412.6980**, 2014.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2012.

KUEHLKAMP, A. **Ferramenta de baixo custo para gaze tracking baseado em imagens**. maio 2013. Dissertação (Mestrado) — Universidade do Vale do Itajaí, Itajaí, SC, Brasil, maio 2013. Dissertação de Mestrado em Computação Aplicada.

KUMAR, D. et al. A novel scheme of fault detection in transmission line using image processing. In: **Applications of Computing, Automation and Wireless Systems in Electrical Engineering**. [S.l.]: Springer, 2018, (Lecture Notes in Electrical Engineering, v. 508).

LANGER, S. Approximating smooth functions by deep neural networks with sigmoid activation function. **arXiv preprint arXiv:2010.04596**, 2020.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LEDIG, C. et al. Photo-realistic single image super-resolution using a generative adversarial network. In: **CVPR**. [S.l.: s.n.], 2017. p. 4681–4690.

LIAN, Z.; WANG, H. An image deblurring method using improved u-net model based on multilayer fusion and attention mechanism. **Scientific Reports**, Nature Publishing Group, v. 13, p. 21402, 2023. Disponível em: <https://www.nature.com/articles/s41598-023-47768-4>.

LIN, T.-Y. et al. Focal loss for dense object detection. **Proceedings of the IEEE International Conference on Computer Vision**, p. 2980–2988, 2017.

_____. Microsoft coco: Common objects in context. In: **European Conference on Computer Vision (ECCV)**. [S.l.]: Springer, 2014. p. 740–755.

LIU, C. et al. Insulator faults detection in aerial images from high-voltage transmission lines based on deep learning model. **Appl. Sci.**, v. 11, n. 10, p. 4647, 2021.

LIU, S. et al. A neural network for long-term super-resolution imaging of live cells with reliable confidence quantification. **Nature Biotechnology**, 2025.

MACDONALD, L. Color space transformation using neural networks. In: **Proc. IS&T 27th Color and Imaging Conf.** [S.l.: s.n.], 2019. p. 153–158.

MADUAKO, I. et al. Deep learning for component fault detection in electricity transmission lines. **Journal of Big Data**, v. 9, n. 1, p. 63, 2022.

MAHARANA, K.; MONDAL, S.; NEMADE, B. A review: Data pre-processing and data augmentation techniques. **Global Transitions Proceedings**, v. 3, n. 1, p. 91–99, 2022.

MALL, P. K. et al. A comprehensive review of deep neural networks for medical image processing: Recent developments and future opportunities. **Healthcare Analytics**, Elsevier, v. 4, p. 100216, 2023. Disponível em: <https://doi.org/10.1016/j.health.2023.100216>.

OBERWEGER, F.; WENDEL, A.; BISCHOF, H. **XAI-guided Insulator Anomaly Detection for Imbalanced Datasets**. 2024. <https://arxiv.org/abs/2409.16821>.

PAN, S. J.; YANG, Q. A survey on transfer learning. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 22, n. 10, p. 1345–1359, 2010.

PANDEY, N. **Mastering Image Contrast: A Step-by-Step Guide to Enhancing Image**. 2023. Acessado em: 20 abr. 2025. Disponível em: <https://www.nomidl.com/computer-vision/mastering-image-contrast/>.

PEI, X. et al. Robustness of machine learning to color, size change, normalization, and image enhancement on micrograph datasets with large sample differences. **Materials & Design**, 2023.

PENG, H. et al. Edf-yolov5: An improved algorithm for power transmission line defect detection based on yolov5. **Electronics**, MDPI, v. 13, n. 1, p. 148, 2023.

PORR, B. et al. Real-time noise cancellation with deep learning. **PLOS ONE**, v. 17, n. 11, p. e0277974, 2022.

RASHID, M. e. a. A survey of neural network optimization algorithms. **Artificial Intelligence Review**, Springer, 2020.

RODRIGUES, L. F.; NALDI, M. C.; MARI, J. F. Comparing convolutional neural networks and preprocessing techniques for hep-2 cell classification in immunofluorescence images. **Computers in Biology and Medicine**, Elsevier, v. 116, p. 103542, 2020. Acesso em: 24 mar. 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0010482519303993>.

RUDER, S. An overview of gradient descent optimization algorithms. **arXiv preprint arXiv:1609.04747**, 2016.

SABOTTKE, C. F. et al. The effect of image resolution on deep learning in radiography. **Radiology: Artificial Intelligence**, v. 2, n. 1, p. e190015, 2020.

SALVI, M. et al. The impact of pre- and post-image processing techniques on deep learning frameworks: A comprehensive review for digital pathology image analysis. **Computers in Biology and Medicine**, Elsevier, v. 128, p. 104129, 2021.

SHARMA, A. et al. Deep learning models for digital image processing: a review. **Artificial Intelligence Review**, 2024.

SHORTEN, C.; KHOSHGOFTAAR, T. M. A survey on image data augmentation for deep learning. **Journal of Big Data**, Springer, v. 6, n. 1, p. 60, 2019.

SILVA, A. L. Vieira-e et al. **Unifying Public Datasets for Insulator Detection and Fault Classification in Electrical Power Lines**. 2020. <https://github.com/heitorcfelix/public-insulator-datasets>.

SOARES, P. L. B.; SILVA, J. P. d. Aplicação de redes neurais artificiais em conjunto com o método vetorial da propagação de feixes na análise de um acoplador direcional baseado em fibra Ótica. **Revista Brasileira de Computação Aplicada**, v. 3, n. 2, p. 58–72, 2011.

STEFFENS, C. R. et al. Cnn based image restoration: Adjusting ill-exposed srgb images in post-processing. **Journal of Intelligent & Robotic Systems**, v. 99, n. 3–4, p. 609–627, 2020.

SUMIDA, I. et al. Deep convolutional neural network for reduction of contrast-enhanced region on ct images. **Journal of Radiation Research**, v. 60, n. 5, p. 586–594, 2019.

The MathWorks, Inc. **Wavelet Denoising**. 2023. Acesso em 20 abr. 2025. Disponível em: <https://www.mathworks.com/help/release/R2021a/wavelet/ug/wavelet-denoising.html>.

_____. **Deblurring Images Using the Lucy-Richardson Algorithm**. 2025. MathWorks Help Center - Image Processing Toolbox. Disponível em: <https://www.mathworks.com/help/images/deblurring-images-using-the-lucy-richardson-algorithm.html>.

TIELEMAN, T.; HINTON, G. **Lecture 6.5—RMSProp: Divide the gradient by a running average of its recent magnitude**. 2012. COURSE: Neural Networks for Machine Learning.

TORRES, L. **Curva ROC y AUC en Python**. 2025. Acesso em: 1 jun. 2025. Disponível em: <https://www.themachinelearners.com/curva-roc-vs-prec-recall/>.

VEEN, F. V. **The Neural Network Zoo**. 2016. <https://www.asimovinstitute.org/neural-network-zoo/>. Acesso em: 21 abr. 2025.

VENTURELLI, M. **The dangers behind image resizing**. 2021. <https://zuru.tech/blog/the-dangers-behind-image-resizing>. Accessed: 2025-04-20.

WANG, L. et al. Sustainable analysis of insulator fault detection based on fine-grained visual optimization. **Sustainability**, v. 15, n. 4, p. 3456, 2023.

YANG, Z. et al. Using convolutional neural network models illumination estimation according to light colors. **Optics Communications**, v. 513, p. 128108, 2022.

YE, J. et al. Detecting usm image sharpening by using cnn. **Signal Processing: Image Communication**, v. 68, p. 258–264, 2018.

YU, J. et al. Edge detection using a neural network. **Pattern Recognition**, v. 27, n. 12, p. 1653–1662, 1994.

ZHANG, Z. et al. Image detection of insulator defects based on morphological processing and deep learning. **Energies**, v. 15, n. 7, p. 2465, 2022.

_____. Edge detection networks inspired by neural mechanisms of selective attention in biological visual cortex. **Frontiers in Neuroscience**, v. 16, p. 1073484, 2022.

ZHANG, Z.; SABUNCU, M. R. Generalized cross entropy loss for training deep neural networks with noisy labels. **Advances in Neural Information Processing Systems (NeurIPS)**, v. 31, 2018. ArXiv:1805.07836.

ZHENG, J. et al. Insulator-defect detection algorithm based on improved yolov7. **Sensors**, MDPI, v. 22, n. 22, p. 8801, 2022.

ZOU, H. et al. A bolt defect detection method for transmission lines based on improved yolov5. **Frontiers in Energy Research**, Frontiers, v. 12, p. 1269528, 2024.

ÖZTÜRK, Ş.; AKDEMİR, B. Effects of histopathological image pre-processing on convolutional neural networks. In: ELSEVIER. **Procedia Computer Science**. [S.l.], 2018. v. 132, p. 396–403. International Conference on Computational Intelligence and Data Science (IC-CIDS 2018).