

UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS NATURAIS E EXATAS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE
IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS
EM CADEIAS DE ISOLADORES**

Santa Maria, RS
2025

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS
À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**. Defesa realizada por videoconferência.

Orientador: Prof. Dr. Daniel Pinheiro Bernardon

Coorientador: Prof. Dr. Paulo César Vargas Luz

Santa Maria, RS
2025

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS
À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**.

Aprovado em 8 de dezembro de 2025:

Daniel Pinheiro Bernardon, Dr. (UFSM)
(Presidente/Orientador)

Paulo César Vargas Luz, Dr. (UFSM)
(Coorientador)

Banca Um, Dra. (UFSM)

Banca Dois, Dr. (UFSM)

Santa Maria, RS
2025

RESUMO

MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES

AUTOR: Luan Willig Silveira
Orientador: Daniel Pinheiro Bernardon
Coorientador: Paulo César Vargas Luz

Escreva seu resumo aqui! Você pode digitá-lo diretamente neste arquivo ou usar o comando input. O resumo deve ter apenas uma página, desde o cabeçalho até as palavras chave. Caso seu resumo seja maior, use comandos para diminuir espaçamento e fonte (até um mínimo de 10pt) no texto. Segundo a MDT, é preciso que os resumos tenham, no máximo, 250 palavras para trabalhos de conclusão de curso de graduação, pós-graduação e iniciação científica e até 500 palavras para dissertações e teses.

Palavras-chave: Processamento de Imagens. Redes Neurais Artificiais. Aprendizado de Máquina. Métricas de Qualidade. Classificação de Imagens. Detecção de Objetos. Regressão. Dataset. Combinação de Processamentos. Otimização. Deep Learning. Segmentação de Imagens. Eficiência Computacional. Redes Convolucionais (CNN). Comparação de Modelos. Inteligência Artificial.

ABSTRACT

IMAGE PROCESSING ENHANCEMENT METHOD APPLIED TO FAULT DETECTION AND CLASSIFICATION IN INSULATOR STRINGS

AUTHOR: Luan Willig Silveira
ADVISOR: Daniel Pinheiro Bernardon
CO-ADVISOR: Paulo César Vargas Luz

Write your abstract here! As recomendações do resumo também se aplicam ao abstract. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: Keyword 1. Keyword 2. Keyword 3. (...)

SUMÁRIO

1	INTRODUÇÃO	8
1.1	PROPOSTA	8
1.2	OBJETIVO GERAL	9
1.3	OBJETIVOS ESPECÍFICOS	10
1.4	JUSTIFICATIVA	10
1.5	CRONOGRAMA	11
2	TRABALHOS RELACIONADOS	12
2.1	ANÁLISE SUSTENTÁVEL DA DETECÇÃO DE FALHAS EM ISOLADORES BASEADA EM OTIMIZAÇÃO VISUAL REFINADA	12
2.2	DETECÇÃO DE FALHAS EM ISOLADORES EM IMAGENS AÉREAS DE LINHAS DE TRANSMISSÃO DE ALTA VOLTAGEM BASEADA EM MODELO DE APRENDIZADO PROFUNDO	12
2.3	DETECÇÃO DE DEFEITOS EM ISOLADORES POR IMAGEM BASEADA EM PROCESSAMENTO MORFOLÓGICO E APRENDIZADO PROFUNDO ...	12
2.4	COMPARANDO REDES NEURAIS CONVOLUCIONAIS E TÉCNICAS DE PRÉ- PROCESSAMENTO PARA CLASSIFICAÇÃO DE CÉLULAS HEP-2 EM IMAGENS DE IMUNOFLUORESCÊNCIA	14
2.5	EFEITOS DO PRÉ-PROCESSAMENTO DE IMAGENS HISTOPATOLÓGICAS EM REDES NEURAIS CONVOLUCIONAIS	15
2.6	O IMPACTO DE TÉCNICAS DE PRÉ-PROCESSAMENTO E PÓS-PROCESSAMENTO DE IMAGENS EM FRAMEWORKS DE APRENDIZADO PROFUNDO: UMA REVISÃO ABRANGENTE PARA ANÁLISE DE IMAGENS DE PATOLOGIA DIGITAL	15
2.7	RESUMO DOS TRABALHOS	16
2.8	JUSTIFICATIVA DA RELEVÂNCIA DA METODOLOGIA PROPOSTA	16
2.9	TABELA COMPARATIVA DOS TRABALHOS	16
2.10	CONSIDERAÇÕES FINAIS DO CAPÍTULO	17
3	REVISÃO BIBLIOGRÁFICA	18
3.1	PROCESSAMENTO DE IMAGENS	18
3.1.1	Normalização	19
3.1.2	Redimensionamento e Recorte	20
3.1.3	Aumento de Dados	21
3.1.4	Redução de Ruído	22
3.1.5	Ajuste de Contraste e Brilho	23
3.1.6	Aumento de Nitidez	24
3.1.7	Conversão de Espaço de Cores	25

3.1.8	Restauração e Desembacamento de Imagens	25
3.1.9	Detecção de Bordas	26
3.1.10	Correção de Iluminação.....	27
3.1.11	Super-Resolução	28
3.1.12	Conclusão parcial da seção	28
3.2	REDES NEURAIS	29
3.2.1	Tipos de redes neurais	30
3.2.1.1	Perceptron (P), Feed Forward Network (FFN)	30
3.2.1.2	Convolutional neural network (CNN) ou Deep convolutional network (DCN)	32
3.2.2	Funções de ativação.....	33
3.2.2.1	ReLU (Rectified Linear Unit)	33
3.2.2.2	Sigmoid	33
3.2.2.3	Softmax	33
3.2.2.4	Regras gerais para escolha de funções de ativação	34
3.2.3	Funções de Custo.....	34
3.2.3.1	Erro Médio Quadrático (MSE)	34
3.2.3.2	Erro Médio Absoluto (MAE)	35
3.2.3.3	Função Huber	35
3.2.3.4	Entropia Cruzada Binária	35
3.2.3.5	Entropia Cruzada Categórica	35
3.2.4	Otimizadores	36
3.3	DATASETS	36
3.4	MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO DE MODELOS	39
4	METODOLOGIA.....	43
4.1	DEFINIÇÃO DAS MÉTRICAS PARA AVALIAR EFICÁCIA DOS PROCESSAMENTOS	43
4.2	ESCOLHA DO TIPO DE MODELO DE REDE NEURAL	45
4.3	SELEÇÃO DOS DATASETS PARA AVALIAÇÃO	45
4.4	METODOLOGIA PARA COMBINAÇÃO DE PROCESSAMENTOS UNITÁRIOS	45
4.5	IMPLEMENTAÇÃO DE UM MÉTODO DE AJUSTE AUTOMÁTICO DE PARÂMETROS.....	45
4.6	CONSTRUÇÃO DE REDES NEURAIS PARA AVALIAÇÃO DOS PROCESSAMENTOS	45
4.7	TESTES COM DIFERENTES ARQUITETURAS E ANÁLISE DE VARIAÇÕES NOS RESULTADOS	45
5	COLETA E ANÁLISE DE RESULTADOS	46
5.1	IMPACTO DOS MODELOS NO DESEMPENHO DOS PROCESSAMENTOS ..	46
5.2	INFLUÊNCIA DOS DATASETS NOS RESULTADOS	46
5.3	COMPARAÇÃO ENTRE DIFERENTES ESTRATÉGIAS DE PROCESSAMENTO ..	46

6	CONCLUSÃO	47
6.1	SÍNTESE DOS RESULTADOS OBTIDOS	47
6.2	LIMITAÇÕES E DESAFIOS ENCONTRADOS	47
6.3	SUGESTÕES PARA PESQUISAS FUTURAS.....	47
	REFERÊNCIAS BIBLIOGRÁFICAS	48

1 INTRODUÇÃO

1.1 PROPOSTA

O presente estudo tem como objetivo desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores. Para isso, serão estabelecidas métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento. Além disso, serão construídos modelos de redes neurais para avaliar o desempenho dos processamentos, podendo abranger tarefas como classificação, detecção e regressão. No decorrer do estudo, serão construídos modelos de redes neurais voltados para a avaliação do desempenho das técnicas de processamento de imagem, sem a intenção de definir um modelo ideal.

Também será analisado o impacto da escolha do modelo de rede neural no desempenho do processamento, visto que diferentes modelos podem gerar resultados distintos para um mesmo processamento. A influência do dataset na eficácia do processamento será outro aspecto a ser investigado, considerando possíveis variações nos resultados devido ao uso de diferentes conjuntos de dados. Para aprimorar os processamentos de imagem, será desenvolvida uma metodologia que permita a combinação de diferentes processamentos unitários (processamentos de imagem que realizam uma única operação). Além disso, será criado um método de ajuste automático de parâmetros das técnicas de processamento de imagem, com o intuito de otimizar seus resultados sem exigir extensa intervenção manual.

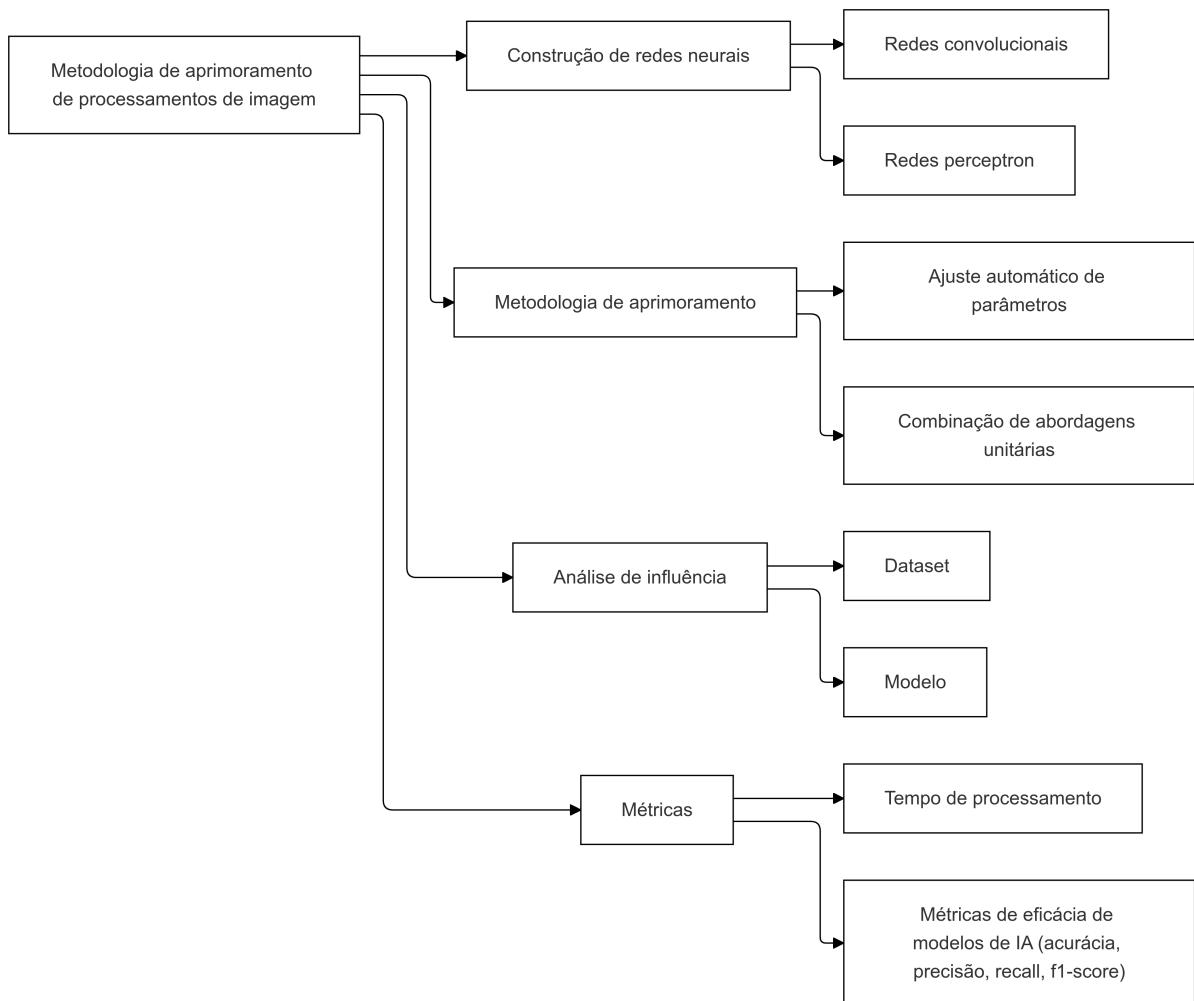
A metodologia proposta será desenvolvida dentro de um conjunto de restrições previamente estabelecidas, garantindo um escopo bem delimitado e viável dentro do período de realização da dissertação. Primeiramente, o estudo será restrito à detecção e classificação de falhas em cadeias de isoladores elétricos, não abrangendo outros componentes elétricos. O uso de imagens previamente adquiridas será uma diretriz, de modo que apenas imagens já disponíveis ou capturadas por métodos convencionais serão utilizadas, sem o desenvolvimento de novas técnicas de aquisição de imagens. Além disso, a metodologia será aplicada exclusivamente a técnicas de processamento de imagem já conhecidas, sem a criação de novos algoritmos de base.

Os modelos de redes neurais desenvolvidos terão o propósito único de avaliar o impacto das redes sobre os processamentos de imagem, sem a intenção de definir um modelo definitivo para diagnóstico industrial. A análise será conduzida utilizando conjuntos de dados já existentes ou obtidos por métodos convencionais, sem a necessidade de criar um novo dataset específico para o estudo. A otimização contemplada estará limitada ao

ajuste de parâmetros das técnicas existentes, não incluindo o desenvolvimento de novas abordagens baseadas em inteligência artificial para otimização dos processamentos. Por fim, toda a avaliação será realizada em ambiente controlado, sem a realização de testes em ambientes industriais reais.

A Figura 1 ilustra o diagrama da proposta de metodologia.

Figura 1 – Diagrama da proposta de metodologia



Fonte: Autor.

1.2 OBJETIVO GERAL

O objetivo geral deste estudo é desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores.

1.3 OBJETIVOS ESPECÍFICOS

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

- Estabelecer métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento.
- Determinar o tipo de modelo de redes neurais ideal para avaliar o desempenho dos processamentos, podendo abranger classificação, detecção e regressão.
- Construir modelos de redes neurais destinados à avaliação do desempenho das técnicas de processamento de imagem, sem o intuito de encontrar um modelo definitivo.
- Analisar o impacto da escolha do modelo de rede neural no desempenho do processamento, considerando que diferentes modelos podem gerar diferentes resultados para um mesmo processamento.
- Avaliar a influência do dataset na eficácia do processamento, considerando possíveis variações nos resultados devido à utilização de diferentes conjuntos de dados.
- Desenvolver uma metodologia para o aprimoramento dos processamentos de imagem por meio da combinação de diferentes abordagens unitárias.
- Criar um método de ajuste automático de parâmetros dos processamentos de imagem, visando otimizar seus resultados sem a necessidade de intervenção manual extensa.

1.4 JUSTIFICATIVA

A crescente demanda por sistemas automatizados de inspeção de cadeias de isoladores evidencia a necessidade de técnicas avançadas de processamento de imagem para a detecção precoce de falhas. Conforme demonstrado por Gonzalez e Woods (GONZALEZ; WOODS, 2008), a análise digital de imagens permite extrair características relevantes para identificar anomalias em componentes elétricos, possibilitando diagnósticos mais precisos. Ademais, o emprego de redes neurais tem se destacado na resolução de problemas complexos de classificação e detecção, conforme ressaltado por LeCun et al. (LECUN; Bengio; HINTON, 2015) e Krizhevsky et al. (KRIZHEVSKY; SUTSKEVER; HINTON, 2012), contribuindo para a robustez dos sistemas de inspeção.

Estudos recentes apontam que a combinação de diferentes técnicas de processamento de imagem, aliada ao ajuste automático de parâmetros, pode resultar em melhorias

significativas no desempenho dos sistemas de diagnóstico (LI et al., 2019). Assim, a proposta deste trabalho visa desenvolver uma metodologia que integre esses avanços, buscando não apenas aprimorar a acurácia e a eficiência dos processamentos, mas também possibilitar uma análise comparativa que leve em conta a influência de diferentes modelos e datasets.

Dessa forma, esta dissertação justifica-se pela necessidade de inovar na abordagem de detecção e classificação de falhas em cadeias de isoladores, promovendo ganhos práticos para a segurança e manutenção das redes elétricas, e contribuindo para a evolução do estado da arte em processamento de imagem e aprendizado de máquina.

1.5 CRONOGRAMA

A seguir, é apresentado um cronograma de atividades para garantir a organização e a execução das tarefas.

Etapa	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
1. Introdução	✓										
2. Revisão Bibliográfica	✓	✓	✓	✓	✓						
3. Metodologia		✓	✓	✓	✓	✓	✓				
4. Implementação dos Modelos							✓	✓			
5. Coleta e Análise de Resultados							✓	✓	✓	✓	
6. Conclusão e Redação Final								✓	✓	✓	
7. Defender											✓

Tabela 1 – Cronograma de Atividades

2 TRABALHOS RELACIONADOS

2.1 ANÁLISE SUSTENTÁVEL DA DETECÇÃO DE FALHAS EM ISOLADORES BASEADA EM OTIMIZAÇÃO VISUAL REFINADA

O primeiro estudo aborda a detecção de falhas em isoladores em linhas de transmissão aéreas, destacando a vulnerabilidade desses componentes a fatores ambientais. A inspeção manual é ineficaz devido ao alto volume de dados e à complexidade dos fundos das imagens, levando à aplicação da rede neural convolucional de atenção regressiva (RA-CNN). O método proposto melhora a acurácia da detecção ao empregar extração de características em múltiplas escalas e operações recursivas, com otimização pelo algoritmo de Enxame de Partículas (PSO). Os resultados indicam que a RA-CNN (1+2+3) atinge 85,3% de acurácia, superando os modelos FCAN e MG-CNN. Além disso, a abordagem proposta demonstra maior eficiência em tempo real, atingindo 25,4 FPS. (WANG et al., 2023)

2.2 DETECÇÃO DE FALHAS EM ISOLADORES EM IMAGENS AÉREAS DE LINHAS DE TRANSMISSÃO DE ALTA VOLTAGEM BASEADA EM MODELO DE APRENDIZADO PROFUNDO

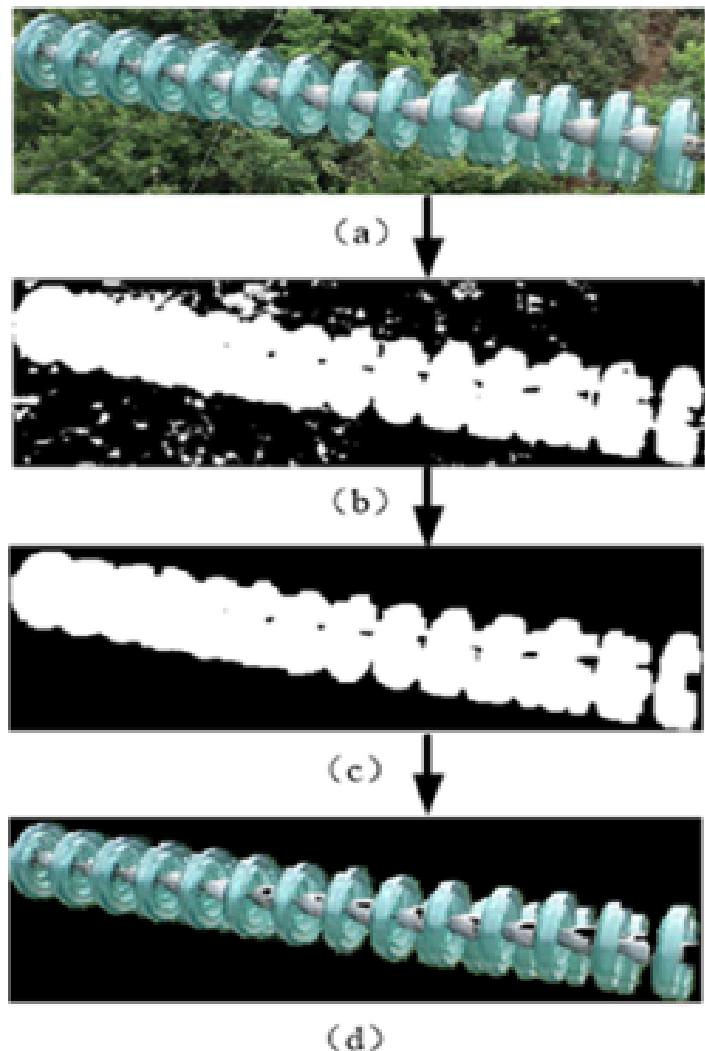
O segundo estudo foca na detecção de falhas em isoladores por meio de imagens aéreas, utilizando um modelo YOLO modificado, denominado CSPD-YOLO, baseado no YOLO-v3 e na Rede Parcial de Estágio Cruzado. A pesquisa envolve a criação do conjunto de dados 'InSF-detection', composto por 1.331 imagens e 2.104 falhas rotuladas. O modelo CSPD-YOLO se destaca por uma alta acurácia (AP = 98,18%) e eficiência no processamento (0,011 s), superando modelos tradicionais como YOLO-v3 e YOLO-v4. A análise qualitativa indica que o método é eficaz mesmo em cenários complexos, como presença de rios, vegetação e torres de energia. (LIU et al., 2021)

2.3 DETECÇÃO DE DEFEITOS EM ISOLADORES POR IMAGEM BASEADA EM PROCESSAMENTO MORFOLÓGICO E APRENDIZADO PROFUNDO

O terceiro estudo propõe um método híbrido para detecção de defeitos em isoladores, combinando aprendizado profundo (Faster RCNN) com processamento morfológico.

A segmentação das imagens utiliza técnicas de transformação de forma para identificação e separação de isoladores, enquanto a detecção de falhas é realizada por um modelo matemático aplicado a imagens binárias. O Faster RCNN alcança $AP = 0,9175$ e $recall = 0,98$, superando abordagens baseadas em ResNet, YOLO e LBP+SVM. Além disso, a análise de desempenho em diferentes níveis de voltagem e condições de ruído demonstra a robustez do modelo (ZHANG et al., 2022). O processo de segmentação realizado no trabalho é apresentado na Figura 2.

Figura 2 – Segmentação de isoladores

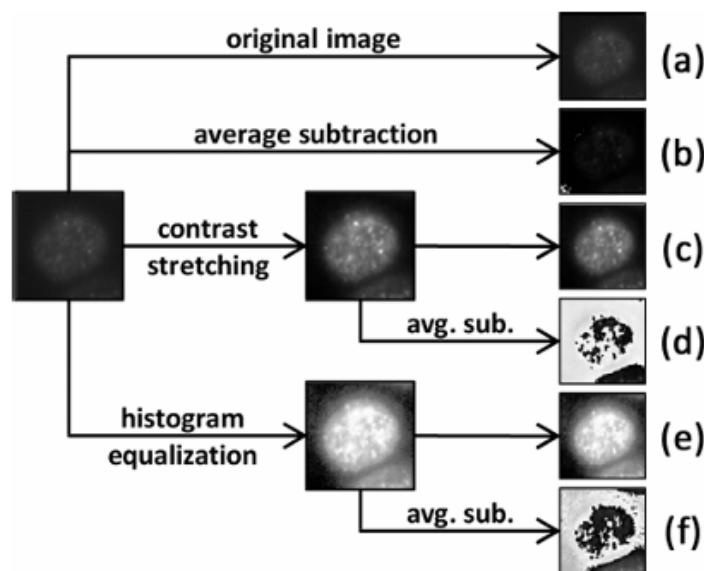


Fonte: Zhang et al. (2022).

2.4 COMPARANDO REDES NEURAIS CONVOLUCIONAIS E TÉCNICAS DE PRÉ-PROCESSAMENTO PARA CLASSIFICAÇÃO DE CÉLULAS HEp-2 EM IMAGENS DE IMUNOFLUORESCÊNCIA

A pesquisa avalia seis estratégias de pré-processamento e cinco arquiteturas de CNNs de última geração para classificar células HEp-2 em imagens de imunofluorescência, uma tarefa crítica em diagnósticos médicos. Métodos como aumento de dados (rotações, espelhamentos), ajuste fino e otimização de hiperparâmetros foram testados em conjunto com arquiteturas como Inception-V3 e ResNet. Surpreendentemente, o melhor desempenho, com 98,28% de precisão, foi alcançado ao treinar o modelo Inception-V3 do zero, utilizando apenas aumento de dados sem pré-processamento adicional. A conclusão sugere que, para esse tipo de imagem, técnicas tradicionais de pré-processamento podem ser menos impactantes quando o aumento de dados é bem implementado, desafiando a necessidade de etapas complexas de preparação. A contribuição do estudo está em mostrar que, em cenários específicos como imagens médicas de imunofluorescência, estratégias simples podem superar abordagens mais elaboradas, oferecendo uma alternativa eficiente para aplicações práticas em classificação (RODRIGUES; NALDI; MARI, 2020). A Figura 3 apresenta os métodos e combinações de pré-processamentos utilizados no trabalho.

Figura 3 – Etapas do método proposto



Fonte: Rodrigues, Naldi e Mari (2020).

2.5 EFEITOS DO PRÉ-PROCESSAMENTO DE IMAGENS HISTOPATOOLÓGICAS EM REDES NEURAIS CONVOLUCIONAIS

O artigo analisa como diferentes níveis de pré-processamento afetam a classificação de imagens histopatológicas por CNNs, dividindo os dados em quatro categorias: imagens originais, pré-processadas normalmente (com redução de ruído e aprimoramento de células), outras pré-processadas normalmente e excessivamente pré-processadas (com operações morfológicas adicionais). Os experimentos revelam que o pré-processamento normal melhora a precisão ao remover ruídos de fundo e realçar características celulares, mas o excesso de processamento não agrega valor e pode até degradar o desempenho ao eliminar informações úteis. A conclusão enfatiza a importância de um equilíbrio no pré-processamento, recomendando ajustes moderados para maximizar a eficácia das CNNs em imagens histopatológicas. A contribuição do trabalho é fornecer uma análise comparativa detalhada que orienta pesquisadores e profissionais na escolha de técnicas de pré-processamento, evitando exageros que comprometam a qualidade dos dados em aplicações médicas (ÖZTÜRK; AKDEMİR, 2018).

2.6 O IMPACTO DE TÉCNICAS DE PRÉ-PROCESSAMENTO E PÓS-PROCESSAMENTO DE IMAGENS EM FRAMEWORKS DE APRENDIZADO PROFUNDO: UMA REVISÃO ABRANGENTE PARA ANÁLISE DE IMAGENS DE PATOLOGIA DIGITAL

Este trabalho explora como técnicas tradicionais de pré- e pós-processamento de imagens, como redução de ruído, correção de iluminação e segmentação, melhoraram o desempenho de redes neurais em tarefas de patologia digital, incluindo classificação (tecido saudável vs. canceroso), detecção (contagem de linfócitos) e segmentação (núcleos e glândulas). Ao analisar uma ampla gama de estudos, os autores concluem que essas técnicas são indispensáveis para lidar com a variabilidade e complexidade das imagens médicas, melhorando significativamente a precisão e a robustez dos modelos de aprendizado profundo. A revisão destaca que o pós-processamento, como refinamento de contornos, também desempenha um papel crucial em tarefas de segmentação. A contribuição do artigo está em consolidar evidências sobre a eficácia dessas abordagens, oferecendo um guia abrangente para pesquisadores que buscam integrar métodos tradicionais ao treinamento de redes neurais, especialmente em contextos de patologia digital onde a qualidade dos dados é crítica (SALVI et al., 2021).

2.7 RESUMO DOS TRABALHOS

Diversos estudos abordam o impacto do pré-processamento de imagens na análise por redes neurais convolucionais (CNNs) e outros modelos de aprendizado profundo. O estudo de Liu et al. (2021) e Wang et al. (2023) optam por não realizar processamentos significativos, utilizando apenas redimensionamento e normalização.

Por outro lado, Öztürk e Akdemir (2018) investigam diferentes algoritmos de pré-processamento, incluindo remoção de fundo, filtros de suavização e equalização de histograma, além de um método de sobre-processamento baseado em limiar adaptativo. Rodrigues, Naldi e Mari (2020) testam técnicas como redimensionamento, alongamento de contraste, equalização de histograma e subtração da média, constatando que o uso de imagens originais favorece o desempenho da CNN, enquanto o data augmentation tem impacto positivo. Salvi et al. (2021) destacam que técnicas como remoção de artefatos, normalização de cor e seleção de patches melhoram a precisão dos modelos e reduzem o tempo computacional. Por fim, Zhang et al. (2022) exploram a segmentação de isoladores para otimizar a classificação.

2.8 JUSTIFICATIVA DA RELEVÂNCIA DA METODOLOGIA PROPOSTA

Os trabalhos analisados demonstram a importância do pré-processamento na análise de imagens, mas também indicam que determinadas abordagens podem comprometer o desempenho da CNN. Em especial, Rodrigues, Naldi e Mari (2020) evidenciam que a eliminação de ruídos e artefatos pode não ser sempre benéfica. Além disso, Salvi et al. (2021) reforçam que técnicas de segmentação e normalização podem aprimorar a análise quando aplicadas corretamente. No entanto, nenhum dos estudos analisados aborda a metodologia específica proposta nesta dissertação, o que destaca sua inovação e potencial contribuição para a área.

2.9 TABELA COMPARATIVA DOS TRABALHOS

A tabela 2 compara os resultados de diferentes estudos sobre pré-processamento de imagens e seu impacto nos modelos de classificação de imagens. Os estudos variam desde melhorias no desempenho até riscos de sobre-processamento, destacando a falta de consenso e a necessidade de novas abordagens. A metodologia proposta neste trabalho busca preencher essa lacuna ao introduzir um método inovador para determinar os processamentos mais eficientes e otimizar os parâmetros de processamento, oferecendo uma solução mais robusta e adaptável para análise de imagens.

Trabalho	Resultado do pré-processamento
Liu et al. (2021)	Sem impacto significativo
Öztürk e Akdemir (2018)	Melhorou contraste, mas risco de sobre-processamento
Rodrigues, Naldi e Mari (2020)	Afetou negativamente a CNN; data augmentation foi positivo
Salvi et al. (2021)	Melhorou precisão e reduziu tempo computacional
Wang et al. (2023)	Sem impacto significativo
Zhang et al. (2022)	Melhorou o desempenho do modelo

Tabela 2 – Comparaçāo dos trabalhos relacionados

A análise desses estudos reforça a lacuna existente na literatura e a necessidade de uma nova abordagem, como a metodologia proposta nesta dissertação. A proposta de um método para determinar os processamentos mais eficientes e otimizar os parâmetros de processamento representa uma contribuição significativa para a área de análise de imagens. Através da combinação de técnicas de pré-processamento adaptativo e otimização de parâmetros, o trabalho busca não apenas melhorar o desempenho dos modelos de aprendizado profundo, mas também oferecer uma solução prática e eficiente para cenários complexos. Essa abordagem pode impactar positivamente diversas áreas, como diagnóstico médico, inspeção industrial e análise de imagens aéreas, ao proporcionar resultados mais precisos e confiáveis. Além disso, a metodologia proposta pode servir como base para futuras pesquisas e aplicações em diferentes contextos, ampliando as possibilidades de utilização das redes neurais em tarefas desafiadoras de classificação e detecção de objetos em imagens.

2.10 CONSIDERAÇĀOES FINAIS DO CAPÍTULO

A metodologia apresentada neste trabalho se diferencia dos estudos revisados ao introduzir um novo enfoque que não foi explorado anteriormente. Enquanto os trabalhos existentes se concentram em construção de modelos de redes neurais e utilização de técnicas tradicionais de pré-processamento e normalização, a metodologia deste trabalho propõe a criação de um método para determinar os processamentos mais eficientes das imagens, além de um método de otimização dos parâmetros de processamento. Além disso, a pesquisa busca integrar novas abordagens que possam aprimorar a análise de dados em contextos variados, contribuindo para a evolução das técnicas de aprendizado profundo. A implementação dessas novas abordagens poderá oferecer insights valiosos para futuras investigações e aplicações práticas.

3 REVISÃO BIBLIOGRÁFICA

O processamento de imagens é uma ferramenta essencial para garantir a confiabilidade do Sistema Elétrico de Potência (SEP), especialmente na detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica. Essa técnica permite identificar problemas em componentes como isoladores, fixadores e suportes, que, se não tratados, podem causar interrupções no fornecimento de energia. O uso de imagens capturadas por drones ou câmeras especiais facilita a inspeção de grandes extensões de linhas de transmissão, reduzindo custos e aumentando a segurança ao evitar a necessidade de intervenções manuais em locais de difícil acesso (EZE et al., 2022).

Métodos avançados de análise de imagens, como os baseados em aprendizado profundo, ajudam a reconhecer padrões que indicam falhas, mesmo em condições adversas, como baixa visibilidade ou equipamentos desgastados (ALTAIE et al., 2023). Essas abordagens são particularmente úteis em regiões com infraestrutura antiga, onde a manutenção regular é desafiadora. Além disso, o processamento de imagens possibilita uma resposta rápida a problemas, minimizando o impacto de falhas na rede elétrica e melhorando a continuidade do serviço (KUMAR et al., 2023).

A automação proporcionada pelo processamento de imagens também contribui para a eficiência operacional. Técnicas modernas permitem monitorar equipamentos em tempo real, identificando danos antes que se tornem críticos (EZE et al., 2022). Isso é crucial para manter a estabilidade do SEP, especialmente em áreas remotas ou com alta demanda energética. Assim, o processamento de imagens não apenas aprimora a manutenção das linhas de transmissão, mas também reforça a segurança e a confiabilidade do fornecimento de energia elétrica.

A seguir, será apresentada uma revisão dos principais conceitos e técnicas de processamento de imagens, que podem ser aplicados na detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica.

3.1 PROCESSAMENTO DE IMAGENS

O processamento de imagens desempenha um papel fundamental no contexto do Sistema Elétrico de Potência (SEP), especialmente em atividades de inspeção, manutenção preditiva e monitoramento de ativos em linhas de transmissão. Com o uso crescente de drones, câmeras térmicas e sensores ópticos, a obtenção de imagens de componentes da rede elétrica tornou-se mais acessível e eficiente. No entanto, a qualidade e a variabilidade dessas imagens exigem técnicas robustas de pré-processamento para garantir resultados precisos em tarefas como a detecção de falhas, corrosões, aquecimentos anô-

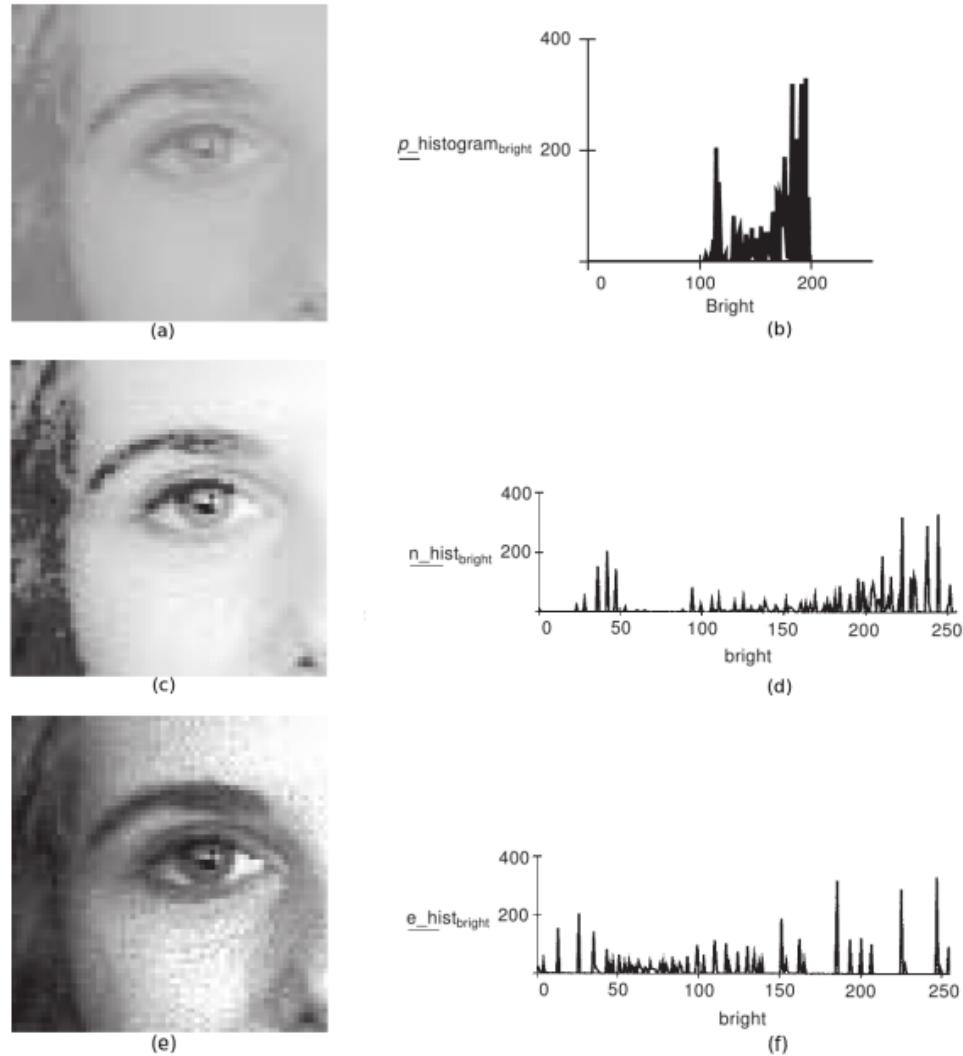
malos e objetos estranhos nas estruturas. Esta seção apresenta os principais métodos de processamento de imagens empregados para preparar dados visuais que serão utilizados em modelos baseados em aprendizado de máquina e redes neurais, contribuindo diretamente para a confiabilidade, segurança e eficiência operacional do SEP.

3.1.1 Normalização

A normalização é uma etapa fundamental no pré-processamento de imagens para redes neurais, pois padroniza os valores dos pixels, facilitando a convergência durante o treinamento e melhorando a generalização do modelo. Um método comum é a normalização de valores de pixels, que escala os valores para intervalos como [0,1] ou [-1,1], frequentemente realizada dividindo os valores originais pelo máximo possível (por exemplo, 255 para imagens de 8 bits) (SHARMA et al., 2024). Outro método é a normalização Z-score, que subtrai a média dos pixels e divide pelo desvio padrão, resultando em dados com média zero e variância unitária (CHEN et al., 2023). A equalização de histograma também é utilizada para redistribuir as intensidades dos pixels, aumentando o contraste e destacando detalhes em imagens de baixa qualidade (CHEN et al., 2023). Além disso, a padronização de cores, como subtrair os valores médios dos canais RGB, centraliza os dados em torno de uma distribuição normal, o que é particularmente útil para redes convolucionais (MALLA et al., 2023). Técnicas mais avançadas, como a normalização por percentis, utilizam o 5º e o 95º percentil como limites para lidar com valores discrepantes, enquanto a correspondência de histogramas ajusta a distribuição de intensidades com base em pontos de referência (ISOLA et al., 2023). Essas abordagens garantem que as redes neurais processem dados de forma consistente, reduzindo a sensibilidade a variações de iluminação ou escala, especialmente em tarefas de visão computacional (SHARMA et al., 2024).

A Figura 4 ilustra o processo de normalização de imagens, onde a imagem original é transformada em uma imagem normalizada, facilitando a extração de características relevantes.

Figura 4 – Normalização de Imagens



Fonte: Kuehlkamp (2013).

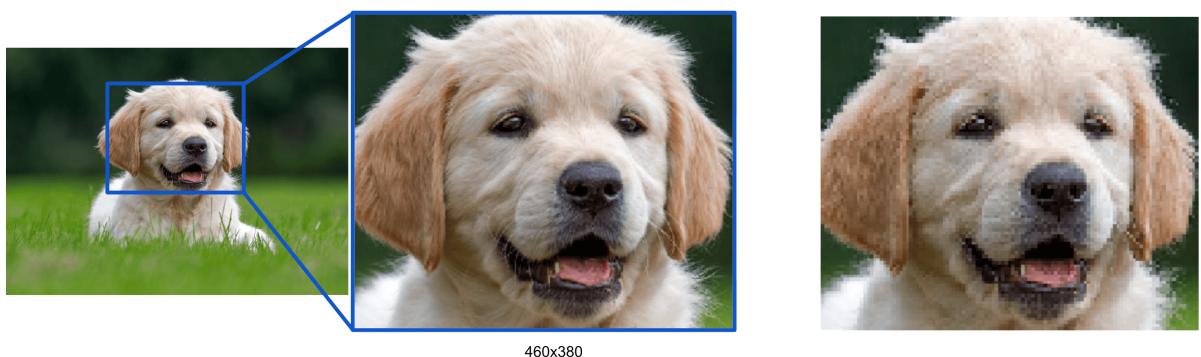
3.1.2 Redimensionamento e Recorte

O redimensionamento é essencial para ajustar as imagens ao tamanho de entrada esperado pelas arquiteturas de redes neurais, garantindo compatibilidade e consistência. Um método comum é redimensionar as imagens para um tamanho fixo, como 224x224 pixels, amplamente utilizado em modelos como ResNet e VGG (CHEN et al., 2023). Isso pode ser feito por meio de interpolação bilinear ou bicúbica, que suaviza as transições entre pixels, embora métodos mais avançados, como interpolação baseada em Fourier, também sejam explorados (DENNANNI, 2019). O recorte, por outro lado, extrai uma região de interesse da imagem, frequentemente centrada, para preservar áreas relevantes, especialmente quando as dimensões originais variam significativamente (MALLA et al.,

2023). Estudos indicam que o redimensionamento para tamanhos menores pode acelerar o treinamento, mas tamanhos muito reduzidos podem comprometer a qualidade das características extraídas (SABOTTKE et al., 2020). Além disso, o recorte aleatório é usado em conjunto com aumento de dados para introduzir variabilidade durante o treinamento (NALEPA et al., 2022). Essas técnicas são cruciais para lidar com conjuntos de dados heterogêneos, garantindo que as entradas sejam uniformes sem perda significativa de informação (CHEN et al., 2023).

A Figura 5 ilustra o processo de redimensionamento e recorte de imagens, na qual a imagem da esquerda (original) é utilizada para extrair uma região de interesse (recorte) e em seguida redimensionada para um tamanho fixo (imagem da direita).

Figura 5 – Redimensionamento e recorte



Fonte: Adaptado de Venturelli (2021).

3.1.3 Aumento de Dados

O aumento de dados é uma estratégia poderosa para ampliar a diversidade do conjunto de treinamento, reduzindo o risco de sobreajuste e melhorando a robustez do modelo. Técnicas geométricas incluem espelhamento horizontal ou vertical, rotações em ângulos variados (de 1° a 359°), translações, cortes aleatórios e ajustes de escala, que simulam diferentes perspectivas e tamanhos (SHORTEN et al., 2019). Transformações no espaço de cores, como ajustes de brilho, contraste, saturação e matiz, ajudam a lidar com variações de iluminação (SHORTEN et al., 2019). Métodos mais avançados, como apagamento aleatório, mascaram partes da imagem para simular oclusões, enquanto a mistura de imagens combina pixels de diferentes amostras para criar novas instâncias (SHORTEN et al., 2019). Por exemplo, o método SamplePairing reduziu o erro no conjunto CIFAR-10 de 8,22% para 6,93% (SHORTEN et al., 2019). Além disso, redes adversárias geradoras (GANs) são usadas para gerar imagens sintéticas, especialmente em domínios com

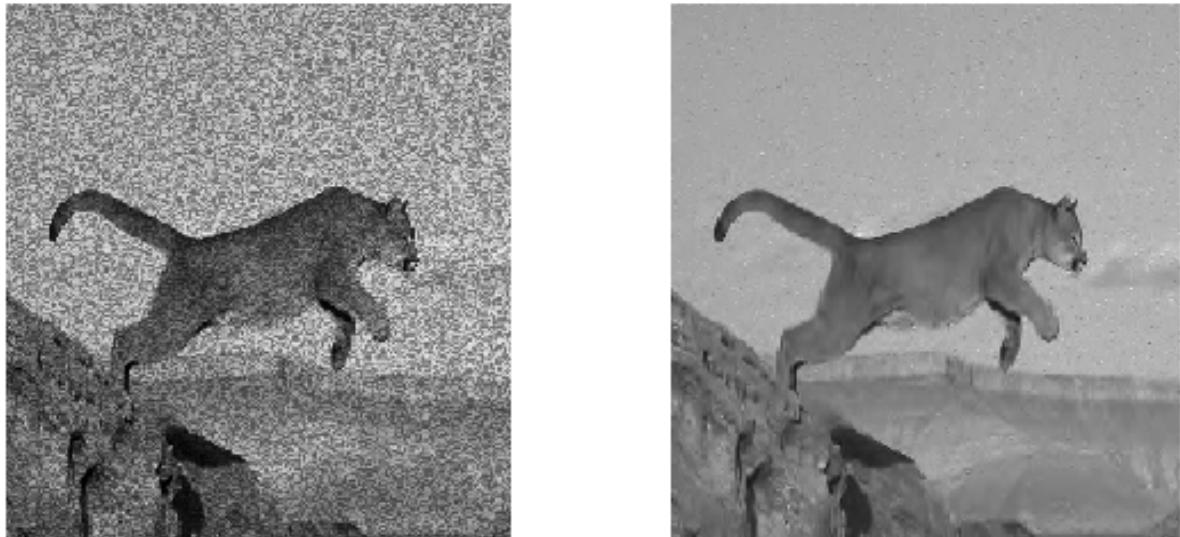
dados limitados, como imagens médicas, alcançando melhorias de até 10% em precisão (SHORTEN et al., 2019). Essas técnicas são particularmente valiosas em cenários com poucos dados, permitindo que as redes neurais generalizem melhor para condições não vistas (NALEPA et al., 2022).

3.1.4 Redução de Ruído

A redução de ruído remove interferências que podem comprometer o desempenho das redes neurais, sendo especialmente crítica em aplicações como imagens médicas e vigilância. Métodos tradicionais, como filtros de média ou mediana, são complementados por abordagens baseadas em aprendizado profundo, como redes neurais convolucionais (CNNs) especializadas, como DnCNNs, que aprendem a mapear imagens ruidosas para versões limpas (SHARMA et al., 2024). Autoencoders também são empregados para reconstruir imagens a partir de representações latentes, eliminando ruídos como Gaussianos ou de sal e pimenta (SHARMA et al., 2024). Técnicas como Total Variation Denoising (TVD) e Non-Local Means (NLM) exploram regularizações e similaridades entre pixels para preservar detalhes (SHARMA et al., 2024). Um estudo demonstrou que a aplicação de DnCNNs em imagens de tomografia computadorizada resultou em uma precisão de detecção de câncer de pulmão variando de 86,17% a 99,67% (SHARMA et al., 2024). Além disso, métodos baseados em redes neurais profundas, como o Deep Neural Filter (DNF), alcançaram melhorias de até 10 dB na relação sinal-ruído em sinais de EEG (PEER et al., 2022). Essas abordagens são essenciais para garantir que as redes neurais processem imagens de alta qualidade, minimizando artefatos que poderiam obscurecer características críticas (SHARMA et al., 2024).

A Figura 6 ilustra o processo de redução de ruído, onde a imagem original (à esquerda) é processada para remover o ruído, resultando em uma imagem mais limpa (à direita).

Figura 6 – Redução de Ruído



Fonte: Adaptado de The MathWorks, Inc. (2023).

3.1.5 Ajuste de Contraste e Brilho

O ajuste de contraste e brilho melhora a visibilidade das características das imagens, sendo crucial para tarefas que dependem de detalhes finos. A equalização de histograma redistribui as intensidades dos pixels para maximizar o contraste, enquanto a equalização adaptativa limitada por contraste (CLAHE) evita a amplificação excessiva de ruído em regiões homogêneas (MALLA et al., 2023). A correção gama ajusta a curva de intensidade para realçar detalhes em áreas escuras ou claras, sendo amplamente usada em imagens de baixa qualidade (MALLA et al., 2023). Métodos baseados em aprendizado profundo, como redes convolucionais fuzzy, integraram filtros Gaussianos e triangulares para melhorar imagens de íris, alcançando até 97% de precisão em tarefas de reconhecimento (SHARMA et al., 2024). Além disso, técnicas como RetinexDIP foram propostas para melhorar a resolução e reduzir o consumo de memória em comparação com métodos tradicionais (SHARMA et al., 2024). Essas abordagens são fundamentais para preparar imagens para redes neurais, garantindo que as características relevantes sejam destacadas (MALLA et al., 2023).

A Figura 7 ilustra o efeito do CLAHE em uma imagem, destacando detalhes que antes estavam obscurecidos.

Figura 7 – Ajuste de Contraste e Brilho com CLAHE



Fonte: Pandey (2023).

3.1.6 Aumento de Nitidez

O aumento de nitidez realça bordas e detalhes finos, facilitando tarefas como detecção de objetos e segmentação. Técnicas tradicionais, como a máscara de desfoque, aplicam filtros de alta passagem para enfatizar transições de intensidade (MALLA et al., 2023). Métodos baseados em redes neurais, como CNNs, foram desenvolvidos para detectar e corrigir nitidez, como no caso da detecção de máscaras de desfoque (USM), superando métodos baseados em codificação ternária perpendicular a bordas (DING et al., 2018). Em aplicações específicas, como imagens de documentos, redes convolucionais combinadas com filtros de Gabor e desfoque melhoraram a legibilidade, reduzindo distorções como sombras e ruídos (BEN et al., 2022). Essas técnicas são particularmente úteis em cenários onde a clareza das bordas é essencial para o desempenho do modelo (SHARMA et al., 2024).

A Figura 8 ilustra o efeito do aumento de nitidez em uma imagem, onde os detalhes são mais evidentes após o processamento.

Figura 8 – Aumento de Nitidez



Fonte: Adaptado de Joshi (2025).

3.1.7 Conversão de Espaço de Cores

A conversão de espaço de cores adapta as imagens às necessidades específicas da tarefa, simplificando o processamento ou destacando características relevantes. A conversão de RGB para escala de cinza reduz a dimensionalidade, sendo útil em tarefas onde a cor não é essencial (SHARMA et al., 2024). Espaços como HSV e LAB são preferidos em aplicações que requerem separação de matiz, saturação ou luminância, como segmentação de objetos (SHARMA et al., 2024). Redes neurais também foram usadas para realizar conversões de espaço de cores, como de RGB para XYZ, alcançando erros de cor inferiores a 1,0 unidade E 2000 em mais de 85% dos casos testados (MACDONALD, 2019). Essas conversões são valiosas para otimizar a extração de características e reduzir a complexidade computacional em tarefas de visão computacional (SHARMA et al., 2024).

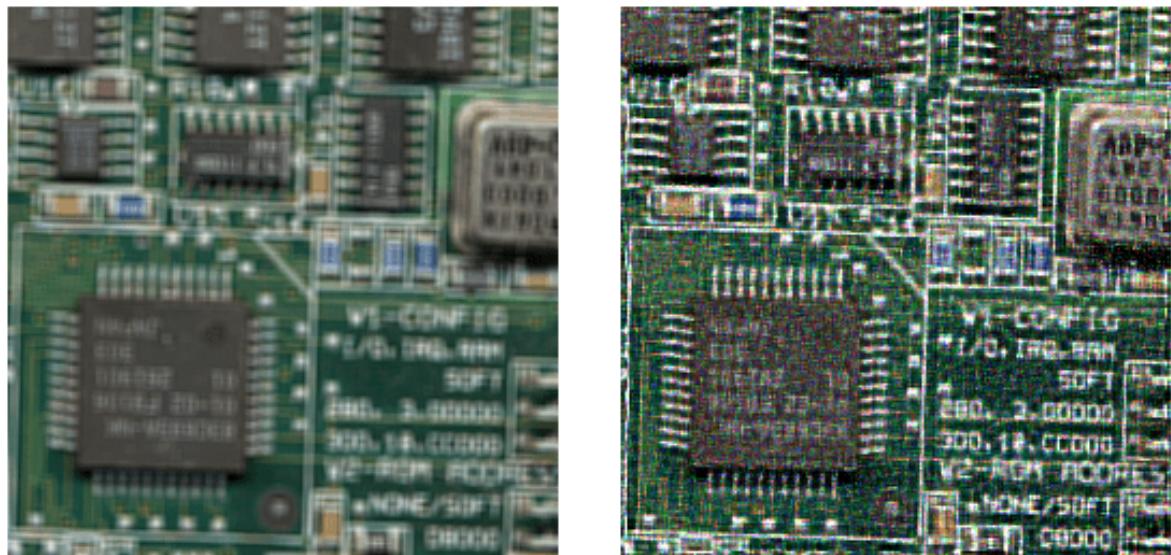
3.1.8 Restauração e Desembacamento de Imagens

A restauração de imagens visa recuperar a imagem original a partir de versões degradadas por desfoco, ruído ou outras distorções. O desembacamento, um subcampo da restauração, utiliza redes neurais como U-Net para corrigir desfoques dinâmicos, alcançando PSNR de 31,53 no conjunto GoPro e 31,32 no Real Blur (LIAN; WANG, 2023). Métodos baseados em autoencoders convolucionais foram propostos para restaurar imagens em aplicações de fotografia computacional e sensoriamento remoto (BARRETO et al., 2020). Além disso, redes neurais como DnCNNs foram aplicadas para remover ruídos específicos, como speckle em imagens holográficas (SHARMA et al., 2024). Essas técnicas

são cruciais para preparar imagens de alta qualidade para redes neurais, especialmente em domínios onde a clareza é essencial (SUMIDA et al., 2019).

A Figura 9 ilustra o processo de desembaçamento, onde a imagem original (à esquerda) é processada para remover o desfoque, resultando em uma imagem mais nítida (à direita).

Figura 9 – Restauração e Desembaçamento de Imagens



Fonte: Adaptado de MathWorks (2025).

3.1.9 Detecção de Bordas

A detecção de bordas identifica limites e formas nas imagens, sendo uma etapa fundamental em muitas tarefas de visão computacional. Redes neurais, como redes de codificação-decodificação, foram desenvolvidas para detectar bordas com alta precisão, superando detectores tradicionais como Canny em imagens ruidosas (YU et al., 1994). Métodos inspirados em mecanismos biológicos, como redes com atenção seletiva, melhoraram a extração de características globais, resultando em mapas de bordas mais robustos (CHEN et al., 2022). Essas abordagens são essenciais para pré-processar imagens, fornecendo informações estruturais que facilitam a segmentação e o reconhecimento de objetos (YU et al., 1994).

A Figura 10 ilustra o processo de detecção de bordas, onde as bordas da imagem original (à esquerda) são destacadas na imagem processada (à direita).

Figura 10 – Detecção de Bordas



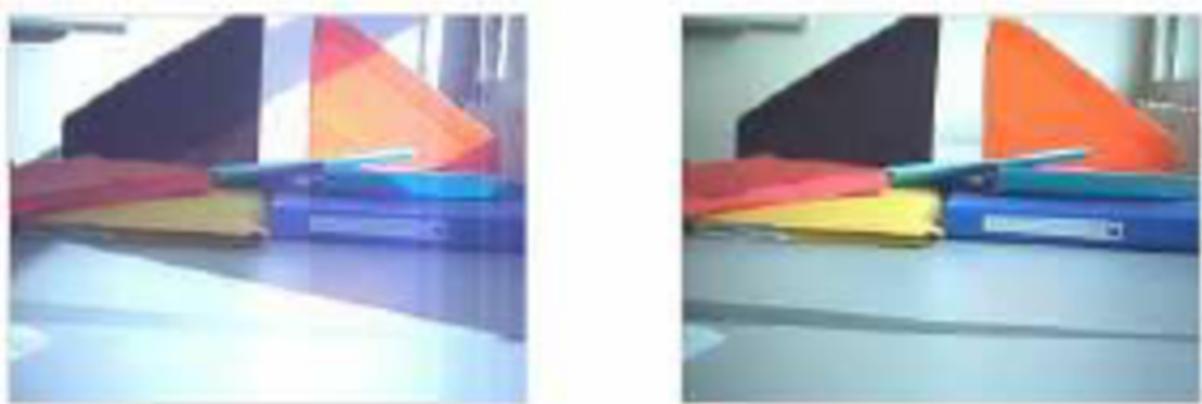
Fonte: Couto (2024).

3.1.10 Correção de Iluminação

A correção de iluminação normaliza as condições de luz nas imagens, garantindo consistência na extração de características. Métodos baseados em aprendizado profundo, como redes convolucionais, foram propostos para corrigir imagens com iluminação desigual, como pinturas, alcançando resultados superiores em métricas como NIQE e LOE (LI et al., 2020). Técnicas híbridas que combinam modelos baseados em aprendizado e físicos foram aplicadas para melhorar a detecção de objetos em condições de luz variada, como em imagens de plantações (YANG et al., 2022). Essas abordagens são particularmente úteis em cenários onde a iluminação não uniforme pode comprometer o desempenho do modelo (LI et al., 2020).

A Figura 11 ilustra o processo de correção de iluminação, onde a imagem original (à esquerda) é processada para uniformizar a iluminação, resultando em uma imagem mais equilibrada (à direita).

Figura 11 – Correção de Iluminação



Fonte: Basile Olivier Bernier (2006).

3.1.11 Super-Resolução

A super-resolução aumenta a resolução de imagens, gerando versões de alta qualidade a partir de entradas de baixa resolução. Redes neurais, como redes convolucionais profundas e redes adversárias generativas (GANs), alcançaram resultados impressionantes, com modelos como SRGAN produzindo imagens fotorrealistas (LEDIG et al., 2017). Em aplicações biológicas, redes como DPA-TISR foram desenvolvidas para imagens de células vivas, alcançando fidelidade temporal e consistência em mais de 10.000 pontos temporais (LIU et al., 2025). Essas técnicas são valiosas para tarefas que requerem detalhes finos, como análise médica e vigilância, permitindo que redes neurais processem imagens com maior clareza (LEDIG et al., 2017).

3.1.12 Conclusão parcial da seção

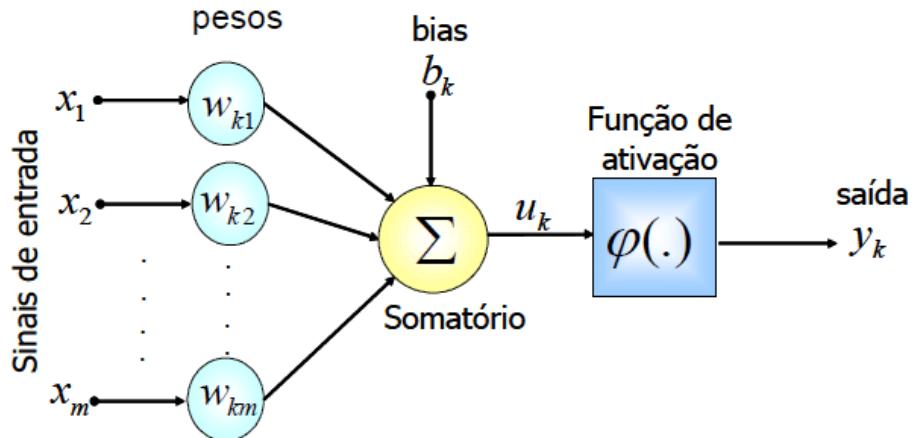
O processamento de imagens é uma etapa crucial para garantir a eficácia dos modelos de aprendizado profundo aplicados ao Sistema Elétrico de Potência (SEP). As técnicas discutidas, como normalização, redimensionamento, aumento de dados e redução de ruído, podem ser fundamentais para preparar as imagens antes de serem alimentadas em redes neurais. Essas abordagens não apenas melhoram a qualidade das imagens, mas também garantem que os modelos sejam mais robustos e capazes de generalizar em diferentes condições. A escolha adequada dessas técnicas pode impactar significativamente o desempenho dos modelos na detecção e classificação de falhas em equipamentos de linhas de transmissão.

Dando continuidade, para que as técnicas de processamento de imagens sejam efetivamente aplicadas, é fundamental compreender os fundamentos das redes neurais, que são as principais ferramentas para análise e classificação dessas imagens. A próxima seção aborda os conceitos essenciais sobre redes neurais.

3.2 REDES NEURAIS

Uma rede neural artificial é formada por um grande número de neurônios para funcionar corretamente, mas para compreender o funcionamento de uma rede neural, deve-se definir o modelo de um único neurônio artificial. Esse modelo é apresentado na Figura 12.

Figura 12 – Modelo de um Neurônio Artificial



Fonte: Braga e Silva (2011).

Os passos para a obtenção da saída de um neurônio artificial são:

1. O modelo recebe um número m de entradas x_1, x_2, \dots, x_m ;
2. Cada uma dessas entradas é multiplicada por um peso, conforme a Equação 3.1:

$$x_i w_i, \quad \text{para } i = 1, 2, \dots, m \quad (3.1)$$

3. Somam-se as entradas multiplicadas pelos seus respectivos pesos, conforme a Equação 3.2:

$$\sum_{n=1}^m w_n x_n \quad (3.2)$$

4. Adiciona-se o bias, conforme a Equação 3.3:

$$b + \sum_{n=1}^m w_n x_n \quad (3.3)$$

5. O resultado passa por uma função de ativação, conforme a Equação 3.4:

$$\varphi \left(b + \sum_{n=1}^m w_n x_n \right) \quad (3.4)$$

Seguidos os passos, a equação de saída de um neurônio artificial é descrita pela Equação 3.5.

$$y = \varphi \left(b + \sum_{n=1}^m w_n x_n \right) \quad (3.5)$$

Visto o modelo de um único neurônio artificial, o conceito de rede neural composta pela associação de diversos neurônios é descrito a seguir.

3.2.1 Tipos de redes neurais

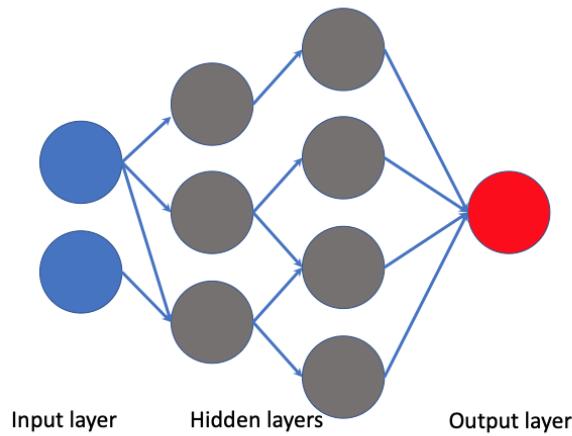
Existem diversos tipos de redes neurais que se distinguem tanto em termos de seus princípios de funcionamento quanto em suas aplicações práticas específicas. A seguir, serão discutidos alguns desses tipos de redes neurais de maneira individualizada, a fim de fornecer uma compreensão mais aprofundada sobre seu funcionamento e suas aplicações (ALEX, 2020).

3.2.1.1 Perceptron (P), Feed Forward Network (FFN)

FFNs são o tipo mais básico de rede neural, em que a informação flui linearmente até a saída e cada neurônio realiza uma operação matemática linear do tipo apresentado na Equação 3.6. Sendo x o valor de entrada, w o peso e b o bias do neurônio. O resultado passa por uma função de ativação e em seguida é enviado para a próxima camada. As redes neurais do tipo FFN (exemplo mostrado através da Figura 13) possuem conexões em apenas um único sentido, geralmente limitadas a 5 camadas (ALEX, 2020).

$$wx + b \quad (3.6)$$

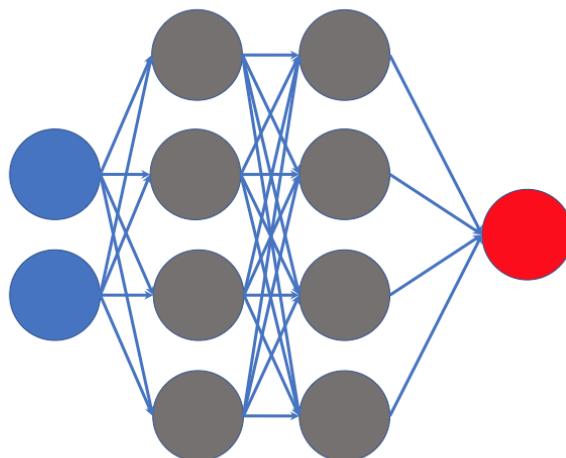
Figura 13 – FFN



Fonte: Alex (2020).

As redes do tipo P, Figura 14, são um caso especial de uma rede FFN, em que todos os neurônios de uma camada são conectados com todos neurônios da camada seguinte (ALEX, 2020).

Figura 14 – Perceptron



Fonte: Alex (2020).

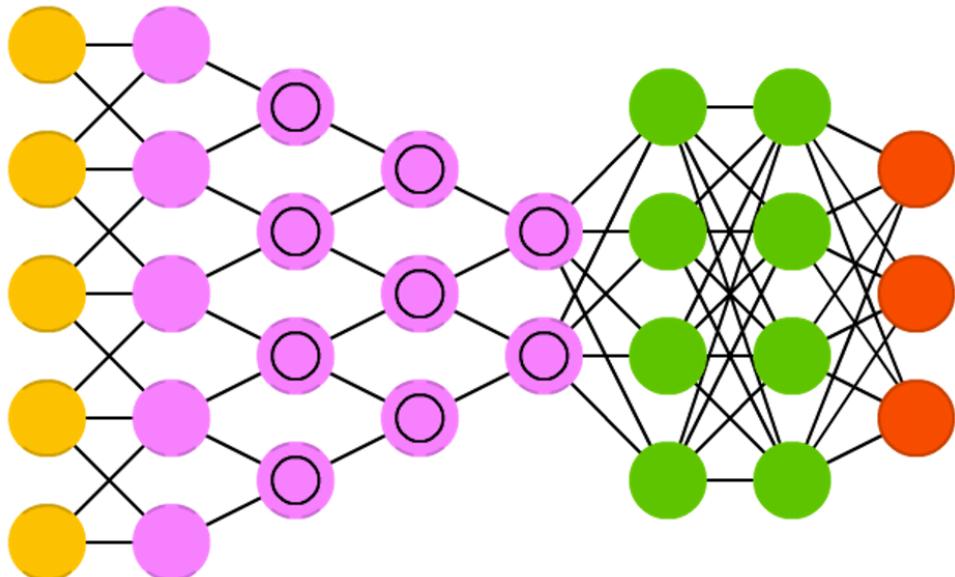
As FFNs são utilizadas para problemas em que os dados de entrada têm impacto atemporal nos dados de saída, em que a saída não depende do estado anterior da rede neural. Um exemplo é usar informações de um exame de sangue para determinar a presença de uma doença.

3.2.1.2 Convolutional neural network (CNN) ou Deep convolutional network (DCN)

As redes neurais estudadas até então, não consideram uma relação de vizinhança entre os dados de entrada. Por exemplo, não faria a menor diferença se antes do treinamento a posição de todos os dados de entrada fossem embaralhadas da mesma forma. Porém, essa relação de vizinhança pode ser muito importante para alguns casos específicos como no reconhecimento de imagens, reconhecimento de voz, análise grafista do mercado financeiro, etc. No reconhecimento de imagens, por exemplo, grande parte da informação está contida na relação de vizinhança dos pixels como o contraste e a textura.

Uma CNN, cuja estrutura está representada através da Figura 15, percebe uma imagem como uma caixa retangular cuja largura e altura são medidas pelo número de pixels da imagem e a profundidade é representada por cada uma das três camadas de cores, vermelho, verde e azul referidas como canais (VEEN, 2016).

Figura 15 – CNN



Fonte: Veen (2016).

Ao longo das camadas de uma rede CNN, as dimensões da imagem se alteram, pois a medida em que a altura e largura da imagem diminuem, o número de canais aumenta, reduzindo o volume de dados. Esse processo é chamado de pooling, que faz um resumo dos dados através do descarte das saídas menos significativas, mantendo somente às de maior valor (VEEN, 2016).

O processo de convolução é realizado arrastando uma janela (kernel) de dimensão menor pela imagem original, sendo essa janela uma rede FFN (VEEN, 2016). Por exemplo, se uma imagem 5x5 pixels passar pelo processo da convolução e supondo uma janela de 3x3 com passo 1 (stride), primeiramente os 3x3 pixels do canto superior esquerdo da imagem original passarão por uma FFN. Em seguida, essa janela é arrastada 1 pixel

(tamanho do passo) para a direita e o processo se repete até ao final da imagem.

3.2.2 Funções de ativação

As funções de ativação introduzem não-linearidade nas redes neurais, permitindo que elas aprendam relações complexas entre entradas e saídas. Sem essas funções, mesmo com múltiplas camadas, a rede se comportaria como um modelo linear (BADIGER; MATHEW, 2022). Cada camada da rede pode ter uma função de ativação diferente, sendo algumas mais adequadas para camadas ocultas e outras para a camada de saída.

A seguir, são apresentadas as três principais funções de ativação:

3.2.2.1 ReLU (Rectified Linear Unit)

Representada pela Equação 3.7, a ReLU é amplamente utilizada em camadas ocultas. Sua principal vantagem é a eficiência computacional e a aceleração da convergência do gradiente. Contudo, pode causar o problema dos neurônios mortos (Dying ReLU), quando valores negativos resultam sempre em zero (AGARAP, 2018).

$$f(x) = \max(0, x) \quad (3.7)$$

3.2.2.2 Sigmoid

Definida pela Equação 3.8, transforma a entrada em um valor entre 0 e 1, sendo útil para problemas de classificação binária. Apesar de ser diferenciável e fornecer gradientes suaves, sofre com o problema do gradiente pequeno para valores extremos, o que dificulta o aprendizado (LANGER, 2020).

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3.8)$$

3.2.2.3 Softmax

A função Softmax é apresentada na Equação 3.9 e é utilizada na camada de saída para classificação multiclasse. Ela converte os valores em uma distribuição de probabilidades, acentuando a classe de maior valor (GAO; PAVEL, 2017).

$$f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (3.9)$$

3.2.2.4 Regras gerais para escolha de funções de ativação

A escolha da função de ativação depende do tipo de problema e da arquitetura da rede. A seguir, são apresentadas algumas diretrizes gerais:

- *Camada de saída:*
 - Regressão: Linear
 - Classificação binária: Sigmoid
 - Classificação multiclasse: Softmax
 - Classificação multirrótulo: Sigmoid
- *Camadas ocultas:*
 - Redes convolucionais: ReLU
 - Redes recorrentes: Tanh ou Sigmoid

3.2.3 Funções de Custo

As funções de custo são responsáveis por medir o quanto distante a saída prevista está da saída real. Elas orientam o processo de treinamento ajustando os pesos da rede para minimizar esse erro (RASHID, 2020).

3.2.3.1 Erro Médio Quadrático (MSE)

O Erro Médio Quadrático (MSE) é uma das funções mais comuns em regressão, penalizando fortemente grandes erros e sendo sensível a outliers (CHICCO; JURMAN, 2020). Ele é definido como a Equação 3.10:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.10)$$

3.2.3.2 Erro Médio Absoluto (MAE)

O Erro Médio Absoluto (MAE) é mais robusto a outliers que o MSE, mas pode ser mais difícil de otimizar. Sua fórmula é apresentada na Equação 3.11:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.11)$$

3.2.3.3 Função Huber

A função Huber combina as vantagens do MSE e MAE, sendo menos sensível a outliers e mais estável para pequenos erros (HUBER, 1964). Ela é definida pela Equação 3.12:

$$L_{\text{Huber}} = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{se } |y - \hat{y}| \leq \delta \\ \delta(|y - \hat{y}| - \frac{1}{2}\delta) & \text{caso contrário} \end{cases} \quad (3.12)$$

3.2.3.4 Entropia Cruzada Binária

A Entropia Cruzada Binária é indicada para problemas de classificação binária (ZHANG; SABUNCU, 2018), sendo expressa pela Equação 3.13:

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (3.13)$$

3.2.3.5 Entropia Cruzada Categórica

Já a Entropia Cruzada Categórica é utilizada em classificação multiclasse com rótulo único por amostra, e sua fórmula é apresentada na Equação 3.14:

$$L = - \sum_{i=1}^n \sum_{j=1}^k y_{ij} \log(\hat{y}_{ij}) \quad (3.14)$$

3.2.4 Otimizadores

Otimizadores são algoritmos que ajustam os pesos da rede neural com base no gradiente da função de custo. Eles influenciam diretamente a velocidade e a qualidade da convergência (RUDER, 2016). Entre os principais otimizadores, destaca-se o Gradiente Descendente, que é a forma mais simples de otimização, mas pode ser lenta e sensível à escolha da taxa de aprendizado. O Gradiente Descendente Estocástico (SGD) atualiza os pesos a cada amostra, adicionando ruído estocástico que pode ajudar a escapar de mínimos locais. O Momentum acrescenta uma fração do gradiente anterior ao atual, acelerando a convergência e suavizando oscilações. O RMSProp ajusta a taxa de aprendizado para cada parâmetro com base na média móvel dos gradientes quadrados (TIELEMAN; HINTON, 2012). Por fim, o Adam combina Momentum e RMSProp, sendo amplamente utilizado por sua eficiência e robustez (KINGMA; BA, 2014).

Compreendidos os principais conceitos sobre redes neurais, é importante discutir o papel dos conjuntos de dados (datasets), que são essenciais para o treinamento e avaliação desses modelos. A próxima seção aborda os desafios e técnicas relacionados aos datasets utilizados em tarefas de detecção de falhas.

3.3 DATASETS

Os conjuntos de dados são fundamentais para o treinamento de redes neurais, fornecendo as amostras necessárias para aprender padrões complexos e realizar previsões precisas. A qualidade, quantidade e diversidade dos dados impactam diretamente o desempenho dos modelos, especialmente em aprendizagem profunda, onde redes com milhões de parâmetros requerem grandes volumes de dados anotados. Conjuntos como o ImageNet, com mais de 14 milhões de imagens em milhares de categorias, foram essenciais para avanços em visão computacional, como a classificação de imagens e detecção de objetos (DENG et al., 2009). Na engenharia elétrica, especificamente na detecção de falhas em cadeias de isoladores e equipamentos de linhas de transmissão, datasets são frequentemente escassos ou desbalanceados, limitando a capacidade dos modelos de generalizar (SHORTEN et al., 2019).

Datasets escassos, caracterizados por um número reduzido de amostras, são comuns em áreas onde a coleta de dados é custosa, demorada ou restrita pela raridade de eventos, como na detecção de falhas em isoladores de linhas de transmissão. A escassez de dados aumenta o risco de sobreajuste, onde modelos de redes neurais memorizam os dados de treinamento em vez de aprender padrões generalizáveis (GOODFELLOW; BENGIO; COURVILLE, 2016). Esse problema é agravado em aplicações de engenharia elétrica, onde imagens de falhas, como quebras ou flashovers por poluição, são difíceis de

obter em quantidade suficiente. A anotação manual de imagens capturadas por drones, frequentemente usada para identificar defeitos, é demorada e propensa a erros, limitando ainda mais o tamanho dos datasets (ZHENG et al., 2022). Por exemplo, o conjunto de dados Insulator-Defect Detection, com apenas 1600 imagens, enfrenta desafios devido ao número limitado de amostras de defeitos (ZHENG et al., 2022).

O aprendizado por transferência é uma técnica amplamente utilizada para mitigar os desafios de datasets escassos, permitindo que modelos pré-treinados em grandes conjuntos de dados, como o ImageNet, sejam ajustados para tarefas específicas com menos dados (PAN; YANG, 2010). Na detecção de falhas em isoladores, Zheng et al. (2022) utilizaram um modelo YOLOv7 pré-treinado, ajustado para detectar defeitos em isoladores a partir de imagens capturadas por veículos aéreos não tripulados (UAVs). Ajustando o modelo para o conjunto de dados Insulator-Defect Detection, os autores alcançaram alta precisão com um número limitado de imagens anotadas. Essa abordagem é eficaz em cenários onde características visuais gerais, como bordas e texturas, podem ser transferidas de datasets genéricos para aplicações especializadas em engenharia elétrica. Outra aplicação foi demonstrada por Zou et al. (2024), que utilizaram um modelo YOLOv5 pré-treinado para detectar defeitos em parafusos de linhas de transmissão, aproveitando pesos pré-treinados no conjunto COCO para melhorar a detecção em datasets pequenos.

O aumento de dados é uma estratégia essencial para lidar com datasets escassos, ampliando artificialmente o tamanho e a diversidade dos dados por meio de transformações como rotação, escala, inversão e alterações de iluminação (SHORTEN et al., 2019). Na detecção de falhas em linhas de transmissão, essas transformações ajudam a simular diferentes condições ambientais, como variações de luz ou ângulos de captura, comuns em imagens de UAVs. Por exemplo, Peng et al. (2023) aplicaram aumento de dados para melhorar a robustez de um modelo YOLOv5 na detecção de defeitos pequenos, como flashovers por poluição, em imagens de linhas de transmissão. Métodos avançados, como redes adversárias generativas (GANs), podem gerar imagens sintéticas de falhas, mas sua aplicação em engenharia elétrica é limitada devido à complexidade computacional (GOODFELLOW et al., 2014). Apesar disso, GANs têm potencial para criar amostras sintéticas de defeitos raros, como quebras em isoladores, ampliando datasets escassos.

O aprendizado semi-supervisionado é uma abordagem promissora para datasets escassos, aproveitando dados não rotulados, que são mais abundantes em inspeções de linhas de transmissão, para melhorar o desempenho do modelo (ENGELEN; HOOS, 2020). Imagens de UAVs capturadas durante inspeções rotineiras podem ser usadas para aprender representações gerais, mesmo sem anotações detalhadas. Embora não haja exemplos específicos na literatura revisada aplicando aprendizado semi-supervisionado diretamente à detecção de falhas em isoladores, Chen et al. (2020) demonstraram sua eficácia em tarefas de visão computacional, sugerindo potencial para aplicações futuras em engenharia elétrica, onde dados não rotulados de inspeções são comuns. Essa técnica

pode ser explorada para pré-treinar modelos em grandes conjuntos de imagens de linhas de transmissão antes de ajustá-los em datasets rotulados menores.

Conjuntos de dados desbalanceados são prevalentes na detecção de falhas em linhas de transmissão, onde amostras de isoladores saudáveis superam significativamente as de defeitos, como quebras ou flashovers por poluição. Esse desbalanceamento pode levar a modelos enviesados que favorecem a classe majoritária, resultando em baixa sensibilidade para a detecção de falhas (HE; GARCIA, 2009). Por exemplo, no conjunto de dados IDID, a proporção de isoladores saudáveis para defeituosos é de aproximadamente 10:1 para quebras e 5:1 para flashovers, o que dificulta a classificação precisa das classes minoritárias (OBERWEGER; WENDEL; BISCHOF, 2024). Esse desafio é crítico em aplicações de engenharia elétrica, onde a detecção de falhas raras é essencial para garantir a segurança e a confiabilidade do sistema.

A reamostragem é uma técnica comum para abordar o desbalanceamento, envolvendo sobreamostragem da classe minoritária ou subamostragem da classe majoritária para equilibrar a distribuição (JOHNSON; KHOSHGOFTAAR, 2019). Métodos como o SMOTE (Synthetic Minority Over-sampling Technique) geram amostras sintéticas da classe minoritária interpolando exemplos existentes (CHAWLA et al., 2002). Em Oberweger, Wendel e Bischof (2024), os autores aplicaram subamostragem para criar partições balanceadas do conjunto de dados IDID, retrainando a última camada do modelo com regressão logística para melhorar a classificação de isoladores defeituosos. Essa abordagem aumentou a precisão em até 12% para quebras e 7% para flashovers, demonstrando eficácia em cenários desbalanceados. A reamostragem é particularmente útil quando o número de amostras de defeitos é extremamente baixo, como em datasets de inspeção de linhas.

A perda focal é uma função de perda especializada que atribui maior peso a exemplos difíceis, frequentemente pertencentes à classe minoritária, reduzindo o impacto de amostras bem classificadas (LIN et al., 2017). Na detecção de falhas em isoladores, Zheng et al. (2022) utilizaram a perda focal em um modelo YOLOv7 para lidar com o desbalanceamento entre amostras de isoladores e defeitos em imagens de UAVs. A aplicação dessa técnica melhorou a precisão na detecção de defeitos pequenos, como flashovers por poluição, que são menos frequentes. A perda focal é particularmente vantajosa em tarefas de detecção de objetos, onde o fundo da imagem pode dominar a distribuição de classes, como em imagens de linhas de transmissão com fundos complexos.

A unificação de datasets públicos, como proposto por Felix et al. (2020), oferece uma abordagem valiosa para a pesquisa em detecção de falhas. O repositório combina datasets como o de Tomaszewski et al. e o CPLID, fornecendo imagens e anotações no formato COCO. Essa consolidação facilita o acesso a dados diversificados, embora o desbalanceamento e a escassez permaneçam desafios que requerem técnicas avançadas de pré-processamento e treinamento. A unificação de datasets é particularmente útil para aumentar o número de amostras disponíveis, permitindo treinar modelos mais robustos

para detecção de falhas em isoladores (FELIX et al., 2020).

A Tabela 3 resume os principais datasets utilizados na detecção de falhas em isoladores, destacando suas características e desafios.

Tabela 3 – Técnicas para Lidar com Escassez e Desbalanceamento de Dados

Categoría	Técnica	Descrição
Escassez	Aprendizado por Transferência	Reutiliza modelos pré-treinados em grandes conjuntos para tarefas com poucos dados (PAN; YANG, 2010).
Escassez	Aumento de Dados	Aplica transformações (e.g., rotação, escala) para ampliar o conjunto de dados (SHORTEN et al., 2019).
Escassez	Aprendizado Semi-Supervisionado	Aproveita dados não rotulados para aprender representações gerais (ENGELEN; HOOS, 2020).
Desbalanceamento	Reamostragem	Sobreamostra a classe minoritária ou subamostra a majoritária (JOHNSON; KHOSHGOFTAAR, 2019).
Desbalanceamento	Perda Focal	Modifica a perda para focar em exemplos difíceis, geralmente da classe minoritária (LIN et al., 2017).

Após a análise das principais estratégias para lidar com escassez e desbalanceamento de dados, é fundamental compreender como avaliar o desempenho dos modelos desenvolvidos. A seguir, são apresentadas as principais métricas de avaliação utilizadas em tarefas de detecção de falhas em linhas de transmissão.

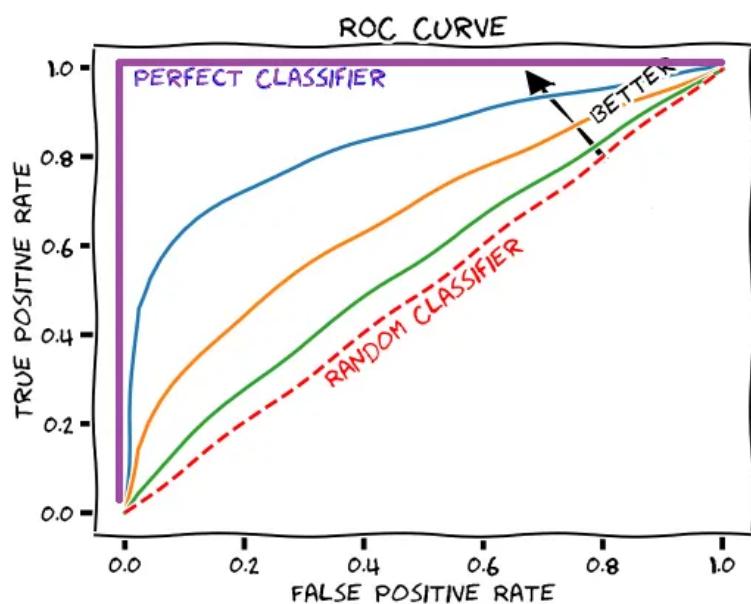
3.4 MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO DE MODELOS

Na detecção de falhas em cadeias de isoladores e equipamentos de linhas de transmissão, a escolha das métricas de avaliação é fundamental para garantir a eficácia e confiabilidade dos modelos de redes neurais. Métricas comumente utilizadas incluem acurácia, precisão, recall, F1-score, área sob a curva ROC (AUC-ROC) e, para tarefas de detecção de objetos, a média da precisão média (mAP). A acurácia, definida como a proporção de previsões corretas em relação ao total, pode ser enganosa em datasets desbalanceados,

onde a classe de falhas (e.g., quebras ou flashovers) é significativamente menos representada que a classe de isoladores saudáveis. Por exemplo, em um dataset com 95% de amostras saudáveis, um modelo que sempre prevê "saudável" alcançará alta acurácia, mas falhará em detectar falhas, comprometendo a segurança do sistema (HE; GARCIA, 2009). Em Alam et al. (2025), os autores reportaram uma acurácia de 99,96% para um modelo ensemble RF-LSTM Tuned KNN, mas complementaram a avaliação com precisão, recall e F1-score para abordar o desbalanceamento, garantindo uma análise mais robusta do desempenho em classes minoritárias.

A Figura 16 ilustra uma curva ROC típica, que representa a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos para diferentes limiares de decisão. A área sob a curva (AUC) é uma métrica importante para avaliar a capacidade discriminativa do modelo.

Figura 16 – Curva ROC



Fonte: Torres (2025).

A precisão mede a proporção de verdadeiros positivos entre todas as previsões positivas, sendo útil para avaliar a confiabilidade das detecções de falhas. O recall, por outro lado, mede a proporção de verdadeiros positivos entre todas as amostras positivas reais, sendo crítico em aplicações onde falsos negativos (falhas não detectadas) podem levar a falhas catastróficas no sistema de transmissão. O F1-score, a média harmônica entre precisão e recall, oferece uma métrica balanceada que considera ambos os aspectos, sendo amplamente utilizado em cenários desbalanceados (JOHNSON; KHOSHGOFTAAR, 2019).

Para tarefas de detecção de objetos, como identificar defeitos em imagens de UAVs, a métrica mAP é padrão, calculando a precisão média para cada classe e tomando a média

geral. Em Zheng et al. (2022), o modelo YOLOv7 foi avaliado no conjunto Insulator-Defect Detection, utilizando mAP para medir a precisão na detecção de quebras e flashovers, com resultados superiores em comparação com modelos anteriores. A AUC-ROC, que avalia a capacidade do modelo de distinguir entre classes em diferentes limiares, também é relevante, especialmente em classificações binárias (falha vs. não falha). Em Alam et al. (2025), a AUC-ROC foi reportada como 1,0 para classificações binárias, indicando excelente separação entre classes, mas valores menores (e.g., 0,94 para algumas classes) foram observados em classificações multi-label, refletindo a complexidade de datasets desbalanceados.

Outras métricas, como a matriz de confusão, fornecem uma visão detalhada dos erros do modelo, permitindo calcular taxas de falsos positivos e negativos. Em Alam et al. (2025), matrizes de confusão foram usadas para avaliar o desempenho do modelo ensemble em classificações binárias e multi-label, complementando as métricas de precisão e recall. Para aplicações em tempo real, como inspeções de UAVs, métricas adicionais, como tempo de inferência e complexidade computacional, também são consideradas, especialmente em modelos como YOLOv5 e YOLOv7, que priorizam eficiência (PENG et al., 2023). A escolha das métricas deve, portanto, alinhar-se com os objetivos da aplicação, priorizando recall para segurança e mAP para detecção precisa de objetos em imagens.

Por fim, compreender as métricas de avaliação é essencial para interpretar corretamente os resultados obtidos com diferentes modelos e técnicas de processamento de imagens. A próxima etapa do trabalho irá detalhar a metodologia proposta para aprimoramento dos processamentos e avaliação dos modelos.

A Tabela 4 apresenta um resumo das principais métricas utilizadas para avaliar o desempenho de modelos em tarefas de detecção de falhas em linhas de transmissão, destacando suas características e aplicações.

Tabela 4 – Principais métricas de avaliação de desempenho de modelos

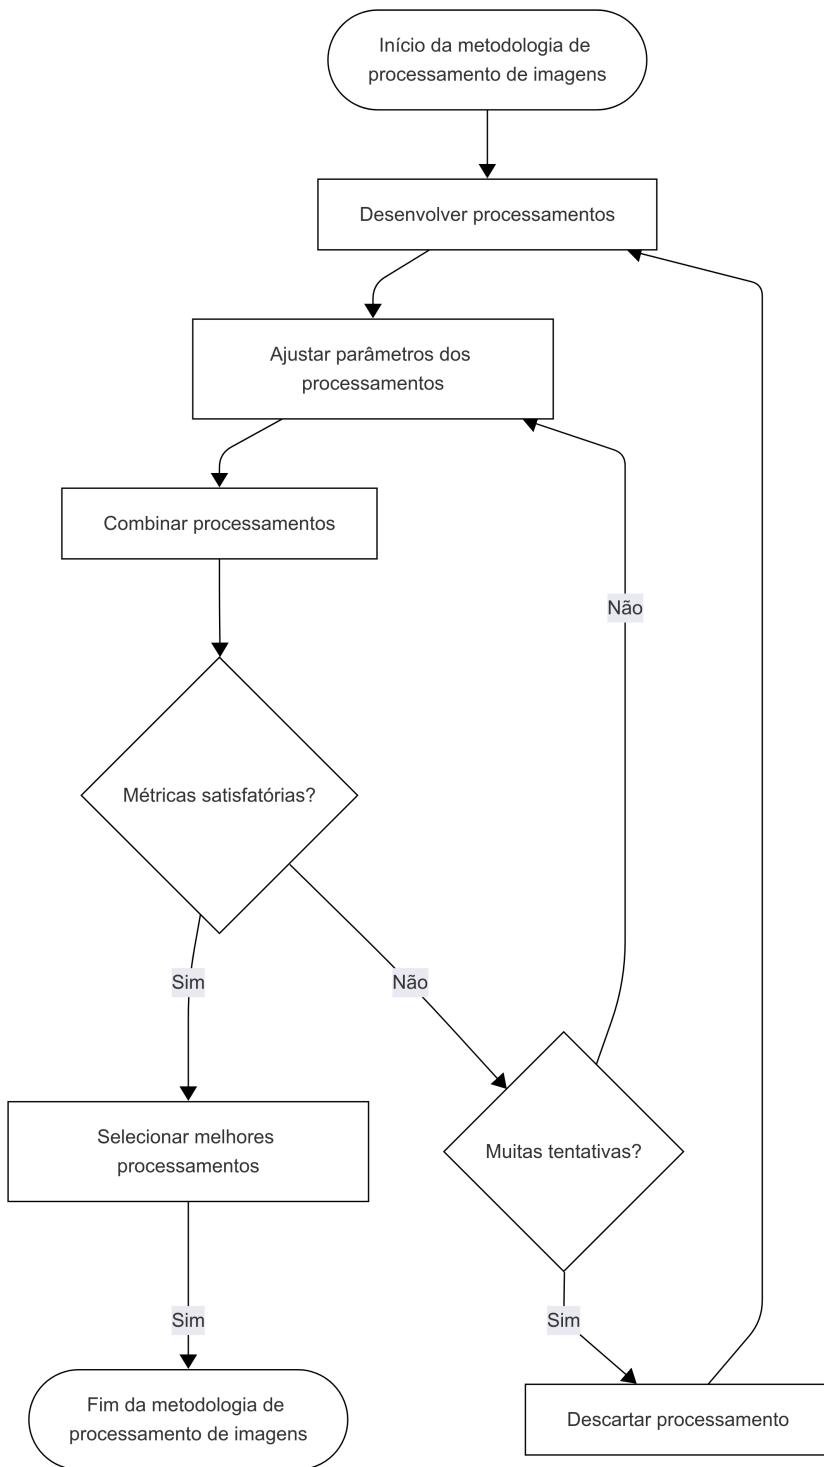
Métrica	Descrição
Acurácia	Proporção de previsões corretas em relação ao total de amostras. Pode ser enganosa em conjuntos desbalanceados.
Precisão	Proporção de verdadeiros positivos entre todas as previsões positivas. Mede a confiabilidade das detecções.
Recall (Sensibilidade)	Proporção de verdadeiros positivos entre todas as amostras positivas reais. Mede a capacidade de encontrar todos os casos positivos.
F1-score	Média harmônica entre precisão e recall. Útil para avaliar o desempenho em cenários desbalanceados.
mAP (mean Average Precision)	Média das precisões médias para cada classe. Padrão em tarefas de detecção de objetos.
AUC-ROC	Área sob a curva ROC. Mede a capacidade do modelo de distinguir entre classes em diferentes limiares.
Matriz de Confusão	Tabela que mostra as previsões corretas e incorretas, detalhando verdadeiros/falsos positivos e negativos.

4 METODOLOGIA

4.1 DEFINIÇÃO DAS MÉTRICAS PARA AVALIAR EFICÁCIA DOS PROCESSAMENTOS

O fluxograma apresentado na Figura 17 descreve o processo de desenvolvimento de uma metodologia para o processamento de imagens. Inicialmente, define-se e desenvolve-se os processamentos necessários, ajustando seus parâmetros e combinando-os para otimizar os resultados. Com isso, são avaliadas as métricas de desempenho para verificar a eficácia das abordagens adotadas. Se os resultados forem satisfatórios, os melhores processamentos são selecionados e o processo é finalizado. Caso contrário, analisa-se o número de tentativas realizadas: se muitas tentativas falhas ocorreram, o processamento é descartado e novas abordagens são consideradas. Se o número de tentativas ainda for baixo, o processo retorna à etapa de ajuste de parâmetros, permitindo novas tentativas até atingir os resultados desejados.

Figura 17 – Fluxograma da metodologia de processamento de imagens



Fonte: Autor.

4.2 ESCOLHA DO TIPO DE MODELO DE REDE NEURAL

Será discutida a escolha do tipo de modelo de rede neural mais adequado para as tarefas de classificação, detecção e regressão no contexto do estudo.

4.3 SELEÇÃO DOS DATASETS PARA AVALIAÇÃO

Serão apresentados os critérios e a seleção dos datasets que serão utilizados para a avaliação dos processamentos de imagem.

4.4 METODOLOGIA PARA COMBINAÇÃO DE PROCESSAMENTOS UNITÁRIOS

Aqui, será detalhada a metodologia desenvolvida para combinar diferentes processamentos unitários de imagem visando a melhoria dos resultados.

4.5 IMPLEMENTAÇÃO DE UM MÉTODO DE AJUSTE AUTOMÁTICO DE PARÂMETROS

Será descrito o método implementado para ajuste automático de parâmetros das técnicas de processamento de imagem, com o objetivo de otimização sem intervenção manual extensa.

4.6 CONSTRUÇÃO DE REDES NEURAIS PARA AVALIAÇÃO DOS PROCESSAMENTOS

Nesta seção, será detalhada a construção dos modelos de redes neurais utilizados para avaliar os processamentos de imagem.

4.7 TESTES COM DIFERENTES ARQUITETURAS E ANÁLISE DE VARIAÇÕES NOS RESULTADOS

Serão apresentados os testes realizados com diferentes arquiteturas de redes neurais e a análise das variações nos resultados obtidos.

5 COLETA E ANÁLISE DE RESULTADOS

5.1 IMPACTO DOS MODELOS NO DESEMPENHO DOS PROCESSAMENTOS

Será analisado o impacto dos diferentes modelos de redes neurais no desempenho dos processamentos de imagem.

5.2 INFLUÊNCIA DOS DATASETS NOS RESULTADOS

Aqui, será discutida a influência dos diferentes datasets nos resultados dos processamentos de imagem.

5.3 COMPARAÇÃO ENTRE DIFERENTES ESTRATÉGIAS DE PROCESSAMENTO

Serão comparadas as diferentes estratégias de processamento de imagem utilizadas no estudo, destacando as vantagens e desvantagens de cada uma.

6 CONCLUSÃO

6.1 SÍNTESE DOS RESULTADOS OBTIDOS

Nesta seção, será feita uma síntese dos principais resultados obtidos ao longo do estudo.

6.2 LIMITAÇÕES E DESAFIOS ENCONTRADOS

Serão discutidas as limitações e os desafios encontrados durante a realização do trabalho.

6.3 SUGESTÕES PARA PESQUISAS FUTURAS

Por fim, serão apresentadas sugestões para pesquisas futuras, com base nos resultados e nas limitações identificadas no estudo.

REFERÊNCIAS

- AGARAP, A. F. Deep learning using rectified linear units (relu). **arXiv preprint arXiv:1803.08375**, 2018.
- ALAM, M. et al. Robust fault detection and classification in power transmission lines via ensemble machine learning models. **Scientific Reports**, Nature Publishing Group, v. 15, p. 86554, 2025.
- ALEX. **Feedforward Neural Networks and Multilayer Perceptrons**. 2020. <https://boostedml.com/2020/04/feedforward-neural-networks-and-multilayer-perceptrons.html>. Acesso em: 21 abr. 2025.
- ALTAIE, A. S. et al. Fault detection on power transmission line based on wavelet transform and scalogram image analysis. **Energies**, MDPI, v. 16, n. 23, p. 7914, 2023. Disponível em: <https://www.mdpi.com/journal/energies>.
- BADIGER, M.; MATHEW, J. A. Retrospective review of activation functions in artificial neural networks. **ResearchGate**, 2022.
- BARRETO, T. et al. Cnn based image restoration. **Journal of Intelligent & Robotic Systems**, v. 100, n. 2, p. 609–620, 2020.
- BASCLE OLIVIER BERNIER, V. L. B. Illumination-invariant color image correction. In: **Lecture Notes in Computer Science**. [S.I.: s.n.], 2006.
- BEN, M. et al. Deep neural network concept for a blind enhancement of document-images. **Applied Sciences**, v. 12, n. 19, p. 9601, 2022.
- BRAGA, P.; SILVA, J. Aplicação de redes neurais artificiais em conjunto com o método vetorial da propagação de feixes na análise de um acoplador direcional baseado em fibra Ótica. **Revista Brasileira de Computação Aplicada**, v. 16, 2011.
- CHAWLA, N. V. et al. Smote: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.
- CHEN, T. et al. A simple framework for contrastive learning of visual representations. **International Conference on Machine Learning**, p. 1597–1607, 2020.
- CHEN, X. et al. Edge detection networks inspired by neural mechanisms of selective attention in biological visual cortex. **Frontiers in Neuroscience**, v. 16, p. 1073484, 2022.
- CHEN, Y. et al. Robustness of machine learning to color, size change, normalization, and image enhancement on micrograph datasets. **Materials & Design**, 2023.
- CHICCO, D.; JURMAN, G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation. **BMC Genomics**, BioMed Central, v. 21, n. 1, p. 6–13, 2020.
- COUTO, G. Segmentação baseada em região. **LinkedIn Artigos**, março 2024. Publicado em 18 de março de 2024.

DENG, J. et al. Imagenet: A large-scale hierarchical image database. **2009 IEEE Conference on Computer Vision and Pattern Recognition**, IEEE, p. 248–255, 2009.

DENNANNI, A. **How to deal with image resizing in Deep Learning**. 2019. Disponível em: <https://medium.com/neuronio/how-to-deal-with-image-resizing-in-deep-learning-e5177fad7d89>.

DING, F. et al. Detecting usm image sharpening by using cnn. **Signal Processing: Image Communication**, v. 68, p. 188–194, 2018.

ENGELEN, J. E. V.; HOOS, H. H. A survey on semi-supervised learning. **Machine Learning**, Springer, v. 109, n. 2, p. 373–440, 2020.

EZE, C. C. et al. Deep learning for component fault detection in electricity transmission lines. **Journal of Big Data**, v. 9, n. 1, p. 63, 2022.

FELIX, H. C. et al. **Unifying Public Datasets for Insulator Detection and Fault Classification in Electrical Power Lines**. 2020. [invalidurl,donotcite].

GAO, B.; PAVEL, L. On the properties of the softmax function with application in game theory and reinforcement learning. **arXiv preprint arXiv:1704.00805**, 2017.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 3. ed. [S.I.]: Prentice Hall, 2008.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.I.]: MIT Press, 2016.

GOODFELLOW, I. et al. Generative adversarial nets. **Advances in Neural Information Processing Systems**, v. 27, 2014.

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 21, n. 9, p. 1263–1284, 2009.

HUBER, P. J. Robust estimation of a location parameter. **The Annals of Mathematical Statistics**, Institute of Mathematical Statistics, v. 35, n. 1, p. 73–101, 1964.

ISOLA, P. et al. Comparison of image normalization methods for multi-site deep learning. **Applied Sciences**, v. 13, n. 15, p. 8923, 2023.

JOHNSON, J. M.; KHOSHGOFTAAR, T. M. Survey on deep learning with class imbalance. **Journal of Big Data**, Springer, v. 6, n. 1, p. 27, 2019.

JOSHI, P. **OpenCV with Python By Example**. O'Reilly Media, Inc., 2025. Disponível em: <https://www.oreilly.com/library/view/opencv-with-python/9781785283932/>.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. **arXiv preprint arXiv:1412.6980**, 2014.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: **Advances in Neural Information Processing Systems**. [S.I.: s.n.], 2012.

KUEHLKAMP, A. **Ferramenta de baixo custo para gaze tracking baseado em imagens.** maio 2013. Dissertação (Mestrado) — Universidade do Vale do Itajaí, Itajaí, SC, Brasil, maio 2013. Dissertação de Mestrado em Computação Aplicada.

KUMAR, D. et al. A novel scheme of fault detection in transmission line using image processing. **Global Journal of Computer Science and Technology**, v. 17, n. 1, 2023.

LANGER, S. Approximating smooth functions by deep neural networks with sigmoid activation function. **arXiv preprint arXiv:2010.04596**, 2020.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LEDIG, C. et al. Photo-realistic single image super-resolution using a generative adversarial network. In: **CVPR**. [S.I.: s.n.], 2017. p. 4681–4690.

LI, C. et al. A simple deep learning based image illumination correction method for paintings. **Pattern Recognition Letters**, v. 138, p. 392–398, 2020.

LI, X. et al. Fusion of image processing techniques for fault detection in electrical insulators. **IEEE Transactions on Power Delivery**, v. 34, n. 3, p. 1234–1241, 2019.

LIAN, Z.; WANG, H. An image deblurring method using improved u-net model based on multilayer fusion and attention mechanism. **Scientific Reports**, Nature Publishing Group, v. 13, p. 21402, 2023. Disponível em: <https://www.nature.com/articles/s41598-023-47768-4>.

LIN, T.-Y. et al. Focal loss for dense object detection. **Proceedings of the IEEE International Conference on Computer Vision**, p. 2980–2988, 2017.

LIU, C. et al. Detecção de falhas em isoladores em imagens aéreas de linhas de transmissão de alta voltagem baseada em modelo de aprendizado profundo. **Appl. Sci.**, v. 11, n. 10, p. 4647, 2021.

LIU, S. et al. A neural network for long-term super-resolution imaging of live cells with reliable confidence quantification. **Nature Biotechnology**, 2025.

MACDONALD, L. Color space transformation using neural networks. In: **Proc. IS&T 27th Color and Imaging Conf.** [S.I.: s.n.], 2019. p. 178–183.

MALLA, P. K. et al. A comprehensive review of deep neural networks for medical image processing: Recent developments and future opportunities. **Healthcare Analytics**, Elsevier, v. 4, p. 100216, 2023. Disponível em: <https://doi.org/10.1016/j.health.2023.100216>.

MATHWORKS. Deblurring images using the lucy-richardson algorithm. **MathWorks Help Center - Image Processing Toolbox**, 2025. Disponível em: <https://www.mathworks.com/help/images/deblurring-images-using-the-lucy-richardson-algorithm.html>.

NALEPA, J. et al. A review: Data pre-processing and data augmentation techniques. **ScienceDirect**, 2022.

OBERWEGER, F.; WENDEL, A.; BISCHOF, H. **XAI-guided Insulator Anomaly Detection for Imbalanced Datasets**. 2024. ArXiv:2409.16821.

PAN, S. J.; YANG, Q. A survey on transfer learning. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 22, n. 10, p. 1345–1359, 2010.

PANDEY, N. **Mastering Image Contrast: A Step-by-Step Guide to Enhancing Image**. 2023. Acessado em: 20 abr. 2025. Disponível em: <https://www.nomidl.com/computer-vision/mastering-image-contrast/>.

PEER, D. et al. Real-time noise cancellation with deep learning. **PMC**, v. 9, p. e9678292, 2022.

PENG, H. et al. Edf-yolov5: An improved algorithm for power transmission line defect detection based on yolov5. **Electronics**, MDPI, v. 13, n. 1, p. 148, 2023.

RASHID, M. e. a. A survey of neural network optimization algorithms. **Artificial Intelligence Review**, Springer, 2020.

RODRIGUES, L. F.; NALDI, M. C.; MARI, J. F. Comparing convolutional neural networks and preprocessing techniques for hep-2 cell classification in immunofluorescence images. **Computers in Biology and Medicine**, Elsevier, v. 116, p. 103542, 2020. Acessado em: 24 mar. 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0010482519303993>.

RUDER, S. An overview of gradient descent optimization algorithms. **arXiv preprint arXiv:1609.04747**, 2016.

SABOTTKE, C. F. et al. The effect of image resolution on deep learning in radiography. **Radiology: Artificial Intelligence**, v. 2, n. 1, p. e190015, 2020.

SALVI, M. et al. The impact of pre- and post-image processing techniques on deep learning frameworks: A comprehensive review for digital pathology image analysis. **Computers in Biology and Medicine**, Elsevier, v. 128, p. 104129, 2021.

SHARMA, A. et al. Deep learning models for digital image processing: a review. **Artificial Intelligence Review**, 2024.

SHORTEN, C. et al. A survey on image data augmentation for deep learning. **Journal of Big Data**, v. 6, n. 1, p. 1–48, 2019.

SUMIDA, I. et al. Deep convolutional neural network for reduction of contrast-enhanced region on ct images. **Journal of Radiation Research**, v. 60, n. 5, p. 586–594, 2019.

The MathWorks, Inc. **Wavelet Denoising**. 2023. Acesso em 20 abr. 2025. Disponível em: <https://www.mathworks.com/help/release/R2021a/wavelet/ug/wavelet-denoising.html>.

TIELEMAN, T.; HINTON, G. **Lecture 6.5—RMSProp: Divide the gradient by a running average of its recent magnitude**. 2012. COURSERA: Neural Networks for Machine Learning.

TORRES, L. **Curva ROC y AUC en Python**. 2025. Acessado em: 1 jun. 2025. Disponível em: <https://www.themachinelearners.com/curva-roc-vs-prec-recall/>.

VEEN, F. V. **The Neural Network Zoo**. 2016. <https://www.asimovinstitute.org/neural-network-zoo/>. Acesso em: 21 abr. 2025.

VENTURELLI, M. **The dangers behind image resizing**. 2021. <https://zuru.tech/blog/the-dangers-behind-image-resizing>. Accessed: 2025-04-20.

WANG, L. et al. Análise sustentável da detecção de falhas em isoladores baseada em otimização visual refinada. **Sustainability**, v. 15, n. 4, p. 3456, 2023.

YANG, Z. et al. Using convolutional neural network models illumination estimation according to light colors. **Optics Communications**, v. 513, p. 128108, 2022.

YU, J. et al. Edge detection using a neural network. **Pattern Recognition**, v. 27, n. 12, p. 1653–1662, 1994.

ZHANG, Z. et al. Detecção de defeitos em isoladores por imagem baseada em processamento morfológico e aprendizado profundo. **Energies**, v. 15, n. 7, p. 2465, 2022.

ZHANG, Z.; SABUNCU, M. R. Cross-entropy loss function and classification performance. **arXiv preprint arXiv:1805.05768**, 2018.

ZHENG, J. et al. Insulator-defect detection algorithm based on improved yolov7. **Sensors**, MDPI, v. 22, n. 22, p. 8801, 2022.

ZOU, H. et al. A bolt defect detection method for transmission lines based on improved yolov5. **Frontiers in Energy Research**, Frontiers, v. 12, p. 1269528, 2024.

ÖZTÜRK, ; AKDEMİR, B. Effects of histopathological image pre-processing on convolutional neural networks. In: ELSEVIER. **Procedia Computer Science**. [S.I.], 2018. v. 132, p. 396–403. International Conference on Computational Intelligence and Data Science (IC-CIDS 2018).