

UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS NATURAIS E EXATAS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE
IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS
EM CADEIAS DE ISOLADORES**

Santa Maria, RS
2025

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS
À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**. Defesa realizada por videoconferência.

Orientador: Prof. Dr. Daniel Pinheiro Bernardon

Coorientador: Prof. Dr. Paulo César Vargas Luz

Santa Maria, RS
2025

Luan Willig Silveira

**MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS
À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**.

Aprovado em 8 de dezembro de 2025:

**Daniel Pinheiro Bernardon, Dr. (UFSM)
(Presidente/Orientador)**

**Paulo César Vargas Luz, Dr. (UFSM)
(Coorientador)**

Banca Um, Dra. (UFSM)

Banca Dois, Dr. (UFSM)

Santa Maria, RS
2025

RESUMO

MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES

AUTOR: Luan Willig Silveira
Orientador: Daniel Pinheiro Bernardon
Coorientador: Paulo César Vargas Luz

Escreva seu resumo aqui! Você pode digitá-lo diretamente neste arquivo ou usar o comando input. O resumo deve ter apenas uma página, desde o cabeçalho até as palavras chave. Caso seu resumo seja maior, use comandos para diminuir espaçamento e fonte (até um mínimo de 10pt) no texto. Segundo a MDT, é preciso que os resumos tenham, no máximo, 250 palavras para trabalhos de conclusão de curso de graduação, pós-graduação e iniciação científica e até 500 palavras para dissertações e teses.

Palavras-chave: Processamento de Imagens. Redes Neurais Artificiais. Aprendizado de Máquina. Métricas de Qualidade. Classificação de Imagens. Detecção de Objetos. Regressão. Dataset. Combinação de Processamentos. Otimização. Deep Learning. Segmentação de Imagens. Eficiência Computacional. Redes Convolucionais (CNN). Comparação de Modelos. Inteligência Artificial.

ABSTRACT

IMAGE PROCESSING ENHANCEMENT METHOD APPLIED TO FAULT DETECTION AND CLASSIFICATION IN INSULATOR STRINGS

AUTHOR: Luan Willig Silveira
ADVISOR: Daniel Pinheiro Bernardon
CO-ADVISOR: Paulo César Vargas Luz

Write your abstract here! As recomendações do resumo também se aplicam ao abstract. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: Keyword 1. Keyword 2. Keyword 3. (...)

SUMÁRIO

1	INTRODUÇÃO	8
1.1	PROPOSTA	8
1.2	OBJETIVO GERAL	9
1.3	OBJETIVOS ESPECÍFICOS	10
1.4	JUSTIFICATIVA	10
1.5	CRONOGRAMA	11
2	TRABALHOS RELACIONADOS	12
2.1	ANÁLISE SUSTENTÁVEL DA DETECÇÃO DE FALHAS EM ISOLADORES BASEADA EM OTIMIZAÇÃO VISUAL REFINADA	12
2.2	DETECÇÃO DE FALHAS EM ISOLADORES EM IMAGENS AÉREAS DE LI- NHAS DE TRANSMISSÃO DE ALTA VOLTAGEM BASEADA EM MODELO DE APRENDIZADO PROFUNDO	13
2.3	DETECÇÃO DE DEFEITOS EM ISOLADORES POR IMAGEM BASEADA EM PROCESSAMENTO MORFOLÓGICO E APRENDIZADO PROFUNDO ...	13
2.4	DETECÇÃO MELHORADA DE DEFEITOS EM ISOLADORES UTILIZANDO YOLOV7	14
2.5	COMPARANDO REDES NEURAIS CONVOLUCIONAIS E TÉCNICAS DE PRÉ- PROCESSAMENTO PARA CLASSIFICAÇÃO DE CÉLULAS HEP-2 EM IMAGENS DE IMUNOFLUORESCÊNCIA	15
2.6	EFEITOS DO PRÉ-PROCESSAMENTO DE IMAGENS HISTOPATOLÓGICAS EM REDES NEURAIS CONVOLUCIONAIS	16
2.7	O IMPACTO DE TÉCNICAS DE PRÉ-PROCESSAMENTO E PÓS-PROCESSAMENTO DE IMAGENS EM FRAMEWORKS DE APRENDIZADO PROFUNDO: UMA REVISÃO ABRANGENTE PARA ANÁLISE DE IMAGENS DE PATOLOGIA DIGITAL	17
2.8	RESUMO DOS TRABALHOS	17
2.9	JUSTIFICATIVA DA RELEVÂNCIA DA METODOLOGIA PROPOSTA	18
2.10	TABELA COMPARATIVA DOS TRABALHOS	18
2.11	CONSIDERAÇÕES FINAIS DO CAPÍTULO	19
3	REVISÃO BIBLIOGRÁFICA	20
3.1	PROCESSAMENTO DE IMAGENS	20
3.1.1	Normalização	21
3.1.2	Redimensionamento e Recorte	22
3.1.3	Aumento de Dados	23
3.1.4	Redução de Ruído	24
3.1.5	Ajuste de Contraste e Brilho	25

3.1.6	Aumento de Nitidez	26
3.1.7	Conversão de Espaço de Cores	27
3.1.8	Restauração e Desembaçamento de Imagens	27
3.1.9	Detecção de Bordas	28
3.1.10	Correção de Iluminação	29
3.1.11	Super-Resolução	30
3.1.12	Conclusão parcial da seção	30
3.2	REDES NEURAIS	31
3.2.1	Tipos de redes neurais	32
3.2.1.1	Perceptron (P), Feed Forward Network (FFN)	32
3.2.1.2	Convolutional neural network (CNN) ou Deep convolutional network (DCN)	34
3.2.2	Funções de ativação	35
3.2.2.1	ReLU (Rectified Linear Unit)	35
3.2.2.2	Sigmoid	35
3.2.2.3	Softmax	35
3.2.2.4	Regras gerais para escolha de funções de ativação	36
3.2.3	Funções de Custo	36
3.2.3.1	Erro Médio Quadrático (MSE)	36
3.2.3.2	Erro Médio Absoluto (MAE)	37
3.2.3.3	Função Huber	37
3.2.3.4	Entropia Cruzada Binária	37
3.2.3.5	Entropia Cruzada Categórica	37
3.2.4	Otimizadores	38
3.3	DATASETS	38
3.4	MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO DE MODELOS	41
3.5	CONSIDERAÇÕES FINAIS DO CAPÍTULO	44
4	METODOLOGIA	46
4.1	INÍCIO E DEFINIÇÃO DE MÉTRICAS	49
4.1.1	Início	49
4.2	SELEÇÃO E VALIDAÇÃO DO DATASET	50
4.2.1	Definir métricas: acurácia, F1-score, tempo	51
4.2.2	Selecionar dataset com imagens rotuladas	52
4.2.3	Dataset está balanceado?	53
4.2.4	Aplicar filtros e balanceamento	53
4.3	PRÉ-PROCESSAMENTO	54
4.3.1	Aplicar técnicas básicas: normalização, recorte, ruído	55
4.3.2	Aplicar data augmentation	55
4.3.3	Combinar técnicas?	56
4.3.4	Gerar pipeline de técnicas combinadas	56

4.3.5	Usar técnicas isoladas	56
4.4	AJUSTE DE PARÂMETROS	57
4.4.1	Otimizar parâmetros com busca automática	57
4.5	ESCOLHA E CONSTRUÇÃO DO MODELO	58
4.5.1	Selecionar modelo: CNN, ResNet, YOLO	59
4.5.2	Tipo de tarefa	60
4.5.3	Montar modelo de classificação	60
4.5.4	Montar modelo de detecção	60
4.5.5	Montar modelo de regressão	61
4.6	TREINAMENTO	61
4.6.1	Treinar modelo com dados processados	62
4.7	AVALIAÇÃO E AJUSTES	63
4.7.1	Avaliar com as métricas definidas	64
4.7.2	Desempenho satisfatório?	64
4.7.3	Ajustar processamentos e modelo	65
4.7.4	Comparar diferentes modelos e técnicas	65
4.7.5	Conclusões e recomendações	66
5	COLETA E ANÁLISE DE RESULTADOS	67
5.1	OTIMIZAÇÃO DE PARÂMETROS DE PRÉ-PROCESSAMENTO EM VISÃO COMPUTACIONAL	67
5.1.1	Metodologia Experimental	67
5.1.1.1	Conjunto de Dados	67
5.1.1.2	Estratégia de Pré-Processamento	68
5.1.1.3	Modelo de Aprendizado de Máquina	68
5.1.1.4	Estratégia de Otimização Paramétrica	69
5.1.2	Apoio Teórico do Método Selecionado	69
5.1.3	Resultados Reportados e Análise Factual	70
5.1.4	Síntese da Etapa e Encaminhamentos	71
5.2	IMPACTO DOS MODELOS NO DESEMPENHO DOS PROCESSAMENTOS	72
5.3	INFLUÊNCIA DOS DATASETS NOS RESULTADOS	72
5.4	COMPARAÇÃO ENTRE DIFERENTES ESTRATÉGIAS DE PROCESSAMENTO	72
6	CONCLUSÃO	73
6.1	SÍNTESE DOS RESULTADOS OBTIDOS	73
6.2	LIMITAÇÕES E DESAFIOS ENCONTRADOS	73
6.3	SUGESTÕES PARA PESQUISAS FUTURAS	73
	REFERÊNCIAS BIBLIOGRÁFICAS	74

1 INTRODUÇÃO

1.1 PROPOSTA

O presente estudo tem como objetivo desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores. Para isso, serão estabelecidas métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento. Além disso, serão construídos modelos de redes neurais para avaliar o desempenho dos processamentos, podendo abranger tarefas como classificação, detecção e regressão. No decorrer do estudo, serão construídos modelos de redes neurais voltados para a avaliação do desempenho das técnicas de processamento de imagem, sem a intenção de definir um modelo ideal.

Também será analisado o impacto da escolha do modelo de rede neural no desempenho do processamento, visto que diferentes modelos podem gerar resultados distintos para um mesmo processamento. A influência do dataset na eficácia do processamento será outro aspecto a ser investigado, considerando possíveis variações nos resultados devido ao uso de diferentes conjuntos de dados. Para aprimorar os processamentos de imagem, será desenvolvida uma metodologia que permita a combinação de diferentes processamentos unitários (processamentos de imagem que realizam uma única operação). Além disso, será criado um método de ajuste automático de parâmetros das técnicas de processamento de imagem, com o intuito de otimizar seus resultados sem exigir extensa intervenção manual.


A metodologia proposta será desenvolvida dentro de um conjunto de restrições previamente estabelecidas, garantindo um escopo bem delimitado e viável dentro do período de realização da dissertação. Primeiramente, o estudo será restrito à detecção e classificação de falhas em cadeias de isoladores elétricos, não abrangendo outros componentes elétricos. O uso de imagens previamente adquiridas será uma diretriz, de modo que apenas imagens já disponíveis ou capturadas por métodos convencionais serão utilizadas, sem o desenvolvimento de novas técnicas de aquisição de imagens. Além disso, a metodologia será aplicada exclusivamente a técnicas de processamento de imagem já conhecidas, sem a criação de novos algoritmos de base.

Os modelos de redes neurais desenvolvidos terão o propósito único de avaliar o impacto das redes sobre os processamentos de imagem, sem a intenção de definir um modelo definitivo para diagnóstico industrial. A análise será conduzida utilizando conjuntos de dados já existentes ou obtidos por métodos convencionais, sem a necessidade de criar um novo dataset específico para o estudo. A otimização contemplada estará limitada ao

ajuste de parâmetros das técnicas existentes, não incluindo o desenvolvimento de novas abordagens baseadas em inteligência artificial para otimização dos processamentos. Por fim, toda a avaliação será realizada em ambiente controlado, sem a realização de testes em ambientes industriais reais.

A Figura 1 ilustra o diagrama da proposta de metodologia.

Figura 1 – Diagrama da proposta de metodologia



Fonte: Autor.

1.2 OBJETIVO GERAL

O objetivo geral deste estudo é desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores.

1.3 OBJETIVOS ESPECÍFICOS

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

- Estabelecer métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento.
- Determinar o tipo de modelo de redes neurais ideal para avaliar o desempenho dos processamentos, podendo abranger classificação, detecção e regressão.
- Construir modelos de redes neurais destinados à avaliação do desempenho das técnicas de processamento de imagem, sem o intuito de encontrar um modelo definitivo.
- Analisar o impacto da escolha do modelo de rede neural no desempenho do processamento, considerando que diferentes modelos podem gerar diferentes resultados para um mesmo processamento.
- Avaliar a influência do dataset na eficácia do processamento, considerando possíveis variações nos resultados devido à utilização de diferentes conjuntos de dados.
- Desenvolver uma metodologia para o aprimoramento dos processamentos de imagem por meio da combinação de diferentes abordagens unitárias.
- Criar um método de ajuste automático de parâmetros dos processamentos de imagem, visando otimizar seus resultados sem a necessidade de intervenção manual extensa.

1.4 JUSTIFICATIVA

A crescente demanda por sistemas automatizados de inspeção de cadeias de isoladores evidencia a necessidade de técnicas avançadas de processamento de imagem para a detecção precoce de falhas. Conforme demonstrado por Gonzalez e Woods (GONZALEZ; WOODS, 2008), a análise digital de imagens permite extrair características relevantes para identificar anomalias em componentes elétricos, possibilitando diagnósticos mais precisos. Ademais, o emprego de redes neurais tem se destacado na resolução de problemas complexos de classificação e detecção, conforme ressaltado por LeCun et al. (LECUN; BENGIO; HINTON, 2015) e Krizhevsky et al. (KRIZHEVSKY; SUTSKEVER; HINTON, 2012), contribuindo para a robustez dos sistemas de inspeção.

Estudos recentes apontam que a combinação de diferentes técnicas de processamento de imagem, aliada ao ajuste automático de parâmetros, pode resultar em melhorias

significativas no desempenho dos sistemas de diagnóstico (LI et al., 2019). Assim, a proposta deste trabalho visa desenvolver uma metodologia que integre esses avanços, buscando não apenas aprimorar a acurácia e a eficiência dos processamentos, mas também possibilitar uma análise comparativa que leve em conta a influência de diferentes modelos e datasets.

Dessa forma, esta dissertação justifica-se pela necessidade de inovar na abordagem de detecção e classificação de falhas em cadeias de isoladores, promovendo ganhos práticos para a segurança e manutenção das redes elétricas, e contribuindo para a evolução do estado da arte em processamento de imagem e aprendizado de máquina.

1.5 CRONOGRAMA

A seguir, é apresentado um cronograma de atividades para garantir a organização e a execução das tarefas.

Etapa	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
1. Introdução	✓										
2. Revisão Bibliográfica	✓	✓	✓	✓	✓						
3. Metodologia						✓	✓	✓			
4. Implementação dos Modelos							✓	✓	✓		
5. Coleta e Análise de Resultados							✓	✓	✓	✓	
6. Conclusão e Redação Final									✓	✓	✓
7. Defender											✓

Tabela 1 – Cronograma de Atividades

2 TRABALHOS RELACIONADOS

A utilização de ferramentas de inteligência artificial para diagnósticos em equipamentos tem se destacado como uma solução promissora no contexto da manutenção preventiva, especialmente diante do aumento da complexidade dos sistemas industriais e da necessidade de maior confiabilidade operacional (SALVI et al., 2021). O avanço tecnológico e a crescente disponibilidade de dados impulsionaram o desenvolvimento de métodos automatizados, tornando o diagnóstico mais eficiente e preciso.

No setor elétrico, particularmente no sistema elétrico de potência, essas soluções têm ganhado relevância devido à criticidade dos ativos e ao impacto direto na continuidade do fornecimento de energia. A detecção precoce de falhas em componentes como isoladores, transformadores e linhas de transmissão é fundamental para evitar interrupções e reduzir custos de manutenção (WANG et al., 2023). O uso de inteligência artificial permite analisar grandes volumes de dados e identificar padrões complexos, superando limitações das abordagens tradicionais.

Diante desse cenário, diversos pesquisadores têm buscado aprimorar os métodos de diagnóstico automatizado, propondo novas técnicas e avaliando o impacto de diferentes estratégias de processamento de imagens e aprendizado profundo. As próximas seções apresentam uma revisão dos principais trabalhos relacionados, com o objetivo de contextualizar a importância do tema e caracterizar o estado da arte na área.

2.1 ANÁLISE SUSTENTÁVEL DA DETECÇÃO DE FALHAS EM ISOLADORES BASEADA EM OTIMIZAÇÃO VISUAL REFINADA

O primeiro estudo aborda a detecção de falhas em isoladores em linhas de transmissão aéreas, destacando a vulnerabilidade desses componentes a fatores ambientais. A inspeção manual é ineficaz devido ao alto volume de dados e à complexidade dos fundos das imagens, levando à aplicação da rede neural convolucional de atenção regressiva (RA-CNN). O método proposto melhora a acurácia da detecção ao empregar extração de características em múltiplas escalas e operações recursivas, com otimização pelo algoritmo de Enxame de Partículas (PSO). Os resultados indicam que a RA-CNN (1+2+3) atinge 85,3% de acurácia, superando os modelos FCAN e MG-CNN. Além disso, a abordagem proposta demonstra maior eficiência em tempo real, atingindo 25,4 FPS. (WANG et al., 2023)


2.2 DETECÇÃO DE FALHAS EM ISOLADORES EM IMAGENS AÉREAS DE LINHAS DE TRANSMISSÃO DE ALTA VOLTAGEM BASEADA EM MODELO DE APRENDIZADO PROFUNDO

O segundo estudo foca na detecção de falhas em isoladores por meio de imagens aéreas, utilizando um modelo YOLO modificado, denominado CSPD-YOLO, baseado no YOLO-v3 e na Rede Parcial de Estágio Cruzado. A pesquisa envolve a criação do conjunto de dados 'InSF-detection', composto por 1.331 imagens e 2.104 falhas rotuladas. O modelo CSPD-YOLO se destaca por uma alta acurácia ($AP = 98,18\%$) e eficiência no processamento (0,011 s), superando modelos tradicionais como YOLO-v3 e YOLO-v4. A análise qualitativa indica que o método é eficaz mesmo em cenários complexos, como presença de rios, vegetação e torres de energia. (LIU et al., 2021)

2.3 DETECÇÃO DE DEFEITOS EM ISOLADORES POR IMAGEM BASEADA EM PROCESSAMENTO MORFOLÓGICO E APRENDIZADO PROFUNDO

O terceiro estudo propõe um método híbrido para detecção de defeitos em isoladores, combinando aprendizado profundo (Faster RCNN) com processamento morfológico. A segmentação das imagens utiliza técnicas de transformação de forma para identificação e separação de isoladores, enquanto a detecção de falhas é realizada por um modelo matemático aplicado a imagens binárias. O Faster RCNN alcança $AP = 0,9175$ e $recall = 0,98$, superando abordagens baseadas em ResNet, YOLO e LBP+SVM. Além disso, a análise de desempenho em diferentes níveis de voltagem e condições de ruído demonstra a robustez do modelo (ZHANG et al., 2022). O processo de segmentação realizado no trabalho é apresentado na Figura 2.

Figura 2 – Segmentação de isoladores



Fonte: Zhang et al. (2022).

2.4 DETECÇÃO MELHORADA DE DEFEITOS EM ISOLADORES UTILIZANDO YOLOV7

O estudo de Zheng et al. (2022) aborda a detecção de defeitos em isoladores utilizando um modelo YOLOv7 modificado por meio de diversas otimizações em sua arquitetura e processo de treinamento. O trabalho foca na detecção de defeitos em imagens com fundos complexos, utilizando um conjunto de dados com 1600 imagens para o experimento.

A abordagem proposta não utiliza aprendizado por transferência, mas sim melhorias diretas no modelo. As principais modificações incluem:

- O uso do algoritmo **K-means++** para gerar caixas de âncora (*anchor boxes*) mais

adequadas aos alvos.


- A adição dos módulos **Coordinate Attention (CoordAtt)** e **HorBlock** para aprimorar a extração de características e focar em informações relevantes.
- A implementação da função de perda **SloU** para acelerar a convergência do modelo e da **focal loss** para lidar com o desbalanceamento entre amostras positivas e negativas.

Os resultados demonstram que o modelo melhorado é eficaz na detecção de defeitos pequenos, como *flashovers* por poluição, alcançando uma precisão média (mAP) de 93,8%. Este desempenho supera o modelo YOLOv7 original, bem como outras abordagens como Faster R-CNN e YOLOv5s.

2.5 COMPARANDO REDES NEURAIS CONVOLUCIONAIS E TÉCNICAS DE PRÉ-PROCESSAMENTO PARA CLASSIFICAÇÃO DE CÉLULAS HEP-2 EM IMAGENS DE IMUNOFLUORESCÊNCIA

A pesquisa avalia seis estratégias de pré-processamento e cinco arquiteturas de CNNs de última geração para classificar células HEp-2 em imagens de imunofluorescência, uma tarefa crítica em diagnósticos médicos. Métodos como aumento de dados (rotações, espelhamentos), ajuste fino e otimização de hiperparâmetros foram testados em conjunto com arquiteturas como Inception-V3 e ResNet. Surpreendentemente, o melhor desempenho, com 98,28% de precisão, foi alcançado ao treinar o modelo Inception-V3 do zero, utilizando apenas aumento de dados sem pré-processamento adicional. A conclusão sugere que, para esse tipo de imagem, técnicas tradicionais de pré-processamento podem ser menos impactantes quando o aumento de dados é bem implementado, desafiando a necessidade de etapas complexas de preparação. A contribuição do estudo está em mostrar que, em cenários específicos como imagens médicas de imunofluorescência, estratégias simples podem superar abordagens mais elaboradas, oferecendo uma alternativa eficiente para aplicações práticas em classificação (RODRIGUES; NALDI; MARI, 2020). A Figura 3 apresenta os métodos e combinações de pré-processamentos utilizados no trabalho.

Figura 3 – Etapas do método proposto



Fonte: Rodrigues, Naldi e Mari (2020).

2.6 EFEITOS DO PRÉ-PROCESSAMENTO DE IMAGENS HISTOPATOLÓGICAS EM REDES NEURAIAS CONVOLUCIONAIS

O artigo analisa como diferentes níveis de pré-processamento afetam a classificação de imagens histopatológicas por CNNs, dividindo os dados em quatro categorias: imagens originais, pré-processadas normalmente (com redução de ruído e aprimoramento de células), outras pré-processadas normalmente e excessivamente pré-processadas (com operações morfológicas adicionais). Os experimentos revelam que o pré-processamento normal melhora a precisão ao remover ruídos de fundo e realçar características celulares, mas o excesso de processamento não agrega valor e pode até degradar o desempenho ao eliminar informações úteis. A conclusão enfatiza a importância de um equilíbrio no pré-processamento, recomendando ajustes moderados para maximizar a eficácia das CNNs em imagens histopatológicas. A contribuição do trabalho é fornecer uma análise comparativa detalhada que orienta pesquisadores e profissionais na escolha de técnicas de pré-processamento, evitando exageros que comprometam a qualidade dos dados em aplicações médicas (ÖZTÜRK; AKDEMİR, 2018).

2.7 O IMPACTO DE TÉCNICAS DE PRÉ-PROCESSAMENTO E PÓS-PROCESSAMENTO DE IMAGENS EM FRAMEWORKS DE APRENDIZADO PROFUNDO: UMA REVISÃO ABRANGENTE PARA ANÁLISE DE IMAGENS DE PATOLOGIA DIGITAL

Este trabalho explora como técnicas tradicionais de pré- e pós-processamento de imagens, como redução de ruído, correção de iluminação e segmentação, melhoram o desempenho de redes neurais em tarefas de patologia digital, incluindo classificação (tecido saudável vs. canceroso), detecção (contagem de linfócitos) e segmentação (núcleos e glândulas). Ao analisar uma ampla gama de estudos, os autores concluem que essas técnicas são indispensáveis para lidar com a variabilidade e complexidade das imagens médicas, melhorando significativamente a precisão e a robustez dos modelos de aprendizado profundo. A revisão destaca que o pós-processamento, como refinamento de contornos, também desempenha um papel crucial em tarefas de segmentação. A contribuição do artigo está em consolidar evidências sobre a eficácia dessas abordagens, oferecendo um guia abrangente para pesquisadores que buscam integrar métodos tradicionais ao treinamento de redes neurais, especialmente em contextos de patologia digital onde a qualidade dos dados é crítica (SALVI et al., 2021).

2.8 RESUMO DOS TRABALHOS

Diversos estudos abordam o impacto do pré-processamento de imagens na análise por redes neurais convolucionais (CNNs) e outros modelos de aprendizado profundo. O estudo de Liu et al. (2021) e Wang et al. (2023) optam por não realizar processamentos significativos, utilizando apenas redimensionamento e normalização.

Por outro lado, Öztürk e Akdemir (2018) investigam diferentes algoritmos de pré-processamento, incluindo remoção de fundo, filtros de suavização e equalização de histograma, além de um método de sobre-processamento baseado em limiar adaptativo. Rodrigues, Naldi e Mari (2020) testam técnicas como redimensionamento, alongamento de contraste, equalização de histograma e subtração da média, constatando que o uso de imagens originais favorece o desempenho da CNN, enquanto o data augmentation tem impacto positivo. Salvi et al. (2021) destacam que técnicas como remoção de artefatos, normalização de cor e seleção de patches melhoram a precisão dos modelos e reduzem o tempo computacional. Por fim, Zhang et al. (2022) exploram a segmentação de isoladores para otimizar a classificação.

2.9 JUSTIFICATIVA DA RELEVÂNCIA DA METODOLOGIA PROPOSTA

Os trabalhos analisados demonstram a importância do pré-processamento na análise de imagens, mas também indicam que determinadas abordagens podem comprometer o desempenho da CNN. Em especial, Rodrigues, Naldi e Mari (2020) evidenciam que a eliminação de ruídos e artefatos pode não ser sempre benéfica. Além disso, Salvi et al. (2021) reforçam que técnicas de segmentação e normalização podem aprimorar a análise quando aplicadas corretamente. No entanto, nenhum dos estudos analisados aborda a metodologia específica proposta nesta dissertação, o que destaca sua inovação e potencial contribuição para a área.

2.10 TABELA COMPARATIVA DOS TRABALHOS

A tabela 2 compara os resultados de diferentes estudos sobre pré-processamento de imagens e seu impacto nos modelos de classificação de imagens. Os estudos variam desde melhorias no desempenho até riscos de sobre-processamento, destacando a falta de consenso e a necessidade de novas abordagens. A metodologia proposta neste trabalho busca preencher essa lacuna ao introduzir um método inovador para determinar os processamentos mais eficientes e otimizar os parâmetros de processamento, oferecendo uma solução mais robusta e adaptável para análise de imagens.

Trabalho	Resultado do pré-processamento
Liu et al. (2021)	Sem impacto significativo
Öztürk e Akdemir (2018)	Melhorou contraste, mas risco de sobre-processamento
Rodrigues, Naldi e Mari (2020)	Afetou negativamente a CNN; data augmentation foi positivo
Salvi et al. (2021)	Melhorou precisão e reduziu tempo computacional
Wang et al. (2023)	Sem impacto significativo
Zhang et al. (2022)	Melhorou o desempenho do modelo
Zheng et al. (2022)	Aumento de dados e aprendizado por transferência melhoraram detecção
Zou et al. (2024)	Aprendizado por transferência eficaz para defeitos em parafusos

Tabela 2 – Comparação dos trabalhos relacionados

A análise desses estudos reforça a lacuna existente na literatura e a necessidade de uma nova abordagem, como a metodologia proposta nesta dissertação. A proposta de um método para determinar os processamentos mais eficientes e otimizar os parâmetros de processamento representa uma contribuição significativa para a área de análise de

imagens. Através da combinação de técnicas de pré-processamento adaptativo e otimização de parâmetros, o trabalho busca não apenas melhorar o desempenho dos modelos de aprendizado profundo, mas também oferecer uma solução prática e eficiente para cenários complexos. Essa abordagem pode impactar positivamente diversas áreas, como diagnóstico médico, inspeção industrial e análise de imagens aéreas, ao proporcionar resultados mais precisos e confiáveis. Além disso, a metodologia proposta pode servir como base para futuras pesquisas e aplicações em diferentes contextos, ampliando as possibilidades de utilização das redes neurais em tarefas desafiadoras de classificação e detecção de objetos em imagens.

2.11 CONSIDERAÇÕES FINAIS DO CAPÍTULO

A metodologia apresentada neste trabalho se diferencia dos estudos revisados ao introduzir um novo enfoque que não foi explorado anteriormente. Enquanto os trabalhos existentes se concentram em construção de modelos de redes neurais e utilização de técnicas tradicionais de pré-processamento e normalização, a metodologia deste trabalho propõe a criação de um método para determinar os processamentos mais eficientes das imagens, além de um método de otimização dos parâmetros de processamento. Além disso, a pesquisa busca integrar novas abordagens que possam aprimorar a análise de dados em contextos variados, contribuindo para a evolução das técnicas de aprendizado profundo. A implementação dessas novas abordagens poderá oferecer insights valiosos para futuras investigações e aplicações práticas.

3 REVISÃO BIBLIOGRÁFICA

O processamento de imagens é uma ferramenta essencial para garantir a confiabilidade do Sistema Elétrico de Potência (SEP), especialmente na detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica. Essa técnica permite identificar problemas em componentes como isoladores, fixadores e suportes, que, se não tratados, podem causar interrupções no fornecimento de energia. O uso de imagens capturadas por drones ou câmeras especiais facilita a inspeção de grandes extensões de linhas de transmissão, reduzindo custos e aumentando a segurança ao evitar a necessidade de intervenções manuais em locais de difícil acesso (EZE et al., 2022).

Métodos avançados de análise de imagens, como os baseados em aprendizado profundo, ajudam a reconhecer padrões que indicam falhas, mesmo em condições adversas, como baixa visibilidade ou equipamentos desgastados (ALTAIE et al., 2023). Essas abordagens são particularmente úteis em regiões com infraestrutura antiga, onde a manutenção regular é desafiadora. Além disso, o processamento de imagens possibilita uma resposta rápida a problemas, minimizando o impacto de falhas na rede elétrica e melhorando a continuidade do serviço (KUMAR et al., 2023).

A automação proporcionada pelo processamento de imagens também contribui para a eficiência operacional. Técnicas modernas permitem monitorar equipamentos em tempo real, identificando danos antes que se tornem críticos (EZE et al., 2022). Isso é crucial para manter a estabilidade do SEP, especialmente em áreas remotas ou com alta demanda energética. Assim, o processamento de imagens não apenas aprimora a manutenção das linhas de transmissão, mas também reforça a segurança e a confiabilidade do fornecimento de energia elétrica.

A seguir, será apresentada uma revisão dos principais conceitos e técnicas de processamento de imagens, que podem ser aplicados na detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica.

3.1 PROCESSAMENTO DE IMAGENS

O processamento de imagens desempenha um papel fundamental no contexto do Sistema Elétrico de Potência (SEP), especialmente em atividades de inspeção, manutenção preditiva e monitoramento de ativos em linhas de transmissão. Com o uso crescente de drones, câmeras térmicas e sensores ópticos, a obtenção de imagens de componentes da rede elétrica tornou-se mais acessível e eficiente. No entanto, a qualidade e a variabilidade dessas imagens exigem técnicas robustas de pré-processamento para garantir resultados precisos em tarefas como a detecção de falhas, corrosões, aquecimentos anô-


malos e objetos estranhos nas estruturas. Esta seção apresenta os principais métodos de processamento de imagens empregados para preparar dados visuais que serão utilizados em modelos baseados em aprendizado de máquina e redes neurais, contribuindo diretamente para a confiabilidade, segurança e eficiência operacional do SEP.

3.1.1 Normalização

A normalização é uma etapa fundamental no pré-processamento de imagens para redes neurais, pois padroniza os valores dos pixels, facilitando a convergência durante o treinamento e melhorando a generalização do modelo. Um método comum é a normalização de valores de pixels, que escala os valores para intervalos como $[0,1]$ ou $[-1,1]$, frequentemente realizada dividindo os valores originais pelo máximo possível (por exemplo, 255 para imagens de 8 bits) (SHARMA et al., 2024a). Outro método é a normalização Z-score, que subtrai a média dos pixels e divide pelo desvio padrão, resultando em dados com média zero e variância unitária (CHEN et al., 2023). A equalização de histograma também é utilizada para redistribuir as intensidades dos pixels, aumentando o contraste e destacando detalhes em imagens de baixa qualidade (CHEN et al., 2023). Além disso, a padronização de cores, como subtrair os valores médios dos canais RGB, centraliza os dados em torno de uma distribuição normal, o que é particularmente útil para redes convolucionais (MALLA et al., 2023). Técnicas mais avançadas, como a normalização por percentis, utilizam o 5º e o 95º percentis como limites para lidar com valores discrepantes, enquanto a correspondência de histogramas ajusta a distribuição de intensidades com base em pontos de referência (ISOLA et al., 2023). Essas abordagens garantem que as redes neurais processem dados de forma consistente, reduzindo a sensibilidade a variações de iluminação ou escala, especialmente em tarefas de visão computacional (SHARMA et al., 2024a).

A Figura 4 ilustra o processo de normalização de imagens, onde a imagem original é transformada em uma imagem normalizada, facilitando a extração de características relevantes.

Figura 4 – Normalização de Imagens



Fonte: Kuehlkamp (2013).

3.1.2 Redimensionamento e Recorte

O redimensionamento é essencial para ajustar as imagens ao tamanho de entrada esperado pelas arquiteturas de redes neurais, garantindo compatibilidade e consistência. Um método comum é redimensionar as imagens para um tamanho fixo, como 224x224 pixels, amplamente utilizado em modelos como ResNet e VGG (CHEN et al., 2023). Isso pode ser feito por meio de interpolação bilinear ou bicúbica, que suaviza as transições entre pixels, embora métodos mais avançados, como interpolação baseada em Fourier, também sejam explorados (DENNANNI, 2019). O recorte, por outro lado, extrai uma região de interesse da imagem, frequentemente centrada, para preservar áreas relevantes, especialmente quando as dimensões originais variam significativamente (MALLA et al.,

2023). Estudos indicam que o redimensionamento para tamanhos menores pode acelerar o treinamento, mas tamanhos muito reduzidos podem comprometer a qualidade das características extraídas (SABOTTKE et al., 2020). Além disso, o recorte aleatório é usado em conjunto com aumento de dados para introduzir variabilidade durante o treinamento (NALEPA et al., 2022). Essas técnicas são cruciais para lidar com conjuntos de dados heterogêneos, garantindo que as entradas sejam uniformes sem perda significativa de informação (CHEN et al., 2023).

A Figura 5 ilustra o processo de redimensionamento e recorte de imagens, na qual a imagem da esquerda (original) é utilizada para extrair uma região de interesse (recorte) e em seguida redimensionada para um tamanho fixo (imagem da direita).

Figura 5 – Redimensionamento e recorte



Fonte: Adaptado de Venturelli (2021).

3.1.3 Aumento de Dados

O aumento de dados é uma estratégia poderosa para ampliar a diversidade do conjunto de treinamento, reduzindo o risco de sobreajuste e melhorando a robustez do modelo. Técnicas geométricas incluem espelhamento horizontal ou vertical, rotações em ângulos variados (de 1° a 359°), translações, cortes aleatórios e ajustes de escala, que simulam diferentes perspectivas e tamanhos (SHORTEN et al., 2019a). Transformações no espaço de cores, como ajustes de brilho, contraste, saturação e matiz, ajudam a lidar com variações de iluminação (SHORTEN et al., 2019a). Métodos mais avançados, como apagamento aleatório, mascaram partes da imagem para simular oclusões, enquanto a mistura de imagens combina pixels de diferentes amostras para criar novas instâncias (SHORTEN et al., 2019a). Por exemplo, o método SamplePairing reduziu o erro no conjunto CIFAR-10 de 8,22% para 6,93% (SHORTEN et al., 2019a). Além disso, redes adversárias generativas (GANs) são usadas para gerar imagens sintéticas, especialmente em domínios com


dados limitados, como imagens médicas, alcançando melhorias de até 10% em precisão (SHORTEN et al., 2019a). Essas técnicas são particularmente valiosas em cenários com poucos dados, permitindo que as redes neurais generalizem melhor para condições não vistas (NALEPA et al., 2022).

3.1.4 Redução de Ruído

A redução de ruído remove interferências que podem comprometer o desempenho das redes neurais, sendo especialmente crítica em aplicações como imagens médicas e vigilância. Métodos tradicionais, como filtros de média ou mediana, são complementados por abordagens baseadas em aprendizado profundo, como redes neurais convolucionais (CNNs) especializadas, como DnCNNs, que aprendem a mapear imagens ruidosas para versões limpas (SHARMA et al., 2024a). Autoencoders também são empregados para reconstruir imagens a partir de representações latentes, eliminando ruídos como Gaussianos ou de sal e pimenta (SHARMA et al., 2024a). Técnicas como Total Variation Denoising (TVD) e Non-Local Means (NLM) exploram regularizações e similaridades entre pixels para preservar detalhes (SHARMA et al., 2024a). Um estudo demonstrou que a aplicação de DnCNNs em imagens de tomografia computadorizada resultou em uma precisão de detecção de câncer de pulmão variando de 86,17% a 99,67% (SHARMA et al., 2024a). Além disso, métodos baseados em redes neurais profundas, como o Deep Neural Filter (DNF), alcançaram melhorias de até 10 dB na relação sinal-ruído em sinais de EEG (PEER et al., 2022). Essas abordagens são essenciais para garantir que as redes neurais processem imagens de alta qualidade, minimizando artefatos que poderiam obscurecer características críticas (SHARMA et al., 2024a).

A Figura 6 ilustra o processo de redução de ruído, onde a imagem original (à esquerda) é processada para remover o ruído, resultando em uma imagem mais limpa (à direita).

Figura 6 – Redução de Ruído



Fonte: Adaptado de The MathWorks, Inc. (2023).

3.1.5 Ajuste de Contraste e Brilho

O ajuste de contraste e brilho melhora a visibilidade das características das imagens, sendo crucial para tarefas que dependem de detalhes finos. A equalização de histograma redistribui as intensidades dos pixels para maximizar o contraste, enquanto a equalização adaptativa limitada por contraste (CLAHE) evita a amplificação excessiva de ruído em regiões homogêneas (MALLA et al., 2023). A correção gama ajusta a curva de intensidade para realçar detalhes em áreas escuras ou claras, sendo amplamente usada em imagens de baixa qualidade (MALLA et al., 2023). Métodos baseados em aprendizado profundo, como redes convolucionais fuzzy, integraram filtros Gaussianos e triangulares para melhorar imagens de íris, alcançando até 97% de precisão em tarefas de reconhecimento (SHARMA et al., 2024a). Além disso, técnicas como RetinexDIP foram propostas para melhorar a resolução e reduzir o consumo de memória em comparação com métodos tradicionais (SHARMA et al., 2024a). Essas abordagens são fundamentais para preparar imagens para redes neurais, garantindo que as características relevantes sejam destacadas (MALLA et al., 2023).

A Figura 7 ilustra o efeito do CLAHE em uma imagem, destacando detalhes que antes estavam obscurecidos.

Figura 7 – Ajuste de Contraste e Brilho com CLAHE



Fonte: Pandey (2023).

3.1.6 Aumento de Nitidez

O aumento de nitidez realça bordas e detalhes finos, facilitando tarefas como detecção de objetos e segmentação. Técnicas tradicionais, como a máscara de desfoque, aplicam filtros de alta passagem para enfatizar transições de intensidade (MALLA et al., 2023). Métodos baseados em redes neurais, como CNNs, foram desenvolvidos para detectar e corrigir nitidez, como no caso da detecção de máscaras de desfoque (USM), superando métodos baseados em codificação ternária perpendicular a bordas (DING et al., 2018). Em aplicações específicas, como imagens de documentos, redes convolucionais combinadas com filtros de Gabor e desfoque melhoraram a legibilidade, reduzindo distorções como sombras e ruídos (BEN et al., 2022). Essas técnicas são particularmente úteis em cenários onde a clareza das bordas é essencial para o desempenho do modelo (SHARMA et al., 2024a).

A Figura 8 ilustra o efeito do aumento de nitidez em uma imagem, onde os detalhes são mais evidentes após o processamento.

Figura 8 – Aumento de Nitidez



Fonte: Adaptado de Joshi (2025).

3.1.7 Conversão de Espaço de Cores

A conversão de espaço de cores adapta as imagens às necessidades específicas da tarefa, simplificando o processamento ou destacando características relevantes. A conversão de RGB para escala de cinza reduz a dimensionalidade, sendo útil em tarefas onde a cor não é essencial (SHARMA et al., 2024a). Espaços como HSV e LAB são preferidos em aplicações que requerem separação de matiz, saturação ou luminância, como segmentação de objetos (SHARMA et al., 2024a). Redes neurais também foram usadas para realizar conversões de espaço de cores, como de RGB para XYZ, alcançando erros de cor inferiores a 1,0 unidade E 2000 em mais de 85% dos casos testados (MACDONALD, 2019). Essas conversões são valiosas para otimizar a extração de características e reduzir a complexidade computacional em tarefas de visão computacional (SHARMA et al., 2024a).


3.1.8 Restauração e Desembaçamento de Imagens

A restauração de imagens visa recuperar a imagem original a partir de versões degradadas por desfoque, ruído ou outras distorções. O desembaçamento, um subcampo da restauração, utiliza redes neurais como U-Net para corrigir desfoques dinâmicos, alcançando PSNR de 31,53 no conjunto GoPro e 31,32 no Real Blur (LIAN; WANG, 2023). Métodos baseados em autoencoders convolucionais foram propostos para restaurar imagens em aplicações de fotografia computacional e sensoriamento remoto (BARRETO et al.,

2020). Além disso, redes neurais como DnCNNs foram aplicadas para remover ruídos específicos, como speckle em imagens holográficas (SHARMA et al., 2024a). Essas técnicas são cruciais para preparar imagens de alta qualidade para redes neurais, especialmente em domínios onde a clareza é essencial (SUMIDA et al., 2019).

A Figura 9 ilustra o processo de desembaçamento, onde a imagem original (à esquerda) é processada para remover o desfoque, resultando em uma imagem mais nítida (à direita).

Figura 9 – Restauração e Desembaçamento de Imagens



Fonte: Adaptado de MathWorks (2025).

3.1.9 Detecção de Bordas

A detecção de bordas identifica limites e formas nas imagens, sendo uma etapa fundamental em muitas tarefas de visão computacional. Redes neurais, como redes de codificação-decodificação, foram desenvolvidas para detectar bordas com alta precisão, superando detectores tradicionais como Canny em imagens ruidosas (YU et al., 1994). Métodos inspirados em mecanismos biológicos, como redes com atenção seletiva, melhoraram a extração de características globais, resultando em mapas de bordas mais robustos (CHEN et al., 2022). Essas abordagens são essenciais para pré-processar imagens, fornecendo informações estruturais que facilitam a segmentação e o reconhecimento de objetos (YU et al., 1994).

A Figura 10 ilustra o processo de detecção de bordas, onde as bordas da imagem original (à esquerda) são destacadas na imagem processada (à direita).

Figura 10 – Detecção de Bordas




Fonte: Couto (2024).

3.1.10 Correção de Iluminação

A correção de iluminação normaliza as condições de luz nas imagens, garantindo consistência na extração de características. Métodos baseados em aprendizado profundo, como redes convolucionais, foram propostos para corrigir imagens com iluminação desigual, como pinturas, alcançando resultados superiores em métricas como NIQE e LOE (LI et al., 2020). Técnicas híbridas que combinam modelos baseados em aprendizado e físicos foram aplicadas para melhorar a detecção de objetos em condições de luz variada, como em imagens de plantações (YANG et al., 2022). Essas abordagens são particularmente úteis em cenários onde a iluminação não uniforme pode comprometer o desempenho do modelo (LI et al., 2020).

A Figura 11 ilustra o processo de correção de iluminação, onde a imagem original (à esquerda) é processada para uniformizar a iluminação, resultando em uma imagem mais equilibrada (à direita).

Figura 11 – Correção de Iluminação



Fonte: Bascle Olivier Bernier (2006).

3.1.11 Super-Resolução

A super-resolução aumenta a resolução de imagens, gerando versões de alta qualidade a partir de entradas de baixa resolução. Redes neurais, como redes convolucionais profundas e redes adversárias generativas (GANs), alcançaram resultados impressionantes, com modelos como SRGAN produzindo imagens fotorrealistas (LEDIG et al., 2017). Em aplicações biológicas, redes como DPA-TISR foram desenvolvidas para imagens de células vivas, alcançando fidelidade temporal e consistência em mais de 10.000 pontos temporais (LIU et al., 2025). Essas técnicas são valiosas para tarefas que requerem detalhes finos, como análise médica e vigilância, permitindo que redes neurais processem imagens com maior clareza (LEDIG et al., 2017).

3.1.12 Conclusão parcial da seção


O processamento de imagens é uma etapa crucial para garantir a eficácia dos modelos de aprendizado profundo aplicados ao Sistema Elétrico de Potência (SEP). As técnicas discutidas, como normalização, redimensionamento, aumento de dados e redução de ruído, podem ser fundamentais para preparar as imagens antes de serem alimentadas em redes neurais. Essas abordagens não apenas melhoram a qualidade das imagens, mas também garantem que os modelos sejam mais robustos e capazes de generalizar em diferentes condições. A escolha adequada dessas técnicas pode impactar significativamente o desempenho dos modelos na detecção e classificação de falhas em equipamentos de linhas de transmissão.

Dando continuidade, para que as técnicas de processamento de imagens sejam efetivamente aplicadas, é fundamental compreender os fundamentos das redes neurais, que são as principais ferramentas para análise e classificação dessas imagens. A próxima seção aborda os conceitos essenciais sobre redes neurais.

3.2 REDES NEURAIS

Uma rede neural artificial é formada por um grande número de neurônios para funcionar corretamente, mas para compreender o funcionamento de uma rede neural, deve-se definir o modelo de um único neurônio artificial. Esse modelo é apresentado na Figura 12.

Figura 12 – Modelo de um Neurônio Artificial



Fonte: Braga e Silva (2011a).

Os passos para a obtenção da saída de um neurônio artificial são:

1. O modelo recebe um número m de entradas $x_1, x_2, \dots, x_m$;
2. Cada uma dessas entradas é multiplicada por um peso, conforme a Equação 3.1:

$$x_i w_i, \quad \text{para } i = 1, 2, \dots, m \quad (3.1)$$

3. Somam-se as entradas multiplicadas pelos seus respectivos pesos, conforme a Equação 3.2:

$$\sum_{n=1}^m w_n x_n \quad (3.2)$$

4. Adiciona-se o bias, conforme a Equação 3.3:

$$b + \sum_{n=1}^m w_n x_n \quad (3.3)$$

5. O resultado passa por uma função de ativação, conforme a Equação 3.4:

$$\varphi \left(b + \sum_{n=1}^m w_n x_n \right) \quad (3.4)$$

Seguidos os passos, a equação de saída de um neurônio artificial é descrita pela Equação 3.5.

$$y = \varphi \left(b + \sum_{n=1}^m w_n x_n \right) \quad (3.5)$$

Visto o modelo de um único neurônio artificial, o conceito de rede neural composta pela associação de diversos neurônios é descrito a seguir.

3.2.1 Tipos de redes neurais


Existem diversos tipos de redes neurais que se distinguem tanto em termos de seus princípios de funcionamento quanto em suas aplicações práticas específicas. A seguir, serão discutidos alguns desses tipos de redes neurais de maneira individualizada, a fim de fornecer uma compreensão mais aprofundada sobre seu funcionamento e suas aplicações (ALEX, 2020).

3.2.1.1 Perceptron (P), Feed Forward Network (FFN)

FFNs são o tipo mais básico de rede neural, em que a informação flui linearmente até a saída e cada neurônio realiza uma operação matemática linear do tipo apresentado na Equação 3.6. Sendo x o valor de entrada, w o peso e b o bias do neurônio. O resultado passa por uma função de ativação e em seguida é enviado para a próxima camada. As redes neurais do tipo FFN (exemplo mostrado através da Figura 13) possuem conexões em apenas um único sentido, geralmente limitadas a 5 camadas (ALEX, 2020).

$$wx + b \quad (3.6)$$


Figura 13 – FFN



Fonte: Alex (2020).

As redes do tipo P, Figura 14, são um caso especial de uma rede FFN, em que todos os neurônios de uma camada são conectados com todos neurônios da camada seguinte (ALEX, 2020).

Figura 14 – Perceptron



Fonte: Alex (2020).


As FFNs são utilizadas para problemas em que os dados de entrada têm impacto atemporal nos dados de saída, em que a saída não depende do estado anterior da rede neural. Um exemplo é usar informações de um exame de sangue para determinar a presença de uma doença.

3.2.1.2 Convolutional neural network (CNN) ou Deep convolutional network (DCN)

As redes neurais estudadas até então, não consideram uma relação de vizinhança entre os dados de entrada. Por exemplo, não faria a menor diferença se antes do treinamento a posição de todos os dados de entrada fossem embaralhadas da mesma forma. Porém, essa relação de vizinhança pode ser muito importante para alguns casos específicos como no reconhecimento de imagens, reconhecimento de voz, análise grafista do mercado financeiro, etc. No reconhecimento de imagens, por exemplo, grande parte da informação está contida na relação de vizinhança dos pixels como o contraste e a textura.

Uma CNN, cuja estrutura está representada através da Figura 15, percebe uma imagem como uma caixa retangular cuja largura e altura são medidas pelo número de pixels da imagem e a profundidade é representada por cada uma das três camadas de cores, vermelho, verde e azul referidas como canais (VEEN, 2016).

Figura 15 – CNN



Fonte: Veen (2016).

Ao longo das camadas de uma rede CNN, as dimensões da imagem se alteram, pois a medida em que a altura e largura da imagem diminuem, o número de canais aumenta, reduzindo o volume de dados. Esse processo é chamado de pooling, que faz um resumo dos dados através do descarte das saídas menos significativas, mantendo somente as de maior valor (VEEN, 2016).

O processo de convolução é realizado arrastando uma janela (kernel) de dimensão menor pela imagem original, sendo essa janela uma rede FFN (VEEN, 2016). Por exemplo, se uma imagem 5x5 pixels passar pelo processo da convolução e supondo uma janela de 3x3 com passo 1 (stride), primeiramente os 3x3 pixels do canto superior esquerdo da imagem original passarão por uma FFN. Em seguida, essa janela é arrastada 1 pixel

(tamanho do passo) para a direita e o processo se repete até ao final da imagem.

3.2.2 Funções de ativação

As funções de ativação introduzem não-linearidade nas redes neurais, permitindo que elas aprendam relações complexas entre entradas e saídas. Sem essas funções, mesmo com múltiplas camadas, a rede se comportaria como um modelo linear (BADIGER; MATHEW, 2022). Cada camada da rede pode ter uma função de ativação diferente, sendo algumas mais adequadas para camadas ocultas e outras para a camada de saída.

A seguir, são apresentadas as três principais funções de ativação:

3.2.2.1 ReLU (Rectified Linear Unit)

Representada pela Equação 3.7, a ReLU é amplamente utilizada em camadas ocultas. Sua principal vantagem é a eficiência computacional e a aceleração da convergência do gradiente. Contudo, pode causar o problema dos neurônios mortos (Dying ReLU), quando valores negativos resultam sempre em zero (AGARAP, 2018).

$$f(x) = \max(0, x) \quad (3.7)$$

3.2.2.2 Sigmoid

Definida pela Equação 3.8, transforma a entrada em um valor entre 0 e 1, sendo útil para problemas de classificação binária. Apesar de ser diferenciável e fornecer gradientes suaves, sofre com o problema do gradiente pequeno para valores extremos, o que dificulta o aprendizado (LANGER, 2020).

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3.8)$$

3.2.2.3 Softmax

A função Softmax é apresentada na Equação 3.9 e é utilizada na camada de saída para classificação multiclasse. Ela converte os valores em uma distribuição de probabilidades, acentuando a classe de maior valor (GAO; PAVEL, 2017).

$$f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (3.9)$$

3.2.2.4 Regras gerais para escolha de funções de ativação

A escolha da função de ativação depende do tipo de problema e da arquitetura da rede. A seguir, são apresentadas algumas diretrizes gerais:

- *Camada de saída:*
 - Regressão: Linear
 - Classificação binária: Sigmoid
 - Classificação multiclasse: Softmax
 - Classificação multirrótulo: Sigmoid
- *Camadas ocultas:*
 - Redes convolucionais: ReLU
 - Redes recorrentes: Tanh ou Sigmoid

3.2.3 Funções de Custo

As funções de custo são responsáveis por medir o quão distante a saída prevista está da saída real. Elas orientam o processo de treinamento ajustando os pesos da rede para minimizar esse erro (RASHID, 2020).

3.2.3.1 Erro Médio Quadrático (MSE)

O Erro Médio Quadrático (MSE) é uma das funções mais comuns em regressão, penalizando fortemente grandes erros e sendo sensível a outliers (CHICCO; JURMAN, 2020). Ele é definido como a Equação 3.10:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.10)$$

3.2.3.2 Erro Médio Absoluto (MAE)

O Erro Médio Absoluto (MAE) é mais robusto a outliers que o MSE, mas pode ser mais difícil de otimizar. Sua fórmula é apresentada na Equação 3.11:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.11)$$

3.2.3.3 Função Huber

A função Huber combina as vantagens do MSE e MAE, sendo menos sensível a outliers e mais estável para pequenos erros (HUBER, 1964). Ela é definida pela Equação 3.12:

$$L_{\text{Huber}} = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{se } |y - \hat{y}| \leq \delta \\ \delta(|y - \hat{y}| - \frac{1}{2}\delta) & \text{caso contrário} \end{cases} \quad (3.12)$$

3.2.3.4 Entropia Cruzada Binária

A Entropia Cruzada Binária é indicada para problemas de classificação binária (ZHANG; SABUNCU, 2018), sendo expressa pela Equação 3.13:

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (3.13)$$

3.2.3.5 Entropia Cruzada Categórica

Já a Entropia Cruzada Categórica é utilizada em classificação multiclasse com rótulo único por amostra, e sua fórmula é apresentada na Equação 3.14:

$$L = -\sum_{i=1}^n \sum_{j=1}^k y_{ij} \log(\hat{y}_{ij}) \quad (3.14)$$

3.2.4 Otimizadores

Otimizadores são algoritmos que ajustam os pesos da rede neural com base no gradiente da função de custo. Eles influenciam diretamente a velocidade e a qualidade da convergência (RUDER, 2016). Entre os principais otimizadores, destaca-se o Gradiente Descendente, que é a forma mais simples de otimização, mas pode ser lenta e sensível à escolha da taxa de aprendizado. O Gradiente Descendente Estocástico (SGD) atualiza os pesos a cada amostra, adicionando ruído estocástico que pode ajudar a escapar de mínimos locais. O Momentum acrescenta uma fração do gradiente anterior ao atual, acelerando a convergência e suavizando oscilações. O RMSProp ajusta a taxa de aprendizado para cada parâmetro com base na média móvel dos gradientes quadrados (TIELEMAN; HINTON, 2012). Por fim, o Adam combina Momentum e RMSProp, sendo amplamente utilizado por sua eficiência e robustez (KINGMA; BA, 2014).

Compreendidos os principais conceitos sobre redes neurais, é importante discutir o papel dos conjuntos de dados (datasets), que são essenciais para o treinamento e avaliação desses modelos. A próxima seção aborda os desafios e técnicas relacionados aos datasets utilizados em tarefas de detecção de falhas.

3.3 DATASETS

Os conjuntos de dados são fundamentais para o treinamento de redes neurais, fornecendo as amostras necessárias para aprender padrões complexos e realizar previsões precisas. A qualidade, quantidade e diversidade dos dados impactam diretamente o desempenho dos modelos, especialmente em aprendizagem profunda, onde redes com milhões de parâmetros requerem grandes volumes de dados anotados. Conjuntos como o ImageNet, com mais de 14 milhões de imagens em milhares de categorias, foram essenciais para avanços em visão computacional, como a classificação de imagens e detecção de objetos (DENG et al., 2009). Na engenharia elétrica, especificamente na detecção de falhas em cadeias de isoladores e equipamentos de linhas de transmissão, datasets são frequentemente escassos ou desbalanceados, limitando a capacidade dos modelos de generalizar (SHORTEN et al., 2019a).

Conjuntos de dados desbalanceados são prevalentes na detecção de falhas em linhas de transmissão, onde amostras de isoladores saudáveis superam significativamente as de defeitos, como quebras ou flashovers (descarga elétrica que ocorre sobre a superfície isolante, quando a rigidez dielétrica é rompida) por poluição. Esse desbalanceamento pode levar a modelos enviesados que favorecem a classe majoritária, resultando em baixa sensibilidade para a detecção de falhas (HE; GARCIA, 2009a). Por exemplo, no conjunto de dados IDID, a proporção de isoladores saudáveis para defeituosos é de aproximada-

mente 10:1 para quebras e 5:1 para flashovers, o que dificulta a classificação precisa das classes minoritárias (OBERWEGER; WENDEL; BISCHOF, 2024). Esse desafio é crítico em aplicações de engenharia elétrica, onde a detecção de falhas raras é essencial para garantir a segurança e a confiabilidade do sistema.

Datasets escassos, caracterizados por um número reduzido de amostras, são comuns em áreas onde a coleta de dados é custosa, demorada ou restrita pela raridade de eventos, como na detecção de falhas em isoladores de linhas de transmissão. A escassez de dados aumenta o risco de sobreajuste, onde modelos de redes neurais memorizam os dados de treinamento em vez de aprender padrões generalizáveis (GOODFELLOW; BENGIO; COURVILLE, 2016). Esse problema é agravado em aplicações de engenharia elétrica, onde imagens de falhas, como quebras ou flashovers por poluição, são difíceis de obter em quantidade suficiente. A anotação manual de imagens capturadas por drones, frequentemente usada para identificar defeitos, é demorada e propensa a erros, limitando ainda mais o tamanho dos datasets (ZHENG et al., 2022). Por exemplo, o conjunto de dados Insulator-Defect Detection, com apenas 1600 imagens, enfrenta desafios devido ao número limitado de amostras de defeitos (ZHENG et al., 2022).

O aprendizado por transferência é uma técnica amplamente utilizada para mitigar os desafios de datasets escassos, permitindo que modelos pré-treinados em grandes conjuntos de dados, como o ImageNet, sejam ajustados para tarefas específicas com menos dados (PAN; YANG, 2010). Essa abordagem é eficaz em cenários onde características visuais gerais, como bordas e texturas, podem ser transferidas de datasets genéricos para aplicações especializadas. O aprendizado por transferência tem se mostrado particularmente útil em aplicações de engenharia elétrica, onde datasets específicos são frequentemente escassos.

Uma das formas de tentar diminuir o impacto negativo de bancos de dados escassos, como são os casos citados, é o aumento de dados, uma estratégia essencial para ampliar artificialmente o tamanho e a diversidade dos dados por meio de transformações como rotação, escala, inversão e alterações de iluminação (SHORTEN et al., 2019a). Esta abordagem é particularmente valiosa quando a coleta de dados reais é custosa, demorada ou limitada pela raridade de eventos, como na detecção de falhas em equipamentos de linhas de transmissão. Na detecção de falhas em linhas de transmissão, essas transformações ajudam a simular diferentes condições ambientais, como variações de luz ou ângulos de captura, comuns em imagens de VANTs (Veículo Aéreo Não Tripulado). Por exemplo, Peng et al. (2023) aplicaram aumento de dados para melhorar a robustez de um modelo YOLOv5 na detecção de defeitos pequenos, como flashovers por poluição, em imagens de linhas de transmissão. Métodos avançados, como redes adversárias generativas (GANs), podem gerar imagens sintéticas de falhas, mas sua aplicação em engenharia elétrica é limitada devido à complexidade computacional (GOODFELLOW et al., 2014). Apesar disso, GANs têm potencial para criar amostras sintéticas de defeitos raros, como quebras em

isoladores, ampliando datasets escassos e reduzindo significativamente o problema da escassez de dados.

O aprendizado semi-supervisionado é uma abordagem promissora para datasets escassos, aproveitando dados não rotulados, que são mais abundantes em inspeções de linhas de transmissão, para melhorar o desempenho do modelo (ENGELEN; HOOS, 2020). Imagens de VANTs capturadas durante inspeções rotineiras podem ser usadas para aprender representações gerais, mesmo sem anotações detalhadas. Embora não haja exemplos específicos na literatura revisada aplicando aprendizado semi-supervisionado diretamente à detecção de falhas em isoladores, Chen et al. (2020) demonstraram sua eficácia em tarefas de visão computacional, sugerindo potencial para aplicações futuras em engenharia elétrica, onde dados não rotulados de inspeções são comuns. Essa técnica pode ser explorada para pré-treinar modelos em grandes conjuntos de imagens de linhas de transmissão antes de ajustá-los em datasets rotulados menores.

A reamostragem é uma técnica comum para abordar o desbalanceamento, envolvendo sobreamostragem da classe minoritária ou subamostragem da classe majoritária para equilibrar a distribuição (JOHNSON; KHOSHGOFTAAR, 2019). Métodos como o SMOTE (Synthetic Minority Over-sampling Technique) geram amostras sintéticas da classe minoritária interpolando exemplos existentes (CHAWLA et al., 2002). Em Oberweger, Wendel e Bischof (2024), os autores aplicaram subamostragem para criar partições balanceadas do conjunto de dados IDID, retrainando a última camada do modelo com regressão logística para melhorar a classificação de isoladores defeituosos. Essa abordagem aumentou a precisão em até 12% para quebras e 7% para flashovers, demonstrando eficácia em cenários desbalanceados. A reamostragem é particularmente útil quando o número de amostras de defeitos é extremamente baixo, como em datasets de inspeção de linhas.

A perda focal é uma função de perda especializada que atribui maior peso a exemplos difíceis, frequentemente pertencentes à classe minoritária, reduzindo o impacto de amostras bem classificadas (LIN et al., 2017). Na detecção de falhas em isoladores, Zheng et al. (2022) utilizaram a perda focal em um modelo YOLOv7 para lidar com o desbalanceamento entre amostras de isoladores e defeitos em imagens de VANTs. A aplicação dessa técnica melhorou a precisão na detecção de defeitos pequenos, como flashovers por poluição, que são menos frequentes. A perda focal é particularmente vantajosa em tarefas de detecção de objetos, onde o fundo da imagem pode dominar a distribuição de classes, como em imagens de linhas de transmissão com fundos complexos.

A unificação de datasets públicos, como proposto por Felix et al. (2020), oferece uma abordagem valiosa para a pesquisa em detecção de falhas. O repositório combina datasets como o de Tomaszewski et al. e o CPLID, fornecendo imagens e anotações no formato COCO. Essa consolidação facilita o acesso a dados diversificados, embora o desbalanceamento e a escassez permaneçam desafios que requerem técnicas avançadas de pré-processamento e treinamento. A unificação de datasets é particularmente útil para

aumentar o número de amostras disponíveis, permitindo treinar modelos mais robustos para detecção de falhas em isoladores (FELIX et al., 2020).

A Tabela 3 resume os principais datasets utilizados na detecção de falhas em isoladores, destacando suas características e desafios.

Tabela 3 – Técnicas para Lidar com Escassez e Desbalanceamento de Dados

Categoria	Técnica	Descrição
Escassez	Aprendizado por Transferência	Reutiliza modelos pré-treinados em grandes conjuntos para tarefas com poucos dados (PAN; YANG, 2010).
Escassez	Aumento de Dados	Aplica transformações (por exemplo, rotação, escala) para ampliar o conjunto de dados (SHORTEN et al., 2019a).
Escassez	Aprendizado Semi-Supervisionado	Aproveita dados não rotulados para aprender representações gerais (ENGELN; HOOS, 2020).
Desbalanceamento	Reamostragem	Sobreamostra a classe minoritária ou subamostra a majoritária (JOHNSON; KHOSHGOFTAAR, 2019).
Desbalanceamento	Perda Focal	Modifica a perda para focar em exemplos difíceis, geralmente da classe minoritária (LIN et al., 2017).

Após a análise das principais estratégias para lidar com escassez e desbalanceamento de dados, é fundamental compreender como avaliar o desempenho dos modelos desenvolvidos. A seguir, são apresentadas as principais métricas de avaliação utilizadas em tarefas de detecção de falhas em linhas de transmissão.


3.4 MÉTRICAS DE AVALIAÇÃO DE DESEMPENHO DE MODELOS

Na detecção de falhas em cadeias de isoladores e equipamentos de linhas de transmissão, a escolha das métricas de avaliação é fundamental para garantir a eficácia e confiabilidade dos modelos de redes neurais. Métricas comumente utilizadas incluem acurácia, precisão, recall, F1-score, área sob a curva ROC (AUC-ROC) e, para tarefas de detecção de objetos, a média da precisão média (mAP). A acurácia, definida como a proporção

de previsões corretas em relação ao total, pode ser enganosa em datasets desbalanceados, onde a classe de falhas é significativamente menos representada que a classe de isoladores saudáveis. Por exemplo, em um dataset com 95% de amostras saudáveis, um modelo que sempre prevê "saudável" alcançará alta acurácia, mas falhará em detectar falhas, comprometendo a segurança do sistema (HE; GARCIA, 2009a). Em Alam et al. (2025), os autores reportaram uma acurácia de 99,96% para um modelo ensemble RF-LSTM Tuned KNN, mas complementaram a avaliação com precisão, recall e F1-score para abordar o desbalanceamento do conjunto de dados, garantindo uma análise mais robusta do desempenho em classes minoritárias.

A Figura 16 ilustra uma curva ROC típica, que representa a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos para diferentes limiares de decisão. A área sob a curva (AUC) é uma métrica importante para avaliar a capacidade discriminativa do modelo.

Figura 16 – Curva ROC



Fonte: Torres (2025).

A precisão mede a proporção de verdadeiros positivos entre todas as previsões positivas, sendo útil para avaliar a confiabilidade das detecções de falhas. O recall, por outro lado, mede a proporção de verdadeiros positivos entre todas as amostras positivas reais, sendo crítico em aplicações onde falsos negativos (falhas não detectadas) podem levar a falhas catastróficas no sistema de transmissão. O F1-score, a média harmônica entre precisão e recall, oferece uma métrica balanceada que considera ambos os aspectos, sendo amplamente utilizado em cenários desbalanceados (JOHNSON; KHOSHGOFTAAR, 2019).

Para tarefas de detecção de objetos, como identificar defeitos em imagens de VANTs,

a métrica mAP é padrão, calculando a precisão média para cada classe e tomando a média geral. Em Zheng et al. (2022), o modelo YOLOv7 foi avaliado no conjunto Insulator-Defect Detection, utilizando mAP para medir a precisão na detecção de quebras e flashovers, com resultados superiores em comparação com modelos anteriores. A AUC-ROC, que avalia a capacidade do modelo de distinguir entre classes em diferentes limiares, também é relevante, especialmente em classificações binárias (falha vs. não falha). Em Alam et al. (2025), a AUC-ROC foi reportada como 1,0 para classificações binárias, indicando excelente separação entre classes, mas valores menores foram observados em classificações multi-label, refletindo a complexidade de datasets desbalanceados.

Outras métricas, como a matriz de confusão, fornecem uma visão detalhada dos erros do modelo, permitindo calcular taxas de falsos positivos e negativos. Em Alam et al. (2025), matrizes de confusão foram usadas para avaliar o desempenho do modelo ensemble em classificações binárias e multi-label, complementando as métricas de precisão e recall. Para aplicações em tempo real, como inspeções de VANTs, métricas adicionais, como tempo de inferência e complexidade computacional, também são consideradas, especialmente em modelos como YOLOv5 e YOLOv7, que priorizam eficiência (PENG et al., 2023). A escolha das métricas deve, portanto, alinhar-se com os objetivos da aplicação, priorizando recall para segurança e mAP para detecção precisa de objetos em imagens.

Por fim, compreender as métricas de avaliação é essencial para interpretar corretamente os resultados obtidos com diferentes modelos e técnicas de processamento de imagens. A próxima etapa do trabalho irá detalhar a metodologia proposta para aprimoramento dos processamentos e avaliação dos modelos.

A Tabela 4 apresenta um resumo das principais métricas utilizadas para avaliar o desempenho de modelos em tarefas de detecção de falhas em linhas de transmissão, destacando suas características e aplicações.

Tabela 4 – Principais métricas de avaliação de desempenho de modelos

Métrica	Descrição
Acurácia	Proporção de previsões corretas em relação ao total de amostras. Pode ser enganosa em conjuntos desbalanceados.
Precisão	Proporção de verdadeiros positivos entre todas as previsões positivas. Mede a confiabilidade das detecções.
Recall (Sensibilidade)	Proporção de verdadeiros positivos entre todas as amostras positivas reais. Mede a capacidade de encontrar todos os casos positivos.
F1-score	Média harmônica entre precisão e recall. Útil para avaliar o desempenho em cenários desbalanceados.
mAP (mean Average Precision)	Média das precisões médias para cada classe. Padrão em tarefas de detecção de objetos.
AUC-ROC	Área sob a curva ROC. Mede a capacidade do modelo de distinguir entre classes em diferentes limiares.
Matriz de Confusão	Tabela que mostra as previsões corretas e incorretas, detalhando verdadeiros/falsos positivos e negativos.

3.5 CONSIDERAÇÕES FINAIS DO CAPÍTULO

Neste capítulo, foram apresentados os principais conceitos e técnicas de processamento de imagens, redes neurais, estratégias para lidar com escassez e desbalanceamento de dados, além das métricas de avaliação de desempenho de modelos aplicados à detecção de falhas em linhas de transmissão. A revisão evidenciou que o uso de métodos avançados de processamento de imagens e aprendizado profundo é fundamental para garantir a confiabilidade e eficiência do Sistema Elétrico de Potência, especialmente em cenários desafiadores, como a inspeção de grandes extensões e a identificação de defeitos raros.

A escolha adequada das técnicas de pré-processamento, arquitetura de redes neurais e estratégias para tratar limitações dos datasets impacta diretamente na robustez e precisão dos modelos desenvolvidos. Além disso, a seleção criteriosa das métricas de


avaliação permite uma análise mais completa do desempenho, especialmente em situações de desbalanceamento entre classes.

Portanto, o domínio desses conceitos é essencial para o desenvolvimento de soluções inovadoras e eficazes na área de inspeção automatizada de linhas de transmissão, contribuindo para a segurança, confiabilidade e continuidade do fornecimento de energia elétrica. O próximo capítulo irá detalhar a metodologia proposta para aprimoramento dos processamentos e avaliação dos modelos, consolidando os fundamentos discutidos nesta revisão.

4 METODOLOGIA

A metodologia delineada neste estudo tem como propósito fundamental o desenvolvimento de um arcabouço sistemático para aprimorar, comparar, selecionar e combinar técnicas de processamento de imagem, visando aprimorar a detecção e classificação de falhas em cadeias de isoladores. O processo é estruturado e iterativo, conforme ilustrado no fluxograma da Figura 17.


Figura 17 – Fluxograma da metodologia de processamento de imagens



Fonte: Autor.

O fluxograma completo apresentado na Figura 17 fornece uma visão macro de todas as etapas envolvidas na metodologia. Para facilitar a compreensão do fluxo e das inter-relações entre as fases, a Figura 18 apresenta o fluxograma geral, que integra todos os fluxogramas menores das etapas subsequentes.

Figura 18 – Fluxograma geral da metodologia, integrando todas as etapas principais



Fonte: Autor.

O fluxograma da metodologia, apresentado na Figura 17, revela uma arquitetura robusta e pensada para a otimização de processamentos de imagens. Um dos pilares desta estrutura é a natureza iterativa do processo, evidenciada pelos ciclos de "Avaliação e

ajustes" que retroalimentam as fases de "Pré-processamento" e "Escolha e construção do modelo". Essa recursividade é crucial, pois permite um refinamento contínuo das técnicas e parâmetros, adaptando-se aos resultados obtidos a cada iteração. A organização em módulos distintos, como "Seleção e validação do dataset", "Pré-processamento", "Ajuste de parâmetros", "Escolha e construção do modelo", "Treinamento" e "Avaliação e ajustes", é outra característica positiva, facilitando a depuração e o aprimoramento localizado de cada componente da metodologia. Essa modularidade assegura que, em caso de falhas ou resultados subótimos, a origem do problema possa ser isolada e corrigida eficientemente, sem comprometer a integridade do sistema como um todo.

A seguir, cada uma das principais fases do processo será detalhada em seções específicas, abordando desde a definição das métricas e preparação dos dados até as estratégias de aprimoramento e avaliação final dos resultados.

4.1 INÍCIO E DEFINIÇÃO DE MÉTRICAS

Esta seção aborda o ponto de partida da metodologia, incluindo a inicialização do ambiente e a definição das métricas que serão utilizadas para avaliar o desempenho ao longo de todo o processo.

4.1.1 Início

O bloco "Início" demarca o ponto de partida formal da execução desta metodologia. Sua função primordial é a de inicializar o ambiente computacional e todos os recursos necessários, garantindo que as ferramentas de software, as bibliotecas de programação estejam devidamente configuradas e acessíveis. A expectativa é que, ao transitar por este ponto, o sistema esteja preparado para as operações subsequentes de definição de métricas, coleta, tratamento e processamento de dados. A presença deste bloco, embora aparentemente trivial, é crucial para a organização lógica do fluxo de trabalho, servindo como um marco zero que assegura a rastreabilidade e a replicabilidade do experimento.


A dificuldade inerente a esta etapa é, em geral, baixa, confinando-se principalmente à fase de setup inicial do projeto. No cenário de um erro, como a falha na inicialização de bibliotecas ou na alocação de recursos, a ação corretiva imediata seria a verificação das dependências de software, a compatibilidade de versões e a adequação do hardware (por exemplo, disponibilidade de GPUs para aceleração de treinamento). A avaliação do sucesso é intrínseca à própria continuidade do fluxograma: uma transição fluida para o próximo estágio é o indicador de que o "Início" foi bem-sucedido. Este bloco, portanto, alinha-se diretamente ao objetivo geral de desenvolver uma metodologia capaz de compa-

rar, selecionar, combinar e aprimorar técnicas de processamento de imagem, pois estabelece as bases operacionais para todas as etapas subsequentes. Sem essa formalização inicial, a execução do projeto careceria de um ponto de partida definido, comprometendo a sistematicidade proposta.

4.2 SELEÇÃO E VALIDAÇÃO DO DATASET

Esta seção detalha o processo de seleção, validação e preparação dos dados que servirão como base para todo o desenvolvimento da metodologia. O fluxograma específico desta etapa é apresentado na Figura 19, permitindo visualizar de forma clara o caminho percorrido desde a definição das métricas até o balanceamento dos dados.

Figura 19 – Fluxograma da etapa de seleção e validação do dataset



Fonte: Autor.

4.2.1 Definir métricas: acurácia, F1-score, tempo

O bloco "Definir métricas: acurácia, F1-score, tempo" é fundamental para estabelecer os critérios objetivos de avaliação que irão nortear todo o processo de otimização da

metodologia. A expectativa é que, nesta fase inicial, sejam claramente especificadas as métricas que serão utilizadas para medir o sucesso das diferentes combinações de técnicas de processamento de imagem e arquiteturas de modelos. A definição prévia dessas métricas é crucial porque elas servirão como bússola para todas as decisões subsequentes, desde a seleção de técnicas de pré-processamento até a escolha final dos modelos mais eficazes.

As três métricas principais definidas - acurácia, F1-score e tempo de processamento - foram selecionadas por fornecerem uma visão abrangente do desempenho do sistema. A acurácia oferece uma medida geral de correção das predições, o F1-score é especialmente valioso para datasets desbalanceados por combinar precisão e recall de forma harmônica, e o tempo de processamento é essencial para aplicações práticas onde a eficiência computacional é crítica, como na inspeção automatizada de linhas de transmissão.

A dificuldade de execução desta etapa é baixa, sendo principalmente conceitual e de planejamento. Um erro comum seria a definição de métricas inadequadas para o tipo de problema ou a omissão de métricas relevantes para a aplicação específica. Se as métricas inicialmente definidas se mostrarem insuficientes durante o desenvolvimento, a ação corretiva seria a revisão e refinamento dos critérios de avaliação, sempre mantendo a coerência com os objetivos do estudo. A avaliação do sucesso desta etapa é confirmada pela clareza e adequação das métricas definidas para o contexto do problema de detecção de falhas em isoladores. Este bloco é fundamental para o objetivo geral da metodologia, pois estabelece as bases quantitativas para todas as comparações e seleções que serão realizadas ao longo do processo.

4.2.2 Selecionar dataset com imagens rotuladas

A etapa de "Selecionar dataset com imagens rotuladas" é uma das mais críticas e de maior impacto sobre a qualidade e a confiabilidade dos resultados. A expectativa é que, nesta fase, seja escolhido um conjunto de dados adequado que contenha imagens de cadeias de isoladores com anotações precisas indicando a presença ou ausência de falhas. O dataset deve apresentar diversidade suficiente em termos de condições de iluminação, ângulos de captura, tipos de isoladores e variações de falhas para garantir que os modelos desenvolvidos tenham boa capacidade de generalização.

Esta etapa é fundamental porque a qualidade, quantidade e diversidade dos dados impactam diretamente o desempenho e a capacidade de generalização dos modelos de aprendizado de máquina. Sem dados adequados e bem rotulados, qualquer processamento subsequente será comprometido. Como mencionado por Shorten et al. (2019b), a robustez de um modelo depende intrinsecamente da riqueza de seu conjunto de treina-

mento.

A dificuldade de execução pode ser consideravelmente alta devido à escassez de datasets públicos específicos para detecção de falhas em isoladores e à necessidade de anotação manual precisa. Se o dataset selecionado se mostrar inadequado, as ações corretivas podem incluir a busca por datasets alternativos, a combinação de múltiplos datasets ou a criação de um dataset próprio através de coleta e anotação manual de imagens.

4.2.3 Dataset está balanceado?

O bloco de decisão "Dataset está balanceado?" é um ponto crítico de validação que verifica se as classes de interesse (isoladores com falha e sem falha) estão adequadamente representadas no dataset selecionado. A expectativa é que esta verificação identifique possíveis desbalanceamentos que poderiam comprometer o treinamento dos modelos, levando a vieses onde o modelo favorece a classe majoritária.

O balanceamento é especialmente importante em problemas de detecção de falhas, onde frequentemente há muito mais amostras de isoladores saudáveis do que defeituosos. Essa assimetria, conforme He e Garcia (2009b), pode levar a modelos enviesados que apresentam alta acurácia geral, mas baixa capacidade de detectar as falhas, que são justamente o objetivo principal do sistema.

A dificuldade desta etapa é baixa, envolvendo principalmente análise estatística das distribuições das classes. Se o dataset estiver desbalanceado, o fluxo direciona para a aplicação de filtros e balanceamento; caso contrário, prossegue diretamente para o pré-processamento.

4.2.4 Aplicar filtros e balanceamento

O bloco "Aplicar filtros e balanceamento" é executado quando o dataset se mostra desbalanceado, implementando estratégias para corrigir a distribuição desigual entre as classes. A expectativa é que esta etapa aplique técnicas como reamostragem (sobre-amostragem da classe minoritária através de duplicação ou técnicas como SMOTE, ou subamostragem da classe majoritária), aplicação de pesos diferenciados nas funções de perda, ou técnicas de data augmentation focadas na classe minoritária.


Esta etapa é crucial porque o desbalanceamento pode significativamente comprometer a capacidade do modelo de detectar falhas, que são tipicamente a classe minoritária mas a mais importante do ponto de vista prático. A aplicação de filtros também pode envolver a remoção de amostras de baixa qualidade ou outliers que poderiam prejudicar o treinamento.

A dificuldade de execução pode ser de média a alta, dependendo do grau de desbalanceamento e das técnicas escolhidas. Se as técnicas de balanceamento não forem eficazes, as ações corretivas podem incluir a exploração de métodos alternativos de balanceamento, a revisão dos critérios de qualidade das amostras, ou a busca por dados adicionais para a classe minoritária.

4.3 PRÉ-PROCESSAMENTO

Esta seção detalha as etapas de processamento de imagens que visam otimizar os dados de entrada para maximizar o desempenho dos modelos de rede neural. O fluxograma da Figura 20 ilustra as decisões e operações realizadas nesta fase.

Figura 20 – Fluxograma da etapa de pré-processamento



Fonte: Autor.

4.3.1 Aplicar técnicas básicas: normalização, recorte, ruído

O bloco "Aplicar técnicas básicas: normalização, recorte, ruído" é uma fase fundamental onde as imagens são submetidas a processamentos essenciais para maximizar a eficácia dos modelos de rede neural. A expectativa é que esta etapa envolva a aplicação de técnicas fundamentais como a normalização (padronização dos valores de pixels para escalas como $[0,1]$ ou Z-score) (SHARMA et al., 2024b), o redimensionamento e recorte (ajustando imagens para as dimensões de entrada do modelo e extraindo regiões de interesse) (SHARMA et al., 2024b), e a redução de ruído (eliminando interferências com filtros como mediana ou filtros gaussianos) (SHARMA et al., 2024b).

Essas operações são cruciais porque, como afirmado por Sharma et al. (2024b), elas "melhoram a qualidade das imagens, mas também garantem que os modelos sejam mais robustos e capazes de generalizar em diferentes condições". A normalização é especialmente importante para garantir convergência estável durante o treinamento, enquanto o recorte adequado pode focar a atenção do modelo nas regiões mais relevantes da imagem.

A dificuldade de execução é geralmente baixa a média, sendo técnicas bem estabelecidas na literatura. Se o desempenho do modelo piorar após a aplicação dessas técnicas básicas, a ação corretiva seria revisar os parâmetros aplicados ou a ordem de aplicação das técnicas, buscando um equilíbrio ideal.

4.3.2 Aplicar data augmentation

O bloco "Aplicar data augmentation" tem como objetivo expandir artificialmente o dataset através de transformações que preservam as características essenciais das imagens mas introduzem variabilidade que pode melhorar a capacidade de generalização do modelo. A expectativa é que esta etapa aplique transformações como rotações, espelha-mentos, ajustes de brilho e contraste, mudanças de escala, e translações, criando varia-ções das imagens originais que simulam diferentes condições de captura.

O data augmentation é especialmente valioso quando o dataset é limitado ou des-balanceado, pois pode artificialmente aumentar o número de amostras disponíveis para treinamento. Como mencionado por Shorten et al. (2019b), técnicas de aumento de dados são fundamentais para melhorar a robustez dos modelos de aprendizado profundo.

A dificuldade de execução é baixa a média, mas requer cuidado para não aplicar transformações que alterem características importantes para a detecção de falhas. Se o data augmentation degradar o desempenho, as ações corretivas incluem revisar os tipos e intensidades das transformações aplicadas.

4.3.3 Combinar técnicas?

O bloco de decisão "Combinar técnicas?" determina se múltiplas técnicas de processamento serão aplicadas em sequência para criar um pipeline de processamento mais sofisticado. Esta decisão é estratégica, pois combinar técnicas pode resultar em melhorias sinérgicas, mas também pode introduzir complexidade desnecessária ou até mesmo degradação da qualidade da imagem.

A expectativa é que esta decisão seja baseada nos resultados preliminares das técnicas aplicadas individualmente e no conhecimento de domínio sobre quais combinações podem ser benéficas. Por exemplo, aplicar redução de ruído seguida por aumento de nitidez pode resultar em imagens mais adequadas para detecção de defeitos.

A dificuldade desta etapa é baixa, sendo principalmente uma decisão estratégica. Se a decisão for por combinar técnicas, o fluxo segue para a geração de pipelines combinados. Caso contrário, utiliza as técnicas de forma isolada.

4.3.4 Gerar pipeline de técnicas combinadas

O bloco "Gerar pipeline de técnicas combinadas" é executado quando se decide explorar a sinergia entre diferentes técnicas de processamento de imagem. A expectativa é que esta etapa crie sequências estratégicas de processamentos, onde a saída de uma técnica serve como entrada para a próxima, buscando um efeito cumulativo que transcenda o impacto de cada técnica isolada.

Por exemplo, um pipeline pode consistir em: normalização → redução de ruído → ajuste de contraste → aumento de nitidez. A ordem das operações é crucial, pois diferentes sequências podem produzir resultados significativamente diferentes. O propósito é explorar o potencial de melhoria que reside na interação entre diferentes processamentos.

A dificuldade de execução pode ser de média a alta, principalmente devido à explosão combinatória de possibilidades e à necessidade de identificar as sequências mais eficazes. Um erro comum é criar combinações que introduzem artefatos ou degradam a imagem. Se as combinações não trouxerem melhorias, as ações corretivas incluem explorar diferentes ordens de aplicação ou revisar a seleção de técnicas.

4.3.5 Usar técnicas isoladas

O bloco "Usar técnicas isoladas" é executado quando se decide não combinar múltiplas técnicas, optando por aplicar e avaliar cada processamento de forma independente. Esta abordagem é mais simples e permite uma avaliação clara do impacto individual de

cada técnica, facilitando a identificação de quais processamentos são mais eficazes para o problema específico.


A expectativa é que cada técnica seja aplicada, avaliada e comparada individualmente, criando um benchmark claro do desempenho de cada abordagem. Esta estratégia é especialmente útil nas fases iniciais do desenvolvimento, quando se busca entender o impacto individual de cada processamento.

A dificuldade de execução é baixa, sendo uma abordagem mais direta. A avaliação do sucesso é feita comparando o desempenho do modelo com cada técnica aplicada individualmente versus o desempenho baseline sem processamento.

4.4 AJUSTE DE PARÂMETROS

Esta seção detalha o processo de otimização automática dos parâmetros das técnicas de processamento de imagem. O fluxograma da Figura 21 apresenta o fluxo de etapa única de ajuste automático dos parâmetros.

Figura 21 – Fluxograma da etapa de ajuste de parâmetros



Fonte: Autor.

4.4.1 Otimizar parâmetros com busca automática

O bloco "Otimizar parâmetros com busca automática" representa um avanço significativo na eficiência da metodologia, substituindo a tediosa e muitas vezes inviável otimização manual. A expectativa é que, nesta fase, algoritmos de otimização automatizada sejam empregados para encontrar os valores ideais para os parâmetros das técnicas de processamento de imagem que estão sendo testadas. Isso pode incluir, por exemplo, a

intensidade de um filtro de desfoque, o limiar de um ajuste de contraste, os parâmetros de técnicas de redução de ruído, ou os fatores de data augmentation.

O propósito fundamental deste bloco é otimizar os resultados dos processamentos sem exigir extensa intervenção manual, como destacado na proposta da metodologia. A automação não apenas acelera o processo, mas também tem o potencial de descobrir configurações de parâmetros que seriam difíceis de identificar heurísticamente. Métodos como busca em grade (grid search), busca aleatória (random search), otimização Bayesiana, algoritmos genéticos, ou otimização por enxame de partículas podem ser empregados dependendo da complexidade do espaço de parâmetros.


A dificuldade de execução pode ser alta, pois envolve a seleção e implementação de algoritmos de otimização apropriados e a definição de um espaço de busca adequado para os parâmetros. Um erro comum é a convergência para ótimos locais em vez do ótimo global, ou um tempo computacional proibitivo para a busca. Se o ajuste automático não encontrar parâmetros que resultem em melhorias significativas, as ações corretivas podem incluir: a modificação do algoritmo de otimização, a redefinição das faixas de valores para os parâmetros, ou a incorporação de critérios de parada mais sofisticados.

A avaliação do sucesso é diretamente quantitativa: a melhoria mensurável nas métricas de desempenho do modelo de rede neural após a aplicação dos parâmetros otimizados automaticamente indica que o processo foi bem-sucedido. Este bloco está diretamente ligado ao objetivo específico de criar um método de ajuste automático de parâmetros dos processamentos de imagem, sendo um pilar central para o aprimoramento contínuo e eficiente das técnicas.

4.5 ESCOLHA E CONSTRUÇÃO DO MODELO

Esta seção detalha o processo de seleção e configuração das arquiteturas de redes neurais que serão utilizadas para avaliar a eficácia das técnicas de processamento de imagem. O fluxograma da Figura 22 ilustra as decisões envolvidas na escolha e montagem do modelo.

Figura 22 – Fluxograma da etapa de escolha e construção do modelo



Fonte: Autor.

4.5.1 Selecionar modelo: CNN, ResNet, YOLO

O bloco "Selecionar modelo: CNN, ResNet, YOLO" representa um ponto estratégico na metodologia onde é definida a arquitetura de rede neural que será utilizada para avaliar o impacto das técnicas de processamento de imagem. A expectativa é que esta seleção seja baseada na natureza específica da tarefa (classificação, detecção, ou regressão) e nas características do problema de detecção de falhas em isoladores.

As opções apresentadas cobrem diferentes abordagens: CNNs convencionais para tarefas de classificação básica, ResNet para problemas que requerem redes mais profundas, e YOLO para tarefas de detecção de objetos em tempo real. A escolha da arquitetura é crucial pois, como apontado na literatura, diferentes tipos de redes neurais possuem princípios de funcionamento e aplicações práticas distintas.

A dificuldade de execução deste bloco é relativamente baixa, sendo principalmente uma decisão estratégica baseada nos requisitos do problema. No entanto, uma escolha inadequada pode comprometer significativamente os resultados subsequentes. Se a arquitetura selecionada não apresentar o desempenho esperado, a ação corretiva seria a reavaliação da escolha, considerando as características específicas dos dados e os objetivos da aplicação.

4.5.2 Tipo de tarefa

O bloco de decisão "Tipo de tarefa" é fundamental para direcionar a configuração específica do modelo selecionado. Esta decisão determina como a arquitetura escolhida será configurada e treinada, influenciando aspectos como a função de perda, as métricas de avaliação, e a estrutura das camadas finais da rede.

As três opções principais são: classificação (determinar se um isolador possui falha ou não), detecção (localizar e classificar falhas nas imagens), e regressão (predizer valores contínuos relacionados ao grau de degradação). Cada tipo de tarefa requer configurações específicas do modelo e métricas de avaliação apropriadas.

A dificuldade desta etapa é baixa, sendo uma decisão conceitual baseada nos objetivos específicos do estudo. A escolha correta é essencial para que o modelo seja apropriadamente configurado para o problema em questão.

4.5.3 Montar modelo de classificação

O bloco "Montar modelo de classificação" é executado quando a tarefa escolhida é classificação. A expectativa é que nesta etapa seja configurada uma rede neural para classificar imagens de isoladores em categorias discretas (por exemplo, "com falha" vs "sem falha", ou múltiplas classes de diferentes tipos de falhas).

A configuração inclui a definição das camadas finais da rede com um número de neurônios correspondente ao número de classes, a seleção de funções de ativação apropriadas (como softmax para classificação multiclasse), e a escolha de funções de perda adequadas (como cross-entropy). Também envolve a definição das métricas de avaliação relevantes como acurácia, precisão, recall e F1-score.

A dificuldade de execução é média, requerendo conhecimento técnico sobre arquiteturas de redes neurais para classificação. Se o modelo não apresentar desempenho satisfatório, as ações corretivas podem incluir ajustes na arquitetura, modificação dos hiperparâmetros, ou revisão do pré-processamento dos dados.

4.5.4 Montar modelo de detecção

O bloco "Montar modelo de detecção" é executado quando a tarefa escolhida é detecção de objetos. A expectativa é que seja configurado um modelo capaz não apenas de classificar a presença de falhas, mas também de localizar espacialmente essas falhas nas imagens, fornecendo coordenadas de bounding boxes ou máscaras de segmentação.

Esta configuração é mais complexa, envolvendo arquiteturas especializadas como YOLO, R-CNN, ou outras redes de detecção. Inclui a definição de hiperparâmetros, confi-

guração de múltiplas escalas, e o balanceamento entre precisão de localização e classificação. As métricas de avaliação incluem mAP (mean Average Precision) e IoU (Intersection over Union).

A dificuldade de execução é alta, devido à complexidade das arquiteturas de detecção e à necessidade de dados rotulados com informações de localização. Se o desempenho não for satisfatório, as ações corretivas podem incluir ajustes nos hiperparâmetros, modificação dos thresholds de confiança, ou revisão da estratégia de aumento de dados.

4.5.5 Montar modelo de regressão

O bloco "Montar modelo de regressão" é executado quando a tarefa escolhida é regressão. A expectativa é que seja configurado um modelo capaz de prever valores contínuos relacionados ao estado dos isoladores, como grau de degradação, probabilidade de falha, ou índices de severidade.


A configuração inclui camadas finais com ativação linear ou outras funções apropriadas para saídas contínuas, seleção de funções de perda para regressão (como MSE ou MAE), e definição de métricas de avaliação como R^2 , RMSE, ou MAE. Esta abordagem pode ser útil quando se deseja uma avaliação mais detalhada do estado dos isoladores.

A dificuldade de execução é média, similar à classificação mas com considerações específicas para saídas contínuas. Se o modelo não apresentar previsões adequadas, as ações corretivas podem incluir normalização das variáveis de saída, ajustes na função de perda, ou modificação da arquitetura da rede.

4.6 TREINAMENTO

Esta seção detalha o processo de treinamento dos modelos de rede neural utilizando os dados processados. O fluxograma da Figura 23 apresenta o fluxo de atividades desta etapa.

Figura 23 – Fluxograma da etapa de treinamento



Fonte: Autor.

4.6.1 Treinar modelo com dados processados

O bloco "Treinar modelo com dados processados" é o cerne do aprendizado e da adaptação do sistema. A expectativa é que, nesta fase, a arquitetura da rede neural previamente selecionada e configurada seja treinada utilizando os dados que passaram pelas etapas de processamento de imagem otimizadas. O propósito central é que o modelo aprenda a identificar e classificar as falhas nas imagens de isoladores, ajustando seus pesos e parâmetros de forma a minimizar a função de custo e otimizar as métricas de desempenho previamente definidas.

Como explicado em Braga e Silva (2011b), o treinamento é onde o neurônio artificial aprende a associar entradas a saídas desejadas. A importância deste bloco é vital, pois os modelos de redes neurais não são apenas as ferramentas para a detecção de falhas, mas também os avaliadores do impacto dos diferentes processamentos de imagem aplicados nas etapas anteriores.

O processo de treinamento envolve a alimentação das imagens processadas através da rede neural, o cálculo do erro entre as previsões e os rótulos verdadeiros, e a atualização dos pesos através de algoritmos de retropropagação. Durante esta etapa, é crucial monitorar métricas como a função de custo, acurácia de treinamento e validação para detectar possíveis problemas como overfitting ou underfitting.


A dificuldade de execução pode ser alta, dada a complexidade do treinamento de redes neurais. Desafios incluem a otimização de hiperparâmetros (como taxa de aprendizado, tamanho do batch, número de épocas), o gerenciamento de recursos computacionais (tempo de processamento, memória de GPU) e a mitigação do sobreajuste. Se o modelo não convergir, apresentar baixo desempenho ou sobreajuste, as ações corretivas podem envolver: a modificação dos hiperparâmetros do treinamento, a escolha de otimizadores mais adequados (como Adam ou RMSProp), a aplicação de técnicas de regularização (como dropout), ou a revisão da própria arquitetura da rede neural.

A diminuição progressiva da função de custo durante o treinamento e, crucialmente, o aumento das métricas de desempenho (acurácia, F1-score, tempo de processamento) nos conjuntos de validação e teste, indicam que o modelo está aprendendo de forma eficaz. Este bloco alinha-se diretamente ao objetivo de construir modelos de redes neurais destinados à avaliação do desempenho das técnicas de processamento de imagem, pois é através do treinamento que esses modelos adquirem a capacidade de realizar tal avaliação com precisão.

4.7 AVALIAÇÃO E AJUSTES

Esta seção detalha o processo de avaliação dos resultados obtidos e os mecanismos de ajuste que permitem a melhoria iterativa da metodologia. O fluxograma da Figura 24 ilustra o ciclo de avaliação e ajustes.

Figura 24 – Fluxograma da etapa de avaliação e ajustes



Fonte: Autor.

4.7.1 Avaliar com as métricas definidas

O bloco "Avaliar com as métricas definidas" é a etapa de quantificação objetiva do desempenho do sistema utilizando as métricas estabelecidas no início da metodologia: acurácia, F1-score e tempo de processamento. A expectativa é que, nesta fase, sejam calculadas e analisadas criticamente essas métricas robustas, que oferecem uma visão multifacetada da performance do modelo treinado.

A acurácia oferece uma medida geral de correção das predições, o F1-score é especialmente valioso para datasets desbalanceados por combinar precisão e recall de forma harmônica, e o tempo de processamento é essencial para aplicações práticas onde a eficiência computacional é crítica, como na inspeção automatizada de linhas de transmissão. Para tarefas de detecção de objetos, métricas adicionais como mAP (mean Average Precision) também podem ser empregadas.

A dificuldade de execução é moderada, residindo mais na interpretação correta das métricas em diferentes contextos de problema, especialmente em face de datasets desbalanceados. O propósito dessas métricas é fornecer uma avaliação compreensiva e imparcial do quão bem o modelo está detectando e classificando as falhas, especialmente considerando que falsos negativos (falhas não detectadas) podem ter consequências graves em aplicações industriais.

4.7.2 Desempenho satisfatório?

O bloco de decisão "Desempenho satisfatório?" serve como um ponto de validação crítico na metodologia, determinando se os resultados obtidos atendem aos critérios de sucesso previamente estabelecidos. A expectativa é que esta decisão seja tomada com base nos valores das métricas definidas (acurácia, F1-score, tempo) comparados com thresholds ou benchmarks pré-estabelecidos.

Por exemplo, pode-se estabelecer que o sistema deve atingir pelo menos 95% de acurácia, F1-score superior a 0.90 para a detecção de falhas, e tempo de processamento inferior a 100ms por imagem para ser considerado satisfatório. Esta decisão é crucial pois determina se o processo deve continuar com ajustes (caso o desempenho não seja satisfatório) ou se pode prosseguir para a fase de comparação e conclusão.

A dificuldade de execução é baixa, sendo uma decisão lógica baseada em critérios objetivos. No entanto, é fundamental que os critérios de sucesso sejam bem definidos e realistas para evitar ciclos de otimização infinitos ou conclusões prematuras.

4.7.3 Ajustar processamentos e modelo

O bloco "Ajustar processamentos e modelo" é executado quando o desempenho não é considerado satisfatório, implementando uma abordagem iterativa de refinamento. A expectativa é que esta etapa revise e modifique tanto as técnicas de processamento de imagem quanto os parâmetros do modelo de rede neural para buscar melhorias no desempenho.

Os ajustes podem envolver: revisão das técnicas de pré-processamento aplicadas, modificação dos parâmetros otimizados automaticamente, exploração de novas combinações de técnicas, ajuste fino dos hiperparâmetros do modelo de rede neural, ou até mesmo a seleção de uma arquitetura de modelo diferente. Esta etapa representa o mecanismo de feedback que permite à metodologia aprender e se adaptar com base nos resultados obtidos.

A dificuldade de execução pode ser de média a alta, dependendo da extensão dos ajustes necessários. Um erro comum é fazer modificações excessivas que comprometem o aprendizado anterior. Se os ajustes repetidos não resultarem em melhorias, as ações corretivas podem envolver uma revisão mais fundamental da abordagem, incluindo a reconsideração dos dados, da arquitetura do modelo, ou dos próprios critérios de sucesso.

4.7.4 Comparar diferentes modelos e técnicas

O bloco "Comparar diferentes modelos e técnicas" é executado quando o desempenho é considerado satisfatório, permitindo uma análise comparativa abrangente dos resultados obtidos com diferentes configurações. A expectativa é que esta etapa consolide e compare sistematicamente os resultados de todas as combinações de técnicas de processamento, parâmetros otimizados, e arquiteturas de modelos testadas ao longo da metodologia.

Esta análise comparativa é fundamental para identificar quais estratégias são mais eficazes, sob quais condições, e por quê. Inclui a comparação de métricas de desempenho, análise de trade-offs entre acurácia e velocidade, identificação de técnicas que se complementam, e documentação de insights sobre a interação entre processamentos de imagem e arquiteturas de modelos.

A dificuldade de execução é de média a alta, exigindo sólidas habilidades analíticas e conhecimento em estatística para realizar comparações significativas. A avaliação do sucesso é dada pela geração de conclusões claras sobre as abordagens mais eficazes e recomendações práticas para implementação.

4.7.5 Conclusões e recomendações

O bloco "Conclusões e recomendações" representa a fase final da metodologia, onde todo o conhecimento adquirido é consolidado em um conjunto de conclusões acionáveis e recomendações práticas. A expectativa é que esta etapa sintetize os principais achados do estudo, incluindo as técnicas de processamento de imagem mais eficazes, as combinações ótimas, o impacto das diferentes arquiteturas de modelos, e as métricas de desempenho alcançadas.

As conclusões devem ser baseadas em evidências empíricas sólidas coletadas ao longo da metodologia, enquanto as recomendações devem fornecer diretrizes práticas para implementação em cenários reais. Isso inclui a apresentação das melhores práticas identificadas, limitações observadas, e sugestões para pesquisas futuras que possam expandir o escopo do trabalho.

A dificuldade de execução é moderada, exigindo clareza na comunicação, capacidade de síntese e rigor na interpretação dos resultados. A avaliação do sucesso é medida pela completude e clareza das conclusões, e pela utilidade prática das recomendações para futuras implementações do sistema de detecção de falhas em isoladores.

5 COLETA E ANÁLISE DE RESULTADOS

Este capítulo apresenta os resultados obtidos a partir da aplicação da metodologia proposta, iniciando com a análise detalhada da otimização de parâmetros de pré-processamento, seguida pela avaliação do impacto dos modelos, influência dos *datasets* e comparação das estratégias.

5.1 OTIMIZAÇÃO DE PARÂMETROS DE PRÉ-PROCESSAMENTO EM VISÃO COMPUTACIONAL

Nesta fase do estudo, realiza-se uma análise detalhada sobre a otimização de parâmetros de pré-processamento em um *pipeline* de aprendizado de máquina aplicado à visão computacional. O objetivo principal consistiu em identificar o valor ótimo do parâmetro de realce de contraste em imagens de um *dataset* específico, visando maximizar o desempenho de um modelo de rede neural convolucional (CNN) em tarefas de classificação. O estudo foi conduzido utilizando uma abordagem sistemática de busca em grade (*grid search*), testando diferentes valores do parâmetro em um conjunto de dados de imagens de isoladores operantes em linhas de transmissão.

5.1.1 Metodologia Experimental

5.1.1.1 Conjunto de Dados

O conjunto de dados utilizado foi o DRNPW (*Dataset for Recognition of Non-ceramic Pollution on Windings*), o qual consiste em imagens de isoladores de linhas de transmissão. Este acervo inclui anotações automáticas para detecção de objetos, perfazendo um total de 779 imagens brutas processadas. Após etapas de pré-processamento e redimensionamento para uma resolução fixa de 640×640 pixels, as imagens foram particionadas em conjuntos de treinamento (468 imagens), validação (87 imagens) e teste (30 imagens). O *dataset* é precipuamente projetado para tarefas de detecção e classificação de defeitos estruturais em isoladores, ostentando grande aptidão para o contexto de manutenção preditiva em infraestrutura elétrica.

5.1.1.2 Estratégia de Pré-Processamento

A técnica de pré-processamento selecionada foi intitulada *ContrastEnhancement*, que recorre à biblioteca PIL (*Python Imaging Library*) para retificar os níveis de contraste das amostras visuais. O método incide sobre o realce de contraste da imagem valendo-se da função `ImageEnhance.Contrast.enhance(factor)`, na qual a variável `factor` governa a intensidade da transformação. Valores de `factor` menores que 1,0 atenuam o contraste, ao passo que frações superiores a 1,0 resultam em intensificação. O hiperparâmetro otimizado foi, de forma exclusiva, o `factor`, estipulado no domínio dos números em ponto flutuante na faixa abarcada entre 0,5 e 3,0.

A sucessão de etapas deste processamento envolveu:

1. Conversão das imagens para o formato original em JPEG.
2. Redimensionamento padronizado e normalização das matrizes componentes e das referidas anotações.
3. Imposição do realce de contraste alinhado ao ponderador `factor` pré-determinado.
4. Formatação de um arquivo diretivo `data.yaml` direcionado ao treinamento por meio do *framework* YOLO (*You Only Look Once*).
5. Divisão das imagens reestruturadas consoante os agrupamentos de treinamento, validação e teste.

5.1.1.3 Modelo de Aprendizado de Máquina

A estratégia de avaliação assentou-se sobre um algoritmo simples de Rede Neural Convolucional (CNN), implementado sob o *framework* TensorFlow/Keras. O projeto estrutural adotado abrange:

- Camada de entrada conformada por dimensões (640, 640, 3), condizente com imagens do espectro RGB.
- Duas camadas convolucionais dispondo de 32 filtros cada (possuindo *kernels* de 3×3 e ativação ReLU), sucedidas recursivamente por rotinas de agrupamento máximo (*max-pooling* com janelas de 4×4).
- Camada com operação de achatamento matricial (*Flatten*).
- Camada densa composta por 8 neurônios artificiais e ativação ReLU.

- Camada de saída dispondo de neurônios correspondentes ao montante de classes do preditor, orientada por uma operação de ativação *softmax*.

Durante a compilação optou-se pelo emprego do otimizador Adam, atrelado a uma função objetivo de entropia cruzada categórica esparsa (*sparse_categorical_crossentropy*) com monitoramento de desempenho provido pela acurácia. O fluxo de treinamento limitou-se a 5 épocas globais. A avaliação do modelo culminou em inferências sobre o subconjunto de testes extraíndo-se as métricas: acurácia, precisão, *recall* e *F1-score*.

5.1.1.4 Estratégia de Otimização Paramétrica

A arquitetura de otimização fundamentou-se no paradigma de Busca em Grade (*Grid Search*), técnica exaustiva que avalia valores uniformemente graduados correspondentes ao hiperparâmetro de interesse. Assinalaram-se 5 instâncias distintas para o *factor*: 0,5, 1,125, 1,75, 2,375 e 3,0, espaçadas iterativamente valendo-se da função *numpy.linspace*.

Para cada valor adotado do respectivo *factor*, o fluxo executou os seguintes passos:

1. Pré-processamento sistemático restrito ao valor atual avaliado.
2. Treinamento estatístico do modelo CNN supervisionado durante as 5 épocas.
3. Extração autônoma das métricas preditivas oriundas do espécime de teste.
4. Transcrição final com registro do limiar ideal balizado pela detecção do ponto de máxima acurácia observada.

5.1.2 Apoio Teórico do Método Selecionado

A busca em grade consolida-se através da literatura como um método de eleição para o dimensionamento prático de parâmetros visando o ótimo absoluto perante discretização de instâncias curtas. A operacionalidade atrela-se a princípios fundamentais:

- **Espaço de Busca:** Pela discretização uniforme aplicada, propiciou-se uma varredura contundente a transitar nas balizas de 0,5 a 3,0 com 5 avaliações diretas.
- **Custeio Paramétrico:** O principal limitador da estratégia em grade perpassa a ineficiência inerente a hiper-espaços compostos de múltiplas variáveis endógenas; restrição que é integralmente mitigada neste cenário de intervenção unidimensional.

- **Atratividade Determinística:** A abordagem denota vasta capacidade de reprodutibilidade científica comparativamente a processos com fundamentos heurísticos associados a *Random Search* ou modelagens estocásticas preexistentes em buscas bayesianas, fundamentando-se adequadamente para explorações pontuais ou cenários incipientes computacionais.

5.1.3 Resultados Reportados e Análise Factual

O ciclo de otimização contemplou satisfatoriamente as 5 métricas submetidas aos blocos do experimento, refletindo na consolidação dos valores de acurácia observados (vide Tabela 5).

Tabela 5 – Resultados da otimização por busca em grade do parâmetro de contraste (*factor*)

Fator (<i>factor</i>)	Acurácia	Precisão	Recall	F1-Score
0,500	0,0000	0,0000	0,0000	0,0000
1,125	0,0000	0,0000	0,0000	0,0000
1,750	0,0000	0,0000	0,0000	0,0000
2,375	0,8333	0,6944	0,8333	0,7576
3,000	0,0000	0,0000	0,0000	0,0000

Fonte: Autor.

Mediante minucioso escrutínio dos eventos computados, atestam-se os pertinentes achados analíticos:

- **Otimização Exponencial e Singular:** O marco otimizado recai sobre o fator aproximado de 2,375, onde obtiveram-se índices altamente significativos: 83,33% de acurácia, 69,44% de precisão e uma pontuação *F1-score* alocada em 75,76%. Este evento infere que um acréscimo de contraste moderadamente acentuado maximizou a discernibilidade morfológica do arcabouço convolucional de filtros em prol de detecção das características relevantes ao diagnóstico do problema.
- **Ineficácia em Vértices Complementares:** Notarizou-se a derrocada dos treinamentos remanescentes (de fatores 0,5 a 1,75 e 3,0), com zeraemento em massa no progresso dos *scores* de eficiência preditiva, possivelmente acarretados pela inviabilização morfológica da imagem perante deficiência nas taxas luminosas do *input*,

parada prematura da rede em minimização do gradiente ou estouro em vazamento nas matrizes visuais de contorno por supressão de textura.

- **Comportamento Não-Linear Intenso:** A volatilidade dos saltos transcreve o elevado patamar da sensibilidade da CNN não correspondendo fielmente com aproximações lineares. Em imediações promissoras como 1,75 as métricas declinaram integralmente indicando limites de operação sensíveis à transformação extrema inserida pelo filtro logarítmico na textura dos elementos constituintes da rede.

Cita-se que o consolidado das medições extraídas foi resguardado visando a reprodutibilidade na trilha `optimization_factor_results.json`.

5.1.4 Síntese da Etapa e Encaminhamentos

As validações empíricas reiteram enfaticamente o papel expressivo da varredura sistemática adotada perfeitamente amoldada ao aperfeiçoamento prévio dos módulos convolucionais. O preditor fixou o `factor` ótimo estimado como sendo 2,375, com proveitos notáveis na detecção base sobre o DRNPW, assinalados no expressivo valor de aderência quantificado (83,33% acurácia).

Frente às discrepâncias contínuas colhidas onde os índices de *score* desfaleceram sob constrições agudas de contraste visual, sinaliza-se expressamente recomendações iminentes focadas nas rodadas sequenciais englobando:

- Verificação de processos autônomos por exploração bayesiana viabilizando eficiências dimensionais mais abrangentes a hiperparâmetros diversificados.
- Expansão amostral adensada que viabilize *trials* de refinação granular em torno da região favorável já mapeada no fator de contraste, isolando picos globais exatos.
- Sindicância exploratória na arquitetura interna recorrendo a laudos em *logs* transientes ou validações em *checkpointing* a fim de diagnosticar com primor a estocástica de impedimentos paralelos encontrados.
- Desdobrar destas simulações elementares as diretrizes vitais à validação robusta para implantações sob vigilância *in loco* em infraestrutura isolante de usinas elétricas convencionais.

5.2 IMPACTO DOS MODELOS NO DESEMPENHO DOS PROCESSAMENTOS

Será analisado o impacto dos diferentes modelos de redes neurais no desempenho dos processamentos de imagem.

5.3 INFLUÊNCIA DOS DATASETS NOS RESULTADOS

Aqui, será discutida a influência dos diferentes datasets nos resultados dos processamentos de imagem.

5.4 COMPARAÇÃO ENTRE DIFERENTES ESTRATÉGIAS DE PROCESSAMENTO

Serão comparadas as diferentes estratégias de processamento de imagem utilizadas no estudo, destacando as vantagens e desvantagens de cada uma.

6 CONCLUSÃO

6.1 SÍNTESE DOS RESULTADOS OBTIDOS

Nesta seção, será feita uma síntese dos principais resultados obtidos ao longo do estudo.

6.2 LIMITAÇÕES E DESAFIOS ENCONTRADOS

Serão discutidas as limitações e os desafios encontrados durante a realização do trabalho.

6.3 SUGESTÕES PARA PESQUISAS FUTURAS

Por fim, serão apresentadas sugestões para pesquisas futuras, com base nos resultados e nas limitações identificadas no estudo.

REFERÊNCIAS

- AGARAP, A. F. Deep learning using rectified linear units (relu). **arXiv preprint arXiv:1803.08375**, 2018.
- ALAM, M. et al. Robust fault detection and classification in power transmission lines via ensemble machine learning models. **Scientific Reports**, Nature Publishing Group, v. 15, p. 86554, 2025.
- ALEX. **Feedforward Neural Networks and Multilayer Perceptrons**. 2020. <https://boostedml.com/2020/04/feedforward-neural-networks-and-multilayer-perceptrons.html>. Acesso em: 21 abr. 2025.
- ALTAIE, A. S. et al. Fault detection on power transmission line based on wavelet transform and scalogram image analysis. **Energies**, MDPI, v. 16, n. 23, p. 7914, 2023. Disponível em: <https://www.mdpi.com/journal/energies>.
- BADIGER, M.; MATHEW, J. A. Retrospective review of activation functions in artificial neural networks. **ResearchGate**, 2022.
- BARRETO, T. et al. Cnn based image restoration. **Journal of Intelligent & Robotic Systems**, v. 100, n. 2, p. 609–620, 2020.
- BASCLE OLIVIER BERNIER, V. L. B. Illumination-invariant color image correction. In: **Lecture Notes in Computer Science**. [S.l.: s.n.], 2006.
- BEN, M. et al. Deep neural network concept for a blind enhancement of document-images. **Applied Sciences**, v. 12, n. 19, p. 9601, 2022.
- BRAGA, P.; SILVA, J. Aplicação de redes neurais artificiais em conjunto com o método vetorial da propagação de feixes na análise de um acoplador direcional baseado em fibra Ótica. **Revista Brasileira de Computação Aplicada**, v. 16, 2011.
- _____. Aplicação de redes neurais artificiais em conjunto com o método vetorial da propagação de feixes na análise de um acoplador direcional baseado em fibra Ótica. **Revista Brasileira de Computação Aplicada**, v. 16, 2011.
- CHAWLA, N. V. et al. Smote: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.
- CHEN, T. et al. A simple framework for contrastive learning of visual representations. **International Conference on Machine Learning**, p. 1597–1607, 2020.
- CHEN, X. et al. Edge detection networks inspired by neural mechanisms of selective attention in biological visual cortex. **Frontiers in Neuroscience**, v. 16, p. 1073484, 2022.
- CHEN, Y. et al. Robustness of machine learning to color, size change, normalization, and image enhancement on micrograph datasets. **Materials & Design**, 2023.

CHICCO, D.; JURMAN, G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation. **BMC Genomics**, BioMed Central, v. 21, n. 1, p. 6–13, 2020.

COUTO, G. Segmentação baseada em região. **LinkedIn Artigos**, março 2024. Publicado em 18 de março de 2024.

DENG, J. et al. Imagenet: A large-scale hierarchical image database. **2009 IEEE Conference on Computer Vision and Pattern Recognition**, IEEE, p. 248–255, 2009.

DENNANNI, A. **How to deal with image resizing in Deep Learning**. 2019. Disponível em: <https://medium.com/neuronio/how-to-deal-with-image-resizing-in-deep-learning-e5177fad7d89>.

DING, F. et al. Detecting usm image sharpening by using cnn. **Signal Processing: Image Communication**, v. 68, p. 188–194, 2018.

ENGELLEN, J. E. V.; HOOS, H. H. A survey on semi-supervised learning. **Machine Learning**, Springer, v. 109, n. 2, p. 373–440, 2020.

EZE, C. C. et al. Deep learning for component fault detection in electricity transmission lines. **Journal of Big Data**, v. 9, n. 1, p. 63, 2022.

FELIX, H. C. et al. **Unifying Public Datasets for Insulator Detection and Fault Classification in Electrical Power Lines**. 2020. [invalidurl,donotcite].

GAO, B.; PAVEL, L. On the properties of the softmax function with application in game theory and reinforcement learning. **arXiv preprint arXiv:1704.00805**, 2017.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 3. ed. [S.l.]: Prentice Hall, 2008.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016.

GOODFELLOW, I. et al. Generative adversarial nets. **Advances in Neural Information Processing Systems**, v. 27, 2014.

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 21, n. 9, p. 1263–1284, 2009.

_____. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 21, n. 9, p. 1263–1284, 2009.

HUBER, P. J. Robust estimation of a location parameter. **The Annals of Mathematical Statistics**, Institute of Mathematical Statistics, v. 35, n. 1, p. 73–101, 1964.

ISOLA, P. et al. Comparison of image normalization methods for multi-site deep learning. **Applied Sciences**, v. 13, n. 15, p. 8923, 2023.

JOHNSON, J. M.; KHOSHGOFTAAR, T. M. Survey on deep learning with class imbalance. **Journal of Big Data**, Springer, v. 6, n. 1, p. 27, 2019.

JOSHI, P. **OpenCV with Python By Example**. O'Reilly Media, Inc., 2025. Disponível em: <https://www.oreilly.com/library/view/opencv-with-python/9781785283932/>.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. **arXiv preprint arXiv:1412.6980**, 2014.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2012.

KUEHLKAMP, A. **Ferramenta de baixo custo para gaze tracking baseado em imagens**. maio 2013. Dissertação (Mestrado) — Universidade do Vale do Itajaí, Itajaí, SC, Brasil, maio 2013. Dissertação de Mestrado em Computação Aplicada.

KUMAR, D. et al. A novel scheme of fault detection in transmission line using image processing. **Global Journal of Computer Science and Technology**, v. 17, n. 1, 2023.

LANGER, S. Approximating smooth functions by deep neural networks with sigmoid activation function. **arXiv preprint arXiv:2010.04596**, 2020.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LEDIG, C. et al. Photo-realistic single image super-resolution using a generative adversarial network. In: **CVPR**. [S.l.: s.n.], 2017. p. 4681–4690.

LI, C. et al. A simple deep learning based image illumination correction method for paintings. **Pattern Recognition Letters**, v. 138, p. 392–398, 2020.

LI, X. et al. Fusion of image processing techniques for fault detection in electrical insulators. **IEEE Transactions on Power Delivery**, v. 34, n. 3, p. 1234–1241, 2019.

LIAN, Z.; WANG, H. An image deblurring method using improved u-net model based on multilayer fusion and attention mechanism. **Scientific Reports**, Nature Publishing Group, v. 13, p. 21402, 2023. Disponível em: <https://www.nature.com/articles/s41598-023-47768-4>.

LIN, T.-Y. et al. Focal loss for dense object detection. **Proceedings of the IEEE International Conference on Computer Vision**, p. 2980–2988, 2017.

LIU, C. et al. Detecção de falhas em isoladores em imagens aéreas de linhas de transmissão de alta voltagem baseada em modelo de aprendizado profundo. **Appl. Sci.**, v. 11, n. 10, p. 4647, 2021.

LIU, S. et al. A neural network for long-term super-resolution imaging of live cells with reliable confidence quantification. **Nature Biotechnology**, 2025.

MACDONALD, L. Color space transformation using neural networks. In: **Proc. IS&T 27th Color and Imaging Conf.** [S.l.: s.n.], 2019. p. 178–183.

MALLA, P. K. et al. A comprehensive review of deep neural networks for medical image processing: Recent developments and future opportunities. **Healthcare Analytics**, Elsevier, v. 4, p. 100216, 2023. Disponível em: <https://doi.org/10.1016/j.health.2023.100216>.

MATHWORKS. Deblurring images using the lucy-richardson algorithm. **MathWorks Help Center - Image Processing Toolbox**, 2025. Disponível em: <https://www.mathworks.com/help/images/deblurring-images-using-the-lucy-richardson-algorithm.html>.

NALEPA, J. et al. A review: Data pre-processing and data augmentation techniques. **ScienceDirect**, 2022.

OBERWEGER, F.; WENDEL, A.; BISCHOF, H. **XAI-guided Insulator Anomaly Detection for Imbalanced Datasets**. 2024. ArXiv:2409.16821.

PAN, S. J.; YANG, Q. A survey on transfer learning. **IEEE Transactions on Knowledge and Data Engineering**, IEEE, v. 22, n. 10, p. 1345–1359, 2010.

PANDEY, N. **Mastering Image Contrast: A Step-by-Step Guide to Enhancing Image**. 2023. Acessado em: 20 abr. 2025. Disponível em: <https://www.nomidl.com/computer-vision/mastering-image-contrast/>.

PEER, D. et al. Real-time noise cancellation with deep learning. **PMC**, v. 9, p. e9678292, 2022.

PENG, H. et al. Edf-yolov5: An improved algorithm for power transmission line defect detection based on yolov5. **Electronics**, MDPI, v. 13, n. 1, p. 148, 2023.

RASHID, M. e. a. A survey of neural network optimization algorithms. **Artificial Intelligence Review**, Springer, 2020.

RODRIGUES, L. F.; NALDI, M. C.; MARI, J. F. Comparing convolutional neural networks and preprocessing techniques for hep-2 cell classification in immunofluorescence images. **Computers in Biology and Medicine**, Elsevier, v. 116, p. 103542, 2020. Acessado em: 24 mar. 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0010482519303993>.

RUDER, S. An overview of gradient descent optimization algorithms. **arXiv preprint arXiv:1609.04747**, 2016.

SABOTTKE, C. F. et al. The effect of image resolution on deep learning in radiography. **Radiology: Artificial Intelligence**, v. 2, n. 1, p. e190015, 2020.

SALVI, M. et al. The impact of pre- and post-image processing techniques on deep learning frameworks: A comprehensive review for digital pathology image analysis. **Computers in Biology and Medicine**, Elsevier, v. 128, p. 104129, 2021.

SHARMA, A. et al. Deep learning models for digital image processing: a review. **Artificial Intelligence Review**, 2024.

_____. Deep learning models for digital image processing: a review. **Artificial Intelligence Review**, 2024.

SHORTEN, C. et al. A survey on image data augmentation for deep learning. **Journal of Big Data**, v. 6, n. 1, p. 1–48, 2019.

_____. A survey on image data augmentation for deep learning. **Journal of Big Data**, v. 6, n. 1, p. 1–48, 2019.

SUMIDA, I. et al. Deep convolutional neural network for reduction of contrast-enhanced region on ct images. **Journal of Radiation Research**, v. 60, n. 5, p. 586–594, 2019.

The MathWorks, Inc. **Wavelet Denoising**. 2023. Acesso em 20 abr. 2025. Disponível em: <https://www.mathworks.com/help/release/R2021a/wavelet/ug/wavelet-denoising.html>.

TIELEMAN, T.; HINTON, G. **Lecture 6.5—RMSProp: Divide the gradient by a running average of its recent magnitude**. 2012. COURSERA: Neural Networks for Machine Learning.

TORRES, L. **Curva ROC y AUC en Python**. 2025. Acessado em: 1 jun. 2025. Disponível em: <https://www.themachinelearners.com/curva-roc-vs-prec-recall/>.

VEEN, F. V. **The Neural Network Zoo**. 2016. <https://www.asimovinstitute.org/neural-network-zoo/>. Acesso em: 21 abr. 2025.

VENTURELLI, M. **The dangers behind image resizing**. 2021. <https://zuru.tech/blog/the-dangers-behind-image-resizing>. Accessed: 2025-04-20.

WANG, L. et al. Análise sustentável da detecção de falhas em isoladores baseada em otimização visual refinada. **Sustainability**, v. 15, n. 4, p. 3456, 2023.

YANG, Z. et al. Using convolutional neural network models illumination estimation according to light colors. **Optics Communications**, v. 513, p. 128108, 2022.

YU, J. et al. Edge detection using a neural network. **Pattern Recognition**, v. 27, n. 12, p. 1653–1662, 1994.

ZHANG, Z. et al. Detecção de defeitos em isoladores por imagem baseada em processamento morfológico e aprendizado profundo. **Energies**, v. 15, n. 7, p. 2465, 2022.

ZHANG, Z.; SABUNCU, M. R. Cross-entropy loss function and classification performance. **arXiv preprint arXiv:1805.05768**, 2018.

ZHENG, J. et al. Insulator-defect detection algorithm based on improved yolov7. **Sensors**, MDPI, v. 22, n. 22, p. 8801, 2022.

ZOU, H. et al. A bolt defect detection method for transmission lines based on improved yolov5. **Frontiers in Energy Research**, Frontiers, v. 12, p. 1269528, 2024.

ÖZTÜRK, ; AKDEMİR, B. Effects of histopathological image pre-processing on convolutional neural networks. In: ELSEVIER. **Procedia Computer Science**. [S.l.], 2018. v. 132, p. 396–403. International Conference on Computational Intelligence and Data Science (IC-CIDS 2018).