

UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS NATURAIS E EXATAS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Luan Willig Silveira

**METODOLOGIA PARA APRIMORAMENTO DE PROCESSAMENTOS DE
IMAGEM PARA DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM
ISOLADORES**

Santa Maria, RS
2025

Luan Willig Silveira

**METODOLOGIA PARA APRIMORAMENTO DE PROCESSAMENTOS DE IMAGEM
PARA DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**. Defesa realizada por videoconferência.

Orientador: Prof. Dr. Daniel Pinheiro Bernardon

Coorientador: Prof. Dr. Paulo César Vargas Luz

Santa Maria, RS
2025

Luan Willig Silveira

**METODOLOGIA PARA APRIMORAMENTO DE PROCESSAMENTOS DE IMAGEM
PARA DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM ISOLADORES**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica, Área de Concentração em CNPq, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Mestre em Engenharia Elétrica**.

Aprovado em 8 de dezembro de 2025:

**Daniel Pinheiro Bernardon, Dr. (UFSM)
(Presidente/Orientador)**

**Paulo César Vargas Luz, Dr. (UFSM)
(Coorientador)**

Banca Um, Dra. (UFSM)

Banca Dois, Dr. (UFSM)

Santa Maria, RS
2025

RESUMO

METODOLOGIA PARA APRIMORAMENTO DE PROCESSAMENTOS DE IMAGEM PARA DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM ISOLADORES

AUTOR: Luan Willig Silveira
Orientador: Daniel Pinheiro Bernardon
Coorientador: Paulo César Vargas Luz

Escreva seu resumo aqui! Você pode digitá-lo diretamente neste arquivo ou usar o comando input. O resumo deve ter apenas uma página, desde o cabeçalho até as palavras chave. Caso seu resumo seja maior, use comandos para diminuir espaçamento e fonte (até um mínimo de 10pt) no texto. Segundo a MDT, é preciso que os resumos tenham, no máximo, 250 palavras para trabalhos de conclusão de curso de graduação, pós-graduação e iniciação científica e até 500 palavras para dissertações e teses.

Palavras-chave: Processamento de Imagens. Redes Neurais Artificiais. Aprendizado de Máquina. Métricas de Qualidade. Classificação de Imagens. Detecção de Objetos. Regressão. Dataset. Combinação de Processamentos. Otimização. Deep Learning. Segmentação de Imagens. Eficiência Computacional. Redes Convolucionais (CNN). Comparação de Modelos. Inteligência Artificial.

ABSTRACT

METHODOLOGY FOR IMPROVING IMAGE PROCESSING FOR DETECTING AND CLASSIFYING FAULTS IN INSULATORS

AUTHOR: Luan Willig Silveira
ADVISOR: Daniel Pinheiro Bernardon
CO-ADVISOR: Paulo César Vargas Luz

Write your abstract here! As recomendações do resumo também se aplicam ao abstract. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: Keyword 1. Keyword 2. Keyword 3. (...)

SUMÁRIO

1	INTRODUÇÃO	7
1.1	PROPOSTA.....	7
1.2	OBJETIVO GERAL.....	8
1.3	OBJETIVOS ESPECÍFICOS.....	9
1.4	JUSTIFICATIVA	9
1.5	CRONOGRAMA.....	10
2	TRABALHOS RELACIONADOS	12
2.1	ESTUDO 1: ANÁLISE SUSTENTÁVEL DA DETECÇÃO DE FALHAS EM ISO- LADORES BASEADA EM OTIMIZAÇÃO VISUAL REFINADA	12
2.2	ESTUDO 2: DETECÇÃO DE FALHAS EM ISOLADORES EM IMAGENS AÉ- REAS DE LINHAS DE TRANSMISSÃO DE ALTA VOLTAGEM BASEADA EM MODELO DE APRENDIZADO PROFUNDO	13
2.3	ESTUDO 3: DETECÇÃO DE DEFEITOS EM ISOLADORES POR IMAGEM BASEADA EM PROCESSAMENTO MORFOLÓGICO E APRENDIZADO PRO- FUNDO	14
2.4	DISCUSSÃO E IMPLICAÇÕES	16
3	REVISÃO BIBLIOGRÁFICA.....	17
3.1	PROCESSAMENTO DE IMAGENS.....	17
3.2	DATASETS.....	17
3.3	REDES NEURAIS.....	17
3.3.1	Métricas	17
3.4	INFLUÊNCIA DE DATASETS NA PERFORMANCE DOS MODELOS.....	17
3.5	MÉTODOS DE AJUSTE DE PARÂMETROS E COMBINAÇÃO DE PROCES- SAMENTOS	18
4	METODOLOGIA	19
4.1	DEFINIÇÃO DAS MÉTRICAS PARA AVALIAR EFICÁCIA DOS PROCESSA- MENTOS.....	19
4.2	ESCOLHA DO TIPO DE MODELO DE REDE NEURAL	20
4.3	SELEÇÃO DOS DATASETS PARA AVALIAÇÃO	21
4.4	METODOLOGIA PARA COMBINAÇÃO DE PROCESSAMENTOS UNITÁRIOS.	21
4.5	IMPLEMENTAÇÃO DE UM MÉTODO DE AJUSTE AUTOMÁTICO DE PARÂ- METROS.....	21
4.6	CONSTRUÇÃO DE REDES NEURAIS PARA AVALIAÇÃO DOS PROCESSA- MENTOS.....	21
4.7	TESTES COM DIFERENTES ARQUITETURAS E ANÁLISE DE VARIAÇÕES NOS RESULTADOS.....	21

5	COLETA E ANÁLISE DE RESULTADOS	22
5.1	IMPACTO DOS MODELOS NO DESEMPENHO DOS PROCESSAMENTOS ...	22
5.2	INFLUÊNCIA DOS DATASETS NOS RESULTADOS	22
5.3	COMPARAÇÃO ENTRE DIFERENTES ESTRATÉGIAS DE PROCESSAMENTO	22
6	CONCLUSÃO	23
6.1	SÍNTESE DOS RESULTADOS OBTIDOS	23
6.2	LIMITAÇÕES E DESAFIOS ENCONTRADOS	23
6.3	SUGESTÕES PARA PESQUISAS FUTURAS	23
	REFERÊNCIAS BIBLIOGRÁFICAS	24

1 INTRODUÇÃO

1.1 PROPOSTA

O presente estudo tem como objetivo desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores. Para isso, serão estabelecidas métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento. Além disso, serão construídos modelos de redes neurais para avaliar o desempenho dos processamentos, podendo abranger tarefas como classificação, detecção e regressão. No decorrer do estudo, serão construídos modelos de redes neurais voltados para a avaliação do desempenho das técnicas de processamento de imagem, sem a intenção de definir um modelo ideal.

Também será analisado o impacto da escolha do modelo de rede neural no desempenho do processamento, visto que diferentes modelos podem gerar resultados distintos para um mesmo processamento. A influência do dataset na eficácia do processamento será outro aspecto a ser investigado, considerando possíveis variações nos resultados devido ao uso de diferentes conjuntos de dados. Para aprimorar os processamentos de imagem, será desenvolvida uma metodologia que permita a combinação de diferentes processamentos unitários (processamentos de imagem que realizam uma única operação). Além disso, será criado um método de ajuste automático de parâmetros das técnicas de processamento de imagem, com o intuito de otimizar seus resultados sem exigir extensa intervenção manual.

A metodologia proposta será desenvolvida dentro de um conjunto de restrições previamente estabelecidas, garantindo um escopo bem delimitado e viável dentro do período de realização da dissertação. Primeiramente, o estudo será restrito à detecção e classificação de falhas em cadeias de isoladores elétricos, não abrangendo outros componentes elétricos. O uso de imagens previamente adquiridas será uma diretriz, de modo que apenas imagens já disponíveis ou capturadas por métodos convencionais serão utilizadas, sem o desenvolvimento de novas técnicas de aquisição de imagens. Além disso, a metodologia será aplicada exclusivamente a técnicas de processamento de imagem já conhecidas, sem a criação de novos algoritmos de base.

Os modelos de redes neurais desenvolvidos terão o propósito único de avaliar o impacto das redes sobre os processamentos de imagem, sem a intenção de definir um modelo definitivo para diagnóstico industrial. A análise será conduzida utilizando conjuntos de dados já existentes ou obtidos por métodos convencionais, sem a necessidade de criar um novo dataset específico para o estudo. A otimização contemplada estará limitada ao

ajuste de parâmetros das técnicas existentes, não incluindo o desenvolvimento de novas abordagens baseadas em inteligência artificial para otimização dos processamentos. Por fim, toda a avaliação será realizada em ambiente controlado, sem a realização de testes em ambientes industriais reais.

A Figura 1 ilustra o diagrama da proposta de metodologia.

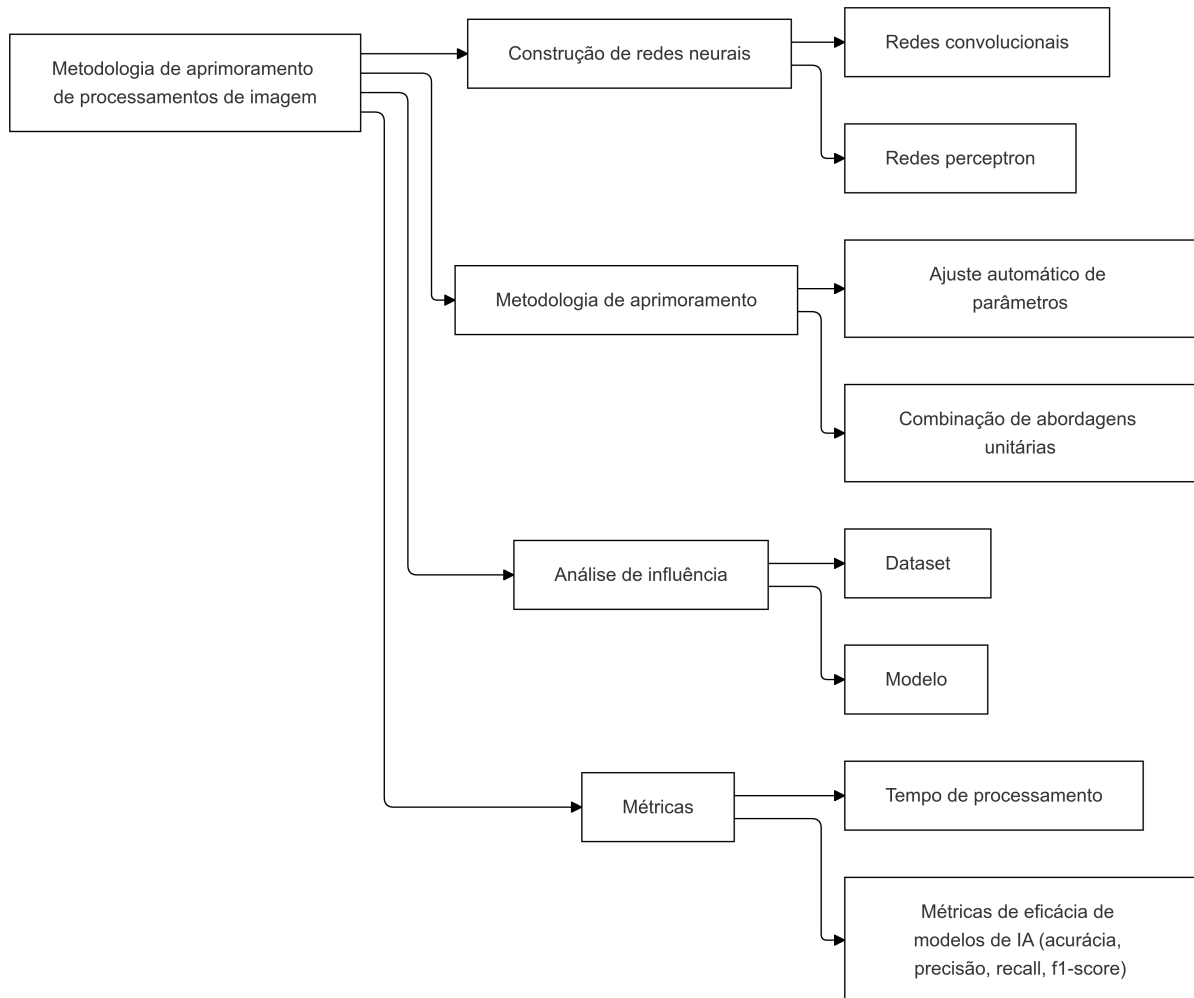


Figura 1 – Diagrama da proposta de metodologia

1.2 OBJETIVO GERAL

O objetivo geral deste estudo é desenvolver uma metodologia capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores.

1.3 OBJETIVOS ESPECÍFICOS

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

- Estabelecer métricas para avaliar a eficácia dos processamentos de imagem, considerando aspectos como acurácia e tempo de processamento.
- Determinar o tipo de modelo de redes neurais ideal para avaliar o desempenho dos processamentos, podendo abranger classificação, detecção e regressão.
- Construir modelos de redes neurais destinados à avaliação do desempenho das técnicas de processamento de imagem, sem o intuito de encontrar um modelo definitivo.
- Analisar o impacto da escolha do modelo de rede neural no desempenho do processamento, considerando que diferentes modelos podem gerar diferentes resultados para um mesmo processamento.
- Avaliar a influência do dataset na eficácia do processamento, considerando possíveis variações nos resultados devido à utilização de diferentes conjuntos de dados.
- Desenvolver uma metodologia para o aprimoramento dos processamentos de imagem por meio da combinação de diferentes abordagens unitárias.
- Criar um método de ajuste automático de parâmetros dos processamentos de imagem, visando otimizar seus resultados sem a necessidade de intervenção manual extensa.

1.4 JUSTIFICATIVA

A crescente demanda por sistemas automatizados de inspeção de cadeias de isoladores evidencia a necessidade de técnicas avançadas de processamento de imagem para a detecção precoce de falhas. Conforme demonstrado por Gonzalez e Woods (GONZALEZ; WOODS, 2008), a análise digital de imagens permite extrair características relevantes para identificar anomalias em componentes elétricos, possibilitando diagnósticos mais precisos. Ademais, o emprego de redes neurais tem se destacado na resolução de problemas complexos de classificação e detecção, conforme ressaltado por LeCun et al. (LECUN; BENGIO; HINTON, 2015) e Krizhevsky et al. (KRIZHEVSKY; SUTSKEVER; HINTON, 2012), contribuindo para a robustez dos sistemas de inspeção.

Estudos recentes apontam que a combinação de diferentes técnicas de processamento de imagem, aliada ao ajuste automático de parâmetros, pode resultar em melhorias

significativas no desempenho dos sistemas de diagnóstico (LI et al., 2019). Assim, a proposta deste trabalho visa desenvolver uma metodologia que integre esses avanços, buscando não apenas aprimorar a acurácia e a eficiência dos processamentos, mas também possibilitar uma análise comparativa que leve em conta a influência de diferentes modelos e datasets.

Dessa forma, esta dissertação justifica-se pela necessidade de inovar na abordagem de detecção e classificação de falhas em cadeias de isoladores, promovendo ganhos práticos para a segurança e manutenção das redes elétricas, e contribuindo para a evolução do estado da arte em processamento de imagem e aprendizado de máquina.

1.5 CRONOGRAMA

A seguir, apresenta-se a estrutura das etapas e subetapas que compõem o desenvolvimento deste trabalho. A lista a seguir organiza os principais tópicos a serem abordados ao longo da pesquisa, detalhando desde a introdução até a conclusão, incluindo as metodologias, a revisão bibliográfica, a implementação dos modelos e a análise dos resultados.

- **1. Introdução**

- Justificativa com apresentação do problema e relevância
- Objetivos gerais e específicos
- Metodologia geral adotada
- Estrutura da dissertação

- **2. Revisão Bibliográfica**

- Processamento de imagens
- Redes neurais para avaliação de processamentos de imagem
- Métricas para análise de desempenho (acurácia, tempo, etc.)
- Influência de datasets na performance dos modelos
- Métodos de ajuste de parâmetros e combinação de processamentos

- **3. Metodologia**

- Definição das métricas para avaliar eficácia dos processamentos
- Escolha do tipo de modelo de rede neural (classificação, detecção, regressão, etc.)

- Seleção dos datasets para avaliação
- Metodologia para combinação de processamentos unitários
- Implementação de um método de ajuste automático de parâmetros

• **4. Implementação dos Modelos**

- Construção de redes neurais para avaliação dos processamentos
- Testes com diferentes arquiteturas e análise de variações nos resultados

• **5. Coleta e Análise de Resultados**

- Impacto dos modelos no desempenho dos processamentos
- Influência dos datasets nos resultados
- Comparação entre diferentes estratégias de processamento

• **6. Conclusão**

- Síntese dos resultados obtidos
- Limitações e desafios encontrados
- Sugestões para pesquisas futuras

A seguir, é apresentado um cronograma de atividades para garantir a organização e a execução das tarefas.

Etapa	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
1. Introdução	✓										
2. Revisão Bibliográfica	✓	✓	✓	✓	✓						
3. Metodologia		✓	✓	✓	✓	✓	✓				
4. Implementação dos Modelos						✓	✓				
5. Coleta e Análise de Resultados						✓	✓	✓	✓		
6. Conclusão e Redação Final								✓	✓	✓	
7. Defender											✓

Tabela 1 – Cronograma de Atividades

2 TRABALHOS RELACIONADOS

2.1 ESTUDO 1: ANÁLISE SUSTENTÁVEL DA DETECÇÃO DE FALHAS EM ISOLADORES BASEADA EM OTIMIZAÇÃO VISUAL REFINADA

- **Resumo e Introdução:** Este estudo, publicado em *Sustainability* em 2023, aborda o papel crítico dos isoladores em linhas de transmissão aéreas, que são suscetíveis a fatores ambientais como clima e temperatura, levando a falhas que ameaçam a segurança da transmissão de energia. A inspeção manual tradicional é pouco confiável devido ao grande volume de dados e fundos complexos, o que levou ao uso de uma rede neural convolucional de atenção regressiva (RA-CNN) para otimização. O artigo visa melhorar a acurácia da detecção de falhas por meio da extração de características em múltiplas escalas e operações recursivas.
- **Metodologia:** O processo experimental envolve uma rede em cascata de três níveis de convolução, cada nível incluindo classificação e amostragem regional, com imagens pré-processadas para 224×224 pixels. O módulo de classificação utiliza redes neurais totalmente convolucionais com fatores de expansão em núcleos de convolução para capturar campos de informação maiores e um novo método de amostragem ascendente para reduzir parâmetros. O algoritmo de Otimização por Enxame de Partículas (PSO) otimiza o processo, com equações específicas para o movimento das partículas, e etiquetas VGG-PSO são usadas para a classificação final via *softmax*. A Tabela ilustra o processo comparando as acurácias.
- **Resultados:** A extração de regiões em múltiplos níveis abrange a estrutura do objeto e a geografia local, com os segundo e terceiro níveis alcançando 81,5% e 80,8% de acurácia, respectivamente. A configuração RA-CNN (1+2+3) atinge 85,3%, melhorando 12,2% em relação ao FCAN (74,9%) e 11,4% em relação ao MG-CNN (75,6%). Experimentos de ablação mostram FCAN com 48,3% de mAP e 5,3 FPS, MG-CNN com 51,2% de mAP e 4,6 FPS, enquanto RA-CNN (1+2+3) alcança 58,6% de mAP e 25,4 FPS, indicando capacidade em tempo real. As Tabelas 2 e 3 detalham essas comparações, e as Figuras 7-9 visualizam os resultados.
- **Relevância para a Dissertação:** O estudo aborda a comparação de modelos de redes neurais (RA-CNN vs. FCAN e MG-CNN), avalia a influência do conjunto de dados por meio da extração em múltiplos níveis e propõe uma metodologia de otimização (PSO), alinhando-se aos seus objetivos de estabelecer métricas, analisar o impacto do modelo e desenvolver métodos de ajuste de parâmetros. O foco em

acurácia e velocidade de processamento também apoia seu objetivo de considerar o tempo de processamento.

Tabela 2 – Comparação de métricas do Estudo 1

Métrica	RA-CNN (1+2+3)	FCAN	MG-CNN
Acurácia (%)	85,3	74,9	75,6
mAP (%)	58,6	48,3	51,2
FPS	25,4	5,3	4,6

Referência: WANG, L.; WAN, H.; HUANG, D.; LIU, J.; TANG, X.; GAN, L. Análise Sustentável da Detecção de Falhas em Isoladores Baseada em Otimização Visual Refinada. *Sustainability*, v. 15, n. 4, p. 3456, 2023. DOI: 10.3390/su15043456.

2.2 ESTUDO 2: DETECÇÃO DE FALHAS EM ISOLADORES EM IMAGENS AÉREAS DE LINHAS DE TRANSMISSÃO DE ALTA VOLTAGEM BASEADA EM MODELO DE APRENDIZADO PROFUNDO

- **Resumo e Introdução:** Publicado em *Appl. Sci.* em 2021, este estudo foca na detecção de falhas em isoladores em imagens aéreas, crucial para a inspeção de linhas de transmissão de alta voltagem. Dado a complexidade dos fundos, os autores propõem um modelo YOLO modificado, CSPD-YOLO, baseado no YOLO-v3 e na Rede Parcial de Estágio Cruzado, para aprimorar a reutilização e propagação de características. Um novo conjunto de dados, 'InSF-detection', foi criado com 1.331 imagens e 2.104 falhas para treinar e testar o modelo.
- **Metodologia:** A metodologia inclui o processamento de dados, criando o conjunto de dados 'InSF-detection' com 809 imagens de treinamento e 522 de teste, rotuladas usando Label-Image e redimensionadas para 416×416 pixels, disponível em GitHub. O modelo CSPD-YOLO usa blocos Cross Stage Partial Dense (CSPD) com Darknet-53 para extração de características, uma rede de pirâmide de características para detecção em múltiplas escalas (camadas de características grande $256 \times 52 \times 52$, média $512 \times 26 \times 26$, pequena $1024 \times 13 \times 13$) e uma função de perda aprimorada usando Interseção Completa sobre União (IoU). Caixas de ancoragem foram agrupadas usando k-means++, alcançando uma IoU média de 89,13%.
- **Resultados:** Os experimentos foram realizados em um PC com Windows 10, CPU Intel i9-9900K, 32 GB de RAM, GPU NVIDIA GeForce GTX 3080, usando CUDA 11.1 e cuDNN 8.0.5. O CSPD-YOLO alcançou uma precisão média (AP) de 98,18%,

precisão (P) de 99%, *recall* (R) de 98%, F1-score de 99% e tempo de processamento de 0,011 segundos, superando o YOLO-v3 (AP 93,31%, tempo 0,01 s), um modelo da literatura (AP 95,07%, tempo 0,011 s) e o YOLO-v4 (AP 96,38%, tempo 0,01 s). A análise qualitativa mostrou eficácia em cenas diversas (rios, vegetação, torres de energia, oclusão).

- **Relevância para a Dissertação:** Este estudo é relevante, pois compara diferentes modelos de redes neurais (CSPD-YOLO vs. YOLO-v3, YOLO-v4), avalia a influência do conjunto de dados por meio da criação do 'InSF-detection' e propõe uma metodologia para melhorar a acurácia da detecção, alinhando-se aos seus objetivos de determinar modelos ideais, analisar seu impacto e desenvolver abordagens combinadas. O foco no tempo de processamento também apoia sua métrica de tempo de processamento.

Tabela 3 – Comparação de métricas do Estudo 2

Modelo	AP (%)	Precisão (%)	Recall (%)	F1-Score (%)	Tempo (s)
CSPD-YOLO	98,18	99	98	99	0,011
YOLO-v3	93,31	94	94	94	0,010
YOLO-v4	96,38	98	95	97	0,010

Referência: LIU, C.; WU, Y.; LIU, J.; SUN, Z.; XU, H. Detecção de Falhas em Isoladores em Imagens Aéreas de Linhas de Transmissão de Alta Voltagem Baseada em Modelo de Aprendizado Profundo. *Appl. Sci.*, v. 11, n. 10, p. 4647, 2021. DOI: 10.3390/app11104647.

2.3 ESTUDO 3: DETECÇÃO DE DEFEITOS EM ISOLADORES POR IMAGEM BASEADA EM PROCESSAMENTO MORFOLÓGICO E APRENDIZADO PROFUNDO

- **Resumo e Introdução:** Publicado em *Energies* em 2022, este estudo aborda a detecção de defeitos em isoladores, enfatizando a ameaça de falhas às operações das linhas de transmissão. Propõe um método combinando aprendizado profundo (Faster RCNN) e processamento morfológico, visando localizar isoladores, segmentar imagens para remover fundos e detectar defeitos usando um modelo matemático em imagens binárias. O estudo compara o desempenho com algoritmos comuns, destacando melhorias na acurácia.
- **Metodologia:** A metodologia usa Faster RCNN com Rede de Proposta de Região (RPN) para geração mais rápida de regiões candidatas, empregando ResNet-152

(50 blocos residuais, entrada $7 \times 7 \times 64$, saída camada FC) para extração de características. A segmentação de imagens envolve agrupamento de pixels com pesos $\omega_1 = 0,5$, $\omega_2 = 0,7$, $\omega_3 = 1,5$, determinados a partir de 50 imagens de isoladores de vidro. A transformação de forma inclui detecção de ângulo de inclinação, rotação e separação de isoladores lado a lado usando ajuste por mínimos quadrados. A detecção de defeitos usa janelas deslizantes, com o lado longo igual ao lado curto da imagem-alvo, lado curto igual à largura da tampa do isolador, passo 1/3 do lado curto, marcando janelas $< 40\%$ como defeitos e $> 80\%$ para contar tampas.

- **Resultados:** O Faster RCNN alcança $AP = 0,9175$ e $Recall = 0,98$, superando Res101 ($AP\ 0,9119$), Res50 ($AP\ 0,9088$), VGG16 ($AP\ 0,9113$), YOLOv3 ($AP\ 0,9119$) e LBP+SVM ($AP\ 0,8012$). A acurácia na detecção de defeitos é 0,98, com resultados específicos por níveis de voltagem: 35kV (100%), 110kV (98% para 1-7, 1-8; 94% para 2-8), 220kV (98% para 1-13, 96% para 1-15, 92% para 2-16). Testes de ruído mostram isoladores curtos (35kV, 110kV) com 0,98 de acurácia sem ruído, $v = 0,005$, $v = 0,01$, e isoladores longos (220kV, 550kV) com 0,94 (sem ruído, $v = 0,005$) e 0,90 ($v = 0,01$). Comparado a outros métodos, alcança 0,98 de acurácia vs. 0,91, 0,96 e 0,83.
- **Relevância para a Dissertação:** Este estudo é relevante, pois combina processamento de imagem (morfológico) com aprendizado profundo (Faster RCNN), comparando modelos e mostrando a influência do conjunto de dados por meio de testes de voltagem e ruído, alinhando-se aos seus objetivos de estabelecer métricas (acurácia, *recall*), determinar modelos ideais e desenvolver metodologias combinadas. Também apoia seu objetivo de analisar o impacto do conjunto de dados por meio de condições variadas.

Tabela 4 – Comparação de métricas do Estudo 3

Modelo	AP	Recall	Acurácia (Detecção de Defeitos)
Método Proposto	0,9175	0,98	0,98
Res101	0,9119	-	-
YOLOv3	0,9119	-	-
LBP+SVM	0,8012	-	-

Referência: ZHANG, Z.; HUANG, S.; LI, Y.; LI, H.; HAO, H. Detecção de Defeitos em Isoladores por Imagem Baseada em Processamento Morfológico e Aprendizado Profundo. *Energies*, v. 15, n. 7, p. 2465, 2022. DOI: 10.3390/en15072465.

2.4 DISCUSSÃO E IMPLICAÇÕES

Esses estudos abordam coletivamente os objetivos da dissertação ao fornecer técnicas de processamento de imagem, avaliação de modelos de redes neurais (RA-CNN, CSPD-YOLO, Faster RCNN) e análise de influência do conjunto de dados. As altas acurácias (até 98,18%) e comparações detalhadas sugerem que metodologia pode aproveitar essas abordagens para estabelecer métricas como acurácia e tempo de processamento, determinar modelos ideais por meio de análise de desempenho e desenvolver ajustes automáticos de parâmetros, como visto nas otimizações PSO e CloU. A criação de conjuntos de dados como 'InSF-detection' também destaca a necessidade de avaliação do conjunto de dados, um aspecto-chave do trabalho.

3 REVISÃO BIBLIOGRÁFICA

3.1 PROCESSAMENTO DE IMAGENS

Nesta seção, serão abordados os conceitos fundamentais de processamento de imagens, incluindo técnicas e algoritmos utilizados para a análise e manipulação de imagens digitais. Também será discutida a importância do processamento de imagens no SEP para a detecção e classificação de falhas em equipamentos de linhas de transmissão de energia elétrica.

3.2 DATASETS

Será discutida a influência dos datasets na performance dos modelos de processamento de imagem, considerando a importância da escolha de conjuntos de dados representativos e diversificados para o treinamento e avaliação dos modelos.

3.3 REDES NEURAIS

Aqui, serão discutidos os diferentes tipos de redes neurais aplicáveis ao processamento de imagens, com foco em suas arquiteturas e aplicações específicas para avaliação de desempenho.

3.3.1 Métricas

Serão apresentadas as principais métricas utilizadas para avaliar a eficácia dos processamentos de imagem, como acurácia, tempo de processamento, precisão, recall, entre outras.

3.4 INFLUÊNCIA DE DATASETS NA PERFORMANCE DOS MODELOS

Esta seção tratará da importância dos datasets na performance dos modelos de processamento de imagem, incluindo a análise de diferentes conjuntos de dados e suas

características.

3.5 MÉTODOS DE AJUSTE DE PARÂMETROS E COMBINAÇÃO DE PROCESSAMENTOS

Serão explorados os métodos para ajuste automático de parâmetros e a combinação de diferentes técnicas de processamento de imagem para otimização dos resultados.

4 METODOLOGIA

4.1 DEFINIÇÃO DAS MÉTRICAS PARA AVALIAR EFICÁCIA DOS PROCESSAMENTOS

O fluxograma apresentado na Figura 2 descreve o processo de desenvolvimento de uma metodologia para o processamento de imagens. Inicialmente, define-se e desenvolve-se os processamentos necessários, ajustando seus parâmetros e combinando-os para otimizar os resultados. Com isso, são avaliadas as métricas de desempenho para verificar a eficácia das abordagens adotadas. Se os resultados forem satisfatórios, os melhores processamentos são selecionados e o processo é finalizado. Caso contrário, analisa-se o número de tentativas realizadas: se muitas tentativas falhas ocorreram, o processamento é descartado e novas abordagens são consideradas. Se o número de tentativas ainda for baixo, o processo retorna à etapa de ajuste de parâmetros, permitindo novas tentativas até atingir os resultados desejados.




Figura 2 – Fluxograma da metodologia de processamento de imagens

4.2 ESCOLHA DO TIPO DE MODELO DE REDE NEURAL

Será discutida a escolha do tipo de modelo de rede neural mais adequado para as tarefas de classificação, detecção e regressão no contexto do estudo.

4.3 SELEÇÃO DOS DATASETS PARA AVALIAÇÃO

Serão apresentados os critérios e a seleção dos datasets que serão utilizados para a avaliação dos processamentos de imagem.

4.4 METODOLOGIA PARA COMBINAÇÃO DE PROCESSAMENTOS UNITÁRIOS

Aqui, será detalhada a metodologia desenvolvida para combinar diferentes processamentos unitários de imagem visando a melhoria dos resultados.

4.5 IMPLEMENTAÇÃO DE UM MÉTODO DE AJUSTE AUTOMÁTICO DE PARÂMETROS

Será descrito o método implementado para ajuste automático de parâmetros das técnicas de processamento de imagem, com o objetivo de otimização sem intervenção manual extensa.

4.6 CONSTRUÇÃO DE REDES NEURAIS PARA AVALIAÇÃO DOS PROCESSAMENTOS

Nesta seção, será detalhada a construção dos modelos de redes neurais utilizados para avaliar os processamentos de imagem.

4.7 TESTES COM DIFERENTES ARQUITETURAS E ANÁLISE DE VARIAÇÕES NOS RESULTADOS

Serão apresentados os testes realizados com diferentes arquiteturas de redes neurais e a análise das variações nos resultados obtidos.

5 COLETA E ANÁLISE DE RESULTADOS

5.1 IMPACTO DOS MODELOS NO DESEMPENHO DOS PROCESSAMENTOS

Será analisado o impacto dos diferentes modelos de redes neurais no desempenho dos processamentos de imagem.

5.2 INFLUÊNCIA DOS DATASETS NOS RESULTADOS

Aqui, será discutida a influência dos diferentes datasets nos resultados dos processamentos de imagem.

5.3 COMPARAÇÃO ENTRE DIFERENTES ESTRATÉGIAS DE PROCESSAMENTO

Serão comparadas as diferentes estratégias de processamento de imagem utilizadas no estudo, destacando as vantagens e desvantagens de cada uma.

6 CONCLUSÃO

6.1 SÍNTESE DOS RESULTADOS OBTIDOS

Nesta seção, será feita uma síntese dos principais resultados obtidos ao longo do estudo.

6.2 LIMITAÇÕES E DESAFIOS ENCONTRADOS

Serão discutidas as limitações e os desafios encontrados durante a realização do trabalho.

6.3 SUGESTÕES PARA PESQUISAS FUTURAS

Por fim, serão apresentadas sugestões para pesquisas futuras, com base nos resultados e nas limitações identificadas no estudo.

REFERÊNCIAS

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 3. ed. [S.l.]: Prentice Hall, 2008.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2012.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.

LI, X. et al. Fusion of image processing techniques for fault detection in electrical insulators. **IEEE Transactions on Power Delivery**, v. 34, n. 3, p. 1234–1241, 2019.