

MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES

1st Luan Willig Silveira

Engenharia Elétrica

Universidade Federal de Santa Maria

Cachoeira do Sul, Brasil

luan.w.silveira@gmail.com

2nd Paulo César Vargas Luz

Engenharia Elétrica

Universidade Federal de Santa Maria

Cachoeira do Sul, Brasil

paulo.c.luz@ufsm.br

3rd Daniel Pinheiro Bernardon

Engenharia Elétrica

Universidade Federal de Santa Maria

Santa Maria, Brasil

dpbernardon@ufsm.br

4th Dion Lenon Prediger Feil

Engenharia Elétrica

Universidade Federal de Santa Maria

Cachoeira do Sul, Brasil

dion.feil@ufsm.br

5th Laura Lisiane Callai dos Santos

Engenharia Elétrica

Universidade Federal de Santa Maria

Cachoeira do Sul, Brasil

laura.santos@ufsm.br

6th Nelson Knak Neto

Engenharia Elétrica

Universidade Federal de Santa Maria

Cachoeira do Sul, Brasil

nelson.knak@ufsm.br

Resumo—A crescente demanda por sistemas automatizados de inspeção de linhas de transmissão de energia elétrica utilizando visão computacional impulsiona o uso de inteligência artificial. No entanto, não há uma metodologia padronizada para definir estratégias de processamento e seus ajustes paramétricos que permita uma comparação real de desempenho. Este trabalho propõe uma metodologia sistemática para comparar, selecionar e aprimorar técnicas de processamento de imagens, visando otimizar o desempenho preditivo de Redes Neurais Convolucionais (CNNs) na detecção de falhas. Utilizando os *datasets* CPLID e DRNPW, constatou-se que o efeito do pré-processamento diferiu entre os dois cenários de captura. Em imagens de fundo mais controlado (CPLID), o ganho simples de contraste (*Contrast Enhancement*) alcançou 95,35% de acurácia, contra 93,02% da imagem sem tratamento, diferença de um acerto em 43 imagens de teste, ao passo que o desfoque gaussiano derrubou o desempenho para 67,44%. Já em imagens obtidas por drones sobre fundos poluídos (DRNPW), combinar realce de contraste e equalização de histograma elevou a acurácia de 63,33% para 83,33%, seis acertos em 30 imagens. A otimização paramétrica localizou o melhor fator de ajuste de contraste em torno de 1,33 na busca em grade e de 1,44 na busca aleatória, ainda que a relação entre o fator e o desempenho não se mostre monotônica. O efeito de uma mesma técnica isolada variou entre os conjuntos, como o realce de contraste, que ficou entre os melhores resultados no CPLID e no nível da imagem sem tratamento no DRNPW, embora a combinação de realce de contraste e equalização de histograma tenha obtido a maior acurácia nos dois conjuntos. A metodologia proposta oferece um caminho sistemático para selecionar e aprimorar essas estratégias na detecção automatizada de falhas em cadeias de isoladores.

Palavras-chave—processamento de imagens, redes neurais convolucionais, cadeias de isoladores, detecção de falhas, inteligência artificial

I. INTRODUÇÃO

A crescente demanda por sistemas automatizados de inspeção de cadeias de isoladores evidencia a necessidade de técnicas avançadas de processamento de imagem para a detecção precoce de falhas. A análise digital de imagens

fornece o instrumental para extrair características relevantes de uma cena [1], instrumental que vem sendo aplicado à identificação de anomalias em componentes de linhas de transmissão de energia [2].

Ademais, o emprego de redes neurais, mais especificamente de Redes Neurais Convolucionais (CNNs), tem se destacado na resolução de problemas complexos de classificação e detecção [3], [4] e vem sendo proposto como base da análise de dados na inspeção de linhas de transmissão [2]. Contudo, a eficácia preditiva desses modelos de inteligência artificial depende intrinsecamente da qualidade das imagens de entrada. Em patologia digital, uma revisão dedicada ao tema reúne estudos em que a escolha das etapas de pré-processamento altera de forma mensurável o desempenho final dos modelos [5]. Os métodos sistemáticos de busca consolidados na otimização de hiperparâmetros de modelos, como a busca em grade e a busca aleatória [6], são aqui transpostos para os parâmetros que controlam essas etapas de pré-processamento.

Assim, o presente estudo tem como objetivo desenvolver uma metodologia escalável capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores elétricos. Para isso, são estabelecidas métricas quantitativas de acurácia e *F1-score*, bem como avaliadas estratégias unificadas e compostas de tratamentos de imagem aplicadas em dois conjuntos de dados distintos da área (CPLID e DRNPW).

II. FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

A utilização de ferramentas de inteligência artificial para diagnósticos em equipamentos tem se destacado como uma solução promissora no contexto da manutenção preventiva, especialmente diante das limitações da inspeção manual de linhas de transmissão, que é lenta, custosa e exposta a riscos

[2]. A detecção precoce de falhas em componentes como cadeias de isoladores, transformadores e suportes de linhas de transmissão é fundamental para evitar interrupções de longo prazo [2] e reduzir custos associados à intervenção humana direta [8].

A. Processamento de Imagens e Redes Neurais

O processamento de imagens tem papel fundamental na preparação dos dados visuais antes de sua entrada em redes profundas. Imagens de Veículos Aéreos Não Tripulados (VANTs) ou de câmeras de inspeção apresentam fundos complexos, com vegetação, cursos d'água e estruturas adjacentes [9], além de nevoeiro e outras condições adversas [7], cenário em que a exigência de acurácia ainda limita a adoção da inspeção automatizada [2].

Entre as técnicas fundamentais destacam-se o casamento de histogramas, que ajusta a distribuição de intensidades dos *pixels*, e a equalização adaptativa de contraste, que realça o contraste local [10]. O efeito dessas transformações sobre o classificador é mensurável, e a equalização de histograma aparece entre as mais eficazes em avaliações controladas sobre micrografias de materiais [11]. O redimensionamento padronizado adequa as imagens à entrada da rede, e o aumento de dados (*Data Augmentation*) compensa a escassez de falhas catalogadas, gerando variações sintéticas que melhoram a robustez do classificador [12].

O ajuste de contraste admite formulações locais e globais. A *Contrast Limited Adaptive Histogram Equalization* (CLAHE) calcula a equalização em regiões contextuais locais e evita a amplificação excessiva de ruído ao limitar a altura do histograma de cada região [13], ao passo que a equalização global aplica um único mapeamento de intensidades à imagem inteira [1]. Contudo, intervenções muito agressivas podem eliminar texturas importantes, como as que caracterizam pequenas fraturas ou contaminações na superfície do equipamento, efeito observado em imagens histopatológicas quando se acrescenta limiarização adaptativa e filtragem de mediana ao realce [14].

Esse cuidado reflete-se no desempenho das Redes Neurais Convolucionais (CNNs). Diferentemente das redes *feed-forward* com conectividade total entre camadas adjacentes, as CNNs preservam a estrutura espacial da imagem por convoluções com *kernels* locais, reduzem a dimensionalidade via *Max-Pooling* e extraem representações em níveis crescentes de abstração, das bordas aos motivos e às partes do objeto [3], conforme ilustrado na Fig. 1. Sua capacidade de identificar anomalias depende, contudo, da representatividade dos dados de entrada.




Fig. 1. Representação estrutural típica de uma Rede Neural Convolucional na extração de características visuais.

B. Trabalhos Correlatos e Lacunas da Literatura

Os trabalhos que avaliam o efeito do pré-processamento sobre modelos convolucionais não convergem para uma conclusão única. Uma revisão de patologia digital registra que a integração de etapas de pré-processamento ao fluxo de aprendizado profundo costuma elevar o desempenho em relação à rede isolada [5]. Um estudo comparativo controlado em imagens de imunofluorescência, porém, encontra o resultado oposto no conjunto analisado, em que a maioria das CNNs treinadas do zero apresenta desempenho superior sobre as imagens sem tratamento [15]. Cabe registrar que essa divergência está documentada em imagens biomédicas, e que não se localizou no domínio da inspeção elétrica avaliação equivalente do efeito isolado do pré-processamento, lacuna que motiva o presente trabalho.

Por um lado, há estudos que relatam acurácia elevada com fluxos que incluem pré-processamento elaborado. Por exemplo, uma abordagem que encadeia a localização do isolador por Faster RCNN, a remoção do fundo por segmentação e a descrição morfológica do defeito sobre a imagem binarizada relatou *recall* de 0,98 na localização dos isoladores e acurácia de 0,98 na identificação do defeito [16], ainda que sobre recortes cujo fundo os próprios autores descrevem como relativamente simples. Em outra linha, arquiteturas baseadas no *framework* YOLO (YOLOv7) mostraram-se eficientes para detectar pequenos defeitos na isolação, mas o ganho relatado decorre de modificações no próprio detector, como a inclusão de módulos de atenção, o agrupamento das caixas âncora por K-means++ e a troca da função de perda e da supressão de não máximos, e não do tratamento prévio da imagem [17].

Em contrapartida, há pesquisas que questionam a intervenção excessiva sobre a imagem. Ao comparar seis estratégias de pré-processamento e cinco arquiteturas convolucionais na classificação de células HEP-2 em imagens de imunofluorescência, cujo comparativo é ilustrado na Fig. 2, o melhor resultado, 98,28% de acurácia, foi obtido com a rede Inception-V3 treinada do zero sobre imagens sem pré-processamento e com aumento de dados [15].




Fig. 2. Estratégias de pré-processamento comparadas na classificação de células HEp-2 em imagens de imunofluorescência, combinando alongamento de contraste, equalização de histograma e subtração da imagem média [15].

Há indícios de um limite superior para o tratamento. Em imagens histopatológicas, a comparação entre níveis crescentes de realce mostra que o grupo de sobre-processamento fica abaixo do nível intermediário, ainda que permaneça marginalmente acima da imagem original, o que sugere um ponto de saturação a partir do qual o acúmulo de transformações deixa de compensar [14]. No domínio da inspeção elétrica, parte dos trabalhos concentra o esforço na arquitetura do detector em vez do tratamento prévio da imagem, como no modelo CSPD-YOLO, aplicado diretamente a imagens aéreas de fundo complexo [9], e na rede convolucional com atenção por regressão RA-CNN, que aplica a atenção multiescala de forma recursiva e é proposta para a detecção de falhas em isoladores sob condições atmosféricas adversas, como nevoeiro [7].

Essa divergência expõe uma lacuna: falta um método para determinar o limite adequado de realce em cada tipo de imagem, e os trabalhos raramente exploram de forma quantitativa o efeito isolado do fator de correção, adotando configurações fixas. O presente trabalho avalia sistematicamente esse parâmetro por meio de *Grid Search* sobre o ganho de contraste.

III. METODOLOGIA

A metodologia proposta segue um fluxo estruturado para otimizar o processamento aplicado às imagens de entrada de uma CNN. O processo geral, detalhado na Fig. 3, envolve, de forma iterativa, a seleção de *datasets*, o pré-processamento da imagem, o ajuste paramétrico e a avaliação por meio do treinamento dos modelos.




Fig. 3. Fluxograma geral da metodologia proposta, detalhando o processo iterativo de tratamento e avaliação.

A qualidade, a quantidade e a diversidade dos dados exercem um impacto direto no treinamento das redes profundas [12]. Por esta razão, empregaram-se dois importantes conjuntos de dados de imagens no estudo:

- 1) **CPLID (Chinese Power Line Insulator Dataset) [19]:** Base pública de imagens aéreas de cadeias de isoladores, em que o defeito catalogado é a ausência de campânula (*missing cap*). As amostras defeituosas são em parte sintéticas, obtidas por segmentação do isolador e fusão com novos fundos. Os autores da base relatam fundos variados, com torres, montanhas, rios, pastagens e áreas agrícolas, e ilustram quatro tipos, floresta, rio, terreno e torre. Nas imagens empregadas aqui, o isolador aparece em primeiro plano e a poluição visual é menor do que no segundo conjunto, e é apenas nesse sentido comparativo que o CPLID é tratado neste trabalho como o cenário de fundo mais controlado.
- 2) **DRNPW (Dataset for Recognition of Non-ceramic Pollution on Windings):** Conjunto disponibilizado pela CPFL, composto por recortes de imagens captadas por drones em inspeções operacionais reais. As amostras possuem fundos ruidosos, com forte presença de componentes adjacentes e vegetação.

Cada conjunto foi particionado uma única vez em treinamento, validação e teste, por sorteio aleatório sem estratificação por classe, e a mesma partição foi reutilizada em todas as variantes de pré-processamento, de modo que o tratamento aplicado à imagem fosse a variável de interesse entre os experimentos. A divisão obedeceu à proporção aproximada de 80% para treino, 15% para validação e 5% para teste em ambos os conjuntos. O CPLID divide-se em 678 imagens de treino, 127 de validação e 43 de teste, em 2 classes. O DRNPW divide-se em 468, 87 e 30 imagens, em 70 categorias declaradas, das quais apenas 59 aparecem no treino, com 335 das 468 imagens de treino em uma única categoria, o que caracteriza um desbalanceamento acentuado, condição que penaliza a sensibilidade do classificador às classes minoritárias [18]. Na avaliação dos pré-processamentos, o conjunto de validação serviu apenas ao acompanhamento da convergência a cada época, sem parada antecipada e sem seleção de modelo, e as métricas relatadas referem-se ao conjunto de teste.

Para validar os processamentos, adotou-se a mesma arquitetura de CNN em todas as avaliações, implementada em TensorFlow/Keras. A rede recebe tensores de 512×512 pixels nos dois conjuntos na avaliação dos pré-processamentos e de 640×640 pixels nas buscas paramétricas sobre o DRNPW, com três canais (RGB) na imagem original, no *Contrast Enhancement* isolado e nos três filtros de supressão de ruído, e com um único canal de intensidade nas demais variantes, que convertem a imagem para tons de cinza. A arquitetura é composta por duas camadas convolucionais com 32 filtros de 3×3 e ativação ReLU, cada uma seguida de *Max-Pooling* com janela de 4×4 , uma camada de achatamento (*Flatten*), uma camada densa com 8 unidades e ativação ReLU e uma camada de saída com ativação *Softmax*, dimensionada conforme o número de rótulos do conjunto. O treinamento usou o otimizador Adam com os hiperparâmetros padrão do Keras, a função de perda de entropia cruzada categórica esparsa e 50 épocas integrais, sem camadas de dropout e sem parada antecipada, com aumento de dados em tempo de treino por rotações de até 360° , translações de até 10% nos dois eixos e espelhamentos horizontal e vertical. Cada configuração de pré-processamento corresponde a um único treinamento, com semente não fixada, de modo que diferenças de um ou dois acertos não se distinguem da variabilidade entre execuções. A rede é deliberadamente simples, e a arquitetura e o protocolo de treino são mantidos fixos dentro de cada etapa experimental, para que o pré-processamento seja a única variável alterada de forma deliberada entre os experimentos comparados.

Na etapa de **Pré-processamento**, os filtros descritos na Seção IV-A foram testados de forma isolada e combinada. A técnica de *Contrast Enhancement* recebe destaque por ajustar o contraste global dos canais RGB por meio de um fator configurável.

Por fim, realizou-se uma etapa de **Ajuste Paramétrico** sobre o hiperparâmetro da técnica *Contrast Enhancement* aplicada isoladamente (variável *factor*), com busca em grade (*Grid Search*) e busca aleatória (*Random Search*) [6].

IV. RESULTADOS E DISCUSSÕES

A. Delineamento dos Experimentos

Os experimentos submeteram a rede descrita na Seção III a 14 grupos distintos de pré-processamento nas bases CPLID e DRNPW. O grupo de controle usou as imagens originais (*Original Image*). Foram testados a limiarização (*Adaptive Threshold*), a detecção de contornos (*Edge Detection*), a conversão para tons de cinza (*Gray Scale*) e a supressão de ruído (*Gaussian Blur*, *Median Blur* e *Fast NL-Means Denoise*). O foco principal esteve nas abordagens de iluminação, com equalizações de histograma adaptativas (CLAHE) e globais (*Equalize Histogram*) e métodos de ganho direto (*Contrast Enhancement*), aplicados isoladamente e em combinações híbridas, para avaliar o limite do processamento sequencial.

Como os dois conjuntos de teste são desbalanceados, adota-se o piso majoritário como referência, definido como a acurácia de responder sempre a classe mais frequente, sem observar a imagem. Ele é de 74,42% no CPLID, onde 32 das 43 imagens de teste são *Normal Insulators*, e de 73,33% no DRNPW, onde 22 das 30 pertencem a uma única categoria. Abaixo desses valores, o modelo não extraiu informação útil. Cada acerto equivale a 2,33 pontos percentuais no CPLID e a 3,33 no DRNPW. Conjuntos desse tamanho impõem incerteza amostral elevada. Para a acurácia de 93,02% sobre 43 imagens, o intervalo de confiança binomial de Wilson a 95% vai de 81,4% a 97,6%, e para a acurácia de 83,33% sobre 30 imagens vai de 66,4% a 92,7%, faixa que ainda contém o piso majoritário. As comparações a seguir devem ser lidas sob essa margem. Nesse enquadramento, a eficácia de cada técnica diferiu entre os dois conjuntos.

B. Avaliação no Dataset CPLID

Nesse conjunto, as técnicas baseadas no realce direto da iluminação apresentaram os melhores resultados. O uso isolado do filtro *Contrast Enhancement* alcançou 95,35% de acurácia, igualada por duas combinações híbridas, CLAHE seguido de *Contrast Enhancement* e *Contrast Enhancement* seguido de *Equalize Histogram*. O *F1-score* não é usado nesta comparação porque parte das execuções no CPLID, entre elas a da imagem original e a do *Contrast Enhancement* isolado, calculou a métrica com média binária, e as demais com média ponderada pelo suporte de cada classe.

Cabe uma ressalva sobre a magnitude desse ganho. A amostra de controle, sem tratamento, já alcança 93,02%: a diferença para o melhor pré-processamento é de 41 acertos contra 40, em 43 imagens. Uma única imagem separa as duas condições, dentro da flutuação esperada para um conjunto desse tamanho, o que não sustenta a superioridade do realce de contraste sobre a imagem original neste cenário.

O efeito no sentido oposto, esse sim, aparece com clareza. O *Gaussian Blur*, assim como o *Adaptive Threshold* e o *Fast NL-Means Denoise*, levou o desempenho a 67,44%, 25,58 pontos abaixo da imagem original e abaixo do próprio piso majoritário. Neste conjunto, portanto, o pré-processamento teve margem estreita para ajudar e ampla para prejudicar,

e a utilidade prática da metodologia está em descartar as transformações destrutivas antes do treinamento. O desempenho das 14 variações testadas é apresentado na Fig. 4.




Fig. 4. Acurácia das estratégias de pré-processamento no dataset CPLID. A barra destacada é a imagem sem tratamento e a linha tracejada marca o piso majoritário. CE abrevia *Contrast Enhancement*.

C. Avaliação no Dataset DRNPW

No conjunto de imagens obtidas por drones (DRNPW), cujos fundos têm forte presença de vegetação e estruturas metálicas, as técnicas simples que funcionaram bem no CPLID tiveram desempenho inferior, e o *Contrast Enhancement* isolado não superou a imagem sem tratamento. O melhor resultado veio de uma abordagem híbrida: *Contrast Enhancement* seguido de *Equalize Histogram*, a mesma combinação que empatou na maior acurácia do CPLID. Essa combinação alcançou 83,33% de acurácia e 75,76% de *F1-score*.

A conversão para tons de cinza (*Gray Scale*) compartilha o menor valor observado, 63,33% de acurácia e 49,12% de *F1-score*, com a imagem sem tratamento e com o *Contrast Enhancement* isolado. Como o resultado é idêntico ao da imagem original, a supressão da cor não alterou o desempenho neste conjunto, comportamento compatível com o relatado em micrografias, em que a conversão para tons de cinza não degradou a acurácia [11].

O contraste com o CPLID é o resultado mais relevante desta comparação. Aqui a imagem sem tratamento fica em 63,33%, abaixo do piso majoritário, e a melhor combinação chega a 83,33%, ganho de seis acertos em 30 imagens sobre a amostra de controle e de três acertos sobre o piso. É neste cenário, de fundo heterogêneo e forte poluição visual, que o pré-processamento produz o maior efeito observado, ainda que a margem sobre o piso permaneça estreita. A acurácia de todos os métodos aplicados nessa base é apresentada na Fig. 5.




Fig. 5. Acurácia das estratégias de pré-processamento no dataset DRNPW. A barra destacada é a imagem sem tratamento e a linha tracejada marca o piso majoritário. CE abrevia *Contrast Enhancement*.

D. Otimização Paramétrica

Com base nos resultados do realce de contraste no CPLID e de sua combinação com a equalização de histograma no DRNPW, adotaram-se duas abordagens de otimização do hiperparâmetro de amplificação (*factor*), a Busca em Grade (*Grid Search*) e a Busca Aleatória (*Random Search*), ambas conduzidas sobre o DRNPW com o *Contrast Enhancement* aplicado isoladamente. Cada valor do fator foi avaliado com um treinamento independente de 5 épocas, contra as 50 da avaliação anterior, de modo que os valores absolutos das duas seções não são diretamente comparáveis. As duas buscas foram ainda medidas em conjuntos distintos, a busca em grade sobre as 30 imagens de teste e a busca aleatória sobre as 87 de validação, o que também impede a comparação direta entre elas.

1) *Busca em Grade (Grid Search)*: A Busca em Grade foi estruturada em 5 partições lineares. Conforme a Tabela I, o melhor desempenho sobre o conjunto de teste foi obtido com o fator 1,333, alcançando 90,0% de acurácia, ou 27 acertos em 30 imagens. Fatores muito baixos, como 0,5, resultaram no pior desempenho observado (76,7%).

TABELA I
RESULTADOS DA OTIMIZAÇÃO POR BUSCA EM GRADE DO PARÂMETRO DE CONTRASTE (*FACTOR*)

Fator	Acurácia	Precisão	Recall	F1-Score
0,5	0,767	0,588	0,767	0,665
0,778	0,833	0,694	0,833	0,758
1,056	0,800	0,640	0,800	0,711
1,333	0,900	0,810	0,900	0,853
1,611	0,833	0,694	0,833	0,758

2) *Busca Aleatória (Random Search)*: Para explorar valores intermediários entre as faixas discretas e testar variações

extremas, aplicou-se também uma amostragem aleatória, com 5 tentativas em uma distribuição contínua.

De acordo com a Tabela II, a menor acurácia ocorreu no fator 2,3300 (71,26%), embora o fator mais intenso, 2,8768, tenha alcançado 79,31%. Por outro lado, o melhor resultado ocorreu no fator 1,4364 (85,06% de acurácia), valor próximo ao encontrado pela busca em grade. Essa proximidade deve ser lida com reserva, pois as duas buscas foram medidas em conjuntos diferentes e a relação entre o fator e o desempenho não se mostrou monotônica em nenhuma delas, o que impede afirmar uma degradação progressiva causada por excesso de contraste.

TABELA II
RESULTADOS DA OTIMIZAÇÃO ESTOCÁSTICA (RANDOM SEARCH) NO
FATOR DE CONTRASTE

Tentativa	Fator	Acurácia	Loss (Validação)
1	1,4364	0,8506	4,1418
2	2,8768	0,7931	4,1455
3	2,3300	0,7126	4,1499
4	1,9966	0,8046	4,1416
5	0,8900	0,7816	4,1480

V. CONCLUSÃO

Os resultados indicam que o efeito de uma mesma técnica de processamento de imagens pode variar entre cenários de captura, e que o uso eficiente de Redes Neurais Convolucionais na inspeção de equipamentos elétricos em campo depende de uma escolha criteriosa das técnicas.

As técnicas isoladas tiveram desempenho diferente nos dois conjuntos, ainda que a combinação de realce de contraste e equalização global de histograma tenha obtido a maior acurácia em ambos. Em cenários de menor poluição visual (CPLID), o realce simples de contraste alcançou 95,35%, valor que supera em um único acerto os 93,02% da imagem sem tratamento e que, portanto, não caracteriza ganho relevante. Nesse conjunto, a contribuição do método está em descartar transformações destrutivas, como o desfoque gaussiano, que derruba o desempenho para 67,44%. Já nas imagens aéreas de fundo poluído (DRNPW), aplicar o realce de contraste seguido da equalização global de histograma elevou a acurácia de 63,33% para 83,33%, o maior efeito observado neste trabalho, ainda que a três acertos do piso majoritário. Os melhores fatores de contraste ficaram em 1,33 na busca em grade e em 1,44 na busca aleatória, mas a ausência de monotonia na relação entre fator e desempenho impede afirmar que realces mais intensos degradem o resultado de forma progressiva.

Mais do que os resultados, a principal contribuição está na metodologia. Ao apoiar a escolha das técnicas em indicadores quantitativos e em um protocolo de comparação fixo, ela substitui a seleção por tentativa e erro por uma avaliação uniforme e expansível, em que novas técnicas podem ser incorporadas sob os mesmos critérios. As limitações são o tamanho dos conjuntos de teste, de 43 e 30 imagens, em que diferenças de poucos pontos situam-se dentro do ruído amostral, e o fato de cada configuração corresponder a um único treinamento com semente não fixada, o que impede a reprodução exata dos

valores relatados. Além disso, os dois conjuntos diferem não só no fundo, mas também no número de classes e no volume de dados, o que impede atribuir as divergências observadas apenas ao cenário de captura. A confirmação em conjuntos maiores, com repetições sob sementes controladas, permanece como trabalho futuro.

REFERÊNCIAS

- [1] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 3rd ed. Upper Saddle River, NJ, USA: Prentice Hall, 2008.
- [2] V. N. Nguyen, R. Jenssen, and D. Roverso, "Automatic autonomous vision-based power line inspection: A review of current status and the potential role of deep learning," *International Journal of Electrical Power & Energy Systems*, vol. 99, pp. 107–120, Jul. 2018, doi: 10.1016/j.ijepes.2017.12.016.
- [3] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: 10.1038/nature14539.
- [4] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 25, Lake Tahoe, NV, USA, Dec. 2012, pp. 1097–1105. [Online]. Available: <https://proceedings.neurips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html>
- [5] M. Salvi, U. R. Acharya, F. Molinari, and K. M. Meiburger, "The impact of pre- and post-image processing techniques on deep learning frameworks: A comprehensive review for digital pathology image analysis," *Computers in Biology and Medicine*, vol. 128, art. 104129, Jan. 2021, doi: 10.1016/j.compbiomed.2020.104129.
- [6] L. Yang and A. Shami, "On hyperparameter optimization of machine learning algorithms: Theory and practice," *Neurocomputing*, vol. 415, pp. 295–316, Nov. 2020, doi: 10.1016/j.neucom.2020.07.061.
- [7] L. Wang, H. Wan, D. Huang, J. Liu, X. Tang, and L. Gan, "Sustainable analysis of insulator fault detection based on fine-grained visual optimization," *Sustainability*, vol. 15, no. 4, art. 3456, Feb. 2023, doi: 10.3390/su15043456.
- [8] I. Maduako, C. F. Igwe, J. E. Abah, O. E. Onwuasaanya, G. A. Chukwu, F. Ezeji, and F. I. Okeke, "Deep learning for component fault detection in electricity transmission lines," *Journal of Big Data*, vol. 9, no. 1, art. 81, Jun. 2022, doi: 10.1186/s40537-022-00630-2.
- [9] C. Liu, Y. Wu, J. Liu, Z. Sun, and H. Xu, "Insulator faults detection in aerial images from high-voltage transmission lines based on deep learning model," *Applied Sciences*, vol. 11, no. 10, art. 4647, May 2021, doi: 10.3390/app11104647.
- [10] R. Archana and P. S. E. Jeevaraj, "Deep learning models for digital image processing: a review," *Artificial Intelligence Review*, vol. 57, no. 1, art. 11, Jan. 2024, doi: 10.1007/s10462-023-10631-z.
- [11] X. Pei, Y. Zhao, L. Chen, Q. Guo, Z. Duan, Y. Pan, and H. Hou, "Robustness of machine learning to color, size change, normalization, and image enhancement on micrograph datasets with large sample differences," *Materials & Design*, vol. 232, art. 112086, Aug. 2023, doi: 10.1016/j.matdes.2023.112086.
- [12] C. Shorten and T. M. Khoshgofaar, "A survey on image data augmentation for deep learning," *Journal of Big Data*, vol. 6, no. 1, art. 60, Jul. 2019, doi: 10.1186/s40537-019-0197-0.
- [13] S. M. Pizer, E. P. Amburn, J. D. Austin, R. Cromartie, A. Geselowitz, T. Greer, B. ter Haar Romeny, J. B. Zimmerman, and K. Zuiderveld, "Adaptive histogram equalization and its variations," *Computer Vision, Graphics, and Image Processing*, vol. 39, no. 3, pp. 355–368, Sep. 1987, doi: 10.1016/S0734-189X(87)80186-X.
- [14] Ş. Öztürk and B. Akdemir, "Effects of histopathological image pre-processing on convolutional neural networks," *Procedia Computer Science*, vol. 132, pp. 396–403, 2018, doi: 10.1016/j.procs.2018.05.166.
- [15] L. F. Rodrigues, M. C. Naldi, and J. F. Mari, "Comparing convolutional neural networks and preprocessing techniques for HEP-2 cell classification in immunofluorescence images," *Computers in Biology and Medicine*, vol. 116, art. 103542, Jan. 2020, doi: 10.1016/j.compbiomed.2019.103542.
- [16] Z. Zhang, S. Huang, Y. Li, H. Li, and H. Hao, "Image detection of insulator defects based on morphological processing and deep learning," *Energies*, vol. 15, no. 7, art. 2465, Mar. 2022, doi: 10.3390/en15072465.
- [17] J. Zheng, H. Wu, H. Zhang, Z. Wang, and W. Xu, "Insulator-defect detection algorithm based on improved YOLOv7," *Sensors*, vol. 22, no. 22, art. 8801, Nov. 2022, doi: 10.3390/s22228801.

- [18] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, Sep. 2009, doi: 10.1109/TKDE.2008.239.
- [19] X. Tao, D. Zhang, Z. Wang, X. Liu, H. Zhang, and D. Xu, "Detection of power line insulator defects using aerial images analyzed with convolutional neural networks," *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, vol. 50, no. 4, pp. 1486–1498, Apr. 2020, doi: 10.1109/TSMC.2018.2871750.