

MÉTODO DE APRIMORAMENTO DE PROCESSAMENTOS DE IMAGENS APLICADOS À DETECÇÃO E CLASSIFICAÇÃO DE FALHAS EM CADEIAS DE ISOLADORES

1st Luan Willig Silveira

Engenharia Elétrica

Universidade Federal de Santa Maria
Cachoeira do Sul, Brasil
luan.w.silveira@gmail.com

2nd Paulo César Vargas Luz

Engenharia Elétrica

Universidade Federal de Santa Maria
Cachoeira do Sul, Brasil
paulo.c.luz@ufsm.br

3rd Daniel Pinheiro Bernardon

Engenharia Elétrica

Universidade Federal de Santa Maria
Santa Maria, Brasil
dpbernardon@ufsm.br

4th Dion Lenon Prediger Feil

Engenharia Elétrica

Universidade Federal de Santa Maria
Cachoeira do Sul, Brasil
dion.feil@ufsm.br

5th Laura Lisiane Callai dos Santos

Engenharia Elétrica

Universidade Federal de Santa Maria
Cachoeira do Sul, Brasil
laura.santos@ufsm.br

6th Nelson Knak Neto

Engenharia Elétrica

Universidade Federal de Santa Maria
Cachoeira do Sul, Brasil
nelson.knak@ufsm.br

Resumo—A crescente demanda por sistemas automatizados de inspeção de linhas de transmissão de energia elétrica utilizando visão computacional impulsiona o uso de inteligência artificial. No entanto, não há uma metodologia padronizada para definir estratégias de processamento e seus ajustes paramétricos que permita uma comparação real de desempenho. Este trabalho propõe uma metodologia sistemática para comparar, selecionar e aprimorar técnicas de processamento de imagens, visando otimizar o desempenho preditivo de Redes Neurais Convolucionais (CNNs) na detecção de falhas. Utilizando os *datasets* CPLID e DRNPW, constatou-se que o pré-processamento é um fator vital. Para imagens com fundos homogêneos (CPLID), a técnica de ganho simples de contraste (*Contrast Enhancement*) alcançou 95,35% de acurácia. Em ambientes complexos com poluição visual obtidos por drones (DRNPW), abordagens híbridas, que combinam realce de contraste e equalização de histograma, tornaram-se necessárias, atingindo 83,33% de acurácia. A otimização paramétrica via busca em grade (*Grid Search*) confirmou um fator ideal de ajuste de contraste situado em torno de 1,33, mitigando interferências destrutivas. Os resultados comprovam que não há uma técnica universalmente superior, dependendo substancialmente das características intrínsecas da imagem e do ambiente de captura. Dessa forma, a metodologia proposta viabiliza uma comparação justa e reprodutível entre as diversas técnicas de processamento de imagens, oferecendo um caminho sistemático para a seleção e o aprimoramento de estratégias de pré-processamento voltadas à detecção automatizada de falhas em cadeias de isoladores.

Palavras-chave—processamento de imagens, redes neurais convolucionais, cadeias de isoladores, detecção de falhas, inteligência artificial

I. INTRODUÇÃO

A crescente demanda por sistemas automatizados de inspeção de cadeias de isoladores evidencia a necessidade de técnicas avançadas de processamento de imagem para a detecção precoce de falhas. A análise digital de imagens permite extrair características relevantes para identificar anomalias em componentes elétricos, possibilitando diagnósticos mais precisos nas linhas de transmissão de energia [1].

Ademais, o emprego de redes neurais, e mais especificamente as Redes Neurais Convolucionais (CNNs), tem se destacado na resolução de problemas complexos de classificação e detecção, contribuindo para a robustez dos sistemas de inspeção [2], [3]. Contudo, a eficácia preditiva desses modelos de inteligência artificial depende intrinsecamente da qualidade das imagens de entrada. Estudos apontam que a combinação de diferentes técnicas de pré-processamento, aliada ao ajuste automático de parâmetros, pode resultar em melhorias significativas no desempenho dos sistemas de diagnóstico automatizados [4].

Assim, o presente estudo tem como objetivo desenvolver uma metodologia escalável capaz de comparar, selecionar, combinar e aprimorar técnicas de processamento de imagem para a detecção e classificação de falhas em cadeias de isoladores elétricos. Para isso, são estabelecidas métricas quantitativas de acurácia e *F1-score*, bem como avaliadas estratégias unificadas e compostas de tratamentos de imagem aplicadas em dois conjuntos de dados distintos da área (CPLID e DRNPW).

II. FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

A utilização de ferramentas de inteligência artificial para diagnósticos em equipamentos tem se destacado como uma solução promissora no contexto da manutenção preventiva, especialmente diante do aumento da complexidade dos sistemas industriais do setor elétrico e da necessidade de maior confiabilidade operacional [9]. A detecção precoce de falhas em componentes como cadeias de isoladores, transformadores e suportes de linhas de transmissão é fundamental para evitar interrupções de longo prazo e reduzir custos associados à intervenção humana direta [10], [11].

A. Processamento de Imagens e Redes Neurais

O processamento de imagens tem papel fundamental na preparação dos dados visuais antes de sua entrada em redes profundas. Imagens capturadas por Veículos Aéreos Não Tripulados (VANTs) ou câmeras de inspeção frequentemente apresentam ruídos, interferência climática, variações fortes de iluminação e fundos com vegetação e poluição ambiental [12].

Entre as técnicas fundamentais destacam-se a normalização e a padronização de histogramas, aplicadas para reduzir variações bruscas de intensidade luminosa nos canais RGB, o que facilita a convergência durante o treinamento das redes [7], [13]. Da mesma forma, o redimensionamento padronizado reduz o custo computacional e adequa as imagens ao tamanho de entrada exigido pela primeira camada convolucional, enquanto o aumento de dados (*Data Augmentation*) compensa a escassez de falhas reais catalogadas, gerando variações sintéticas que melhoram a robustez do classificador [5].

O ajuste de contraste é especialmente crítico no contexto de isoladores. Enquanto a *Contrast Limited Adaptive Histogram Equalization* (CLAHE) evita a amplificação excessiva de ruído ao subdividir a imagem para correção localizada [14], a equalização global favorece a separação nítida das bordas do material cerâmico ou vítreo deteriorado. Contudo, intervenções muito agressivas, como filtros de supressão excessivos, podem eliminar texturas importantes que caracterizam pequenas fraturas ou contaminações na superfície do equipamento [7].

Esse cuidado com o tratamento inicial reflete-se diretamente no desempenho das Redes Neurais Convolucionais (CNNs). Diferentemente das redes *Feed-Forward* tradicionais, as CNNs preservam a estrutura espacial da imagem por meio de convoluções com *kernels* locais, reduzem a dimensionalidade via *MaxPooling* e extraem mapas hierárquicos de textura e contraste [2]. Entretanto, sua capacidade de identificar anomalias na rede elétrica depende diretamente da representatividade dos dados, o que reforça a importância do tratamento da imagem de entrada, conforme a estrutura ilustrada na Fig. 1.




Fig. 1. Representação estrutural típica de uma Rede Neural Convolucional na extração de características visuais.

B. Trabalhos Correlatos e Lacunas da Literatura

A literatura recente apresenta divergências relevantes quanto ao impacto das técnicas de pré-processamento sobre o desempenho dos modelos.

Por um lado, diversos estudos relatam ganhos expressivos de acurácia a partir de pré-processamentos elaborados. Por exemplo, abordagens híbridas que combinam segmentação morfológica ao classificador Faster RCNN conseguiram lidar com fundos complexos de torres de energia, alcançando *recall* de 0,98 na localização de isoladores fraturados [15]. De forma semelhante, arquiteturas baseadas no *framework* YOLO (YOLOv7) mostraram-se eficientes para detectar pequenos defeitos na isolação quando aliadas a ajustes de arquitetura voltados a mecanismos de atenção [16].

Em contrapartida, há pesquisas que questionam a intervenção excessiva sobre a imagem. Alguns autores, ao testar diferentes modificações em bases de imagens médicas (cujo comparativo é ilustrado na Fig. 2), concluíram que modelos treinados do zero com imagens brutas atingiram precisão superior (98,28%) à de versões submetidas a realces extremos e equalizações forçadas [17].




Fig. 2. Comparativo de estratégias de processamento de imagens propostas na literatura para avaliação de modelos preditivos [17].

Essa perspectiva é reforçada por estudos que alertam para o risco do "sobre-processamento", indicando que exageros no realce podem eliminar informações que a própria rede seria capaz de aprender [18]. Mesmo em detecções diretas sobre redes elétricas com modelos RA-CNN, há autores que defendem o treinamento com redimensionamento simples [19].

Essa divergência expõe uma lacuna importante: a falta de um método para determinar o limite adequado de realce em diferentes tipos de imagem. Os trabalhos raramente exploram de forma quantitativa o efeito isolado do fator de correção, adotando configurações fixas. O presente trabalho, conforme detalhado nas próximas seções, busca preencher essa lacuna ao avaliar sistematicamente esse parâmetro por meio de *Grid*

Search sobre o ganho de contraste, oferecendo uma referência prática sobre quando e quanto uma imagem de inspeção deve ser processada.

III. METODOLOGIA

A metodologia proposta segue um fluxo estruturado para otimizar o processamento aplicado às imagens de entrada de uma CNN. O processo geral, detalhado na Fig. 3, envolve, de forma iterativa, a seleção de *datasets*, o pré-processamento da imagem, o ajuste paramétrico e a avaliação por meio do treinamento dos modelos.




Fig. 3. Fluxograma geral da metodologia proposta, detalhando o processo iterativo de tratamento e avaliação.

A qualidade, a quantidade e a diversidade dos dados exercem um impacto direto no treinamento das redes profundas

[5], [6]. Por esta razão, empregaram-se dois importantes conjuntos de dados de imagens no estudo:

- 1) **CPLID (Chinese Power Line Insulator Dataset)**: Base caracterizada por fundos homogêneos, com recortes de isoladores sadios e com fraturas visíveis nas peças de vidro ou cerâmica.
- 2) **DRNPW (Dataset for Recognition of Non-ceramic Pollution on Windings)**: Composto por recortes obtidos em inspeção aérea com drones. As amostras possuem fundos ruidosos, com forte presença de componentes adjacentes e vegetação.

Para validar os processamentos, adotou-se a mesma arquitetura de CNN em todas as avaliações. As imagens originais (512×512 ou 640×640 pixels) passam por duas camadas convolucionais sequenciais (*kernels* de 3×3 , 32 filtros, função de ativação ReLU, acopladas a agrupamentos *Max-Pooling* de 4×4). Em seguida, os mapas de características são achatados em um vetor denso (*Flatten layer*) conectado a 8 unidades ReLU, antes da camada final de classificação (*Softmax*).

Na etapa de **Pré-processamento**, dezenas de filtros foram testados, de forma isolada e combinada, incluindo equalização adaptativa (CLAHE), conversão para tons de cinza (*Gray Scale*), binarização (*Adaptive Threshold*) e supressão de ruído (*Fast NL-Means Denoise*, *Gaussian Blur*). A técnica de *Contrast Enhancement* recebe destaque por ajustar o contraste global dos canais RGB por meio de um fator configurável.

Por fim, após identificar a configuração de melhor desempenho, realizou-se uma etapa de **Ajuste Paramétrico** com busca em grade (*Grid Search*), a fim de encontrar o valor ideal do hiperparâmetro de contraste (variável *factor*), evitando distorções [7].

IV. RESULTADOS E DISCUSSÕES

A. Delineamento dos Experimentos e Arquitetura

A validação avaliou o desempenho de uma Rede Neural Convolucional (CNN) desenvolvida para este trabalho. A arquitetura é composta por camadas convolucionais sequenciais com 32 filtros de *kernels* 3×3 , ativação ReLU e redução espacial via *Max-Pooling*. A classificação final é feita por achatamento vetorial (*Flatten*) e 8 neurônios nas camadas densas, com saída de probabilidade por *softmax*. O modelo foi treinado por 50 épocas com *Data Augmentation*.

Os experimentos submeteram essa rede a 14 grupos distintos de pré-processamento nas bases CPLID e DRNPW. O grupo de controle usou as imagens originais (*Original Image*). Foram testados: limiarização (*Adaptive Threshold*), detecção de contornos (*Edge Detection*), conversão para tons de cinza (*Gray Scale*) e técnicas de suavização e supressão de ruído (*Gaussian Blur*, *Median Blur* e *Fast NL-Means Denoise*).

O foco principal esteve nas abordagens de iluminação, variando equalizações de histograma adaptativas (CLAHE) e globais (*Equalize Histogram*), além de métodos de ganho direto (*Contrast Enhancement*). Além das aplicações isoladas, testaram-se combinações híbridas de filtros para avaliar o limite do processamento sequencial.

Os testes mostraram que a eficácia de cada técnica depende fortemente do tipo de fundo presente na imagem.

B. Avaliação no Dataset CPLID

Devido ao fundo predominantemente homogêneo dessas imagens, técnicas baseadas no realce direto da iluminação mostraram-se superiores para destacar as trincas na cerâmica. O uso isolado do filtro **Contrast Enhancement** alcançou 95,35% de acurácia e 96,55% de *F1-score*. Combinações de **Contrast Enhancement** com equalização adaptativa obtiveram valores de acurácia equivalentes.

Em contrapartida, filtros de desfoque, em especial o **Gaussian Blur**, atenuaram as bordas das anomalias e reduziram significativamente o desempenho do modelo, registrando apenas 67,44% de acurácia, resultado inferior até ao das imagens originais (93,02%). O desempenho de todas as 14 variações testadas nesse conjunto de dados é apresentado na Fig. 4.




Fig. 4. Acurácia das diferentes estratégias de pré-processamento avaliadas no dataset CPLID.

C. Avaliação no Dataset DRNPW

No conjunto de imagens obtidas por drones (DRNPW), a forte presença de fundos com vegetação e estruturas metálicas reduziu a eficácia das técnicas simples que funcionaram bem no CPLID. O melhor resultado veio de uma abordagem híbrida: **Contrast Enhancement seguido de Equalize Histogram**. Essa combinação alcançou 83,33% de acurácia, isolando de forma eficiente os objetos de interesse do fundo ruidoso.

Conversões como a de tons de cinza (*Gray Scale*) não lidaram bem com as variações tonais e reduziram a acurácia ao mínimo de 63,33%, evidenciando que a informação de cor é importante para o classificador localizar objetos em cenas ruidosas [8]. A acurácia de todos os métodos aplicados nessa base é apresentada na Fig. 5.




Fig. 5. Acurácia das diferentes estratégias de pré-processamento avaliadas no dataset DRNPW.

D. Otimização Paramétrica

Com base nos bons resultados da técnica de ajuste de contraste, adotaram-se duas abordagens de otimização do hiperparâmetro de amplificação (*factor*): a Busca em Grade (*Grid Search*) e a Busca Aleatória (*Random Search*).

1) *Busca em Grade (Grid Search)*: A Busca em Grade foi estruturada em 5 partições lineares. Conforme a Tabela I, o melhor desempenho de validação foi obtido com o fator 1,333, alcançando 90,0% de acurácia. Fatores muito baixos, como 0,5, resultaram no pior desempenho observado (76,7%).

TABELA I
RESULTADOS DA OTIMIZAÇÃO POR BUSCA EM GRADE DO PARÂMETRO DE CONTRASTE (FACTOR)

Fator	Acurácia	Precisão	Recall	F1-Score
0,5	0,767	0,588	0,767	0,665
0,778	0,833	0,694	0,833	0,758
1,056	0,800	0,640	0,800	0,711
1,333	0,900	0,810	0,900	0,853
1,611	0,833	0,694	0,833	0,758

2) *Busca Aleatória (Random Search)*: Para explorar valores intermediários entre as faixas discretas e testar variações extremas, aplicou-se também uma amostragem aleatória, com 5 tentativas em uma distribuição contínua.

De acordo com a Tabela II, os resultados confirmaram a sensibilidade do modelo a realces muito intensos (a acurácia caiu para 71,26% no fator 2,3300). Por outro lado, o melhor resultado ocorreu no fator 1,4364 (85,06% de acurácia), valor bastante próximo ao encontrado pelo *Grid Search*. As duas buscas confirmam, de forma complementar, que ajustes sutis (próximos de 1,3 e 1,4) são mais eficientes do que realces excessivos.

TABELA II
RESULTADOS DA OTIMIZAÇÃO ESTOCÁSTICA (RANDOM SEARCH) NO FATOR DE CONTRASTE

Tentativa	Fator	Acurácia	Loss (Validação)
1	1,4364	0,8506	4,1418
2	2,8768	0,7931	4,1455
3	2,3300	0,7126	4,1499
4	1,9966	0,8046	4,1416
5	0,8900	0,7816	4,1480

V. CONCLUSÃO

O trabalho demonstrou que não existe um método de processamento de imagens universal nem uma solução trivial. O uso eficiente de Redes Neurais Convolucionais na inspeção de equipamentos elétricos em campo depende de uma escolha criteriosa das técnicas.

Os resultados indicaram que o processamento ideal depende diretamente do contexto de fundo da imagem. Em cenários com baixo ruído visual (CPLID), o realce simples de contraste alcançou resultados superiores a 95% de acurácia. Já diante da maior complexidade das imagens aéreas obtidas por drones (DRNPW), foi necessária uma abordagem híbrida, combinando equalização global de histograma e ganho de contraste paramétrico. O valor ideal de intensidade, entre 1,3 e 1,4, confirma que realces agressivos são contraproducentes e consolida um fluxo adequado à manutenção automatizada no setor elétrico.

Mais do que os resultados obtidos, a principal contribuição deste trabalho está na própria metodologia. Ao apoiar a escolha das técnicas em indicadores quantitativos (acurácia e *F1-score*) e em uma comparação padronizada entre as abordagens, ela substitui a seleção empírica, baseada em tentativa e erro, por uma avaliação justa e reproduzível. Além disso, a metodologia é expansível: novas técnicas de processamento que venham a surgir podem ser incorporadas e comparadas sob os mesmos critérios, mantendo a validade das conclusões ao longo do tempo.

REFERÊNCIAS

- [1] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 3rd ed. Prentice Hall, 2008.
- [2] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [3] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," *Advances in Neural Information Processing Systems*, 2012.
- [4] X. Li et al., "Fusion of image processing techniques for fault detection in electrical insulators," *IEEE Transactions on Power Delivery*, vol. 34, no. 3, pp. 1234–1241, 2019.
- [5] C. Shorten et al., "A survey on Image Data Augmentation for Deep Learning," *Journal of Big Data*, vol. 6, no. 1, pp. 1–48, 2019.
- [6] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [7] A. Sharma et al., "Deep learning models for digital image processing: a review," *Artificial Intelligence Review*, 2024.
- [8] P. Braga and J. Silva, "Aplicação de Redes Neurais Artificiais em Conjunto com o Método Vetorial da Propagação de Feixes na Análise de um Acoplador Direcional Baseado em Fibras Ópticas," *Revista Brasileira de Computação Aplicada*, vol. 16, 2011.
- [9] M. Salvi et al., "The impact of pre- and post-image processing techniques on deep learning frameworks: A comprehensive review for digital pathology image analysis," *Computers in Biology and Medicine*, vol. 128, 2021.
- [10] L. Wang et al., "Análise Sustentável da Detecção de Falhas em Isoladores Baseada em Otimização Visual Refinada," *Sustainability*, vol. 15, no. 4, 2023.
- [11] C. C. Eze et al., "Deep learning for component fault detection in electricity transmission lines," *Journal of Big Data*, vol. 9, no. 1, 2022.
- [12] D. Kumar et al., "A Novel Scheme of Fault Detection in Transmission Line using Image Processing," *Global Journal of Computer Science and Technology*, vol. 17, no. 1, 2023.
- [13] Y. Chen et al., "Robustness of machine learning to color, size change, normalization, and image enhancement on micrograph datasets," *Materials & Design*, 2023.
- [14] P. K. Malla et al., "A comprehensive review of deep neural networks for medical image processing: Recent developments and future opportunities," *Healthcare Analytics*, vol. 4, 2023.
- [15] Z. Zhang et al., "Detecção de Defeitos em Isoladores por Imagem Baseada em Processamento Morfológico e Aprendizado Profundo," *Energies*, vol. 15, no. 7, 2022.
- [16] J. Zheng et al., "Insulator-Defect Detection Algorithm Based on Improved YOLOv7," *Sensors*, vol. 22, no. 22, 2022.
- [17] L. F. Rodrigues, M. C. Naldi, and J. F. Mari, "Comparing convolutional neural networks and preprocessing techniques for HEp-2 cell classification in immunofluorescence images," *Computers in Biology and Medicine*, vol. 116, 2020.
- [18] Ş. Öztürk and B. Akdemir, "Effects of Histopathological Image Pre-processing on Convolutional Neural Networks," *Procedia Computer Science*, vol. 132, pp. 396–403, 2018.
- [19] C. Liu et al., "Detecção de Falhas em Isoladores em Imagens Aéreas de Linhas de Transmissão de Alta Voltagem Baseada em Modelo de Aprendizado Profundo," *Appl. Sci.*, vol. 11, no. 10, 2021.